ANOTACIÓN DE GENOMAS

Curso de análisis de datos de NGS

sabio@cbm.csic.es

La secuencia del genoma es “inútil” sin anotación…

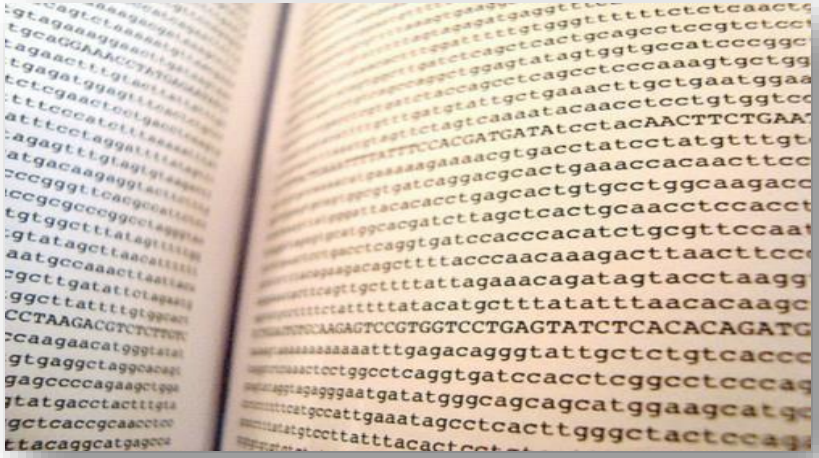

¿Qué es la anotación de un genoma?

- **Anotación** – Identificación de las características del genoma usando métodos computacionales y experimentales

- Dos niveles:
  - Búsqueda de genes
  - Anotación funcional

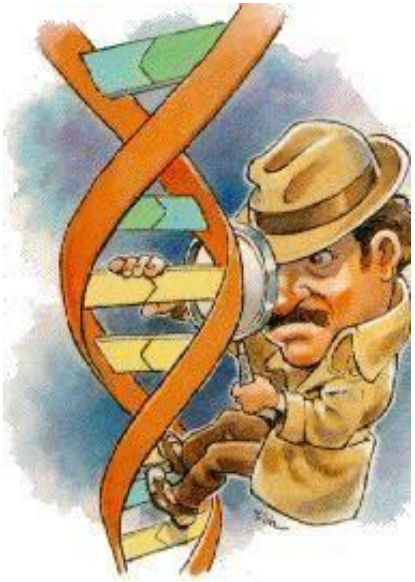

¿Qué es un gen?

- Segmentos completos de DNA responsables de generar productos funcionales (como mínimo transcritos)
  - Eucariotas: La región que es transcrita
  - Procariotas: La región codificante – porque genes múltiples pueden estar en un mismo transcrito formando un operón

- Productos
  - Proteínas
  - Moléculas funcionales de RNA
    - RNAi (RNA interferencia)
    - RNAr (RNA ribosomal)
    - RNAsn (nuclear pequeño)
    - RNAt (transfer RNA)

Métodos para la anotación de genomas

- ***Ab-initio:*** basado directamente en las características de la secuencia
  - INFERNAL/rFAM -> genes RNA
  - miRBASE (miRNAs)
  - Muchos de los algoritmos para la predicción de genes (Glimmer, GeneMark, AUGUSTUS, …)

- **Homología**
  - Similitud con secuencias homólogas (ej. Ensembl, UNIPROT)

- **Basados en evidencia**
  - Require datos del transcriptoma para el organismo a estudiar (TopHat/Cufflinks, Scripture)

Mejor opción: combinar todas estas estrategias.

¿Qué estamos buscando?

- Búsqueda de **ORFs**

  Secuencia ARN entre:
  - codón de inicio y
  - codon de terminación.

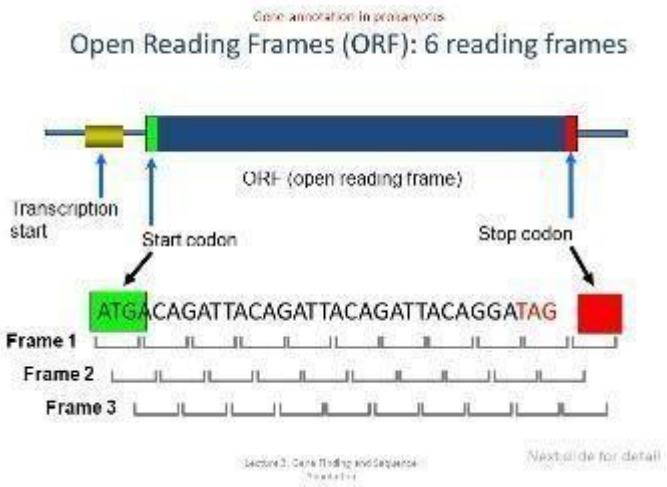

blog.naver.com

- Elementos que codifican para proteínas: péptido señal, proteínas transmembrana, dominios, motivos

- Elementos que no codifican proteínas: tRNA, rRNA, tmRNA, snRNA, miRNA precursors, CRISPR

- Características ontológicas: Rutas y funciones celulares

Encontrar genes en procariotas … fácil?

Predicción de genes sencilla en genomas microbianos

- Genomas pequeños, densidad de genes alta, pocas secuencias repetitivas y genomas completes disponibles
- La secuencia de un gen está definido:
  - codon de inicio: Normalmente **ATG** (genecode)
  - codon de terminación

-DNA traducido en las seis pautas de lectura
-Sitios de unión a ribosoma/secuencia Shine Dalgarno

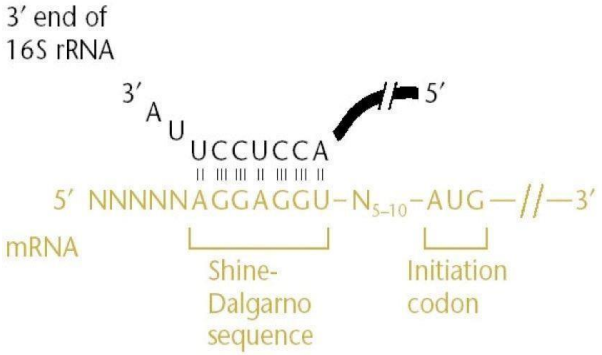

Modelos probabilísticos

Secuencia de DNA compuesta por A,T,C,G

Mejorar predicciones mediante la descripción estadística de un gen

A) Distribución multinomial con parámetros n, p_A, p_C, p_G, p_T

- Probabilidad de encontrar una secuencia de longitud n: ($p_A+p_C+p_G+p_T = 1$)

  Problema: Ignora la información del nucleótido adyacente

B) Modelo de Markov (https://en.wikipedia.org/wiki/Markov_model)

- Probabilidad de encontrar un nucleotido a una posición dada i+1 depende de lo que pase en la posición i de la cadena.

  Problema: diferentes regiones a lo largo del genoma, ej. **Islas C_PG**

C) Modelo oculto de Markov (https://en.wikipedia.org/wiki/Hidden_Markov_model)

- Probabilidad de que una base aparezca en una posición no depende de aquella precedente sino del **estado de la región** precedente.
- Secuencia de DNA está modelada como un mosaico de muchos tipos de regiones de un número relativamente pequeño de tipos, cada tipo contiene sus propias propiedades
- Cada tipo de región es un estado oculto del modelo

Ejemplos de programas para encontrar ORF en procariotas

- **ORF Finder -** https://www.ncbi.nlm.nih.gov/orffinder/
  - Búsqueda de ORFs por BLAST

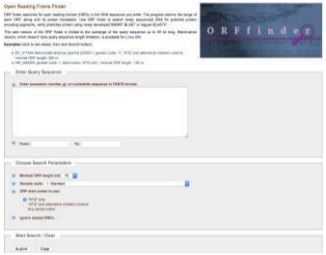

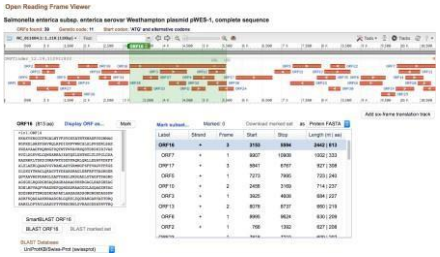

- **Glimmer 3 -** https://www.ncbi.nlm.nih.gov/genomes/MICROBES/glimmer_3.cgi
  - Sensibilidad del 99% y una precisión del >98%
  - Detecta genes superpuestos
  - Usa un conjunto de datos apropiado para su entrenamiento
  - **No anota genes de rRNA y tRNA**
  - Dos pasos:
    - Entrenamiento con el organismo de referencia
    - Lanzar el Glimmer entrenado contra ese genoma secuenciado

```
build-icm -r run1.icm < run1.train
glimmer3 -o50 -g110 -t30 genom.seq run1.icm run1
```

Ejemplos de programas para encontrar ORF en procariotas

- Prodigal - http://code.google.com/p/prodigal/

  - Herramienta de reconocimiento de genes microbiales
  - Rápido y preciso
  - Algoritmo sigue unas funciones de **probabilidad logarítmica *naïve***
  - Funciona bien con genomas con **alto contenido en GC**
  - Usa sitios de inicio de traducción y RBS → refinar la lista de genes

```
prodigal.exe -i <input_file.faa> –f <output format> –o
<output_file_name.gff>
```

Ejemplos de programas para encontrar ORF en procariotas

PRODIGAL

Prokaryotic Dynamic Programming Genefinding Algorithm

Home / Server / Algorithm / Results / Downloads / Compbio@ORNL

Prodigal (**Pro**karyotic **Dy**namic Programming **G**enefinding **Al**gorithm) is a microbial (bacterial and archaeal) gene finding program developed at Oak Ridge National Laboratory and the University of Tennessee. Key features of Prodigal include:

- **Speed**: Prodigal is an extremely fast gene recognition tool (written in very vanilla C). It can analyze an entire microbial genome in 30 seconds or less.
- **Accuracy**: Prodigal is a highly accurate gene finder. It correctly locates the 3' end of every gene in the experimentally verified Ecogene data set (except those containing introns). It possesses a very sophisticated ribosomal binding site scoring system that enables it to locate the translation initiation site with great accuracy (96% of the 5' ends in the Ecogene data set are located correctly).
- **Specificity**: Prodigal's false positive rate compares favorably with other gene identification programs, and usually falls under 5%.
- **GC-Content Indifferent**: Prodigal performs well even in high GC genomes, with over a 90% perfect match (5'+3') to the *Pseudomonas aeruginosa* curated annotations.
- **Metagenomic Version**: Prodigal can run in metagenomic mode and analyze sequences even when the organism is unknown.
- **Ease of Use**: Prodigal can be run in one step on a single genomic sequence or on a draft genome containing many sequences. It does not need to be supplied with any knowledge of the organism, as it learns all the properties it needs to on its own.
- **Open Source**: Prodigal source code is freely available under the General Public License.

Download the latest version of Prodigal at the Prodigal github page.
or
Browse the wiki documenation.
or
Join the Prodigal discussion group for updates.

Referencing Prodigal: Hyatt D, Chen GL, Locascio PF, Land ML, Larimer FW, Hauser LJ. Prodigal: prokaryotic gene recognition and translation initiation site identification. BMC Bioinformatics. 2010 Mar 8;11(1):119. (Highly Accessed) Abstract Full Text

Referencing MetaProdigal: Hyatt D, Locascio PF, Hauser LJ, Uberbacher EC. Gene and translation initiation site prediction in metagenomic sequences. Bioinformatics. 2012 Sep 1;28(17):2223-2230. Abstract Full Text

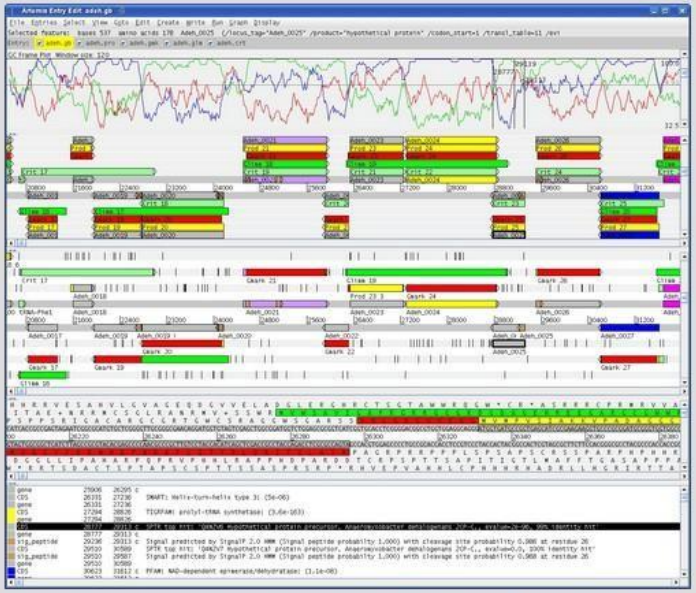

*Artemis Screenshot of Prodigal Results Compared with Curated Annotations and other Computational Genefinders for **Anaeromyxobacter dehalogenans 2CP-C** (Click to enlarge)*

- **Otros programas**: GeneMark.hmm, FGENESB, Zcurve, AMIGENE, EasyGene…

Anotación automática y funcional

Bacteria: Basado en homología de secuencia y transferencia de información de genomas próximos y/o ya curados

- Servicios on-line: **RAST, BASys**
- Descargado y lanzado localmente: **Prokka**

Ejemplos de programas para la anotación automática

RAST - Rapid Annotation using Subsystem Technology

- Genomas de arqueas y bacterianos
- Identifica genes codificantes a proteínas, genes de rRNA, tRNA
- Usa: **Glimmer3, GeneMarks, Prodigal** para buscar los genes
- Asigna **funciones** a los genes
- Output: **GenBank, GFF3, y EMBL**; con y sin **números EC**
- Gestión de tu trabajo: seguimiento, compartir.
- Acceso gráfico a la anotación: navegación por el genoma, comparación de regiones, reconstrucción metabólica, …

Ejemplos de programas para la anotación automática

Prokka

- Procariotas
- Encuentra y anota: CDSs, rRNAs, tRNA, CRISPRs, ncRNAs
- Usa:

  Prodigal - identifica coordinadas de genes candidatos

  Aragorn (tRNA), **Barrnap** and **RNAmmer** → RNA

  HMMER+ (busca similitudes contra familia de proteínas)

  BLAST+

  Infernal → ncRNA
- Se pueden **añadir nuevas librerías** a las bases de datos (en caso necesario)
- Outputs: GFF3, GBK, SQN

Anotación del genoma de *E. coli*

Scripts para la anotación de *E. coli*

- **Prokka**:

prokka --kingdom Bacteria --genus Escherichia --species coli --gcode 11 --usegenus --gram neg --prefix ecoli contigs.fasta

- **Prodigal**:

prodigal -i contigs.fasta -a Ecoli_cds_proteins.faa -d Ecoli_cds_ntd.fna -f gff -g 11 -s Ecoli_summary.txt -o Ecoli_prodigal.gff

- **¿cuántos…**
- **¿tRNA se han anotado?**
- **¿y rRNA?**
- **¿y péptidos señales?**
- **¿habéis encontrado alguna región CRISPR en el genoma de E.coli?**