Dia 2. Alineamiento y análisis de variantes

Servicio de Análisis Biocomputacional (SABio) CBM (CSIC-UAM)
CURSO NGS 2026 - abril 2026

Resecuenciación

- ✓ La Resecuenciación → Se dispone de un genoma de referencia.
- ✓ Consiste en alinear (mapear) las lecturas sobre el genoma de referencia para detectar las diferencias entre ambos.

Los algoritmos de mapeo + rápidos + precisos.

¿Que es una variante?

Cambio en la secuencia de ADN comparada con un genoma de referencia

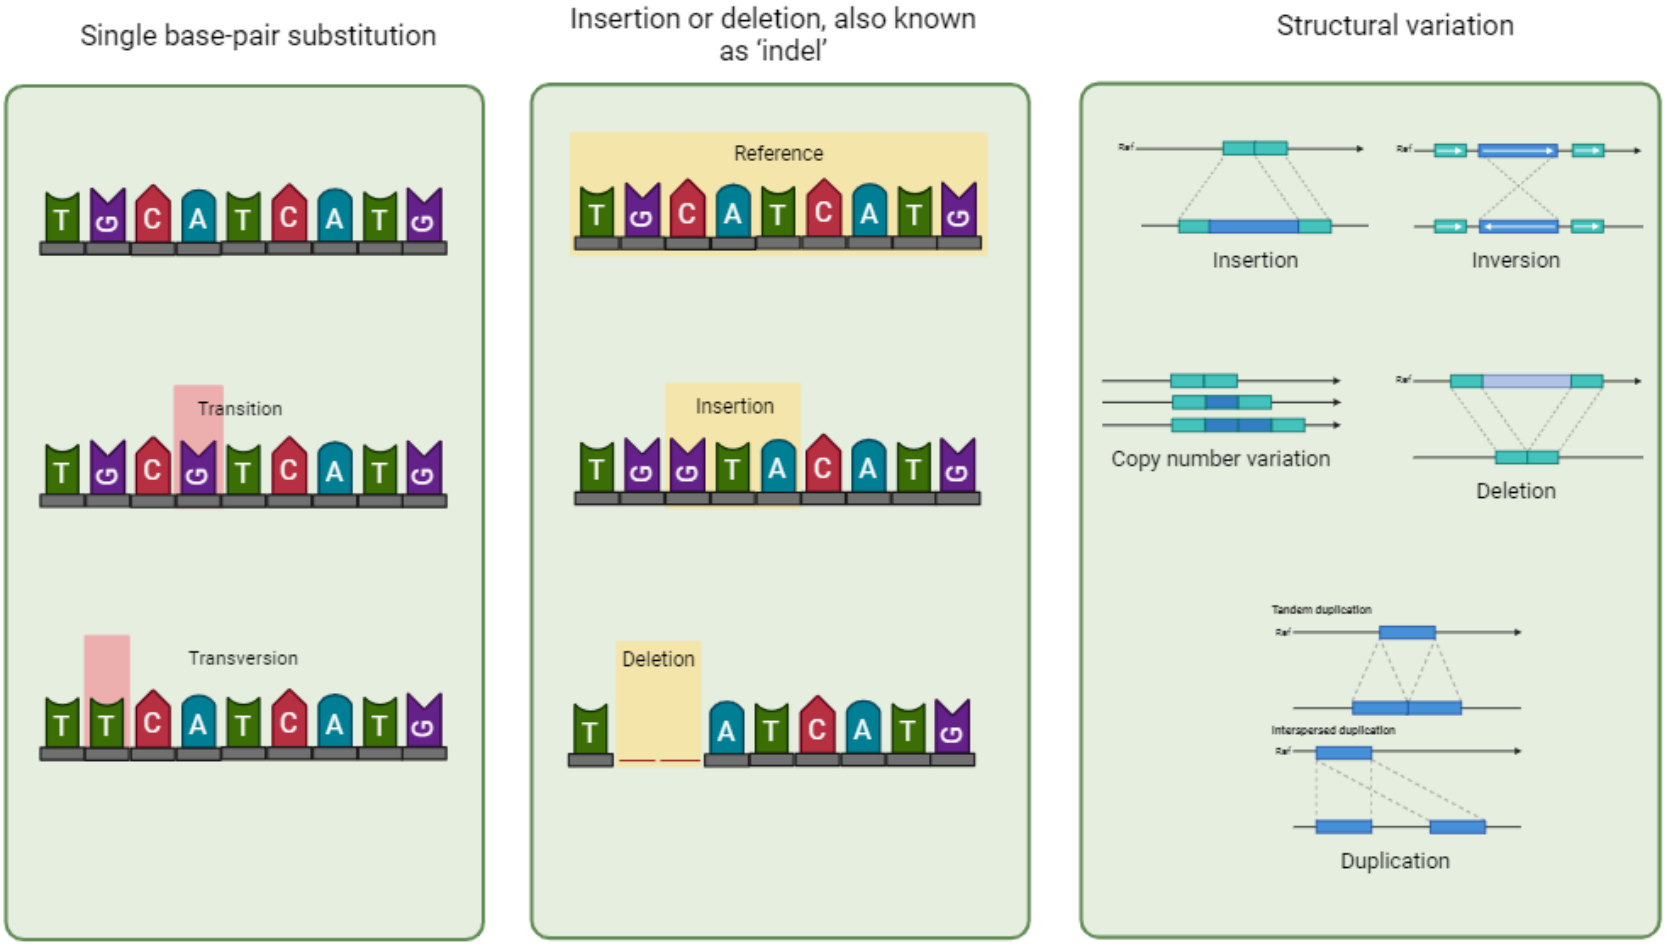

¿Que es una variante?

Cambio en la secuencia de ADN comparada con un genoma de referencia

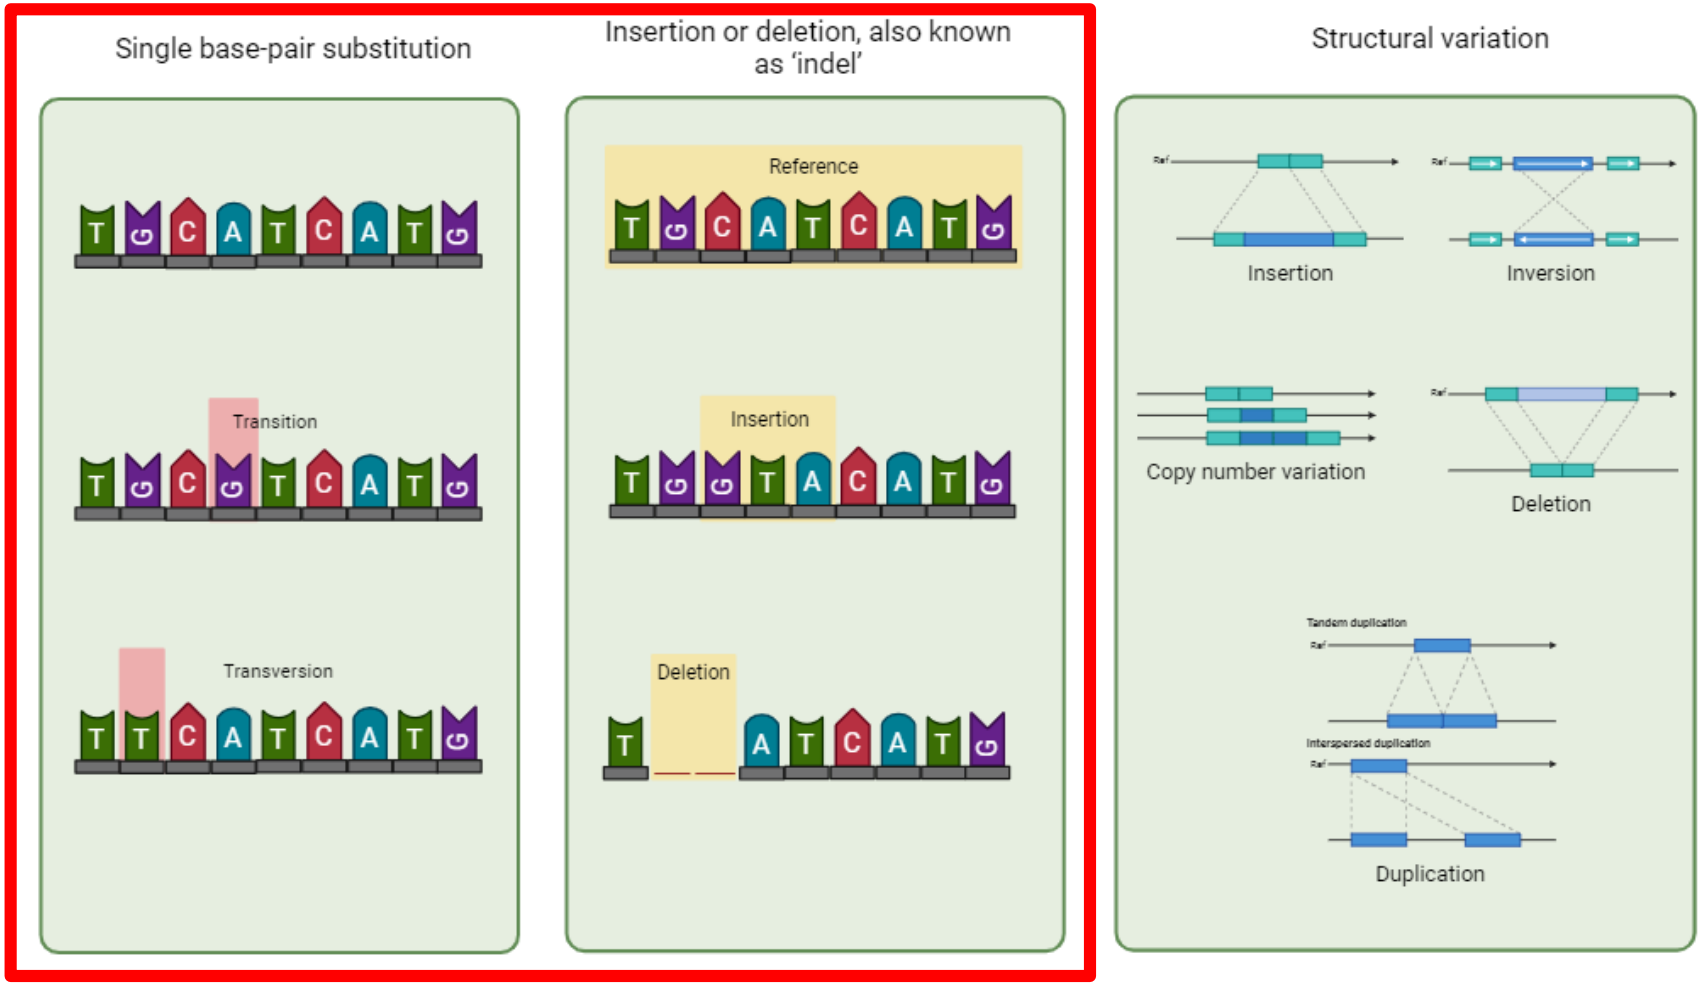

Workflow

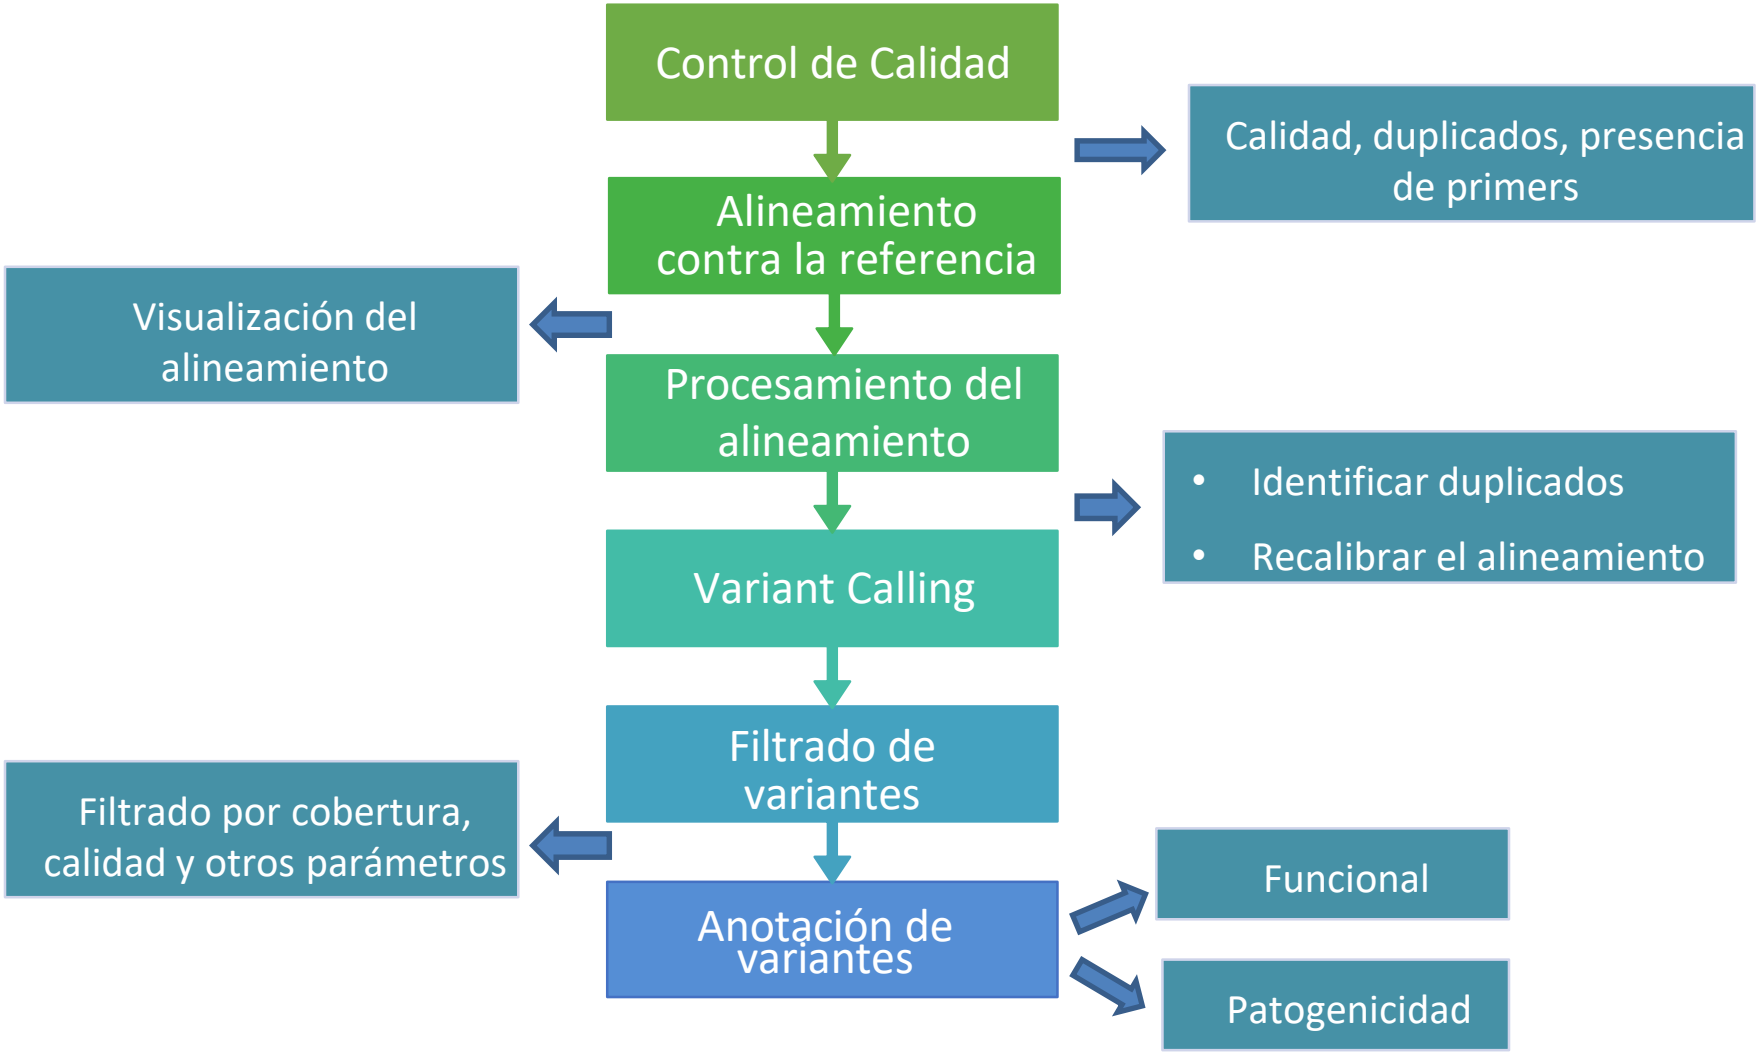
Control de Calidad
Calidad, duplicados, presencia de primers
Alineamiento contra la referencia
Visualización del alineamiento
Procesamiento del alineamiento
Identificar duplicados
Recalibrar el alineamiento
Variant Calling
Filtrado de variantes
Filtrado por cobertura, calidad y otros parámetros
Anotación de variantes
Funcional
Patogenicidad

Descarga de lecturas usando línea de comandos.

***Activamos el environment del Día 2!!**

```
conda activate Dia2
```

ENA Study PRJEB2371 → https://www.ebi.ac.uk/ena

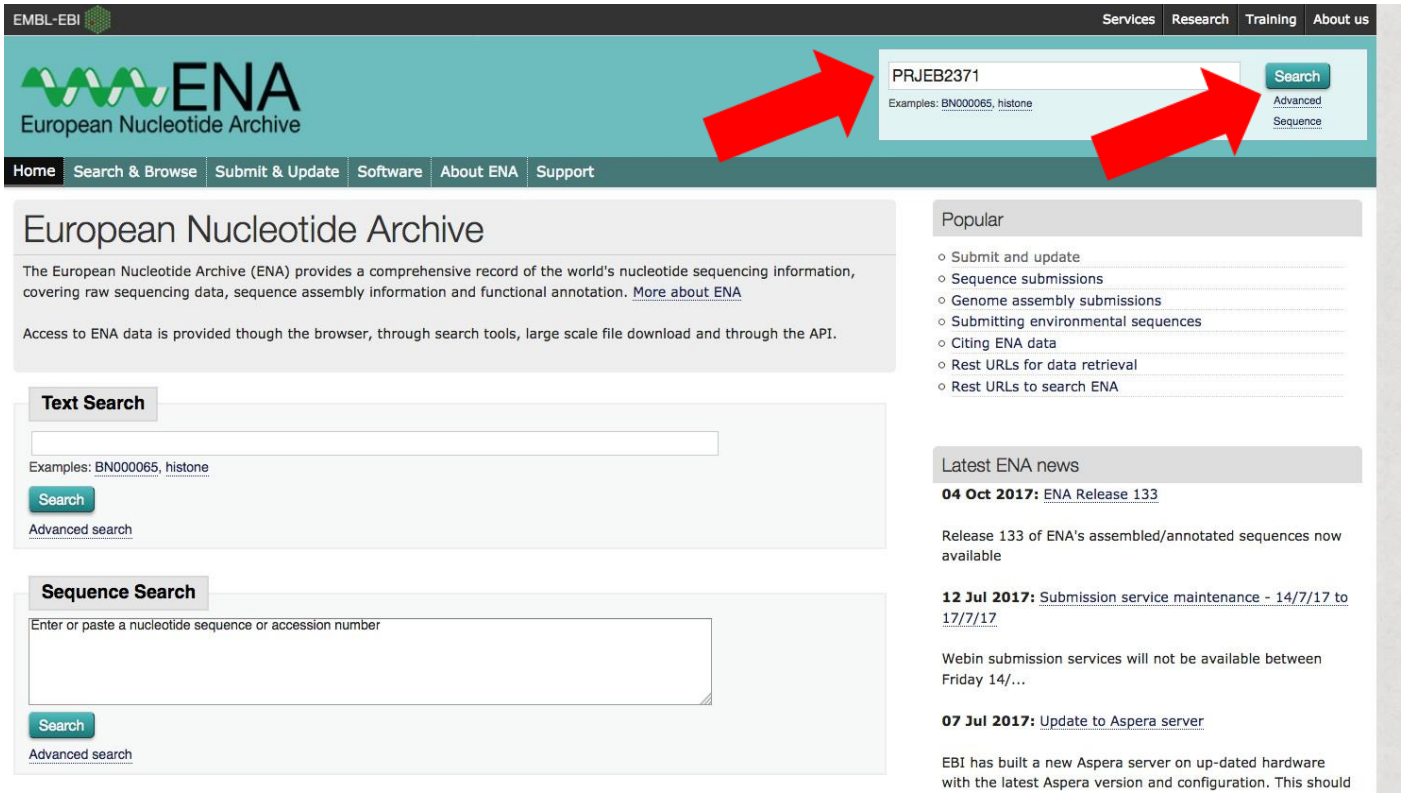

Descarga de lecturas

ENA Estudio PRJEB2371

RUNS → ERR023195 → sensitive to isoniazid and rifampicin (INHS and RIFS)
ERR023197 → resistant to isoniazid and rifampicin (INHR and RIFR)

Showing results 1 - 4 of 4 results

Study accession	Sample accession	Secondary sample accession	Experiment accession	Run accession	Tax ID	Scientific name	Instrument model	Library layout	FASTQ files (FTP)	FASTQ files (Galaxy)	Submitted files (FTP)	Submitted files (Galaxy)	NCBI SRA file (FTP)	NCBI SRA file (Galaxy)	CRAM Index files (FTP)	CRAM Index files (Galaxy)
PRJEB2371	SAMEA748124	ERS017895	ERX009495	ERR023195	940668	Mycobacterium tuberculosis MR054150Z	Illumina Genome Analyzer II	PAIRED	File 1 File 2	File 1 File 2	File 1 File 2	File 1 File 2	File 1	File 1		
PRJEB2371	SAMEA748120	ERS017896	ERX009496	ERR023196	940669	Mycobacterium tuberculosis MR071702G	Illumina Genome Analyzer II	PAIRED	File 1 File 2	File 1 File 2	File 1 File 2	File 1 File 2	File 1	File 1		
PRJEB2371	SAMEA748122	ERS017897	ERX009497	ERR023197	940670	Mycobacterium tuberculosis MR075750X	Illumina Genome Analyzer II	PAIRED	File 1 File 2	File 1 File 2	File 1 File 2	File 1 File 2	File 1	File 1		
PRJEB2371	SAMEA748122	ERS017897	ERX009497	ERR023198	940670	Mycobacterium tuberculosis MR075750X	Illumina Genome Analyzer II	PAIRED	File 1 File 2	File 1 File 2	File 1 File 2	File 1 File 2	File 1	File 1		

Prev Next Go to page: 1 Go

$ wget ftp://ftp.sra.ebi.ac.uk/vol1/fastq/ERR023/ERR023195/ERR023195_1.fastq.gz
$ wget ftp://ftp.sra.ebi.ac.uk/vol1/fastq/ERR023/ERR023195/ERR023195_2.fastq.gz
… etc …

Descarga del genoma de referencia

- ✓ *Mycobacterium Tuberculosis H37Rv* → Ensembl vía FTPsite
- ✓ http://www.ensembl.org/info/data/ftp/index.html

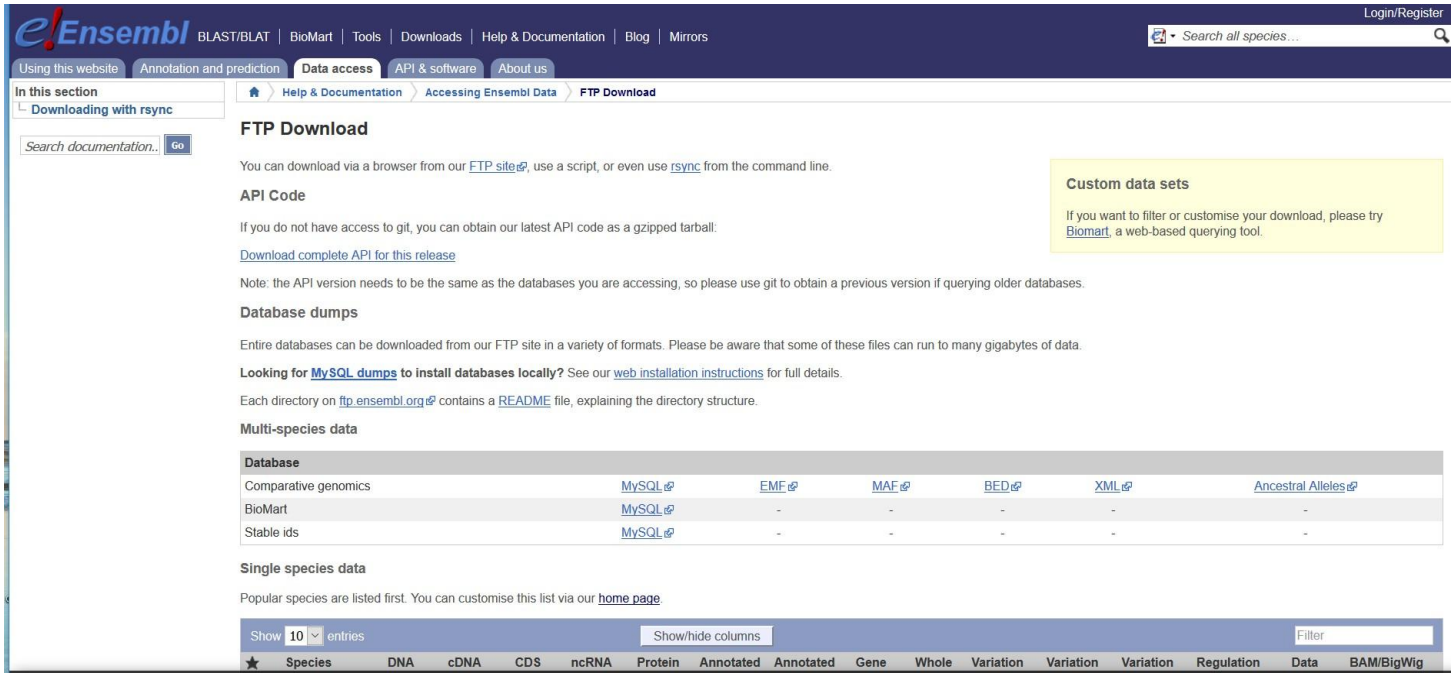

Control de calidad: FastQC

http://www.bioinforma4cs.babraham.ac.uk/projects/fastqc/

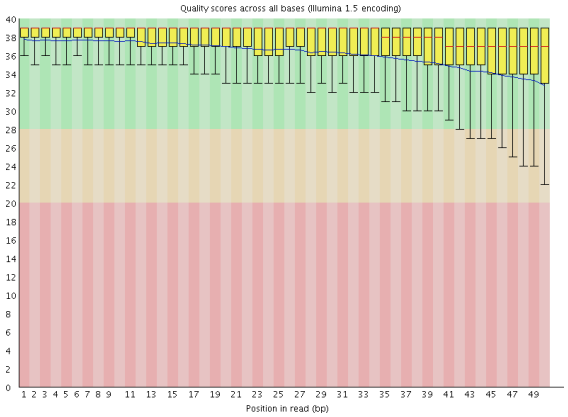

Good quality!

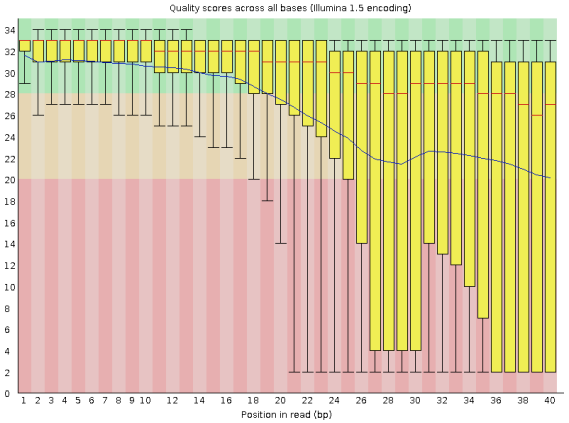

Poor quality!

Run FastQC:
$fastqc sample.fastq

Alineamiento → BWA

- ✓ Alineador que emplea la transformada *Burrows-Wheeler* (BWT) para indexar el genoma de referencia
- ✓ Muy veloz para alineamiento con lecturas cortas
- ✓ Los archivos SAM generados pueden ser procesador con otro paquete de programas llamado SAMtools

Alineamiento → Bwa-mem

http://bio-bwa.sourceforge.net/bwa.shtml

- Consiste en 3 algoritmos { BWA-backtrack, BWA-SW, BWA-mem }
- **BWA-backtrack** → Illumina, hasta 100pb
- **BWA-SW** → Lecturas + largas (70 pb-1Mpb)
- **BWA-mem** → Lecturas + largas, calidad alta, rapido. Mas nuevo y mejor que los anteriores.

Creación del index:	**bwa index** mtu.fasta
Alinear lecturas paired-end	**bwa mem** mtu.fasta read_1.fastq read_2.fastq > bwa.sam
Convertir SAM a BAM	**samtools view** -bS bwa.sam> bwa.bam
Ordenar el BAM	**samtools sort** bwa.bam -o bwa_sorted.bam
Creación del index en el sortedBAM	**samtools index** bwa_sorted.bam
Cargar en IGV el genoma de referencia y el archivo *sorted.bam*	Podemos usar un visualizador para cargar alguna zona de interés.

BWA mem → Pasos

Cobertura y visualización

Análisis de cobertura

http://bedtools.readthedocs.io/en/latest/content/tools/genomecov.html

Dentro del paquete bedtools, la función genomecov permite extraer información de la cobertura de un alineamiento frente a la referencia.

Obtener cobertura para cada posicion (-d)

genomeCoverageBed –ibam file.BAM -g reference.fasta -d > genomeCovBed.cov

En base a la cobertura por posición, podemos calcular la cobertura del genoma en ventanas de una longitud determinada y representarla gráficamente.

IGV → Integrative Genomics Viewer

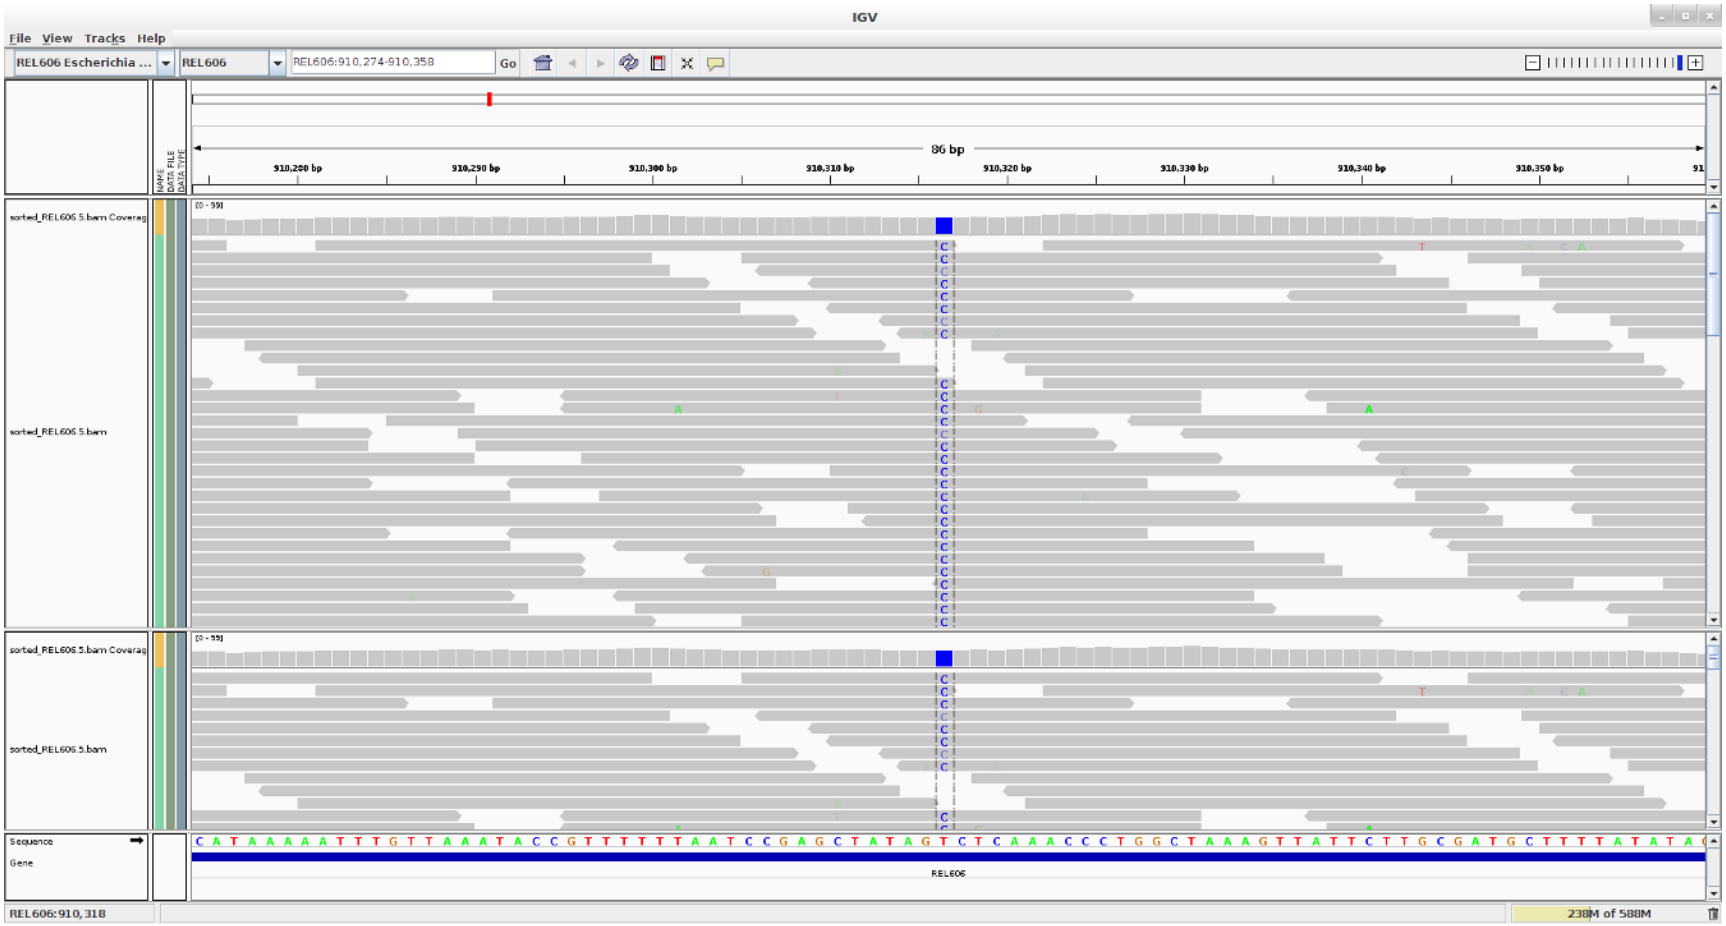

Análisis de variantes

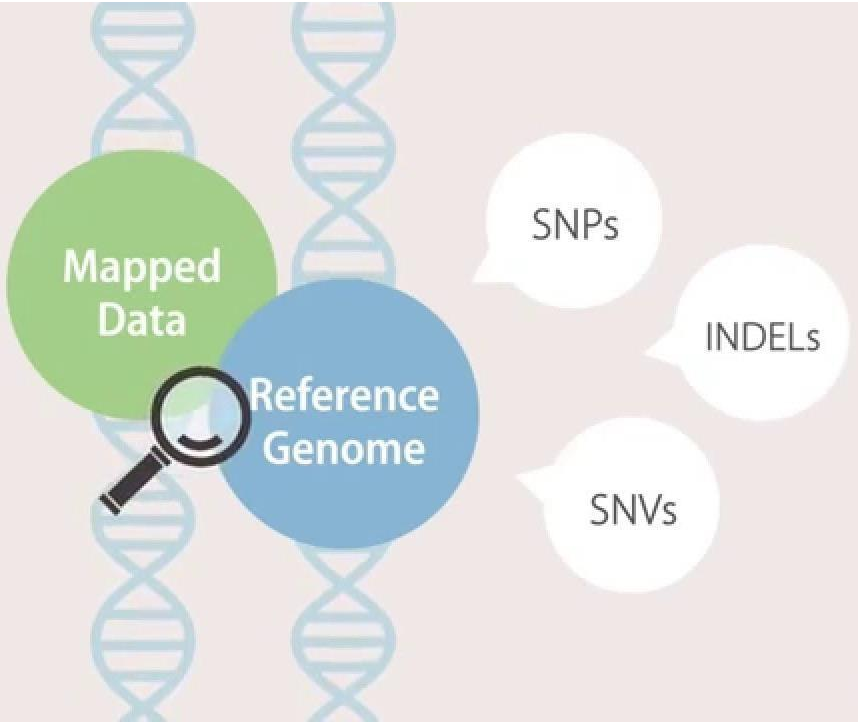

Análisis de variantes

Detectar y a ser posible caracterizar diferencias en la secuencia de un genoma frente a otro de referencia.

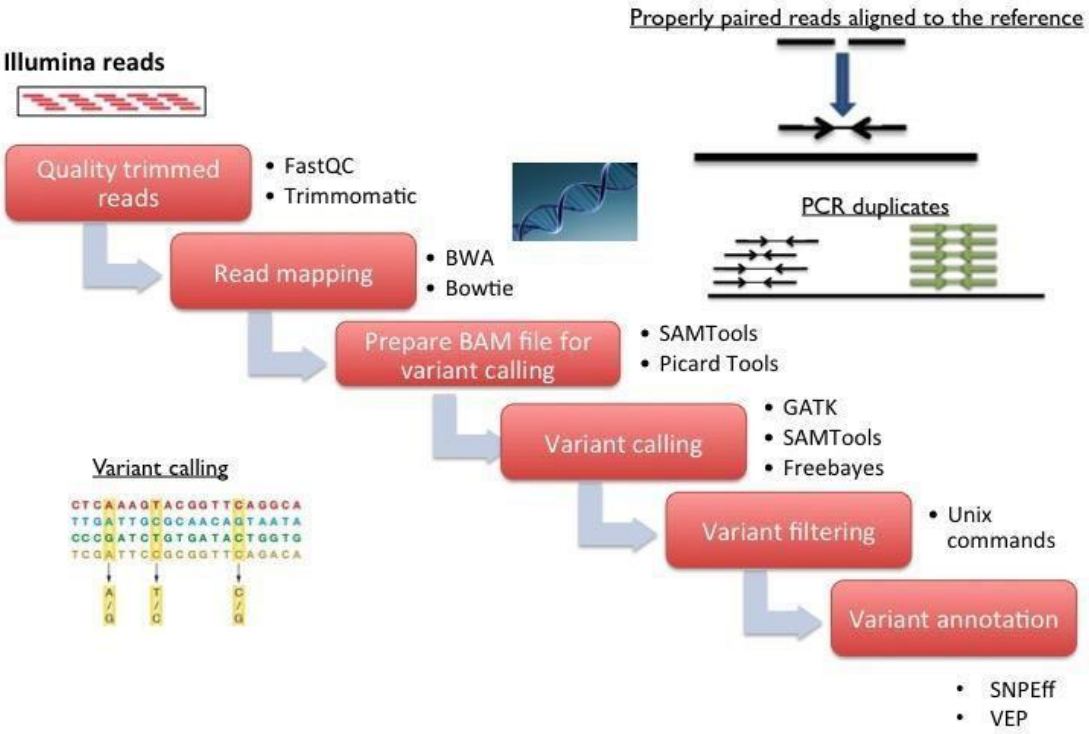

Es recomendable procesar el alineamiento (reordenar, eliminar duplicados, etc), antes del variant calling.

Pre-procesamiento del alineamiento

http://broadinstitute.github.io/picard/

Picard tools es un conjunto de herramientas para manipular datos de secuenciación en formato SAM/BAM/VCF.

1. Crear diccionario (dict) para la referencia:

java -jar picard.jar CreateSequenceDictionary R=mtu.fasta O=mtu.dict

2. Marcar duplicados de PCR:

java -jar picard.jar MarkDuplicates I=sorted.bam O=sorted_duplicated.bam METRICS_FILE=duplicate_genome.bam.txt

3. Reemplazar la información del grupo de muestras

java -jar picard.jar AddOrReplaceReadGroups I=sorted_duplicated.bam O=duplicated_readGroup.bam RGID=[1,2] RGSM=1 RGLB=lib1 RGPU=unit1 RGPL=illumina

4. Crear index del archivo BAM.

java –jar picard.jar BuildBamIndex I=duplicated_readGroup.bam

Análisis de variantes

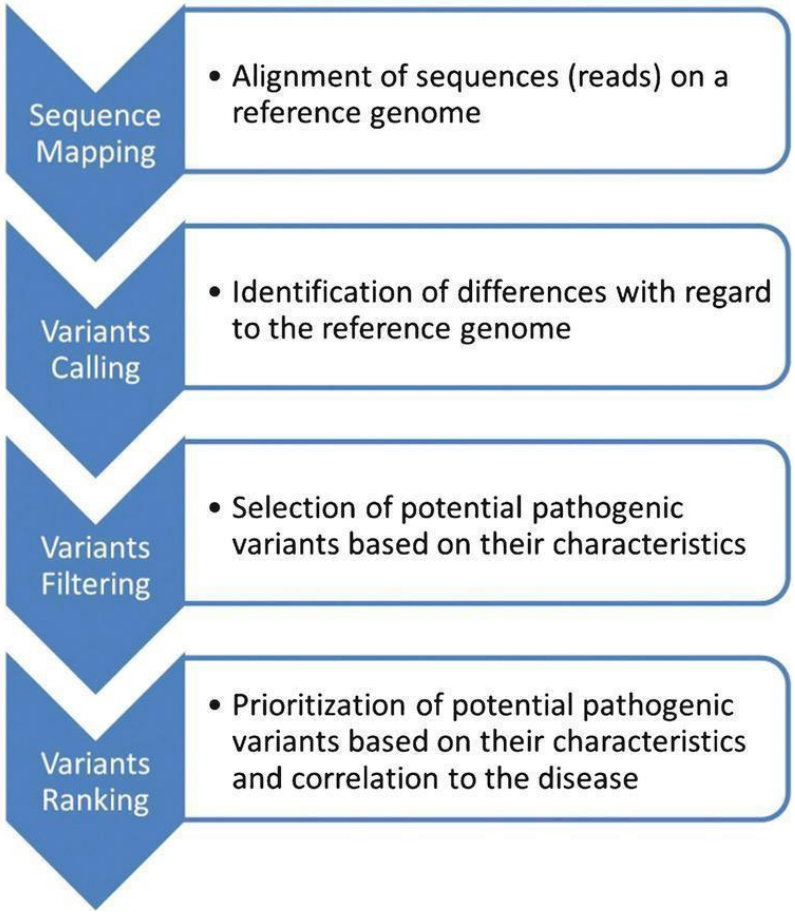

- Existen distintos métodos y programas para la búsqueda de variantes a partir de un alineamiento.
- La especificidad y la sensibilidad varían tanto entre distintos programas, como dentro del mismo programa a lo largo del genoma.
- Existen bastantes discrepancias entre los resultados de distintos programas.

Variant Calling con GATK

https://software.broadinstitute.org/gatk/

Genome Analysis Tool Kit permite detectar tanto variantes pequeñas (SNPs, indels) como grandes cambios en el genoma (CNVs, translocaciones); y tiene protocolos tanto para variantes somáticas como germinales.

- **MUY COMPLEJO** (utiliza múltiples algoritmos), pero con buenos resultados en genomas complejos.
- **Práctica -> Pipeline para detectar variantes pequeñas en línea germinal**

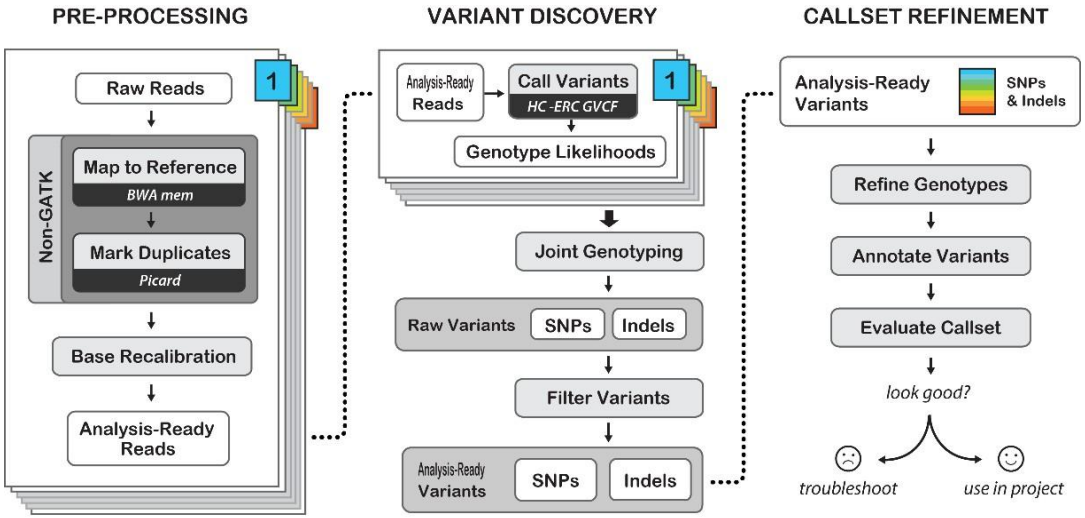

Best Practices for Germline SNPs and Indels in Whole Genomes and Exomes - June 2016

Variant Calling con GATK

Los creadores del programa recomiendan haber hecho el preproesamiento con picard, pero se podría empezar el flujo directamente con el archivo BAM original ordenador.

1. Crear un diccionario (.dict) del genoma:

java -jar /home/curso/Sofware/picard.jar CreateSequenceDictionary R=mtu.fasta O=mtu.dict

samtools faidx mtu.fasta

2. Llamar variantes con la función HaplotypeCaller:

for index **in** sensitive resistant**:**

do

gatk HaplotypeCaller -R mtu.fasta -I duplicate_${index}_readGroup.bam -O variantsGATK_${index}.vcf -ploidy 1

vcffilter -f “DP > 9” -f “QUAL > 10” variantsGATK_${index}.vcf > filtered_variantsGATK_${index}.vcf

done

Otros programas
Variant Calling con Freebayes

https://github.com/ekg/freebayes

Freebayes es un detector de variantes **Bayesiano,** capaz de detectar variantes, siempre menores que la longitud de la lectura alineada (SNPs, INDELs, MNPs, y eventos más complejos)

Genera un archivo en formato vcf con las posiciones del genoma que detecta como polimórficas, incluyendo la base de referencia, la base alternativa y la calidad de esa variante.

freebayes –f <reference.fasta> <sorted_duplicated.bam> -p 1 --use-mapping- quality > variantsFreebayes.vcf

Otros programas
Variant Calling con VarScan

http://varscan.sourceforge.net/

- VarScan es un detector de variantes que basado en **estadística robusta**.
- Necesita la información en formato mpileup, que describe y resume la cobertura de las lecturas mapeadas frente a la referencia, facilitando la detección de variantes.

1. Crear mpileup para SNP y para INDELs.

   samtools mpileup -B -f <reference sequence> <bam> > file.mpileup

2. VarScan toma el archivo BAM, y el mpileup:

   java -jar VarScan.jar mpileup2snp file.mpileup --min-coverage 10 --min-var-freq 0.8 --p-value 0.05 --variants --output-vcf 1 >> snp.vcf

   java -jar VarScan.jar mpileup2indel file.mpileup --min-coverage 10 --min-var-freq 0.8 --p-value 0.05 --variants --output-vcf 1 >> indel.vcf

VCF (Variant caller format)

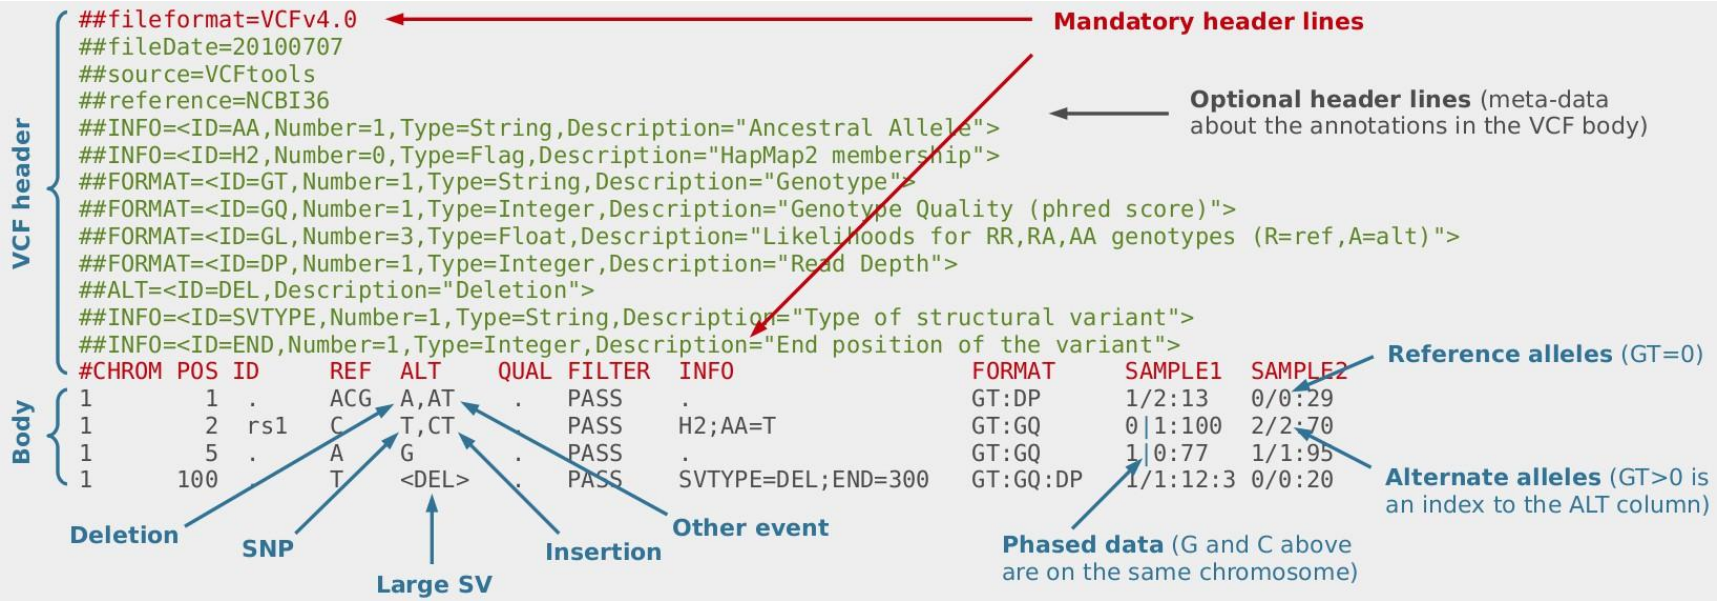

Anotación de variantes

http://snpeff.sourceforge.net/

Objetivo: Dar significado biología a las variantes detectadas.

SnpEff es un anotador de variantes y predictor de efectos, que añade la información de la anotación en la columna 8 del VCF (columna INFO).

feature ID
dependent on annotation
transcript ID, motif ID, ChipSwq peak …

gene name
common gene name (HGNC)

biotype
Ensemble biotypes
Coding, non-coding..

feature type
using Sequence Ontology
transcript, motif, miRNA …

```
#CHROM  POS     ID  REF  ALT    QUAL  FILTER  INFO
chr1    123456  .   C    A      .     .       ANN=A|...
chr1    234567  .   A    G,T    .     .       ANN=G|... , T|...
```

ANN = Annotation aka effect or consequence

putative impact
description of consequence
exon_loss_variant, stop_lost,
frameshift_variant

impact
estimation of level of impact
HIGH, LOW, MODERATE

SnpEff
Genetic variant annotation and effect prediction toolbox.

Anotación de variantes

0. Activamos el environment de conda específico para snpEff

```
conda activate Dia2_snpeff
```

1. Buscar el genoma de referencia en la base de datos de snpEff

```
snpEff databases | grep -i Mycobacterium_tuberculosis_h37rv [o el genoma de interés]
```

2. Si es la primera vez que usais este genoma, se puede instalar localmente

```
snpEff.jar databases download Mycobacterium_tuberculosis_h37rv
```

3. Anotar variantes

```
snpEff.jar –c snpEff.config –v Mycobacterium_tuberculosis_h37rv
-s stats.html file.vcf  >  file.eff.vcf
```

Anotación de variantes

Ademas del vcf anotado, snpEff genera un html con las estadísticas de las variantes identificadas.

Variants rate details

Chromosome	Length	Variants	Variants rate
Chromosome	4,411,532	612	7,208
Total	**4,411,532**	**612**	**7,208**

Number variants by type

Type	Total
SNP	537
MNP	0
INS	42
DEL	33
MIXED	0
INV	0
DUP	0
BND	0
INTERVAL	0
Total	**612**

Number of effects by impact

Type (alphabetical order)	Count	Percent
HIGH	46	0.745%
LOW	171	2.768%
MODERATE	312	5.05%
MODIFIER	5.649	91.437%

Number of effects by functional class

Type (alphabetical order)	Count	Percent
MISSENSE	302	62.917%
NONSENSE	7	1.458%
SILENT	171	35.625%

Missense / Silent ratio: 1.7661

Number of effects by type and region

Type

Type (alphabetical order)	Count	Percent
conservative_inframe_deletion	2	0.032%
conservative_inframe_insertion	3	0.049%
disruptive_inframe_deletion	2	0.032%
disruptive_inframe_insertion	4	0.065%
downstream_gene_variant	2,791	45.155%
frameshift_variant	38	0.615%
intergenic_region	82	1.327%
missense_variant	301	4.87%
non_coding_transcript_exon_variant	5	0.081%
splice_region_variant	2	0.032%
stop_gained	7	0.113%
stop_lost	2	0.032%
synonymous_variant	171	2.767%
upstream_gene_variant	2,771	44.831%

Region

Type (alphabetical order)	Count	Percent
DOWNSTREAM	2,791	45.176%
EXON	534	8.644%
INTERGENIC	82	1.327%
UPSTREAM	2,771	44.853%
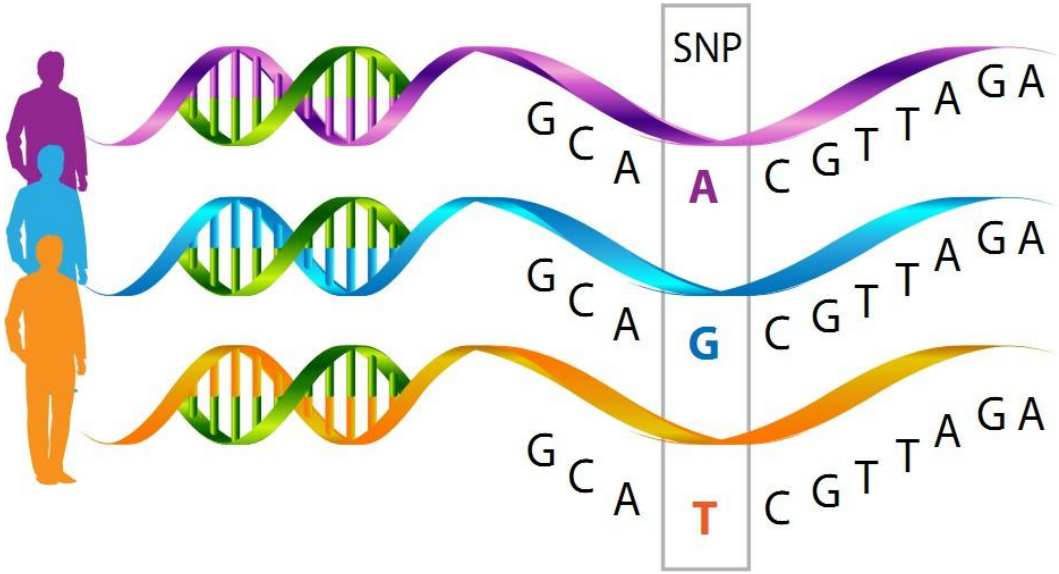
¿Preguntas?