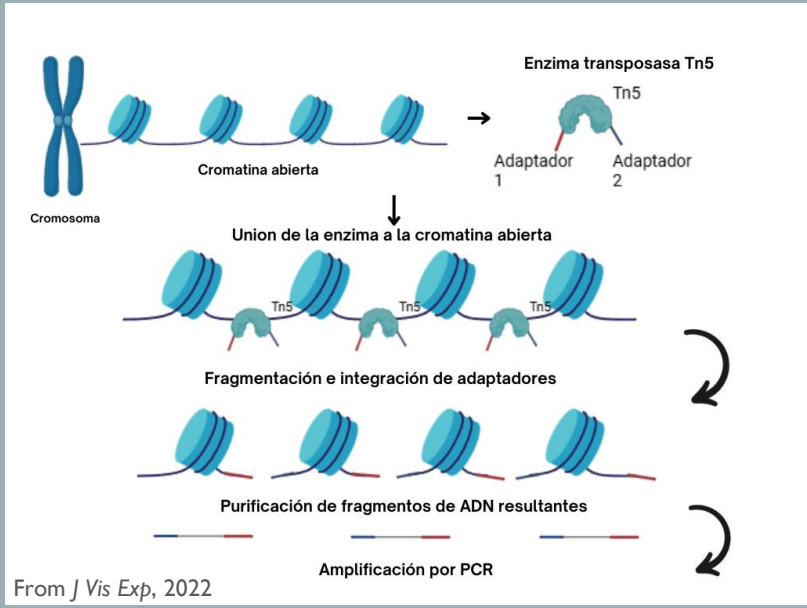
ANÁLISIS DE DATOS DE SECUENCIACIÓN **ATAC-SEQ**

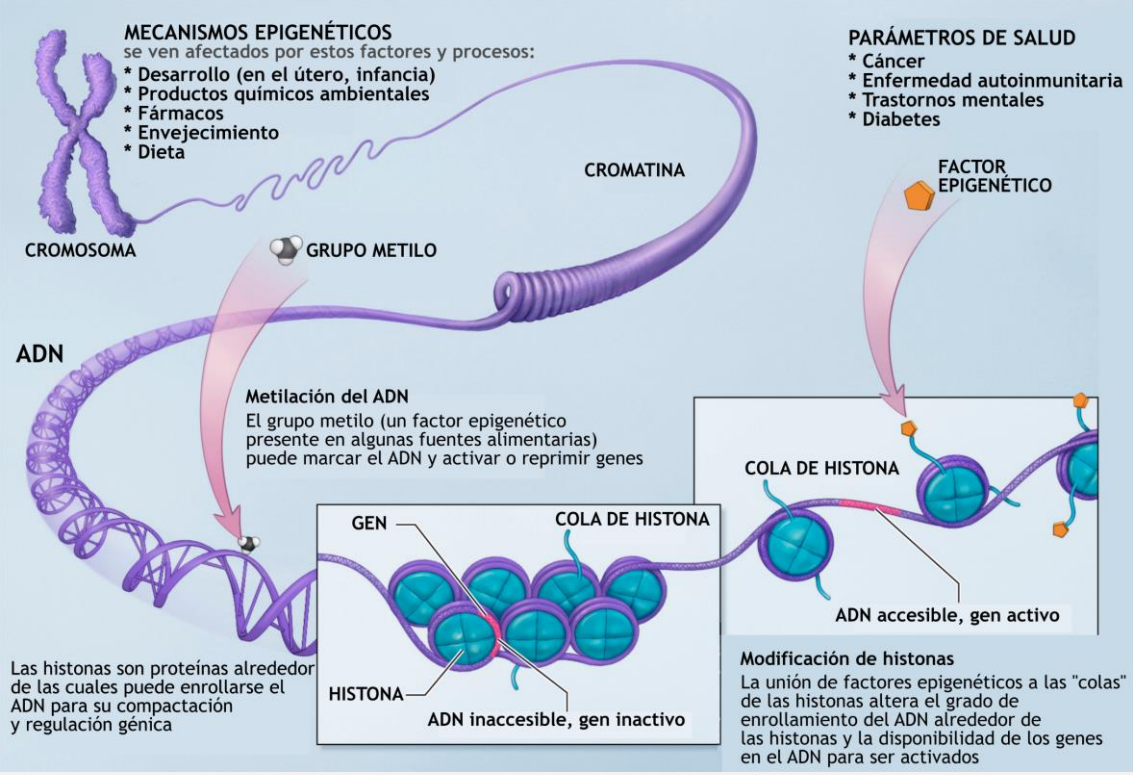


From *J Vis Exp*, 2022

Sandra González de la Fuente y María Santos Romero (SABio) - Centro de Biología Molecular Severo Ochoa

Epigenómica

Modificaciones químicas y estructurales que regulan la expresión génica sin alterar la secuencia del ADN



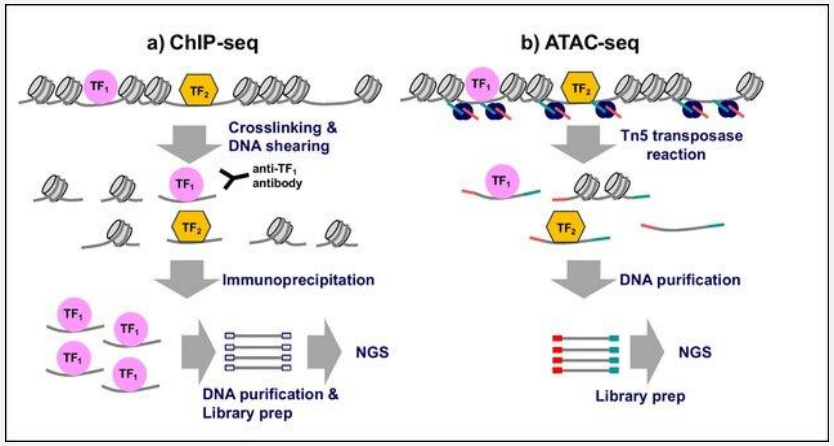
from Wikipedia

Técnicas de epigenómica

ATAC-seq (Assay for Transposase-Accessible Chromatin Sequencing)
- *Objetivo*: Identificar regiones de cromatina abierta (accesibles).

- *Pasos*:
1.Acción de la transposasa Tn5 sobre la cromatina.
2.Corte y etiquetado de regiones abiertas con secuencias específicas.
3.Amplificación y secuenciación (NGS).

- *Resultados*: Secuencias accesibles a Tn5 = Regiones de cromatina abierta.



ChIP-seq (Chromatin Immunoprecipitation Sequencing) (**CUT&Tag**; **CUT&RUN**)
- *Objetivo*: Identificar regiones de ADN asociadas a una proteína específica.

- *Pasos*:
1.Fijación: ADN de cromatina se entrecruza con formaldehído.
2.Fragmentación: Mediante sonicación o enzimas (100-600 pb).
3.Inmunoprecipitación: Uso de anticuerpo específico para la proteína de interés.
4.Eliminación de proteínas y purificación del ADN.
5.Amplificación y secuenciación (NGS).

- *Resultados*: Regiones del genoma que interactúan con la proteína de interés.

PCR específica de metilación (MSP)
Esta técnica convierte citosinas no metiladas en uracilos mediante un tratamiento con bisulfito de sodio. Luego, se realiza una PCR para detectar la presencia o ausencia de metilación en sitios CpG específicos.

ATAC-seq (Assay for Transposase-Accessible Chromatin)

Técnica epigenómica que se utiliza para detectar regiones accesibilidad de la cromatina en un genoma

Técnica

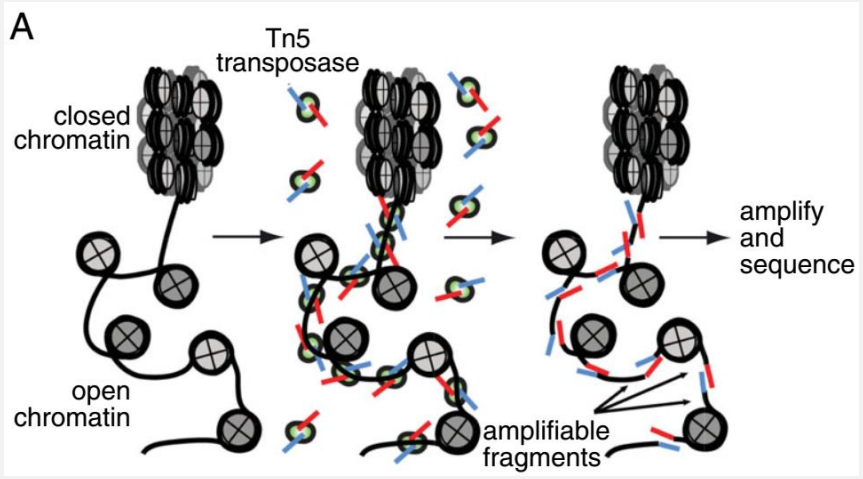
- Rápida, sencilla y necesita pocas células.
- Usa la enzima Tn5 (transposasa) que corta el ADN solo en regiones de cromatina abierta.
- Al cortar, añade los adaptadores para secuenciar.
- Amplificación y secuenciación

Aplicaciones

- Identificar enhancers, promotores y sitios de unión de factores de transcripción.
- Estudiar regulación génica: por ejemplo combinada con ChIP-seq y RNA-seq.
- Estudiar como cambia la accesibilidad de la cromatina en regiones reguladoras ante distintos estímulos y compararlos entre diferentes tipos celulares o estados de las células.
- La accesibilidad de la cromatina y los cambios epigenéticos que están estrechamente relacionados con la aparición y el desarrollo del cáncer y otras enfermedades.

ATAC-seq

Method for determining chromatin accessibility accross the genome. It utilizesa hyperactive Tn5 transposase to insert sequencing adapters into open chromatin regions.



From Buenrostro. Curr Protoc Mol Biol. 2015

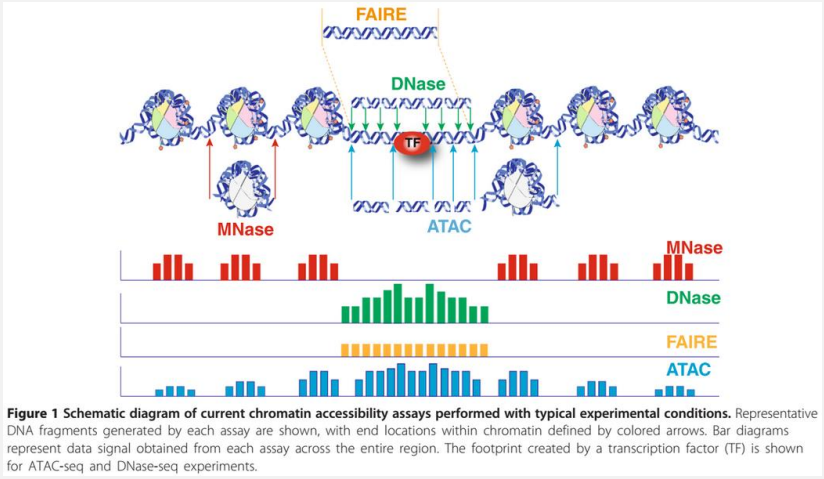
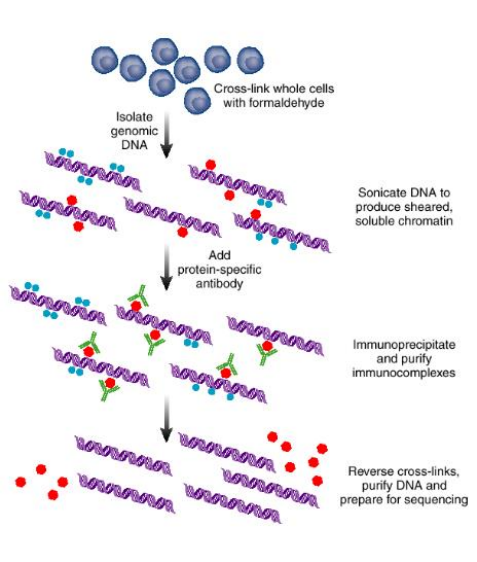
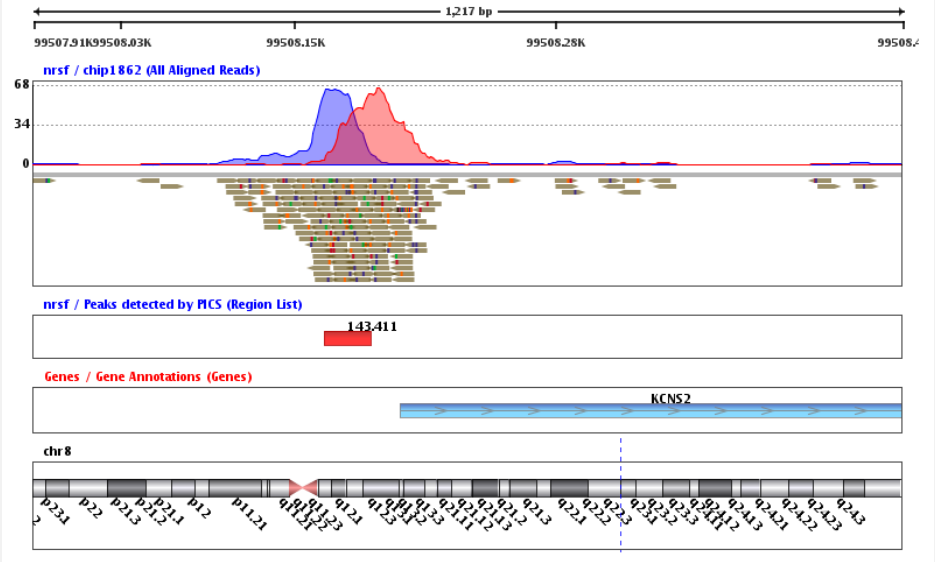


Figure 1 Schematic diagram of current chromatin accessibility assays performed with typical experimental conditions. Representative DNA fragments generated by each assay are shown, with end locations within chromatin defined by colored arrows. Bar diagrams represent data signal obtained from each assay across the entire region. The footprint created by a transcription factor (TF) is shown for ATAC-seq and DNase-seq experiments.

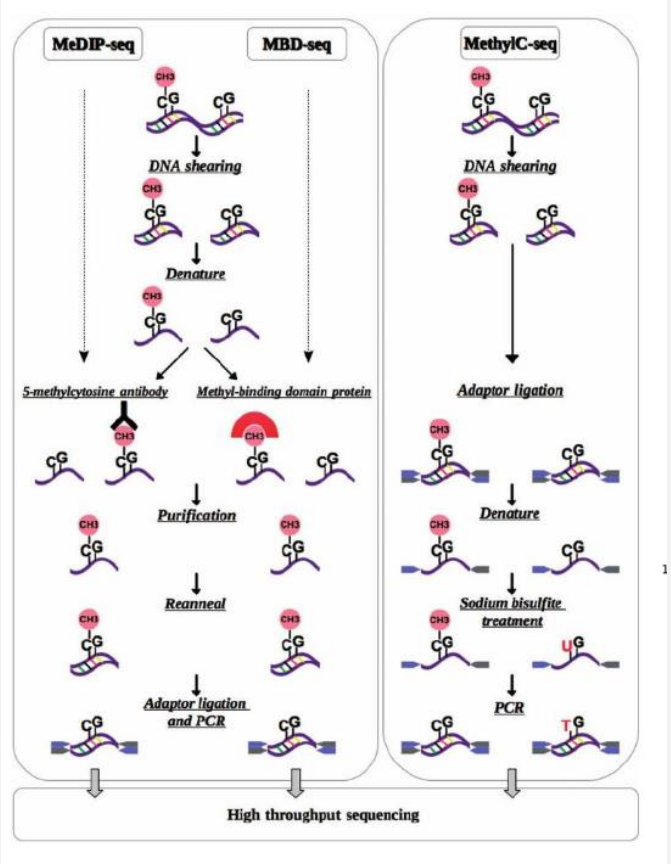
From Tsompana and Buck, 2014

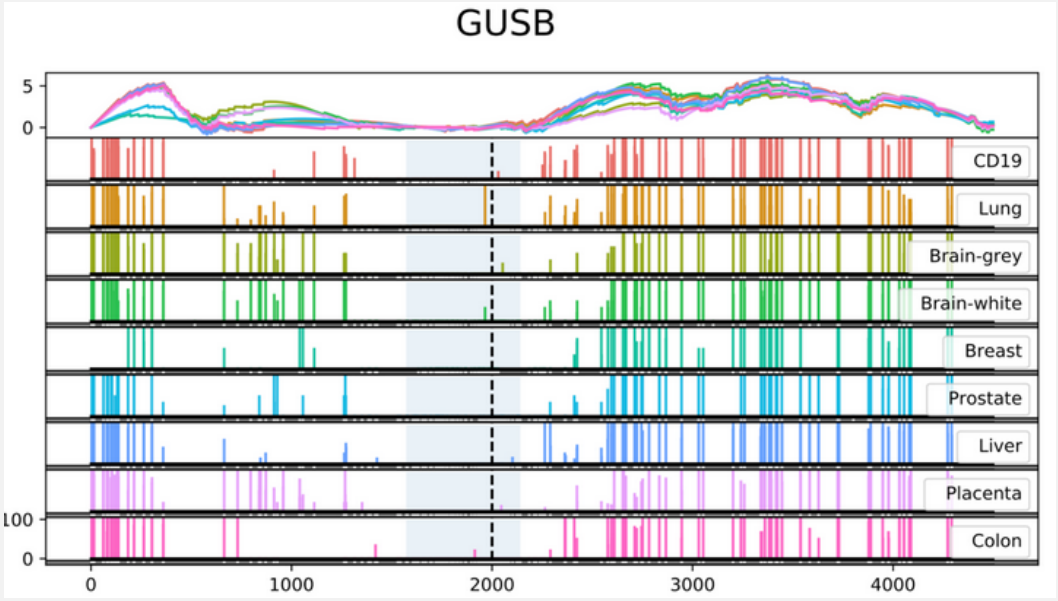
ChIP-seq


Cross-link whole cells with formaldehyde
Isolate genomic DNA
Sonicate DNA to produce sheared, soluble chromatin
Add protein-specific antibody
Immunoprecipitate and purify immunocomplexes
Reverse cross-links, purify DNA and prepare for sequencing


1,217 bp
99507.91K
99508.03K
99508.15K
99508.28K
nrsf / chip1862 (All Aligned Reads)
68
34
0
nrsf / Peaks detected by PICS (Region List)
143,411
Genes / Gene Annotations (Genes)
KCNS2
chr8

Metilación de DNA





Diseño experimental

Profundidad, depende de:

- Tamaño del genoma
- Número de sitios de unión (ChIP-seq)
- Lo limpia o sucia que sea la IP (ChIP-seq)

CUT&Tag vs. CUT&RUN vs. ChIP-Seq

	CUT&Tag	CUT&RUN	ChIP-Seq
Performed Under Native Conditions?	Yes	Yes	No
Chromatin Fragmentation Method	Tn5-based tagmentation	MNase digestion	Sonication
Cell Number Requirements	5,000-500,000 cells	500,000 cells	1-10 million cells
Sequencing Depth Required *	2 million reads **	8 million reads	20-50 million reads
Integrated Library Preparation?	Yes, uses tagmentation	No, separate library prep required	No, separate library prep required
Compatible Targets	Primarily histone modifications, some transcription factors and co-factors	Wide range of histone modifications, transcription factors, and co-factors	Wide range of histone modifications, transcription factors, and co-factors
Workflow Length	1-2 days	1-2 days	2-3 days

* Kaya-Okur et al. *Nature Communications* (2019) 10:1930

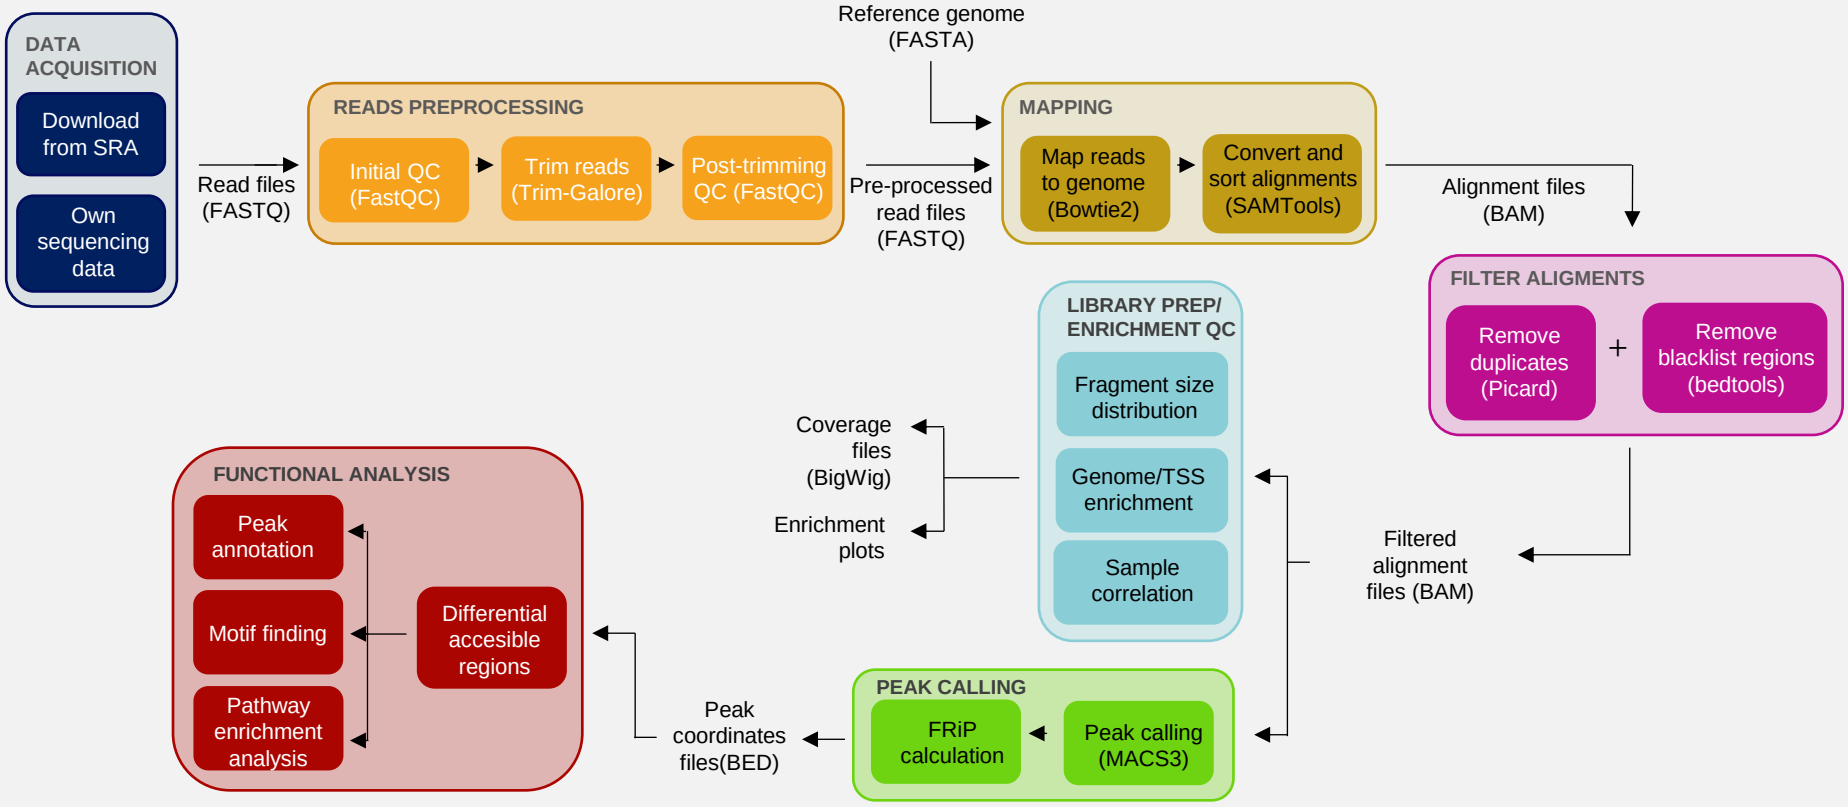
** For less abundant targets of interest, 8 to 10 million reads are recommended

From https://www.activemotif.com

ATAC-seq
Yes
Tn5-based tagmentation
50,000-100,000 cells
50-200 million reads
Yes, uses tagmentation
Accesible chromatin
1-2 days

ChIP-seq suele ser suficiente con lecturas sencillas de longitud corta (1x35, 1x50), para ATAC-seq mejor pareadas (2x75, 2x100)

Análisis de ATAC-seq (flowchart)



Notas prácticas

Specifying file paths

If I'm in `/home/user`

- Absolute path:

  `/home/user/Data/big_data.fq.gz`

- Relative path:

  `Data/big_data.fq.gz`



Command line completion

- Command line completion is achieved by typing a partial path and then pressing the TAB key (to the left of Q).
- You should use TAB completion to fill in paths for locations which exist so you can't make typing mistakes.

Contexto de la práctica

- Células musculares de ratón (*Mus musculus*)
- Condiciones experimentales:
  - Ratones Dmd KO (n=3); modelo de distrofia muscular
  - Ratones wild-type (n=3)
- Librerías de ATACseq
- Secuenciación: Illumina NovaSeq 6000; **PAIRED**; 150bp x 2; ~50M de lecturas paired por muestra.

Objetivo: identificar regiones diferencialmente accesibles en las dos condiciones y genes/rutas potencialmente afectadas.

1. Adquisición de datos

1.1. Descarga de secuencias

Sahinyan, Blackburn, Simon, et al. 2022. *Application of ATAC-Seq for genome-wide analysis of the chromatin state at single myofiber resolution*. eLife;11:e72792. DOI: https://doi.org/10.7554/eLife.72792

Data availability

The data discussed in this study have been deposited in NCBI's Gene Expression Omnibus and are accessible through GEO Series accession numbers GSE173676 and GSE171534.

The following datasets were generated:

Author(s)	Year	Dataset title	Dataset URL	Database and Identifier
Soleimani V	2021	ATAC-Seq of single myofibers	https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE173676	NCBI Gene Expression Omnibus, GSE173676
Soleimani V	2021	ATAC-Seq of young and aged satellite cells	https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE171534	NCBI Gene Expression Omnibus, GSE171534

1. Adquisición de datos

1.1. Descarga de secuencias

GEO website: https://www.ncbi.nlm.nih.gov
GEO accesion number: **GSE173676**



1. Adquisición de datos

1.1. Descarga de secuencias

NCBI GEO Gene Expression Omnibus

GSM5502605	MDX single fiber 1
GSM5502606	MDX single fiber 2
GSM5502607	MDX single fiber 3
GSM5502608	WT single fiber 1
GSM5502609	WT single fiber 2
GSM5502610	WT single fiber 3

Miofibras de un modelo murino de Distrofia Muscular de Duchenne (MDX) frente a modelo WT

NCBI SRA

Found 13 Items

	Run	BioSample	Bases	Bytes	Experiment	GEO_Accession	create_date	strain
7	SRR15343189	SAMN20571154	16.24 G	5.07 Gb	SRX11647413	GSM5502605	2021-08-07 11:43:00Z	C57/B10ScSn-Dmdmdx
8	SRR15343190	SAMN20571155	15.57 G	4.80 Gb	SRX11647414	GSM5502606	2021-08-07 11:11:00Z	C57/B10ScSn-Dmdmdx
9	SRR15343191	SAMN20571156	16.33 G	5.05 Gb	SRX11647415	GSM5502607	2021-08-07 10:19:00Z	C57/B10ScSn-Dmdmdx
10	SRR15343192	SAMN20571157	15.74 G	5.07 Gb	SRX11647416	GSM5502608	2021-08-07 09:58:00Z	C57/B10ScSn
11	SRR15343193	SAMN20571158	16.63 G	5.37 Gb	SRX11647417	GSM5502609	2021-08-07 12:24:00Z	C57/B10ScSn
12	SRR15343194	SAMN20571159	27.72 G	8.82 Gb	SRX11647418	GSM5502610	2021-08-07 17:32:00Z	C57/B10ScSn

1. Adquisición de datos

1.1. Descarga de secuencias

```
# Descarga los archivos SRA
curl -O https://sra-pub-run-odp.s3.amazonaws.com/sra/SRR15343189/SRR15343189
curl -O https://sra-pub-run-odp.s3.amazonaws.com/sra/SRR15343190/SRR15343190
curl -O https://sra-pub-run-odp.s3.amazonaws.com/sra/SRR15343191/SRR15343191
curl -O https://sra-pub-run-odp.s3.amazonaws.com/sra/SRR15343192/SRR15343192
curl -O https://sra-pub-run-odp.s3.amazonaws.com/sra/SRR15343193/SRR15343193
curl -O https://sra-pub-run-odp.s3.amazonaws.com/sra/SRR15343194/SRR15343194

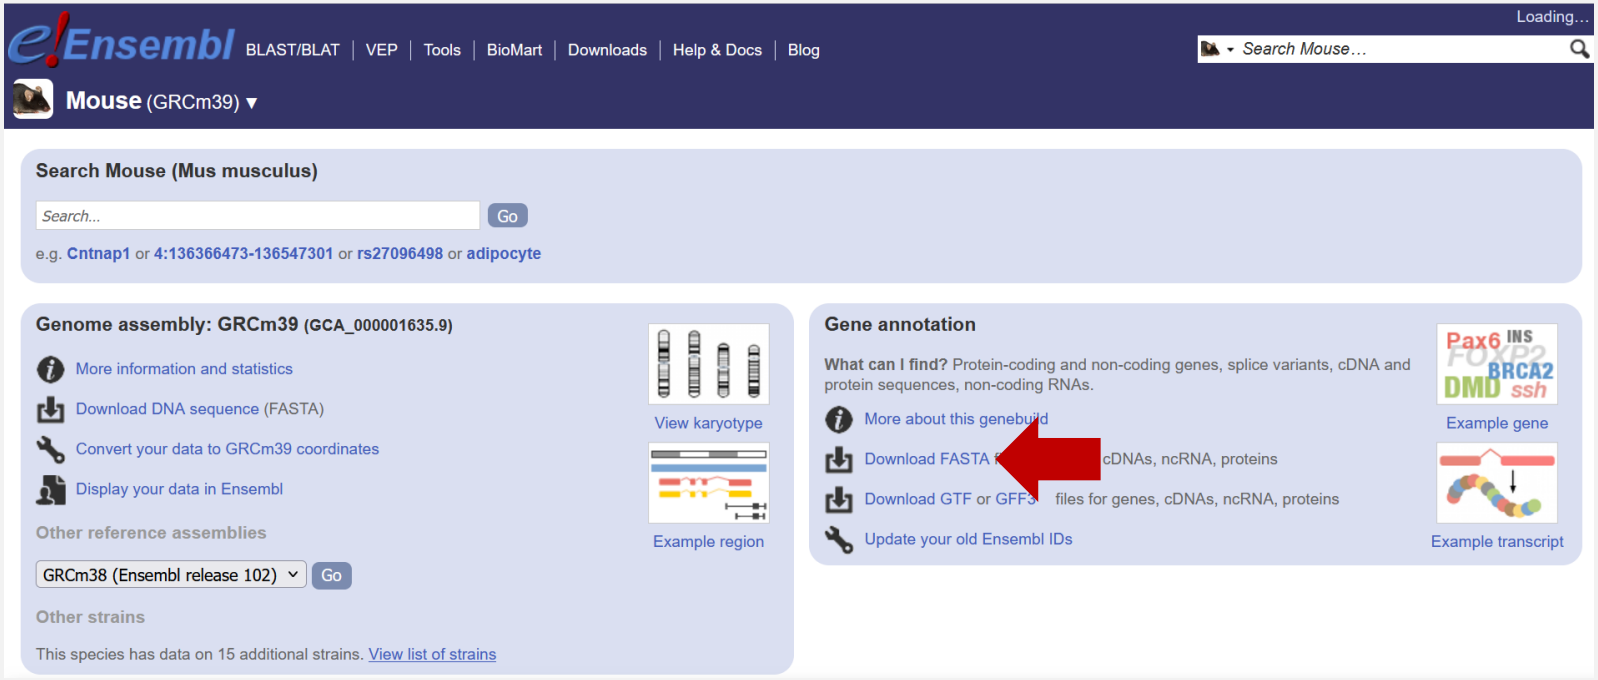
# Extrae archivos FASTQ de los archivos SRA
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
      fastq-dump --split-files $file
done

# Toma una muestra aleatoria de 1M de lecturas
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
      seqtk sample -s100 ${file}_1.fastq 1000000 | gzip > ${file}_1M_1.fastq.gz
      seqtk sample -s100 ${file}_2.fastq 1000000 | gzip > ${file}_1M_2.fastq.gz
done
```

1. Adquisición de datos

1.2. Descarga del genoma de referencia (FASTA)

https://www.ensembl.org/Mus_musculus/Info/Index



1. Adquisición de datos

1.3. Descarga anotación del genoma de referencia (GTF)

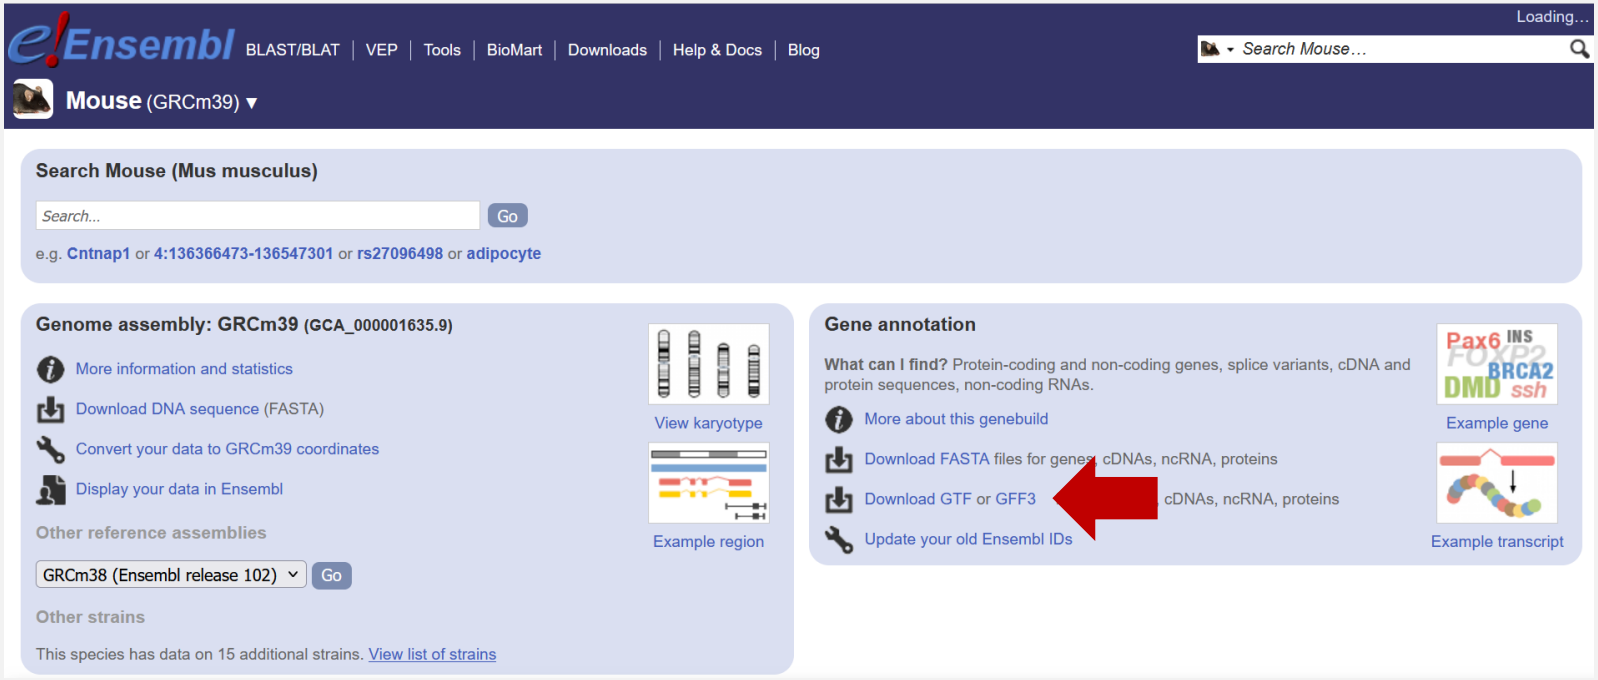
GTF – Gene transfer format

```
#!genome-build GRCm39
#!genome-version GRCm39
#!genome-date 2020-06
#!genome-build-accession GCA_000001635.9
#!genebuild-last-updated 2022-04
1     havana      gene  150956201   150958296   .     +     .     gene_id "ENSMUSG00000102628"; ...;
1     havana      transcript  150956201   150958296   .     +     .     gene_id "ENSMUSG00000102628"; ...;
1     havana      exon  150956201   150958296   .     +     .     gene_id "ENSMUSG00000102628"; ...;
1     havana      gene  150983666   150984611   .     +     .     gene_id "ENSMUSG00000100595"; ...;
1     havana      transcript  150983666   150984611   .     +     .     gene_id "ENSMUSG00000100595"; ...;
```

1. Adquisición de datos

1.3. Descarga anotación del genoma de referencia (GTF)

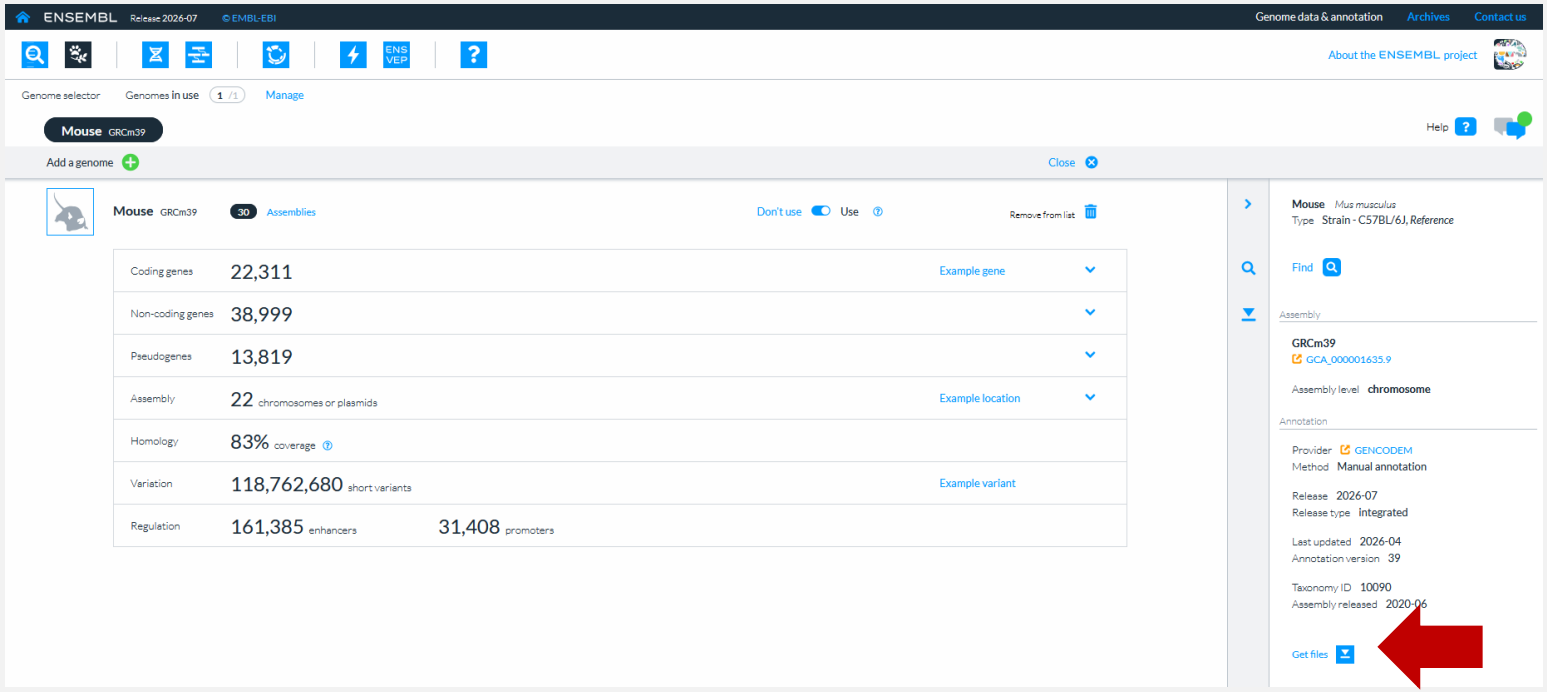
https://www.ensembl.org/Mus_musculus/Info/Index



1. Adquisición de datos

Nuevo release de ENSEMBL (verano, 2026)

https://www.ensembl.org/Mus_musculus/Info/Index



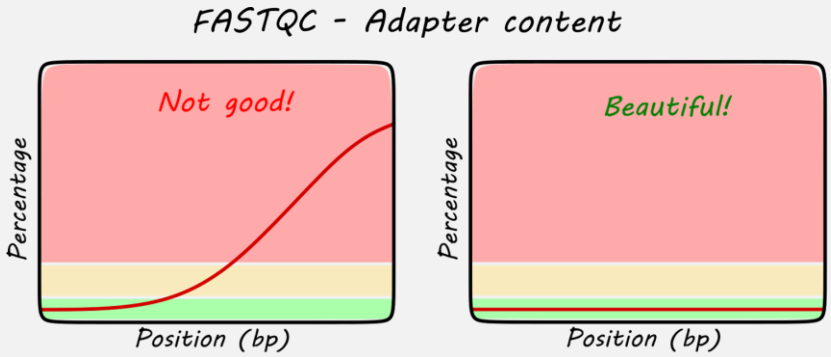
2. Preprocesamiento de lecturas

2.1. Análisis de calidad inicial

```
# Crea un directorio en el que almacenar los resultados
mkdir raw_fastqc

# Genera informes de calidad de las secuencias
fastqc *.fastq.gz -t 6 --outdir /home/curso/dia3/raw_fastqc

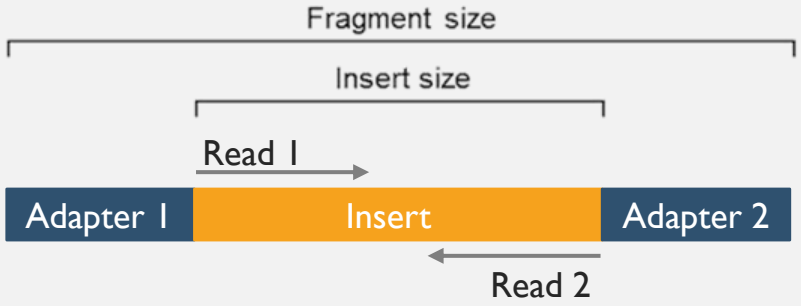
# Agrega los informes generados en un único informe
multiqc raw_fastqc/
```



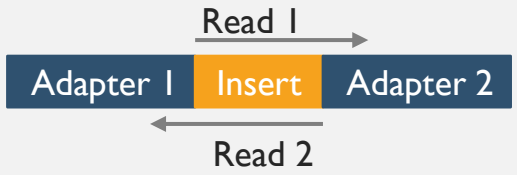
2. Preprocesamiento de lecturas

2.2. Recorte de lecturas

- Acorta lecturas para eliminar secuencia de adaptadores
- Descarta lecturas muy cortas (default: < 20bp)



Lecturas SIN adaptadores



Lecturas **CON** adaptadores

2. Preprocesamiento de lecturas

2.2. Recorte de lecturas (Trim Galore)

```
# Elimina adaptadores de Nextera y descarta lecturas recortadas menores de 50bp
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
  trim_galore --nextera --length 50 --paired \
    ${file}_1M_1.fastq.gz ${file}_1M_2.fastq.gz \
    --fastqc --fastqc_args "--outdir /home/curso/dia3/trimmed_fastqc" \
    -j 6 -o /home/curso/dia3/trimmed_reads
done
```

Trim Galore!

Babraham Bioinformatics

3. Alineamiento de lecturas al genoma de referencia (Bowtie2)

```
# Genera un índice del genoma de referencia
bowtie2-build mm39_107.fa mm39_107

# Mapea las lecturas al genoma de referencia
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
    bowtie2  --very-sensitive --no-discordant -X 2000 -p 6 \
        -x ../reference/mm39_107 \
        -1 ../trimmed_reads/${file}_1M_1_val_1.fq.gz \
        -2 ../trimmed_reads/${file}_1M_2_val_2.fq.gz > ${file}.sam

    samtools view -bS ${file}.sam --threads 7 -o ${file}.bam
    samtools sort ${file}.bam --threads 7 -o ${file}_1M_sorted.bam
    samtools index ${file}_1M_sorted.bam

    rm -rf ${file}.bam ${file}.sam #take care with deleting files within a loop!

done
```

4. Depurado de los alineamientos

4.1. Detección y eliminación de duplicados (Picard)

Duplicados: parejas de lecturas procedentes de un solo fragmento de ADN. Alinean en las mismas posiciones del genoma de referencia (mismas coordenadas) y con la misma orientación. Pueden producirse durante la preparación de la muestra (duplicados de PCR) o en la secuenciación (duplicados ópticos).

```
# Identificar, marcar y eliminar lecturas que proceden del mismo fragmento de DNA.
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
    java -jar picard.jar MarkDuplicates \
        I=../alignment/${file}_1M_sorted.bam \
        O=${file}_1M_sorted_rmDup.bam \
        M=${file}.MarkDuplicates.txt \
        REMOVE_DUPLICATES=true

    samtools index ${file}_1M_sorted_rmDup.bam
    samtools flagstat ${file}_1M_sorted_rmDup.bam > ${file}_1M_sorted_rmDup.flagstat.txt
done
```

4. Depurado de los alineamientos

4.2. Descarte de lecturas en regiones *blacklist*

Regiones blacklist: zonas del genoma que producen señales no fiables o artefactos en experimentos de secuenciación.

Se excluyen del análisis para evitar una mala interpretación de estos datos.

- Regiones muy repetitivas (ej. satélites, telómeros, …)
- Regiones con alta cobertura anómala en múltiples datasets.
- Regiones con secuencias poco mapeables o con errores de ensamblaje.

```
# Convierte las coordenadas genómicas de las regiones "blacklist" entre versiones del genoma
CrossMap bed mm10ToMm39.over.chain mm10.blacklist.bed mm39.blacklist.bed

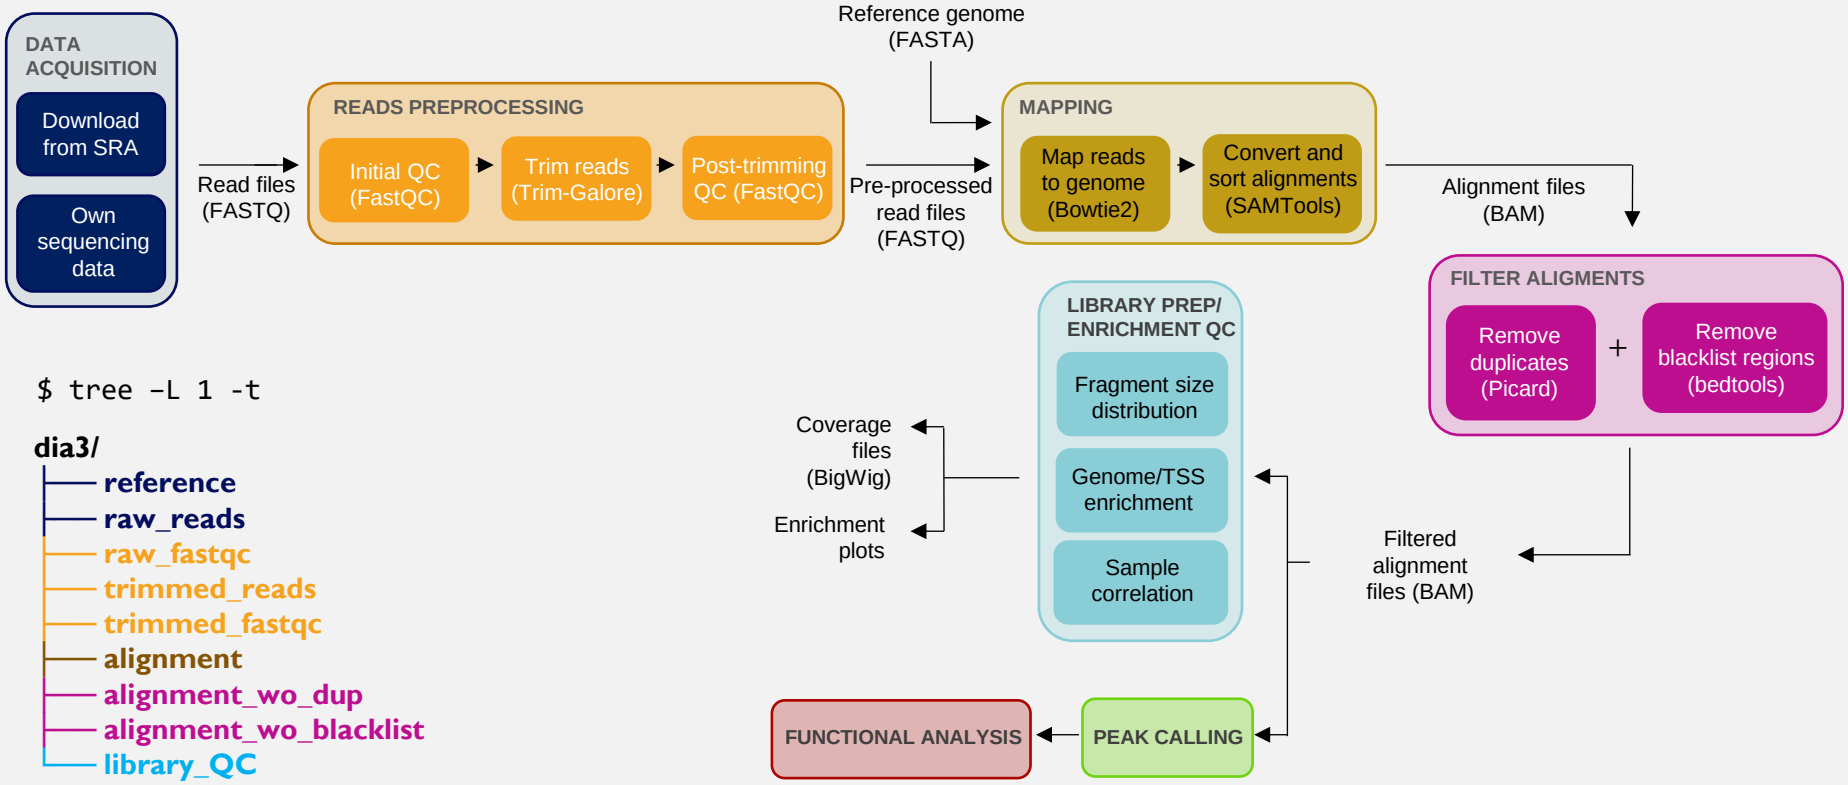
# Añade el cromosoma mitocondrial a la lista de regiones no deseadas
cat mm39.blacklist.bed MT.txt > combined_blacklist.bed

# Descarta las lecturas que solapan con las regiones no deseadas
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
    bedtools intersect  -v \
                        -a ../alignment_wo_dup/${file}_1M_sorted_rmDup.bam \
                        -b combined_blacklist.bed > ${file}_1M_flt.bam

    samtools index ${file}_1M_flt.bam

done
```

Análisis de ATAC-seq (flowchart)




```
$ tree -L 1 -t
```

dia3/

- **reference**
- **raw_reads**
- **raw_fastqc**
- **trimmed_reads**
- **trimmed_fastqc**
- **alignment**
- **alignment_wo_dup**
- **alignment_wo_blacklist**
- **library_QC**

9 directories, 0 files

5. QC de las librerías de ATAC-seq

¿Ha funcionado nuestro ATAC-seq? ¿Podemos distinguir regiones accesibles en el genoma?

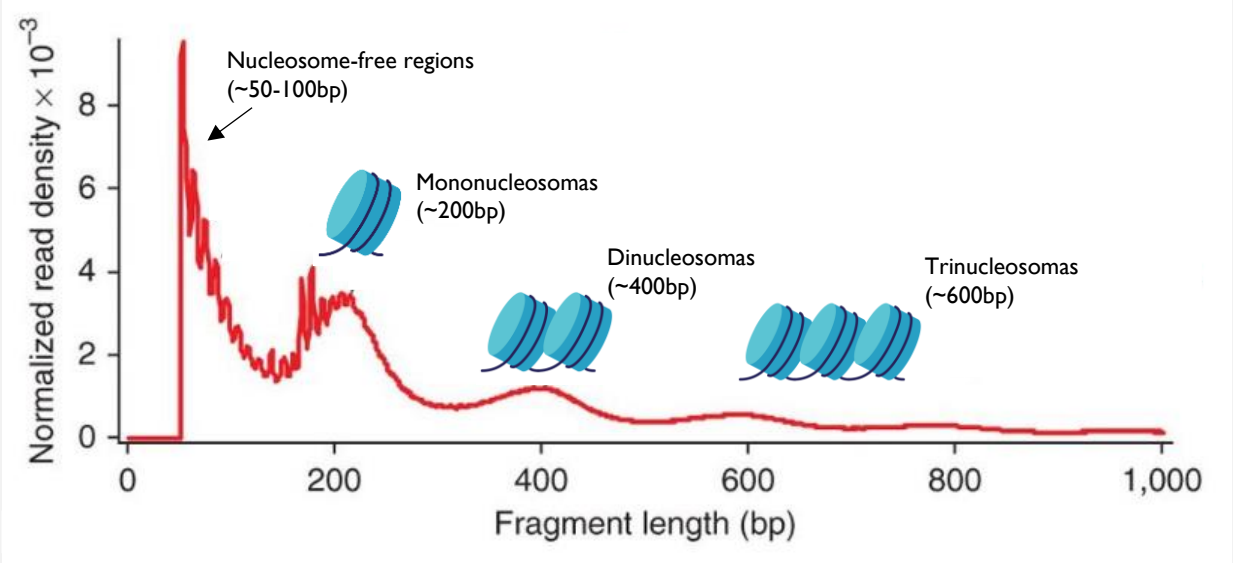
En un ATAC-seq exitoso esperamos observar:

- Distribución característica del tamaño de fragmentos.
- Enriquecimiento de regiones accesibles de cromatina frente al resto del genoma (=picos de cobertura).
- Enriquecimiento alrededor del TSS (Transcription Start Site) de los genes activos.
- Reproducibilidad entre réplicas biológicas y buena correlación entre ellas.

5. QC de las librerías de ATAC-seq

5.1. Distribución del tamaño de los fragmentos

La tagmentación genera un patrón característico de tamaño de fragmentos correspondiente con regiones libres de nucleosomas (NFR), mononucleosomas, dinucleosomas, y otros oligonucleosomas en regiones abiertas de la cromatina.

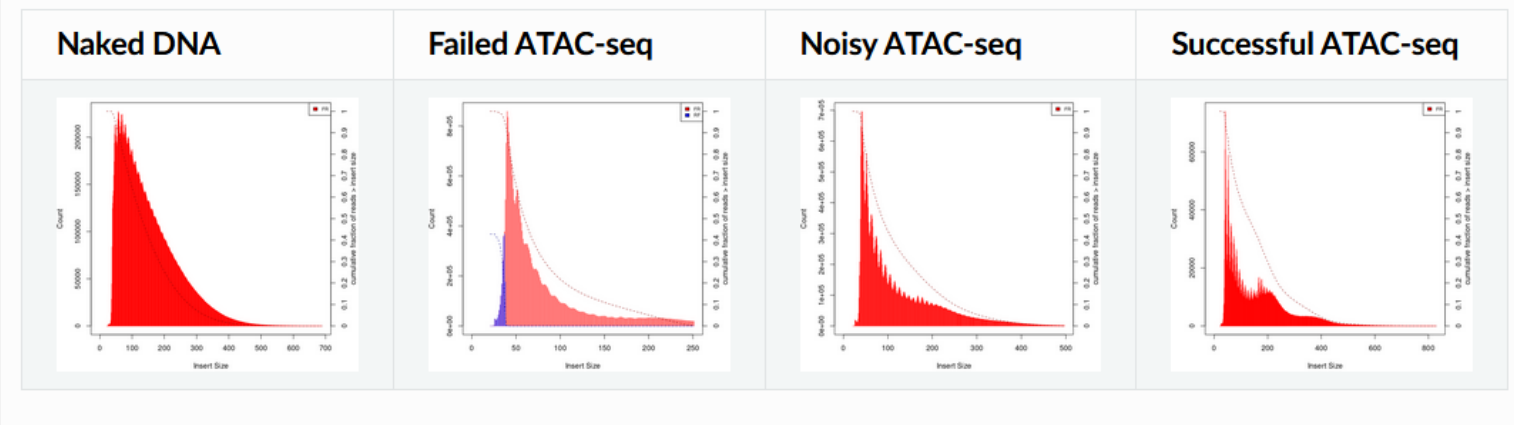


Modified from Jason D Buenrostro, et.al. *Nature Methods* 10 (2013)

5. QC de las librerías de ATAC-seq

5.1. Distribución del tamaño de los fragmentos

```
# Genera un histograma con el tamaño de fragmentos
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
     picard.jar CollectInsertSizeMetrics \
          -I ${file}_1M_flt.bam \
          -O ${file}.fraglen.stats \
          -H ${file}.fraglen.pdf
done
```



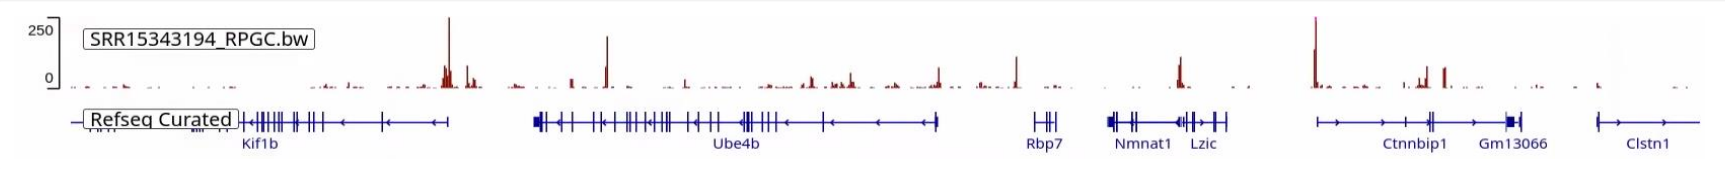
NO EJECUTAR

5. QC de las librerías de ATAC-seq

5.2. Visualización de picos de cobertura

BigWig es formato de archivo utilizado para **visualizar la cobertura** o cantidad de lecturas a lo largo del genoma de forma eficiente y rápida en navegadores genómicos (como UCSC Genome Browser o IGV).

```
# Genera archivos BigWig para cada muestra
for file in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
     bamCoverage --bam ../alignment_wo_blacklist/${file}_1M_flt.bam \
          -o ${file}_RPGC.bw \
          --binSize 10 \
          --normalizeUsing RPGC \
          --ignoreForNormalization MT \
          --effectiveGenomeSize 2654621783
done
```



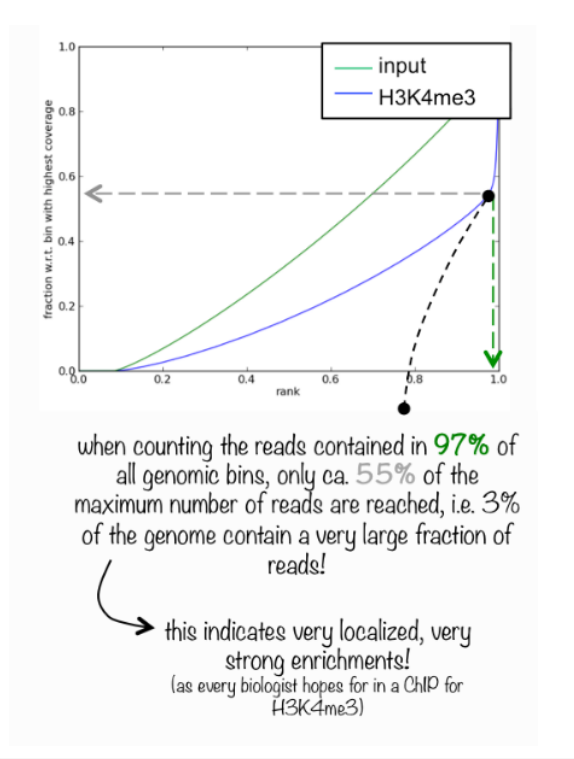
5. QC de las librerías de ATAC-seq

5.3. Fingerprint

Permite evaluar la **homogeneidad de la cobertura a lo largo del genoma** y con ello, el enriquecimiento en determinadas regiones.

Para generarlo, el genoma se divide en ventanas de tamaño fijo y se calcula la cobertura (número de lecturas) en cada ventana. Luego las ventanas se ordenan de menor a mayor cobertura y se grafica la suma acumulada de lecturas a lo largo del ranking.

En una **muestra** con **sin enriquecimiento** (una distribución homogénea de lecturas), la curva resultante es cercana a la **diagonal**. En una **muestra con enriquecimiento**, la curva tiene un **ascenso pronunciado hacia el final del ranking**, indicando que la mayor parte de las lecturas se concentran en un número reducido de ventanas.

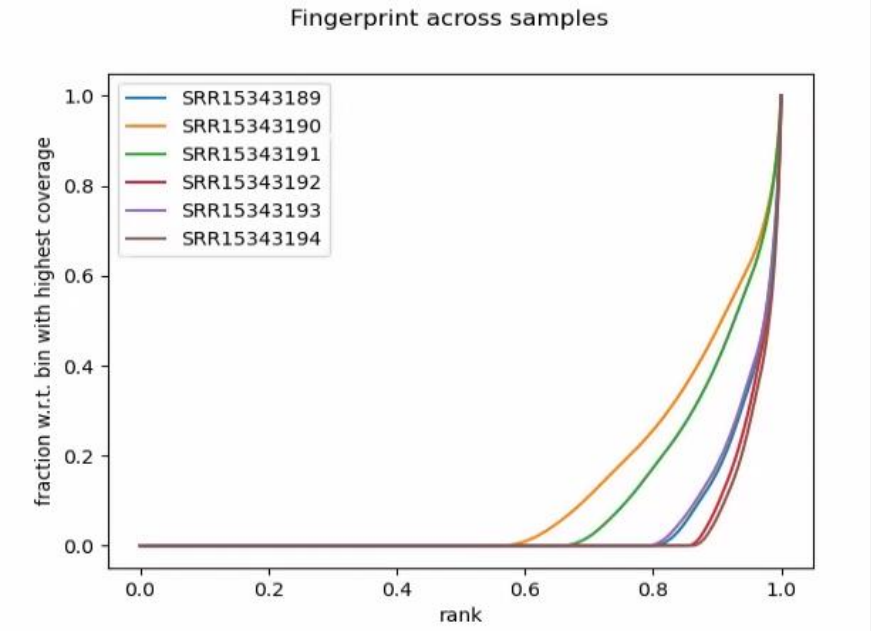


NO EJECUTAR

5. QC de las librerías de ATAC-seq

5.3. Fingerprint

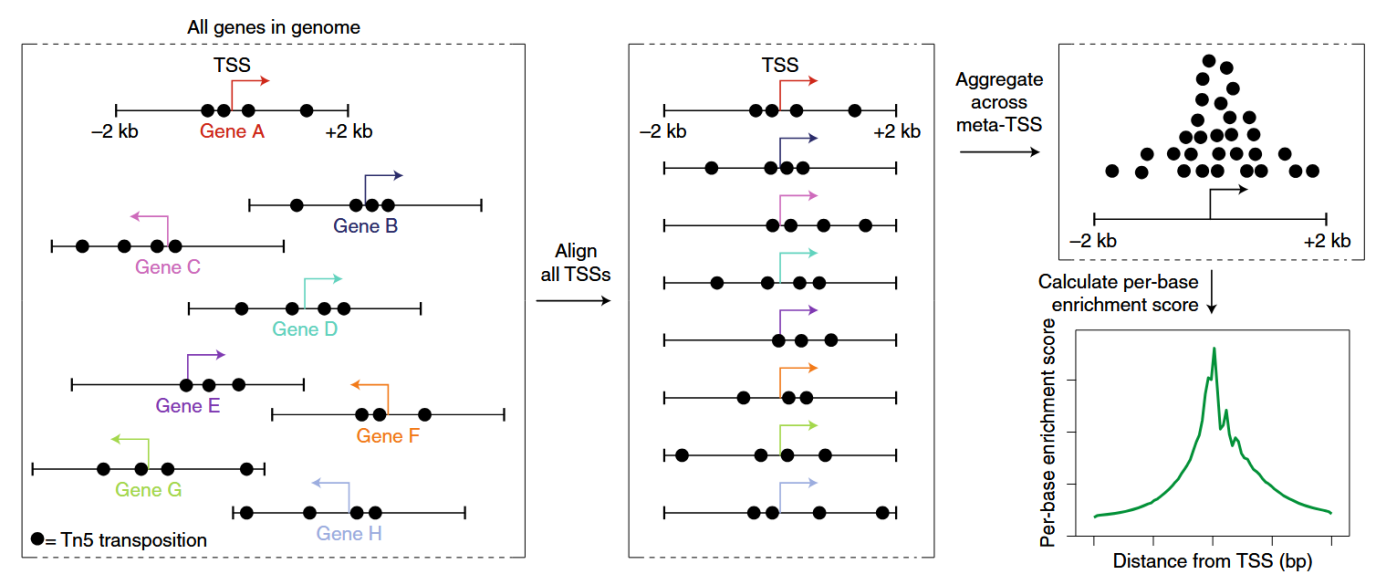
```
# Plotea el enriquecimiento para cada muestra
plotFingerprint -b ../alignment_wo_blacklist/*_1M_flt.bam \
     --minMappingQuality 30 \
     --labels SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194 \
     --skipZeros \
     --numberOfSamples 50000 \
     -T "Fingerprint across samples" \
     --plotFile fingerprints.png \
     --outRawCounts fingerprints.tab
```



5. QC de las librerías de ATAC-seq

5.4. Enriquecimiento en el origen de transcripción (TSS)

Las regiones promotoras (adyacentes al TSS) están enriquecidas en cromatina accesible. En un ATAC-seq exitoso deberíamos ver un mayor número de fragmentos/lecturas en estas zonas respecto a las colindantes.



From *Nat Protoc.* 2022

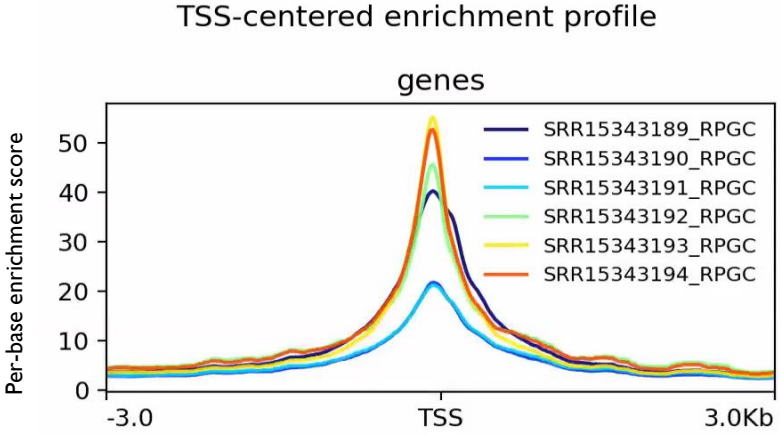
NO EJECUTAR

5. QC de las librerías de ATAC-seq

5.4. Enriquecimiento en el origen de transcripción (TSS)

```
# Genera una matriz con los valores de cobertura a ±3Kb TSS
computeMatrix reference-point --referencePoint TSS --scoreFileName *_RPGC.bw \
   --regionsFileName /home/curso/dia3/reference/Mus_musculus.GRCm39.107.chr.gtf \
   --outFileName TSSmeta.gz \
   --beforeRegionStartLength 3000 \
   --afterRegionStartLength 3000 \
   --binSize 20 \
   --missingDataAsZero \
   --sortRegions no \
   --skipZeros

# Haz un plot a partir de la matriz generada
plotProfile -m TSSmeta.gz \
     -out TSS_prof.png \
     --plotTitle "TSS-centered enrichment profile" \
     --perGroup
```



NO EJECUTAR

5. QC de las librerías de ATAC-seq

5.5. Correlación en el perfil de enriquecimiento entre muestras

Evalúa la correlación entre muestras a nivel de accesibilidad de cromatina. **¿Se comportan las muestras de la misma condición de manera coherente?**

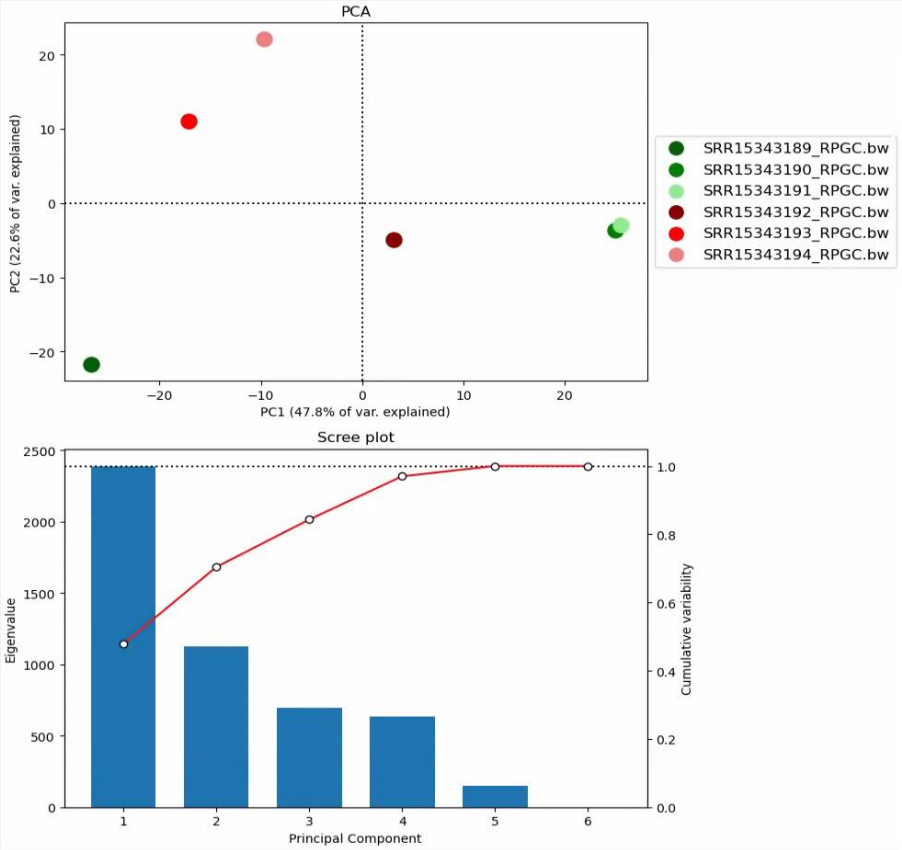
```
# Condensa los valores de enriquecimiento de múltiples archivos BigWig en una única matriz
multiBigwigSummary bins \
   --bwfiles *.bw \
   --outFileName coverage_matrixAll_NORM.npz \
   --binSize 10000 \
   -p 6

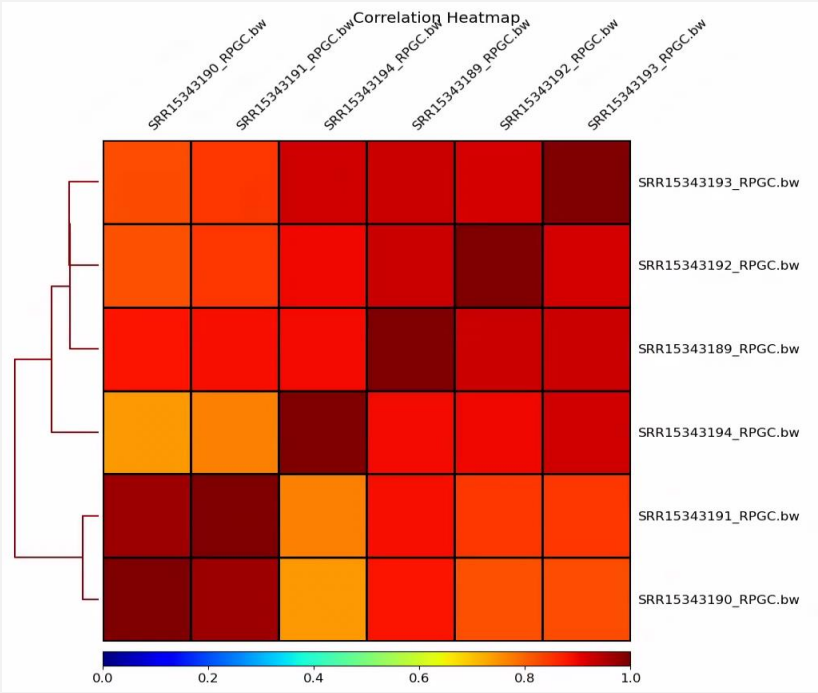
# Haz un principal component análisis (PCA)
plotPCA -in coverage_matrixAll_NORM.npz \
   -o pca_NORM.png \
   --plotTitle "PCA" \
   --colors darkgreen green lightgreen darkred red lightcoral \
   --markers 'o' \
   --transpose

# Genera un heatmap de correlación entre muestras
plotCorrelation -in coverage_matrixAll_NORM.npz \
   --corMethod pearson \
   --labels SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194 \
   --plotTitle "Correlation Heatmap" \
   --whatToPlot heatmap \
   --outFileCorMatrix correlation_matrixNorm.tab \
   --plotFile correlation_heatmapNorm.png \
   --removeOutliers
```

5. QC de las librerías de ATAC-seq

5.5. Correlación en el perfil de enriquecimiento entre muestras





starting with 10M reads

6. Detección y consolidación de picos

6.1. Peak calling (MACS3)

Detectar y **delimitar** las regiones accesibles (= **picos de cobertura**) a partir de lecturas alineadas al genoma.

```
# Genera un archivo BED con las coordenadas de los picos de cobertura
for sample in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
    macs3 callpeak -f BAMPE -t ../alignment_10M_flt/${sample}_10M_flt.bam -g mm -n
${sample}.macs3 -B -q 0.05
done
```

6. Detección y consolidación de picos

6.1. Peak calling (MACS3)

FRiP (**Fraction of Reads in Peaks**) es una métrica utilizada para evaluar la calidad de los datos en experimentos como ChIP-seq, ATAC-seq, o cualquier análisis donde se busquen regiones enriquecidas de interés.

Cuanto mayor sea el valor, **mejor**. Según ENCODE, idealmente debe ser superior a 0.3, y valores mayores a 0.2 son aceptables.

```
# Calcula FRiP para cada muestra
for sample in SRR15343189 SRR15343190 SRR15343191 SRR15343192 SRR15343193 SRR15343194
do
    frip.sh -s ${sample} \
           -b ../alignment_10M_flt/${sample}_10M_flt.bam \
           -p ../peak_calling_10M/${sample}.macs3_peaks.narrowPeak
done
```

```
FRiP score for SRR15343189: 0.309392
--------------------------
FRiP score for SRR15343190: 0.293099
--------------------------
FRiP score for SRR15343191: 0.261428
--------------------------
FRiP score for SRR15343192: 0.568603
--------------------------
FRiP score for SRR15343193: 0.494554
--------------------------
FRiP score for SRR15343194: 0.641141
--------------------------
```

OPCIONAL

6. Detección y consolidación de picos

6.2. Consolidación de picos consenso entre réplicas (MSCP)

Consolidar los picos que solapan entre replicados en picos consenso.

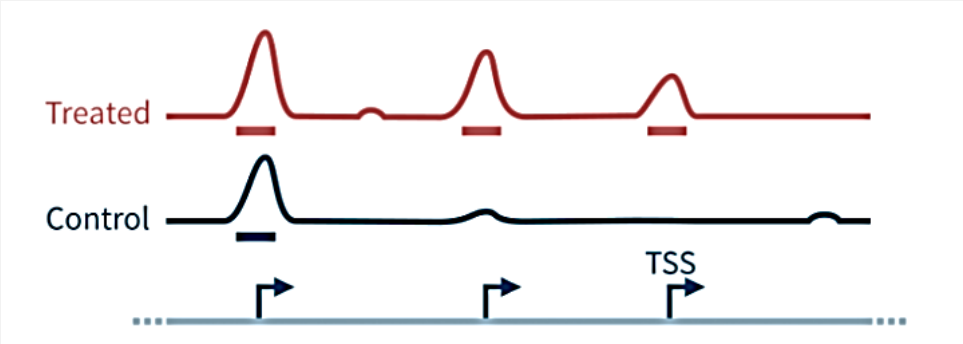
```
# Picos consenso en las muestras WT
mspc -i SRR15343189.macs3_peaks.narrowPeak -i SRR15343190.macs3_peaks.narrowPeak
-i SRR15343191.macs3_peaks.narrowPeak \
    -r bio -s 0,01 -w 0,05 -a 0,05 -c 2 \
    -p ../mspc_parser_config.json \
    -o consensus_peak_MDX

# Picos consenso en las muestras MDX
mspc -i SRR15343192.macs3_peaks.narrowPeak -i SRR15343193.macs3_peaks.narrowPeak
-i SRR15343194.macs3_peaks.narrowPeak \
    -r bio -s 0,01 -w 0,05 -a 0,05 -c 2 \
    -p ../mspc_parser_config.json \
    -o consensus_peak_WT
```

7. Análisis de regiones diferencialmente accesibles (DARs)

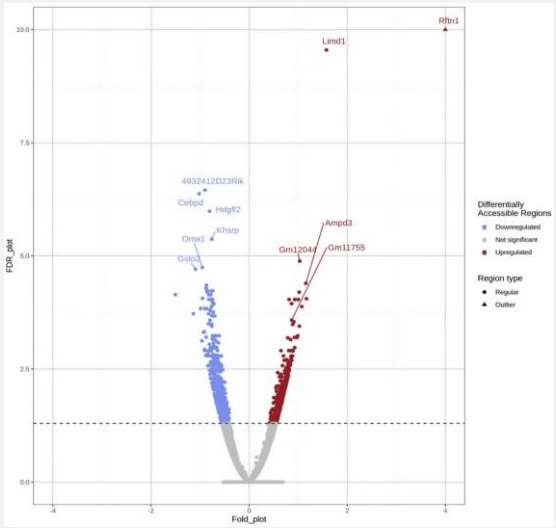
Este análisis nos permite:

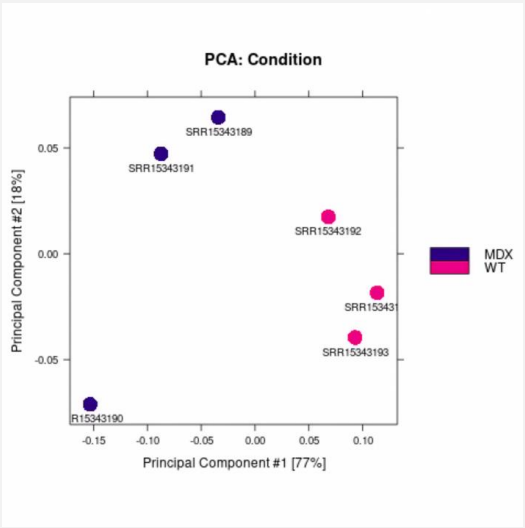
- Identificar zonas diferencialmente accesibles entre condiciones, fenotipos, tipos celulares…
- Dar un significado funcional a las regiones diferencialmente accesibles (anotación de genes próximos, tipo de región en el genoma, …).

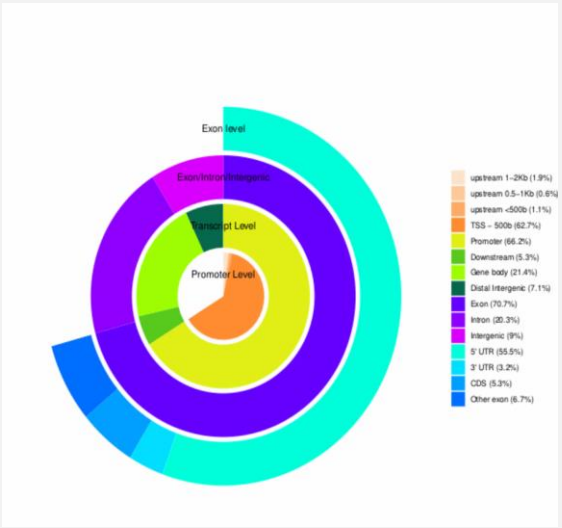


7. Regiones diferencialmente accesibles (DAR)

```
# Análisis diferencial
Rscript --vanilla diffbind_deseq.R \
    -d diffbind.config \
    -l 0.5 \
    -g Mus_musculus.GRCm39.107.chr.gtf \
    -r WT
```







8. Anotación de DARs (HOMER)



HOMER (v5.1, 7-16-2024)

Software for motif discovery and next generation sequencing analysis

```
# Anota los picos al atributo genómico más cercano

annotatePeaks.pl DiffBind.res.MDX-WT.FDR.05.tsv \
    ../reference/mm39_107.fa \
    -gid \
    -gtf ../reference/Mus_musculus.GRCm39.107.chr.gtf \
    -cpu 6 > DARs_MDX-WT_annotated.bed
```

9. Búsqueda de motivos (HOMER)

```
# Selecciona las DARs en promotores
grep promoter-TSS DARs_MDX-WT_annotated.bed > DARs_MDX-WT_annotated_promoters.bed

# Encuentra motivos enriquecidos en estas regiones
findMotifsGenome.pl DARs_MDX-WT_annotated_promoters.bed ../reference/mm39_107.fa
homer_motifs_PROMOTER_DARs -p 6 -mset vertebrates
```

9. Búsqueda de motivos (HOMER)

Non-redundant Motif File of Results
Known Motif Enrichment Results
Gene Ontology Enrichment Results
If Homer is having trouble matching a motif to a known motif, try copy/pasting the matrix file into STAMP
More information on motif finding results: HOMER | Description of Results | Tips
Total target sequences = 622
Total background sequences = 72952
* - possible false positive

Rank	Motif	P-value	log P-pvalue	% of Targets	% of Background	STD(Bg STD)	Best Match/Details	Motif File
1		1e-58	-1.351e+02	26.85%	6.18%	56.8bp (92.1bp)	NFY(CCAAT)/Promoter/Homer(0.958) More Information | Similar Motifs Found	motif file (matrix)
2		1e-53	-1.241e+02	41.80%	15.66%	54.5bp (110.3bp)	Sp2(Zf)/HEK293-Sp2.eGFP-ChIP-Seq(Encode)/Homer(0.940) More Information | Similar Motifs Found	motif file (matrix)
3		1e-22	-5.209e+01	10.29%	2.25%	55.9bp (111.4bp)	Nrf1/MA0506.3/Jaspar(0.938) More Information | Similar Motifs Found	motif file (matrix)
4		1e-20	-4.765e+01	17.68%	6.50%	52.2bp (106.8bp)	ETS(ETS)/Promoter/Homer(0.977) More Information | Similar Motifs Found	motif file (matrix)
5		1e-20	-4.613e+01	5.79%	0.74%	53.9bp (92.8bp)	GFY(?)/Promoter/Homer(0.817) More Information | Similar Motifs Found	motif file (matrix)
6		1e-18	-4.192e+01	1.13%	0.00%	58.4bp (29.5bp)	ZBED2(Zf)/SUIT2-ZBED2.HA-ChIP-Seq(GSE141606)/Homer(0.607) More Information | Similar Motifs Found	motif file (matrix)
7		1e-14	-3.408e+01	4.50%	0.63%	57.6bp (90.5bp)	Pbx3(Homeobox)/GM12878-PBX3-ChIP-Seq(GSE32465)/Homer(0.950) More Information | Similar Motifs Found	motif file (matrix)
8		1e-14	-3.336e+01	25.72%	13.83%	57.4bp (102.4bp)	OVOL2/MA1545.2/Jaspar(0.714) More Information | Similar Motifs Found	motif file (matrix)
9		1e-14	-3.233e+01	39.07%	25.03%	56.4bp (94.5bp)	BARHL1/MA0877.4/Jaspar(0.693) More Information | Similar Motifs Found	motif file (matrix)
10		1e-13	-3.209e+01	17.85%	8.22%	56.9bp (109.4bp)	ZBED1/MA0749.2/Jaspar(0.839) More Information | Similar Motifs Found	motif file (matrix)
11		1e-13	-3.095e+01	2.57%	0.17%	49.8bp (105.8bp)	ZNF263/MA0528.3/Jaspar(0.630) More Information | Similar Motifs Found	motif file (matrix)
12		1e-12	-2.980e+01	4.66%	0.81%	55.4bp (110.1bp)	YY1(Zf)/Promoter/Homer(0.917) More Information | Similar Motifs Found	motif file (matrix)

http://geneontology.org/ https://www.genome.jp/kegg/ https://reactome.org/

10. Análisis de rutas

Over-representation análisis (ORA)

Evalúa si ciertos conjuntos de genes (gene sets, ontologías, rutas) están sobrerrepresentados en tu lista comparado con un background de referencia (todas los genes posibles).

Input: lista de genes asociados a DARs (por ejemplo, genes cercanos a regiones accesibles diferencialmente).
Output: listado de ontologías o rutas enriquecidas, sin considerar dirección o magnitud de cambio.

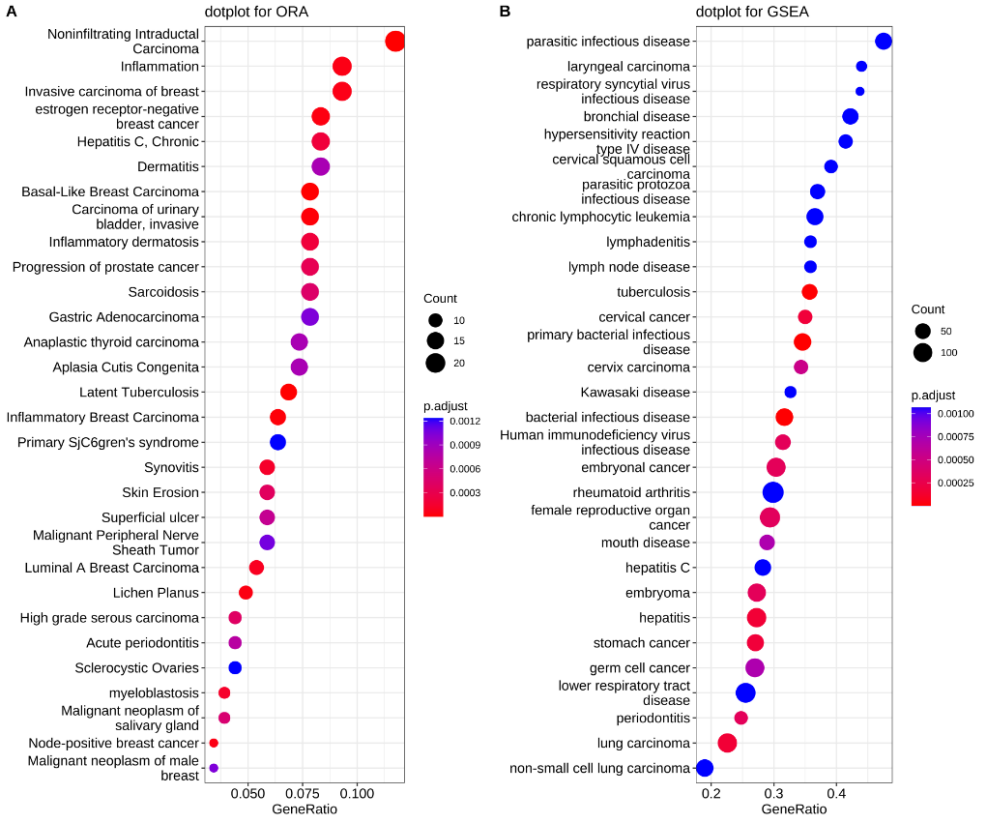
Gene set enrichment análisis (GSEA)

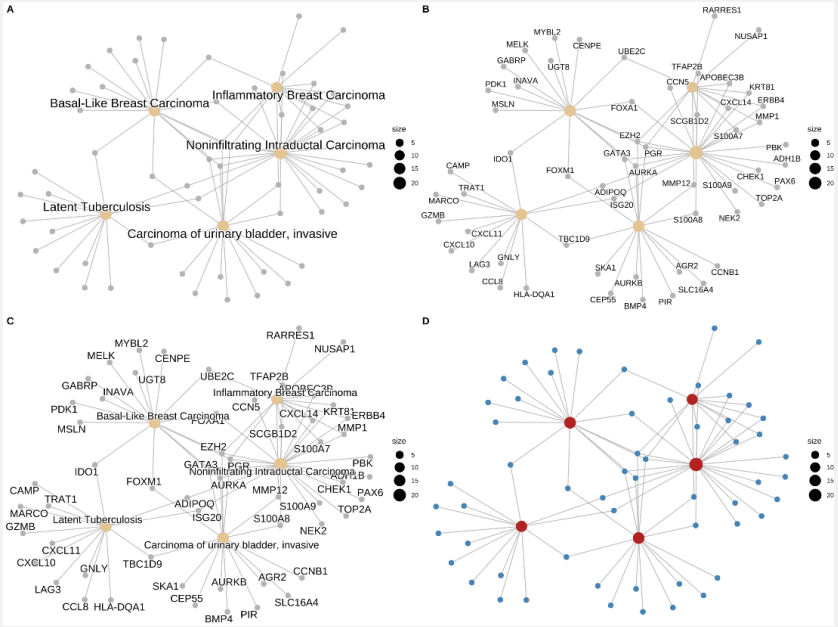
Ordena todos los genes por su magnitud de cambio y evalúa si los genes de un conjunto específico tienden a aparecer al inicio o al final de la lista.

Input: lista de genes asociados a DARs con valores cuantitativos (p. ej., log2 fold change de accesibilidad o expresión).
Output: listado de rutas o ontologías enriquecidas en genes up- o down-regulados, considerando dirección y magnitud del cambio.

```
# GSEA usando términos GO como referencia
Rscript --vanilla gseaGO_analysis.R -i MDX_WT_DARs_FC_qval.tsv
-o org.Mm.eg.db -p MDX_vs_WT
```

10. Análisis de rutas







Gracias por su atención

¿Preguntas?

Nota I. Sintaxis en Bash

Muchas **instrucciones en Bash** se componen de:

- **Comando**: instrucción que quieres ejecutar.
- **Opciones**: modifican el comportamiento del comando.
- **Argumento**: objetos sobre los que el comando actúa.

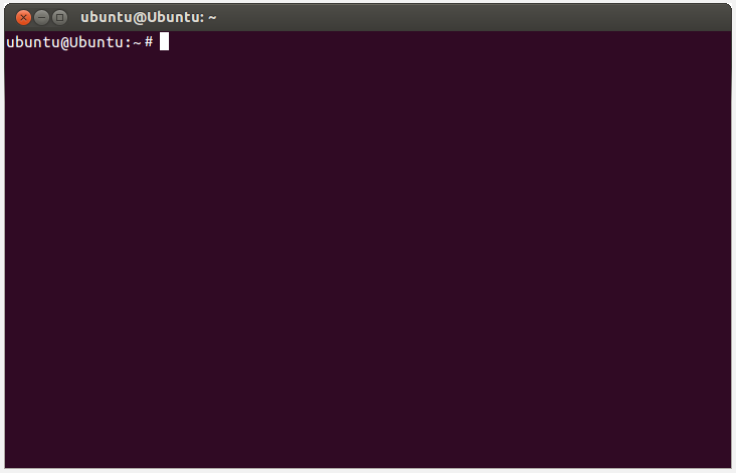
```
# Comentarios que no se ejecutan
comando --opciones (-o) argumentos
```

Ejemplo:

```
# Muestra las 10 primeras líneas de un fichero
head mi_texto.txt

# Muestra las 100 primeras líneas de un fichero
head --lines 100 mi_texto.txt

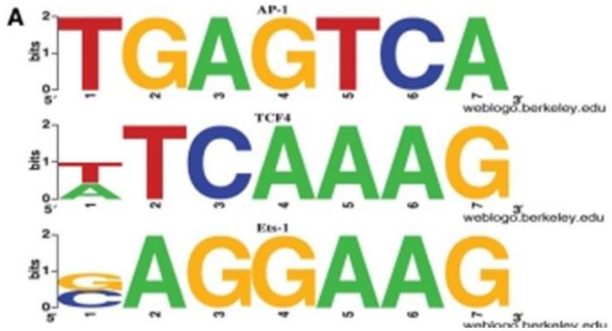
# Muestra las 100 primeras líneas de un fichero
head -n 100 mi_texto.txt
```



9. Búsqueda de motivos (HOMER)

ANÁLISIS DE MOTIVOS

- **Identificar el motivo** del pico.
- Si algún motivo/pico es conocido, sirve como **validación** del experimento.
- Si no es conocido, identificar un motivo en una fracción grande de los picos es indicativo de un **experimento exitoso.**



7. Regiones diferencialmente accesibles (DAR)

Output Diffbind_deseq.R

- Samples.csv: tabla resumen de las muestras incluidas en el análisis, las muestras sin picos se excluyen.
- En el script, db_obj significa diffbind object

Gráficos generados:
DiffBind.PCA.plot.peakcount.norm.png: PCA hecho con peak counts normalizadas.
DiffBind.PCA.plot.peakcount.png: PCA hecho con peak counts NO normalizadas.
DiffBind.PCA.plot.png: PCA hecho con posición o perfil de picos, no con intensidad (=counts por pico).
DiffBind.sample.correlation.peakcount.norm.png: correlación con cuentas normalizadas.
DiffBind.sample.correlation.peakcount.png: correlación con cuentas NO normalizadas.
DiffBind.sample.correlation.png: correlación con posición o perfil de picos, no con intensidad.
DiffBind.MDX-WT.MA.plot.png: MA plot, en lugar de representar la expresión media de cada gen en el eje X, se plotea algo proporcional al enriquecimiento. Con counts NO normalizadas.
DiffBind.MDX-WT_norm.MA.plot.png: similar al anterior pero con counts normalizadas (con método DESEQ)
DiffBind.MDX-WT.Volcano.plot.png: gráfico volcano.
DiffBind.MDX-WT.heatmapDiff_LFC.plot.pdf: heatmap con los valores de enriquecimiento para los picos diferenciales en KO y WT. Con cutoff de FC.
DiffBind.MDX-WT.heatmapDiff.plot.pdf: heatmap con los valores de enriquecimiento para los picos diferenciales en KO y WT. Sin cutoff de FC.