ANÁLISIS DE RNAseq

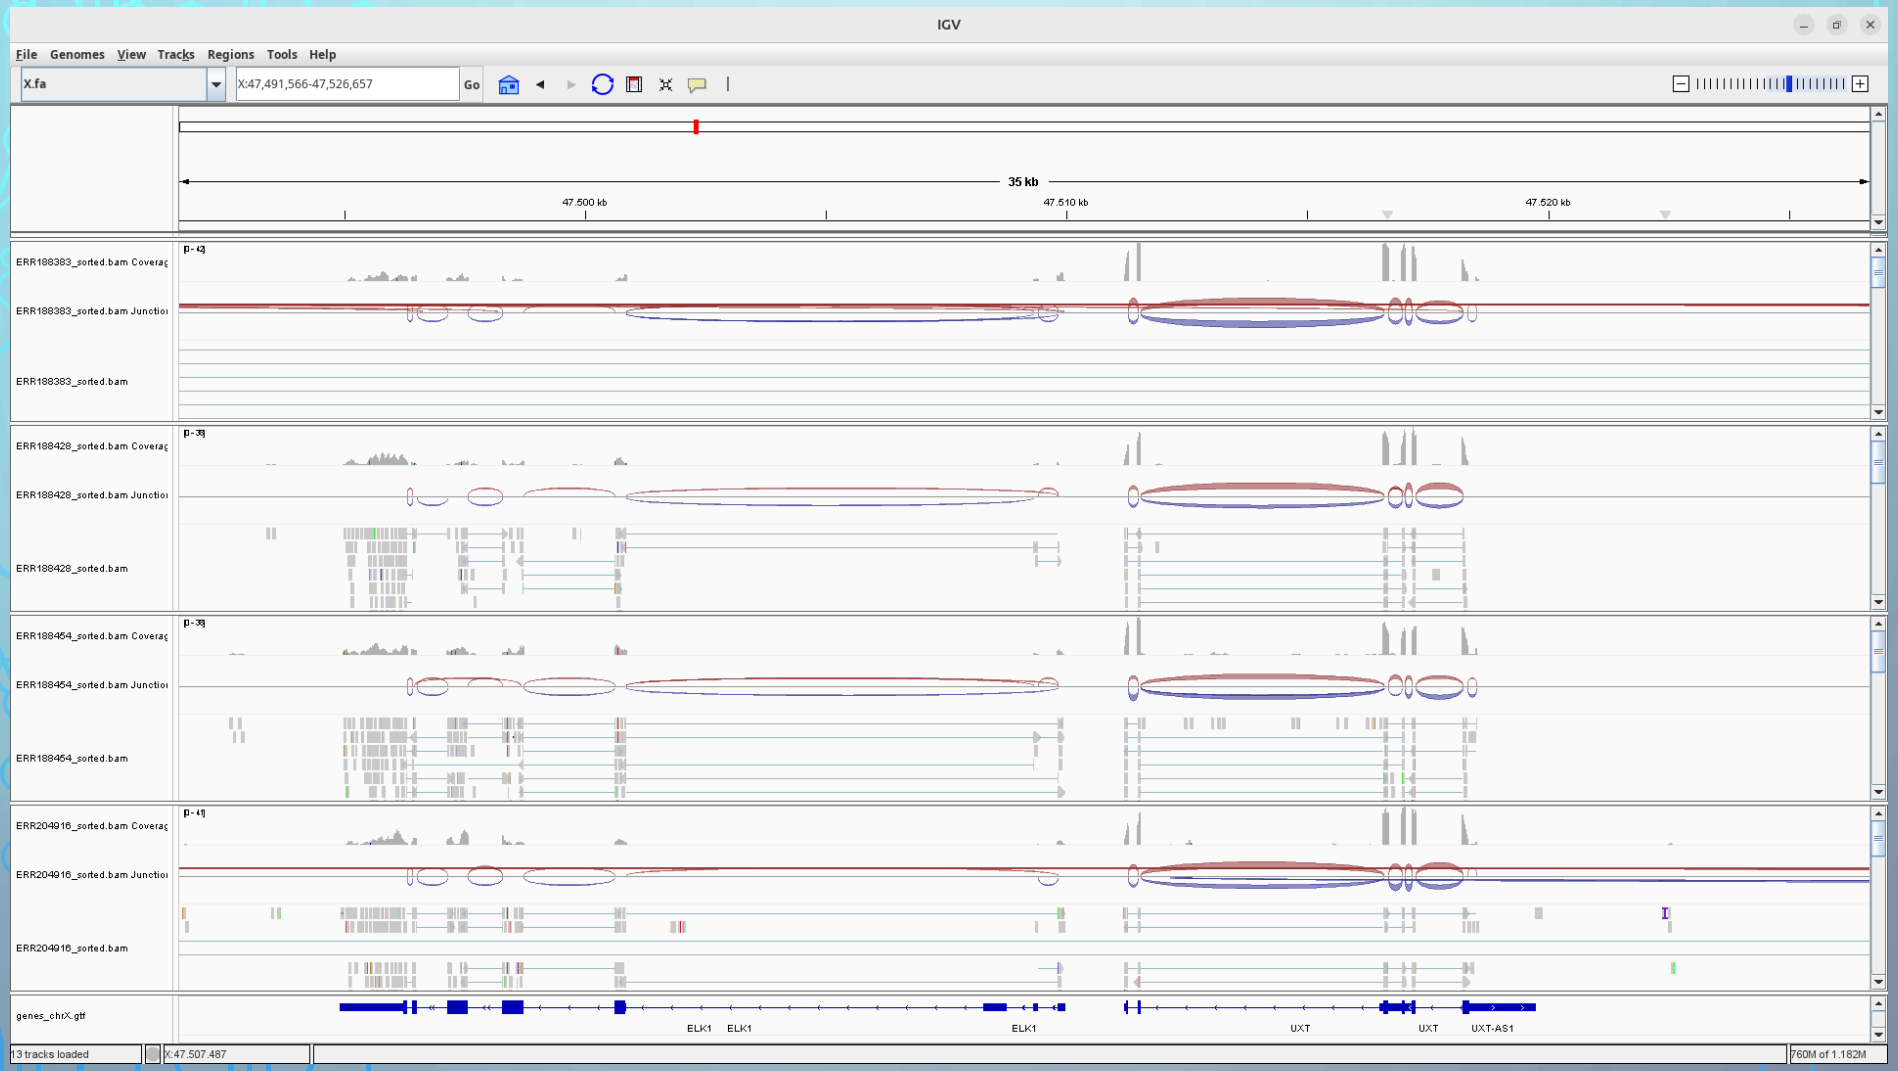
Curso ANÁLISIS DE DATOS DE NGS

(Gabinete de Formación del CSIC)

María Santos Galindo

Servicio de Análisis BIOcomputacional (SABio) - Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: imagen típica - IGV



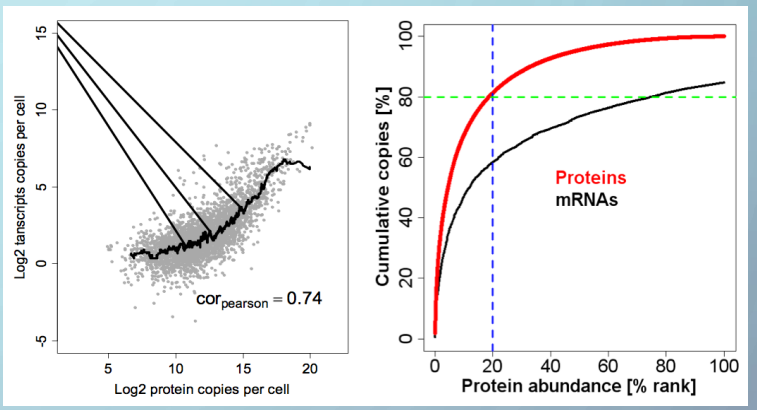
Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: ¿para qué sirve?

OBJETIVOS

- Cuantificar la abundancia de los tránscritos
- Cuantificar los cambios en los niveles de expresión de cada tránscrito entre condiciones
- Identificar la estructura transcripcional de los genes, como p.e. splicing alternativo
- Ensamblaje de transcriptomas
- miRNAs / siRNAs
- Detección de variantes a nivel de mensajero

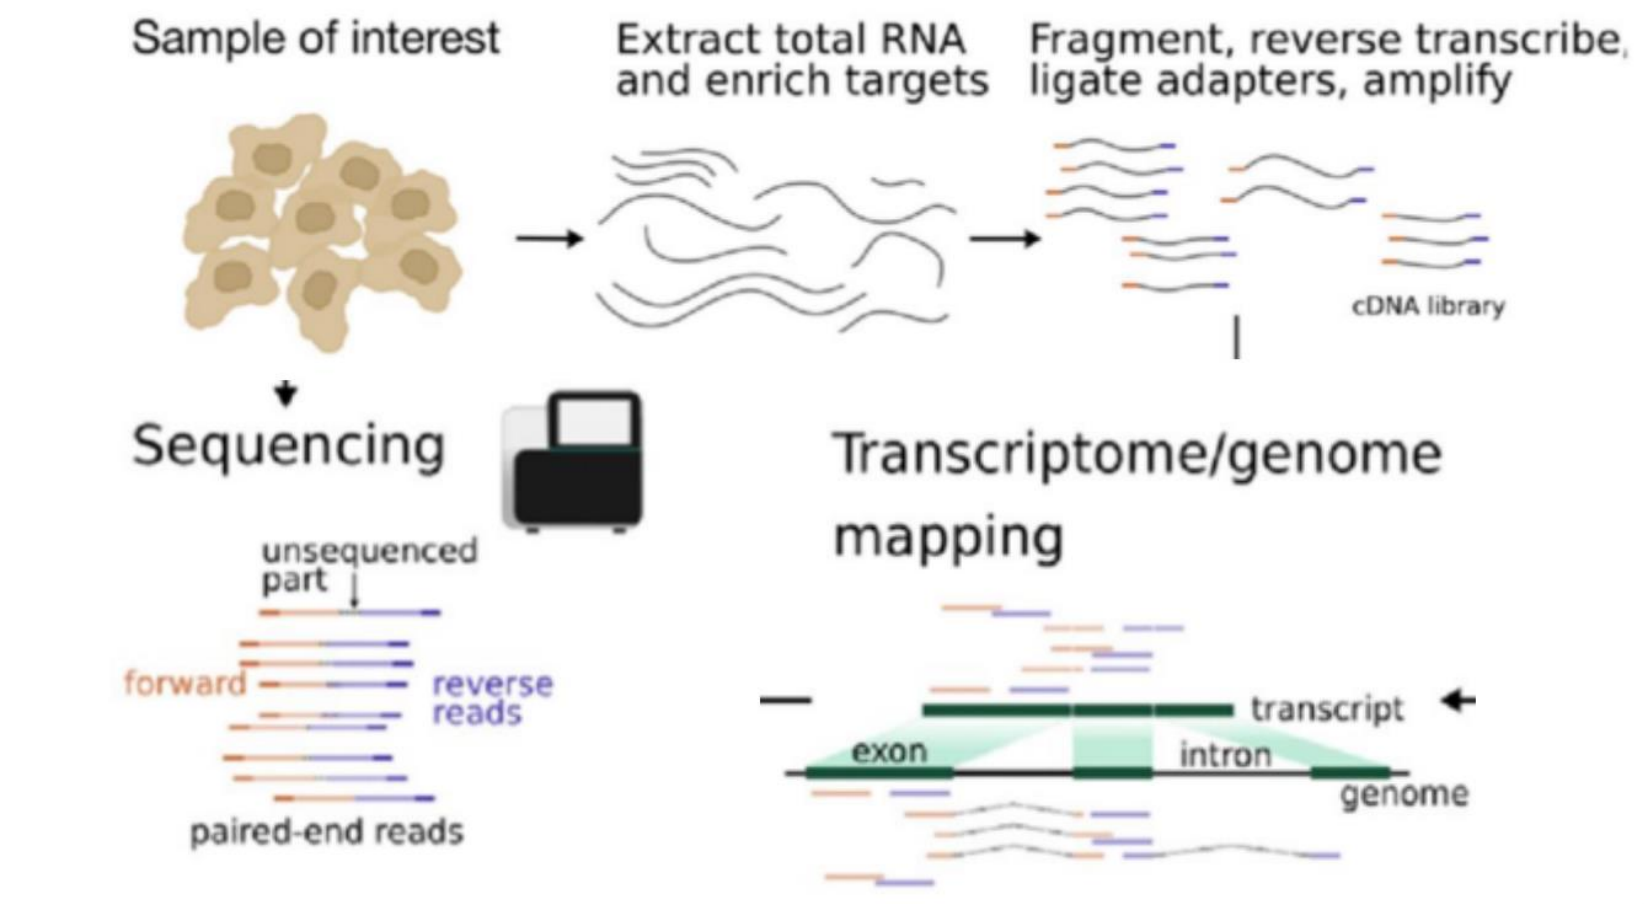
Asunción de partida: La cantidad de mRNA y de proteínas están bien correlacionadas.



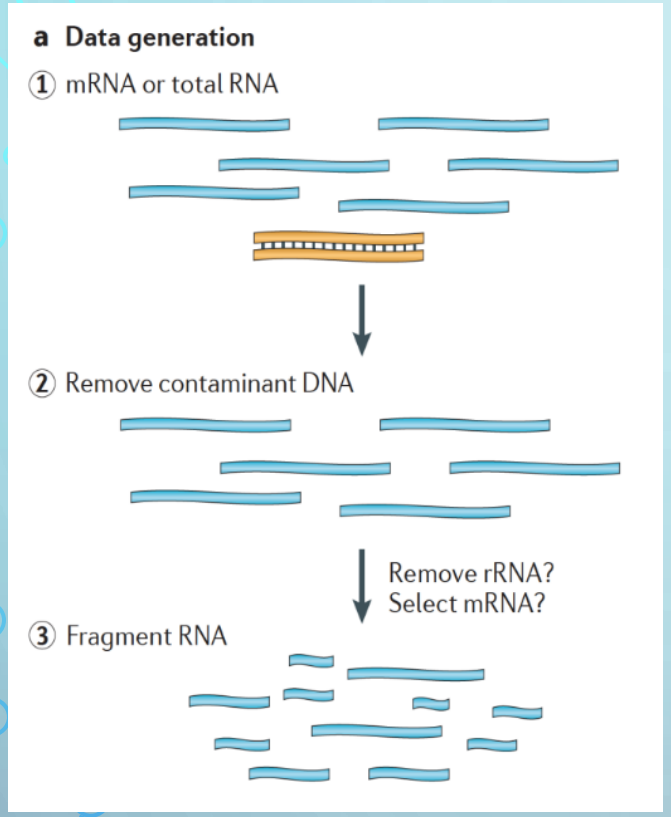
Bähler (2014) *6th Annual NGS Congress* London

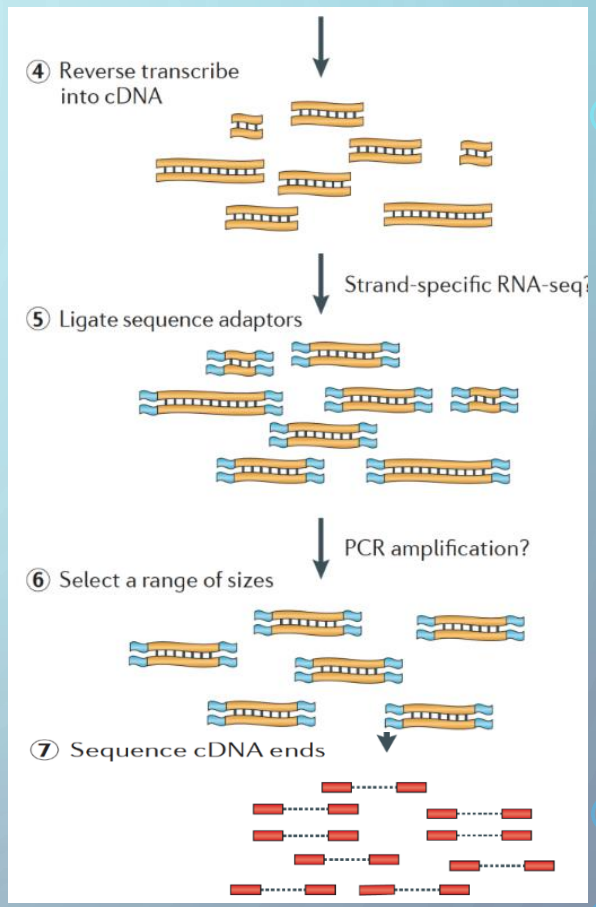
Servicio de Análisis BIOcomputacional (SABio)- Centro de Biologia Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: ¿cómo se hace?



RNAseq: ¿cómo se hace?





Martin J.A. and Wang Z., Nat. Rev. Genet. (2011) 12:671–682

RNAseq: diseño experimental

1.- **La pregunta biológica**

El OBJETIVO DEL EXPERIMENTO

- comparar condiciones
- búsqueda de isoformas
- análisis de splicing
- ensamblaje de transcriptoma
- reanotación de genomas

va a definir:

- profundidad
- tipo de biblioteca
- número de réplicas

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: diseño experimental

1.- **La pregunta biológica**

2.- **Réplicas biológicas**

Cuantas más mejor.
Mínimo **3**
RECOMENDADO 6

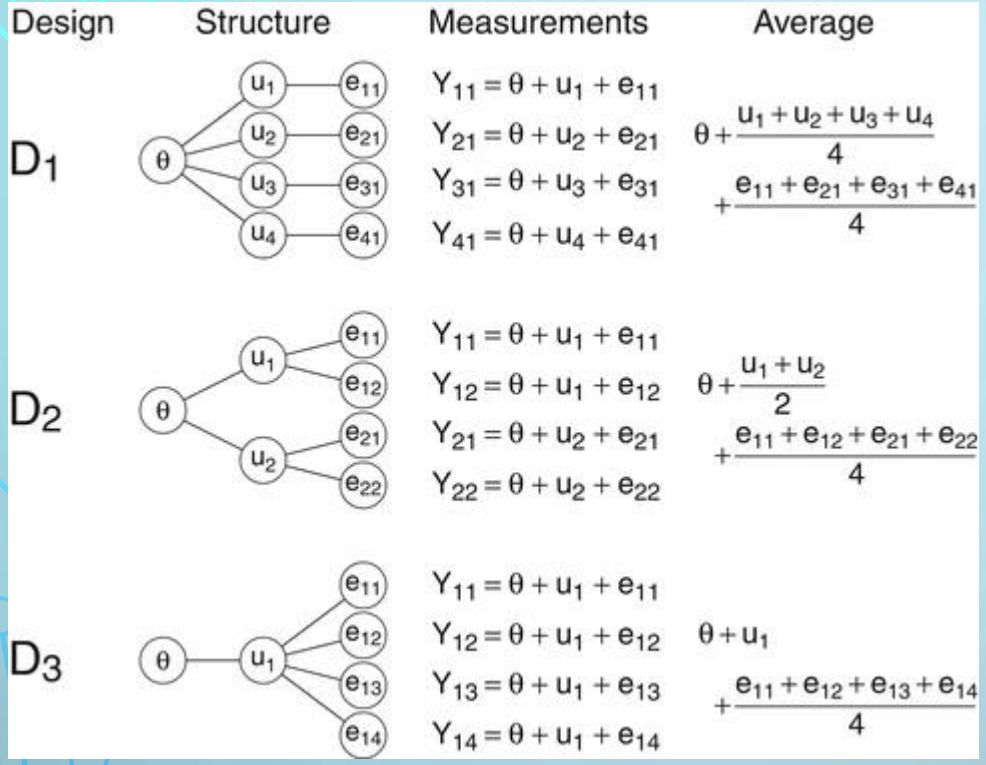
Factores a considerar:

• Variabilidad biológica **intragrupal** → magnitud de las diferencias que pretendemos encontrar y validar estadísticamente

• Variabilidad **técnica** del procedimiento de RNA-seq → importancia de la randomización)

• Potencia **estadística** → ¿qué porcentaje del total de expresiones diferenciales pretendemos detectar?

Réplicas



Varianza de la media:

- Diseño D1 → $\sigma_u^2/4 + \sigma_e^2/4$
- Diseño D2 → $\sigma_u^2/2 + \sigma_e^2/4$
- Diseño D3 → $\sigma_u^2 + \sigma_e^2/4$

"These results favor designs that **maximize biological replication at the sacrifice of reduced sequencing depth** per experimental unit"

Nettleton (2014) Design of RNA sequencing experiments DOI:10.1007/978-3-319-07212-8_5

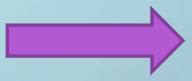
RNAseq: diseño experimental

1.- **La pregunta biológica**

2.- **Réplicas biológicas**

3.- **Controles y randomización**

- incluir controles positivos/negativos
- aleatorizar la preparación
- aleatorizar el orden de secuenciación



evitar batch effects

RNAseq: diseño experimental

1.- **La pregunta biológica**

2.- **Réplicas biológicas**

3.- **Controles y randomización**

4.- **Tipo de ARN**

→ Enriquecimiento de Poly(A) - Eucariotas

→ Depleción de rRNA - Procariotas
- Muestras degradadas

RNAseq: diseño experimental

1.- **La pregunta biológica**

2.- **Réplicas biológicas**

3.- **Controles y randomización**

4.- **Tipo de ARN**

5.- **Tipo de librería**

Stranded vs non-stranded:

STRANDED recomendado (conserva información sobre sentido de la transcripción).

RNAseq: diseño experimental

1.- **La pregunta biológica**

2.- **Réplicas biológicas**

3.- **Controles y randomización**

4.- **Tipo de ARN**

5.- **Tipo de librería**

6.- **Longitud y profundidad**

Depende del objetivo del estudio:

→ **DEGs** ~10–30 millones de reads por muestra (single-end 50–75 nt)
→ **Isoformas/splicing/fusiones:** ~30–100 millones (paired-end 75–150 nt) – o long reads!!
→ **Ensamblaje de transcriptoma:** long-reads

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: diseño experimental

1.- **La pregunta biológica**

2.- **Réplicas biológicas**

3.- **Controles y randomización**

4.- **Tipo de ARN**

5.- **Tipo de librería**

6.- **Longitud y profundidad**

7.- **Calidad de muestra**

- **Pureza** (ratios 260/280 y 260/230) > 1,8 y 2,0
- **RIN** >= 7 ideal

RNAseq: diseño experimental

1.- **La pregunta biológica**

2.- **Réplicas biológicas**

3.- **Controles y randomización**

4.- **Tipo de ARN**

5.- **Tipo de librería**

6.- **Longitud y profundidad**

7.- **Calidad de muestra**

8.- **Metadatos**

Registrar toda la **información** posible:

- edad
- sexo
- lote
- fecha de extracción
- plataforma
- …

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: diseño experimental

1.- **La pregunta biológica**: comparar condiciones, búsqueda de isoformas, análisis de splicing.

2.- **Réplicas biológicas**: mínimo 3 por condición; ideal 4–6 para variabilidad natural y potencia estadística.

3.- **Controles y randomización**: incluir controles positivos/negativos si aplica; aleatorizar la preparación y el orden de secuenciación para evitar batch effects.

4.- **Tipo de ARN** a capturar: → Enriquecimiento dePoly(A)
→ Depleción de rRNA

5.- **Tipo de librería**: Stranded vs non-stranded: STRANDED recomendado (conserva información sobre sentido de la transcripción).

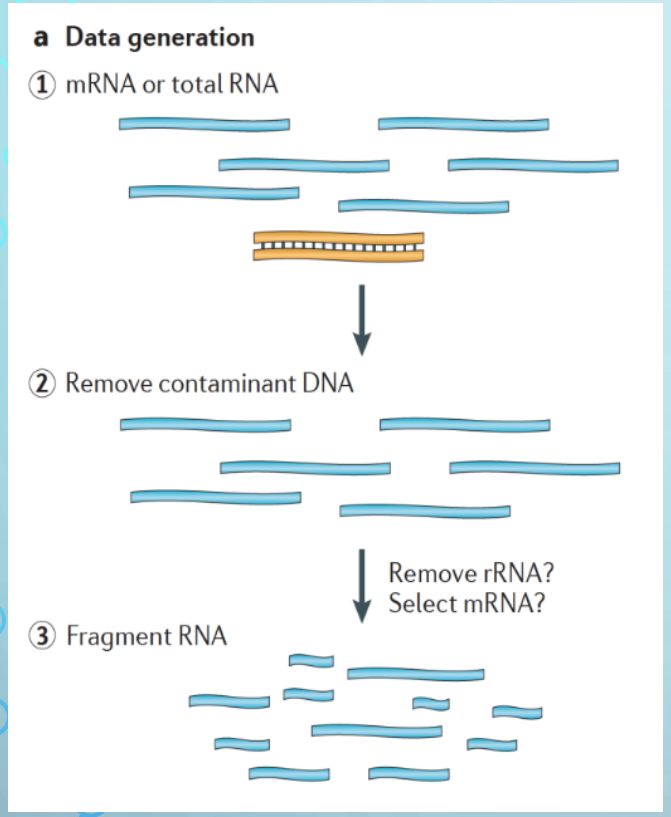
6.- **Longitud y profundidad**: → DEGs ~10–30 millones de reads por muestra (single-end 50–75 nt)
→ Isoformas/splicing/fusiones: ~30–100 millones (paired-end 75–150 nt)

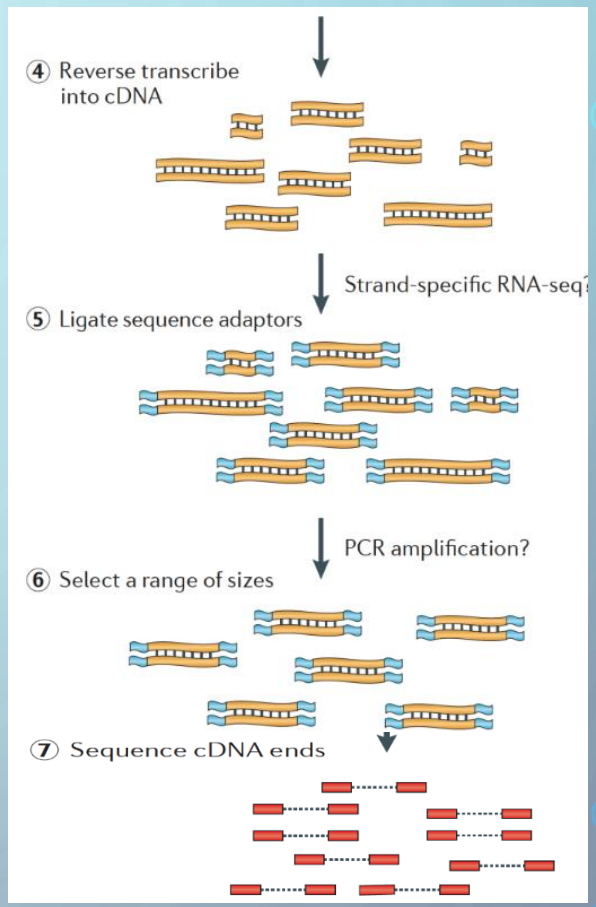
7.- **Calidad de muestra**: Pureza (ratios 260/280 y 260/230) > 1,8 y 2,0
RIN >= 7 ideal

8.- **Metadatos**: registrar edad, sexo, lote, fecha de extracción, plataforma, número de índice, etc.

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

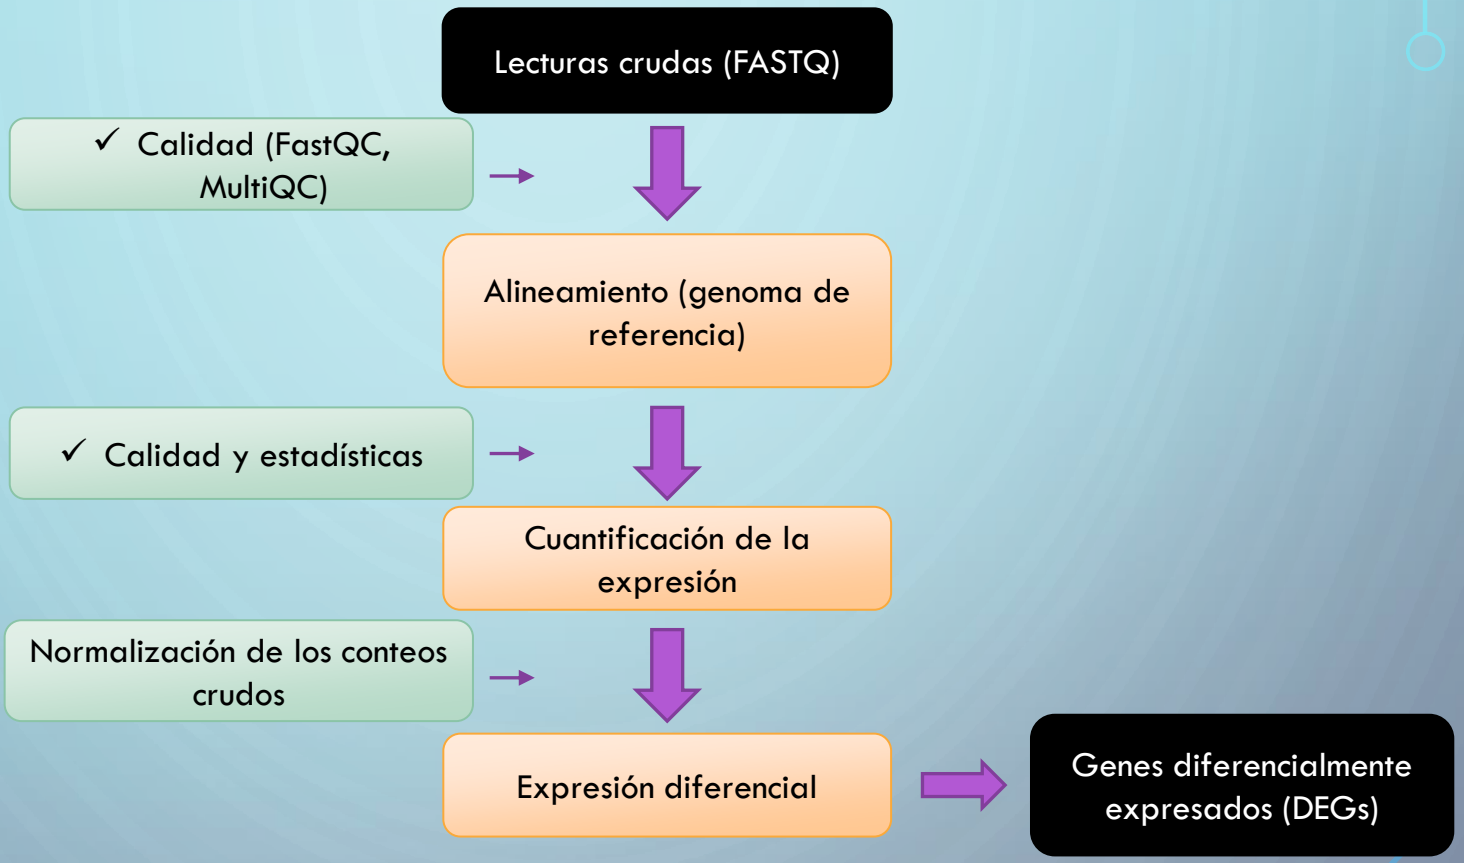
RNAseq: del RNA a las lecturas





Martin J.A. and Wang Z., Nat. Rev. Genet. (2011) 12:671–682

RNAseq: análisis bioinformático básico



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biologia Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (1). Descarga de secuencias

https://www.ebi.ac.uk/ena/browser/home

Estudio: **PRJNA998264**

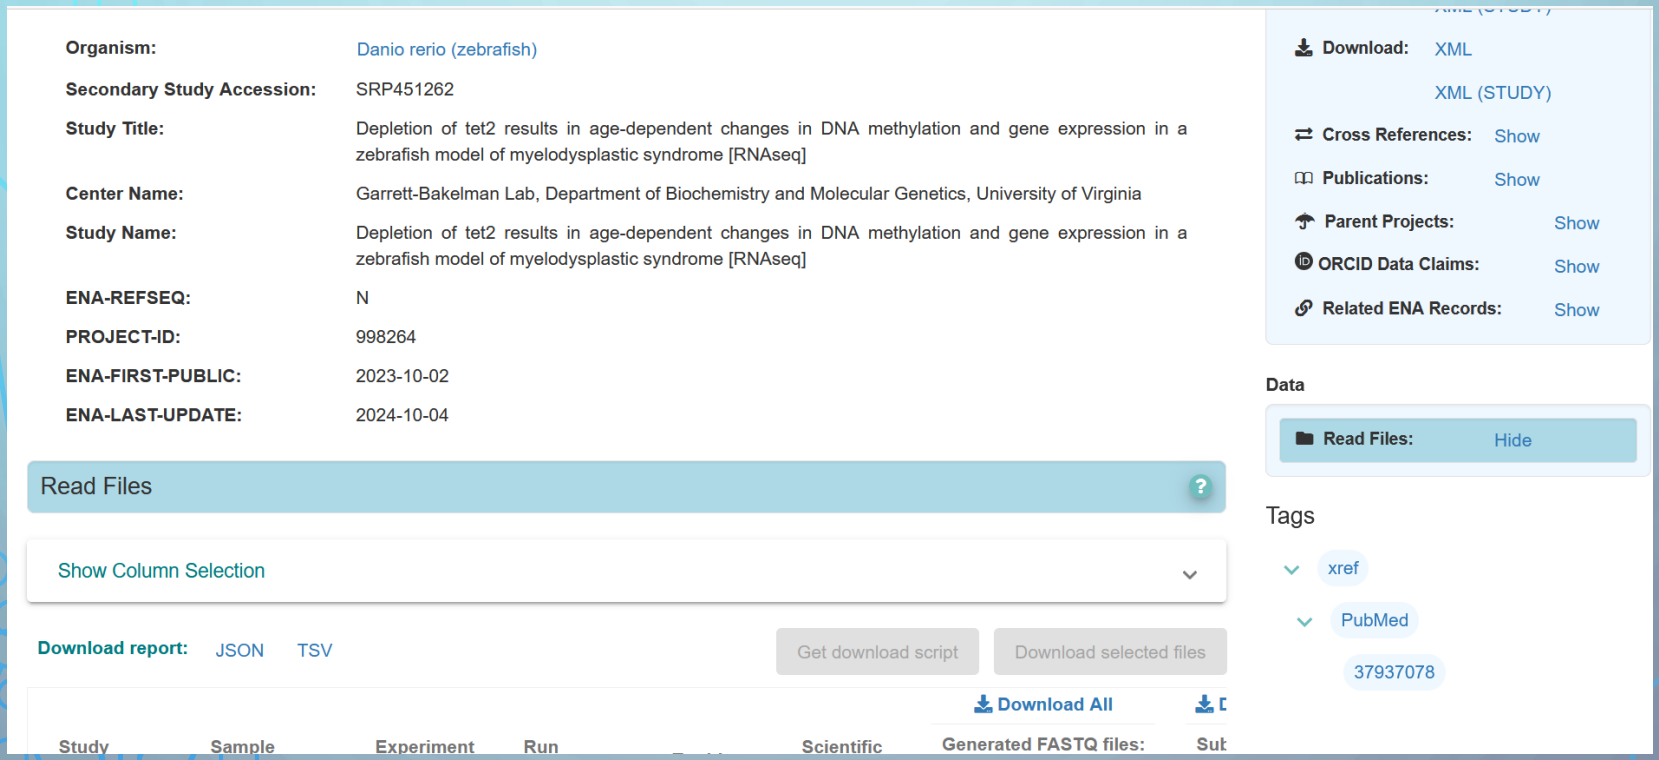


Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (1). Descarga de secuencias

https://www.ebi.ac.uk/ena/browser/home

Estudio: **PRJNA998264**



Organism:	Danio rerio (zebrafish)
Secondary Study Accession:	SRP451262
Study Title:	Depletion of tet2 results in age-dependent changes in DNA methylation and gene expression in a zebrafish model of myelodysplastic syndrome [RNAseq]
Center Name:	Garrett-Bakelman Lab, Department of Biochemistry and Molecular Genetics, University of Virginia
Study Name:	Depletion of tet2 results in age-dependent changes in DNA methylation and gene expression in a zebrafish model of myelodysplastic syndrome [RNAseq]
ENA-REFSEQ:	N
PROJECT-ID:	998264
ENA-FIRST-PUBLIC:	2023-10-02
ENA-LAST-UPDATE:	2024-10-04

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biologia Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (1). Descarga de secuencias



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biologia Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (1). Descarga de secuencias

https://www.ebi.ac.uk/ena/browser/home

Estudio: **PRJNA998264**

Experiment Accession	Run Accession	Scientific Name	Generated FASTQ files: FTP	Sample Title
SRX21146778	SRR25411167	Danio rerio	SRR25411167.fastq.gz	RNAseq_4month_tet2_wt_rep1
SRX21146777	SRR25411175	Danio rerio	SRR25411175.fastq.gz	RNAseq_4month_tet2_mut_rep2
SRX21146780	SRR25411155	Danio rerio	SRR25411155.fastq.gz	RNAseq_4month_tet2_wt_rep2
SRX21146779	SRR25411161	Danio rerio	SRR25411161.fastq.gz	RNAseq_4month_tet2_mut_rep1

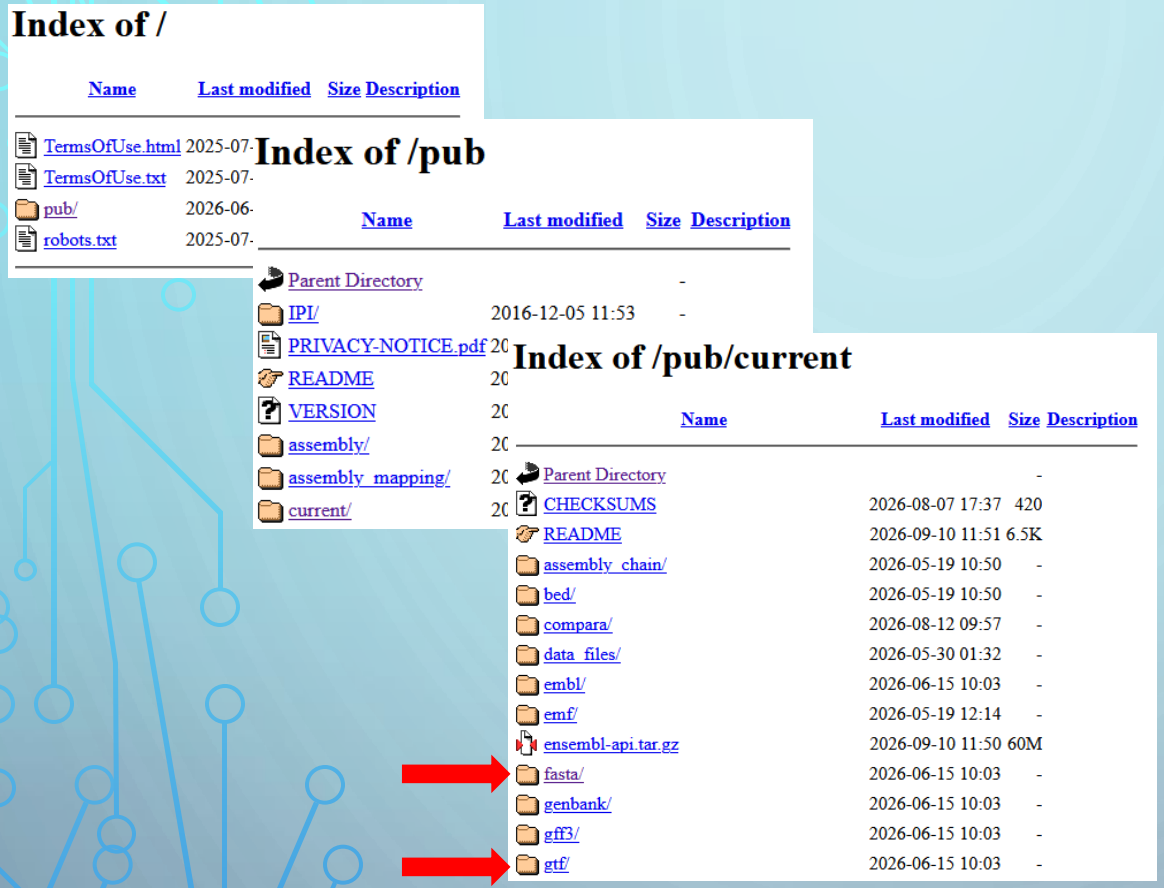
Controles:
SRR2541115**5**
SRR2541116**7**

Mutantes:
SRR2541116**1**
SRR2541117**5**

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (2). Descarga de la referencia

https://ftp.ensembl.org



Index of /

Name	Last modified	Size	Description
TermsOfUse.html	2025-07-		
TermsOfUse.txt	2025-07-		
pub/	2026-06-		
robots.txt	2025-07-		

Index of /pub

Name	Last modified	Size	Description
Parent Directory		-	
IPI/	2016-12-05 11:53	-	
PRIVACY-NOTICE.pdf	20		
README	20		
VERSION	20		
assembly/	20		
assembly_mapping/	20		
current/	20		

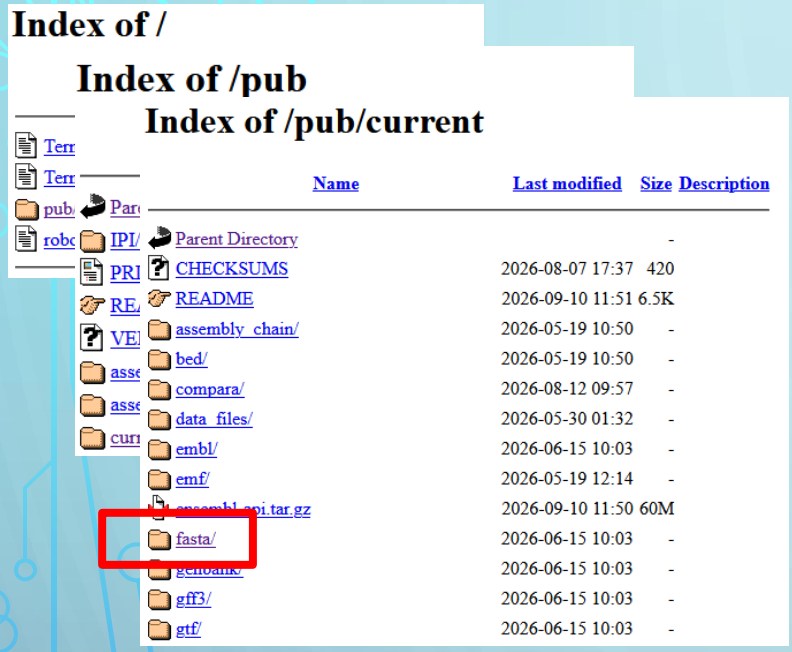
Index of /pub/current

Name	Last modified	Size	Description
Parent Directory		-	
CHECKSUMS	2026-08-07 17:37	420	
README	2026-09-10 11:51	6.5K	
assembly_chain/	2026-05-19 10:50	-	
bed/	2026-05-19 10:50	-	
compara/	2026-08-12 09:57	-	
data_files/	2026-05-30 01:32	-	
embl/	2026-06-15 10:03	-	
emf/	2026-05-19 12:14	-	
ensembl-api.tar.gz	2026-09-10 11:50	60M	
fasta/	2026-06-15 10:03	-	
genbank/	2026-06-15 10:03	-	
gff3/	2026-06-15 10:03	-	
gtf/	2026-06-15 10:03	-	

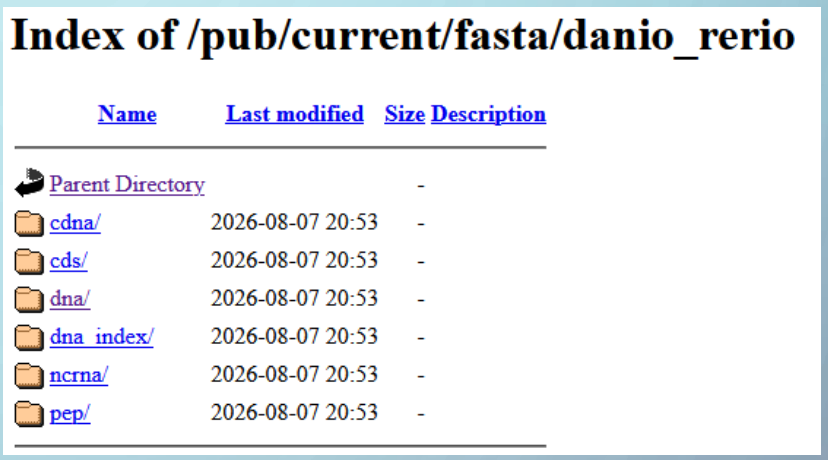
Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (2). Descarga de la referencia

https://ftp.ensembl.org





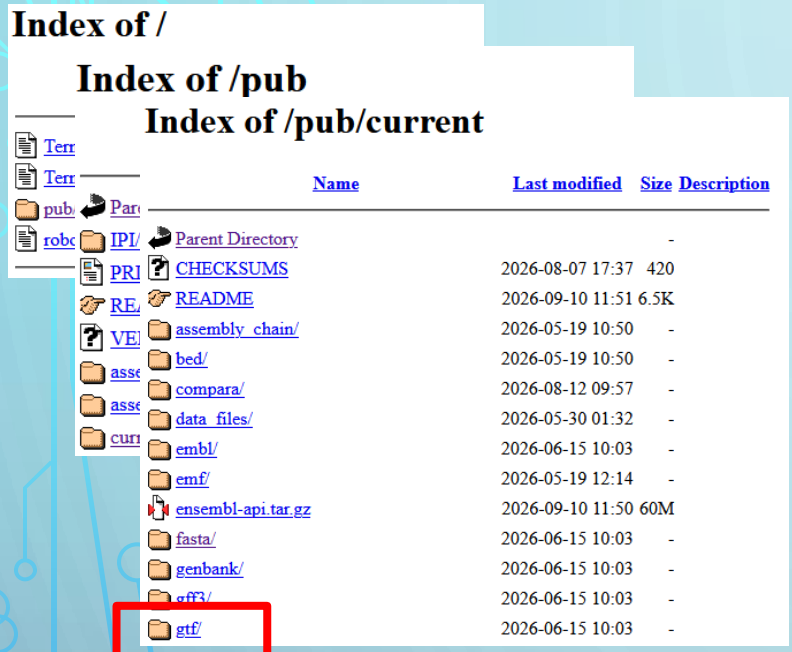





```
$ wget https://ftp.ensembl.org/pub/current/fasta/danio_rerio/dna/Danio_rerio.GRCz11.dna.primary_assembly.fa.gz
```

RNAseq: hands-on (2). Descarga de la referencia

https://ftp.ensembl.org

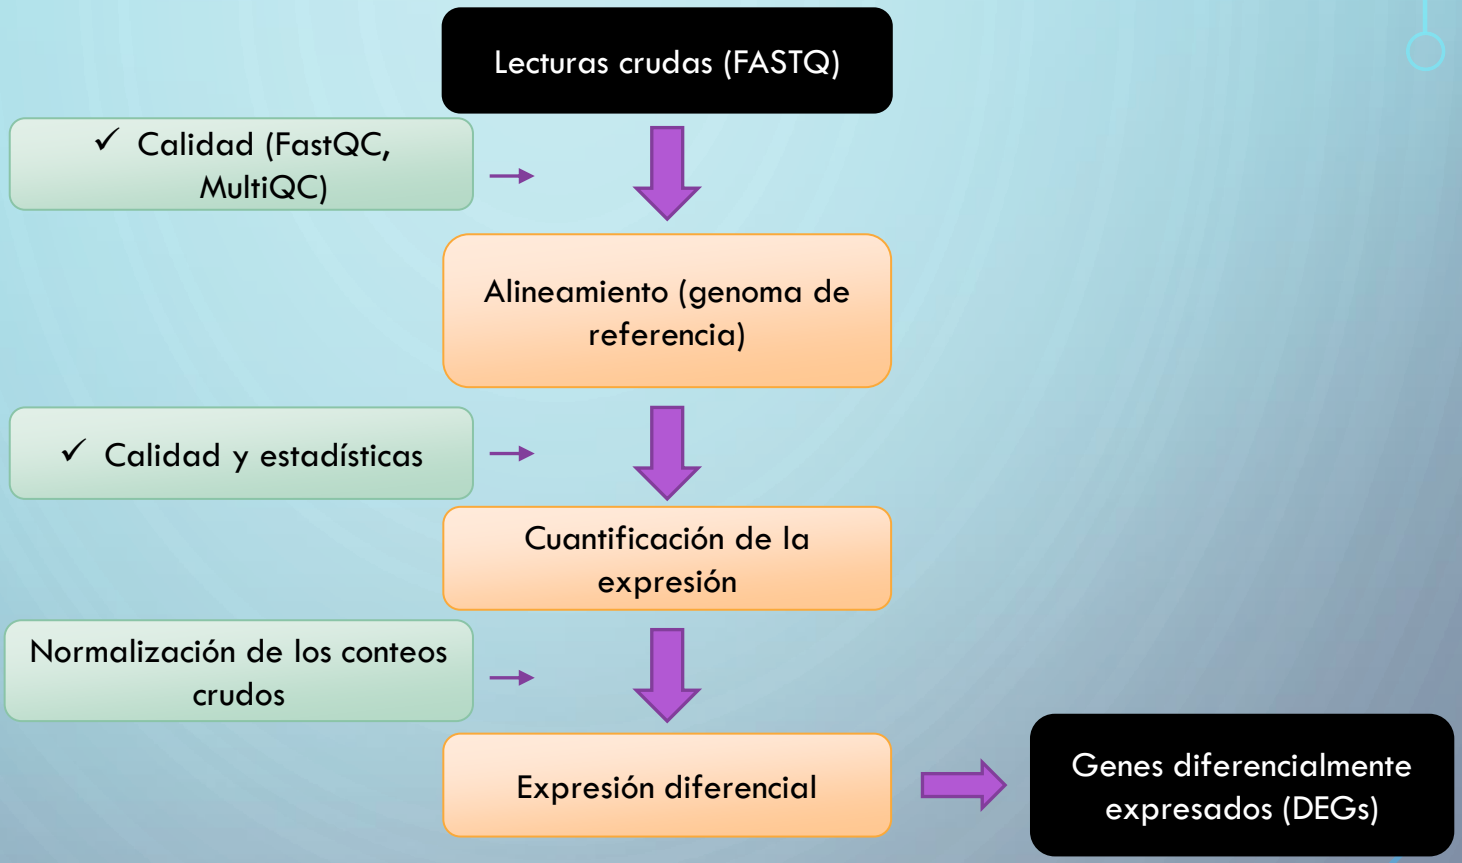






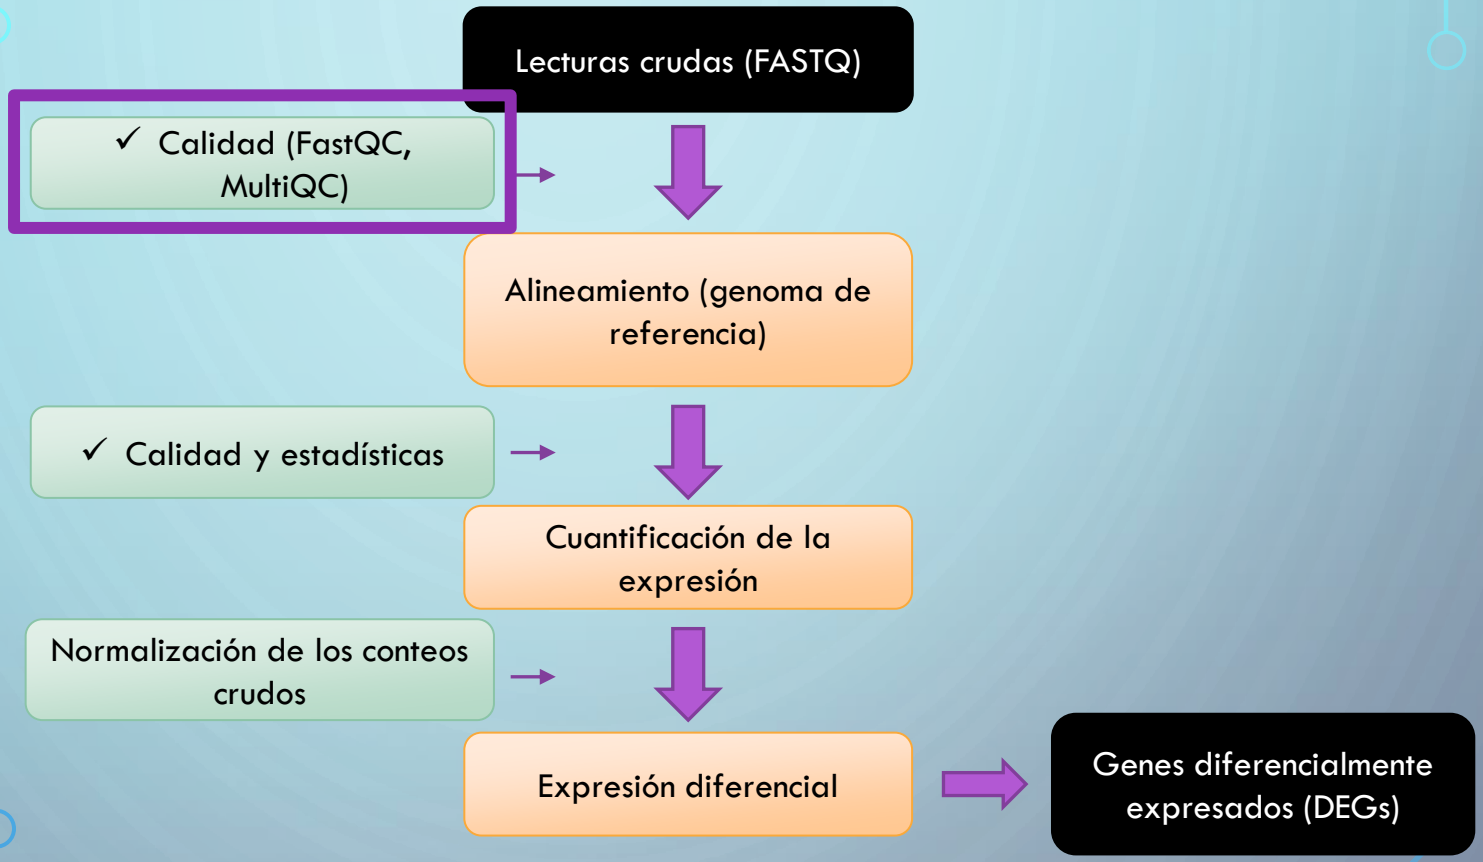

```
wget https://ftp.ensembl.org/pub/current/gtf/danio_rerio/Danio_rerio.GRCz11.116.gtf.gz
```

RNAseq: análisis bioinformático básico



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

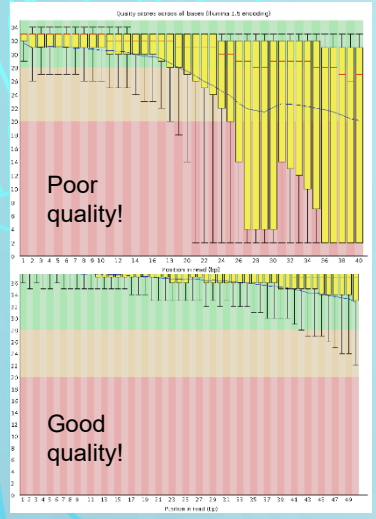
RNAseq: análisis bioinformático básico

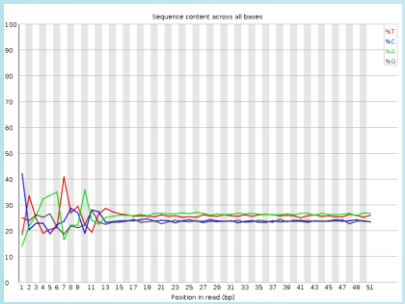


Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

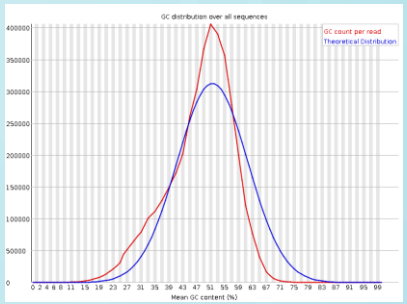
RNAseq: hands-on (3). Control de calidad

Programas : fastQC y multiQC

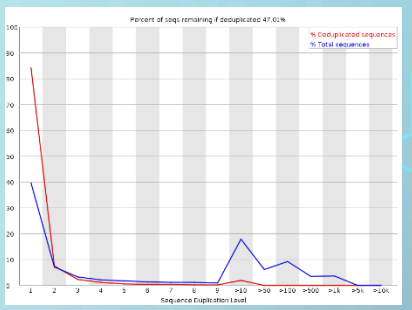




Per base sequence content

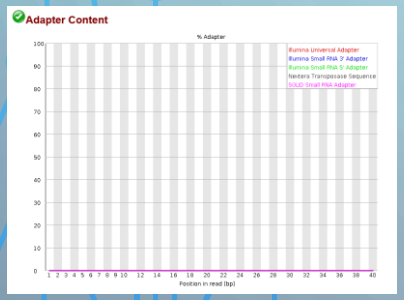


Per sequence GC content



Sequence Duplication Levels

- Sesgo inicial (bases 1–10): en RNA-seq es esperable debido a la transcripción inversa y primers aleatorios; no es motivo de alarma.
- GC content: considerar siempre la especie, puede desviarse de forma natural.
- Niveles de duplicación: la sobre-representación de genes muy expresados es biológica.

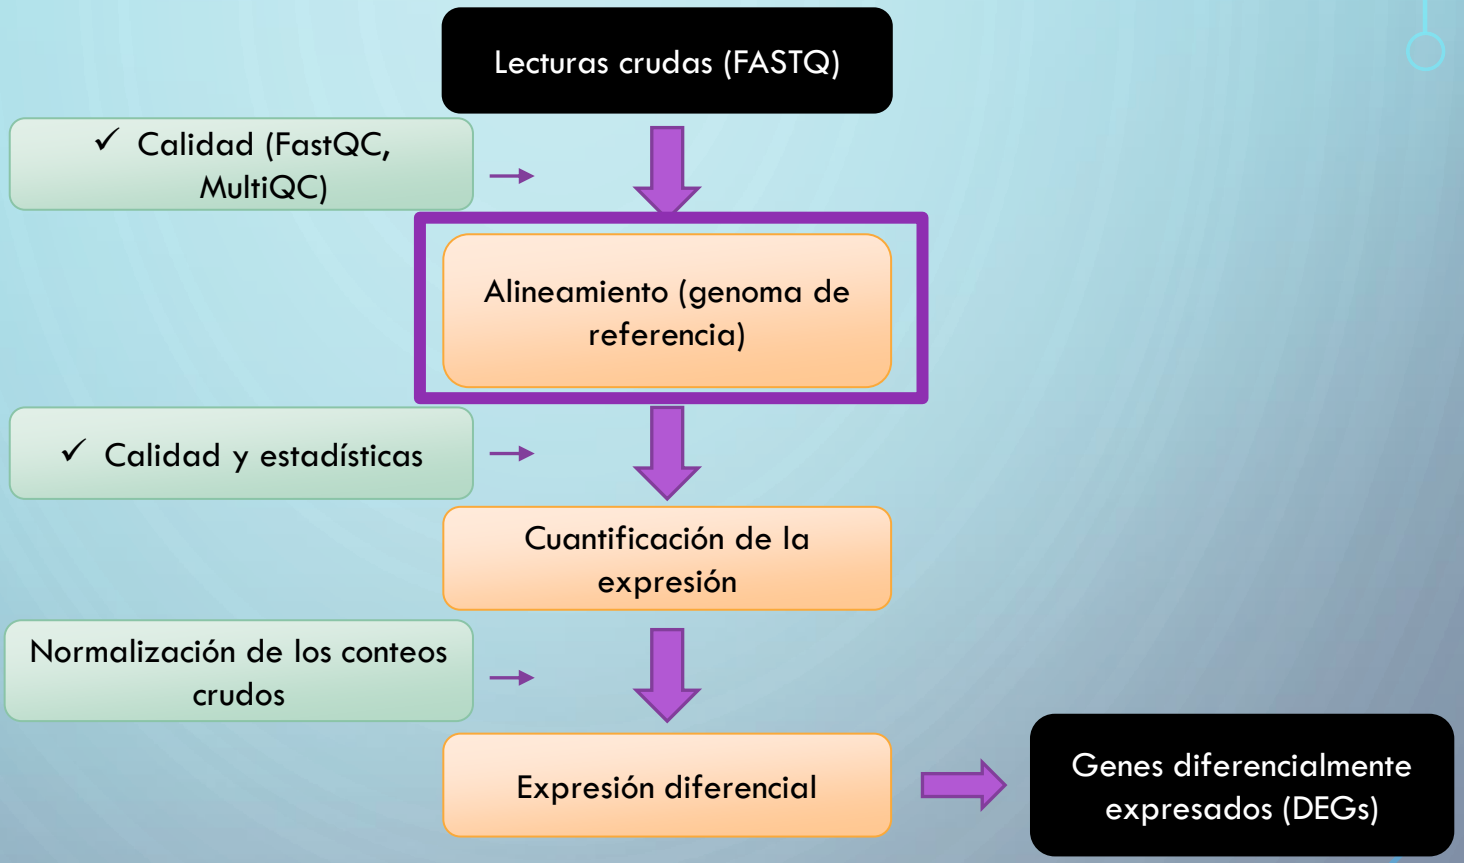


- REVISAR SIEMPRE CONTENIDO DE ADAPTADORES Y HACER TRIMMING SI CORRESPONDE.

```
$ fastqc *gz
$ multiqc ./
```

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

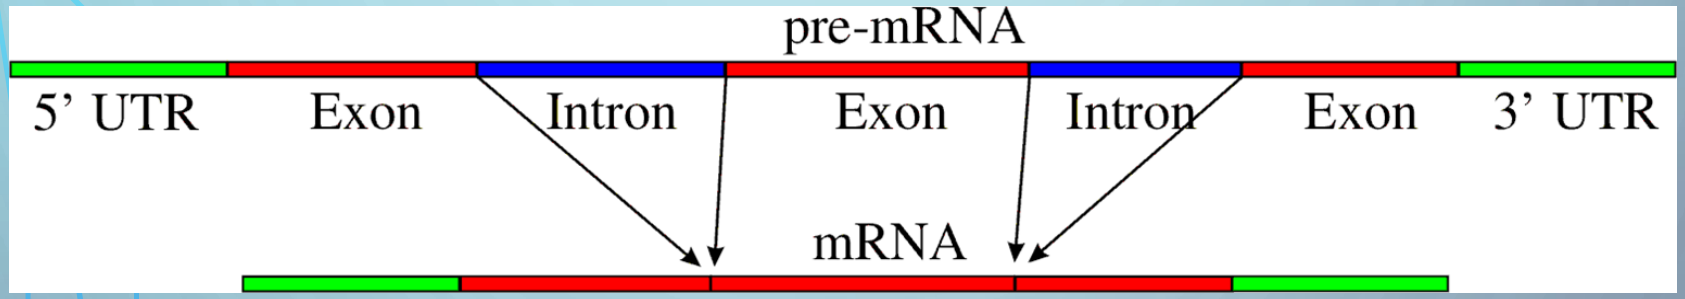
RNAseq: análisis bioinformático básico



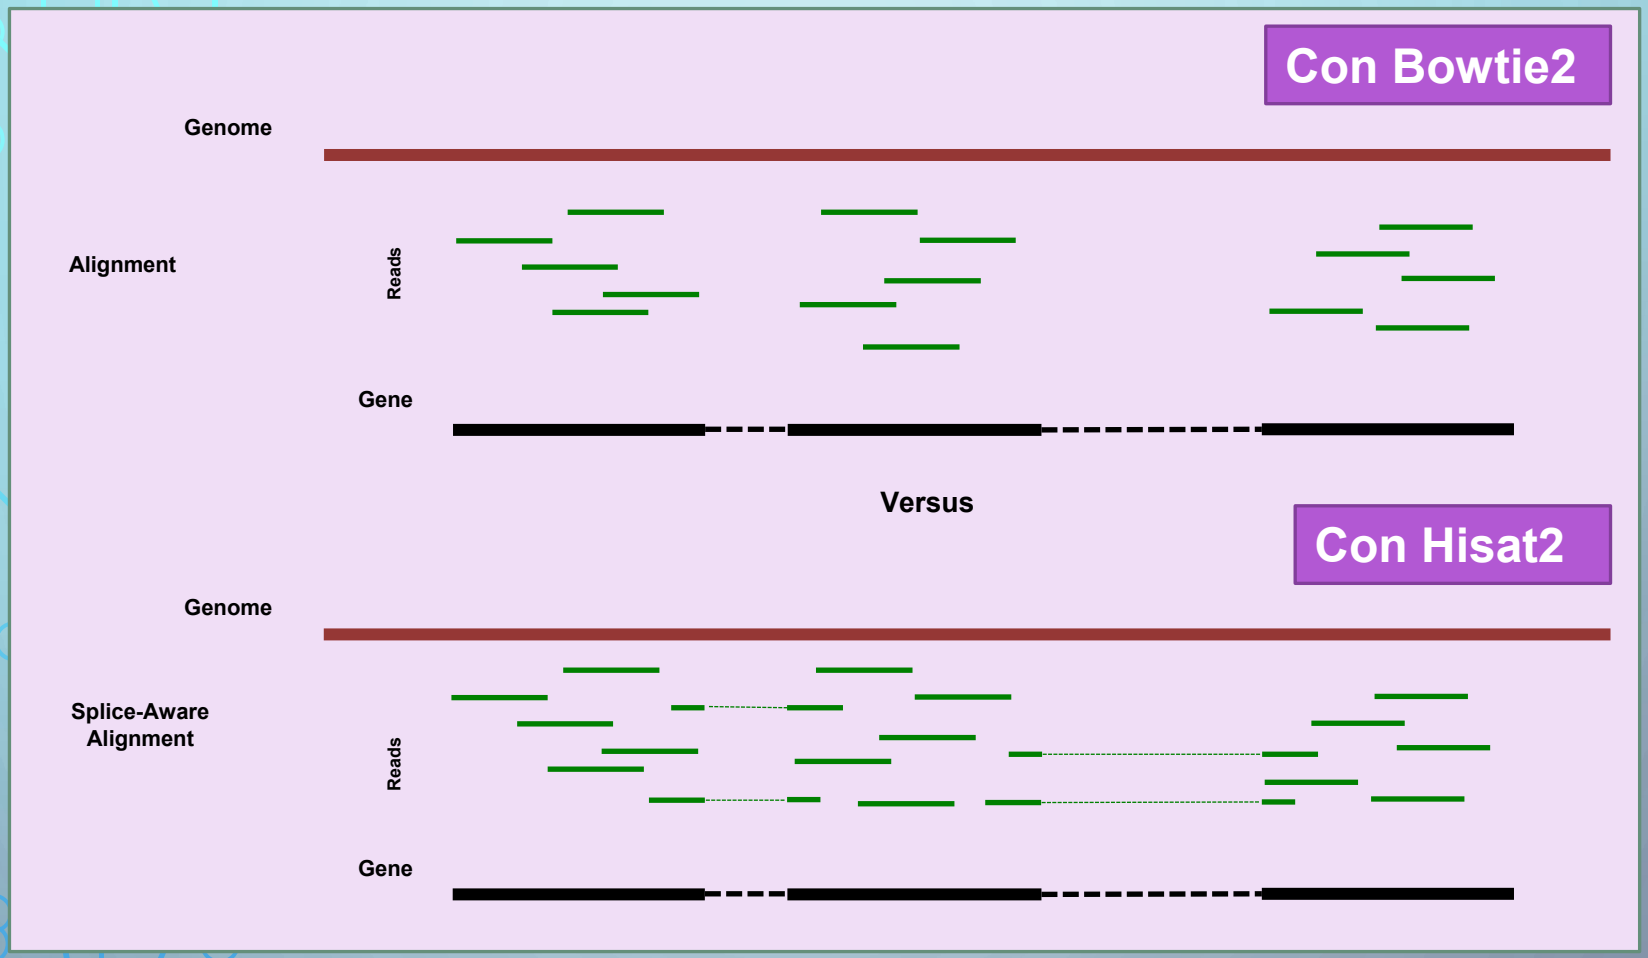
Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Alineamiento

- Vamos a alinear las secuencias contra el genoma de referencia del organismo de interés.
- En el **RNAseq,** hay que utilizar alineadores que permitan GAPS EN LAS LECTURAS, puesto que pueden contener información de diferentes exones



RNAseq: Alineamiento – splice aware



RNAseq: hands-on (4). Alineamiento

Alineador : Hisat2

Creamos un directorio, hacemos enlaces simbólicos a las lecturas y referencia (FASTA y GFF) y alineamos …. ***todo a la vez***

```
hisat2-build -p 8  Danio_rerio.GRCz11.dna.primary_assembly.fa Drerio

for sample in SRR25411155 SRR25411167 SRR25411161 SRR25411175
do
    hisat2 -x Drerio -q -k 1  -p 8 -U ../reads/${sample}.fastq.gz \
      -S ${sample}.sam 2> ${sample}_RF_summarymetrics.txt
    samtools view -S -b ${sample}.sam --threads 8 > ${sample}.bam
    samtools sort ${sample}.bam -o ${sample}_sorted.bam --threads 8
    samtools index ${sample}_sorted.bam
    rm -rf ${sample}.bam ${sample}.sam
done
```

RNAseq: hands-on (4). Alineamiento

Alineador : Hisat2

Creamos un directorio, hacemos enlaces simbólicos a las lecturas y referencia (FASTA y GFF) y alineamos …. ***todo a la vez***

```
vim samples.txt
i
55 67 61 75
Esc :wq

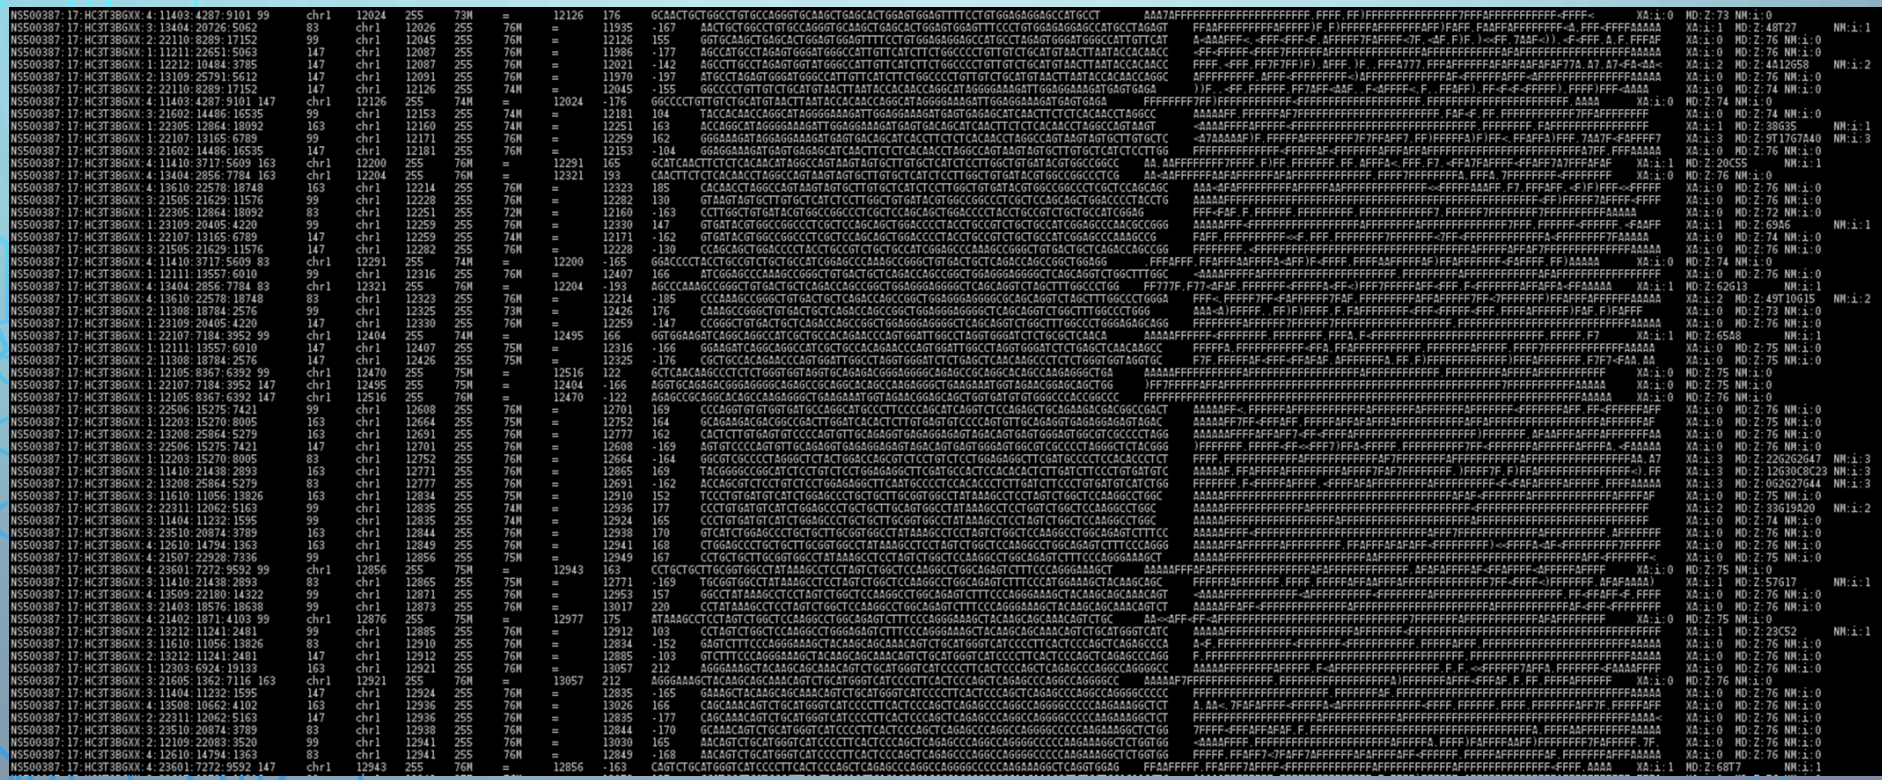
for sample in `cat samples.txt`
do
    hisat2 -x Drerio -q -k 1  -p 8 -U SRR254111${sample}.fastq.gz \
      -S ${sample}.sam 2> ${sample}_RF_summarymetrics.txt
    samtools view -S -b ${sample}.sam --threads 8 > ${sample}.bam
    samtools sort ${sample}.bam -o ${sample}_sorted.bam --threads 8
    samtools index ${sample}_sorted.bam
    rm -rf ${sample}.bam ${sample}.sam
done
```

RNAseq: Alineamiento – Repaso formatos

FORMATOS: SAM / BAM -> Sequence Alignment Format

Más información:

http://samtools.github.io/hts-specs/SAMv1.pdf
http://genome.sph.umich.edu/wiki/SAM



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Alineamiento – Repaso formatos

FORMATOS: SAM / BAM -> Sequence Alignment Format

Campo	Nombre	Descripción	Ejemplo
1	QNAME	**Identificador de la lectura**	`ERR459201.1`
2	FLAG	**"Estado" de la lectura (en código numérico).** Indica si la secuencia se alineó bien, si es una lectura emparejada (paired-end), o si es un duplicado. *(Ej: 16 significa que se alineó en la cadena inversa).*	`99`
3	RNAME	**Identificador de la referencia.** Especifica en qué cromosoma o secuencia de referencia alineó la lectura. `*`: no alineó.	`1`
4	POS	**Posición de inicio.**	`120450`
5	MAPQ	**Calidad del alineamiento.** Indicador de la fiabilidad del mapeo.	`60`
6	CIGAR	**Resumen del alineamiento.** El valor "CIGAR" es una fórmula que indica la coincidencia con la referencia. *(Ej: `50M` significa que 50 letras coinciden perfectamente; `4I` significa que se insertaron 4 letras).*	`150M`
7	RNEXT	**Referencia de la pareja.** En paired-end, indica en qué cromosoma la pareja. =, mismo cromosoma	`=`
8	PNEXT	**Posición de la pareja.**	`120650`
9	TLEN	**Tamaño total del fragmento.** La distancia desde el inicio de la primera lectura hasta el final de su pareja.	`350`
10	SEQ	**Secuencia** (`A`, `C`, `G`, `T`)	`ATCGGCTAAA...`
11	QUAL	**Calidad de la lectura.** Caracteres ASCII que representan la calidad de la lectura por nucleótido	`BFFFFAFFF...`

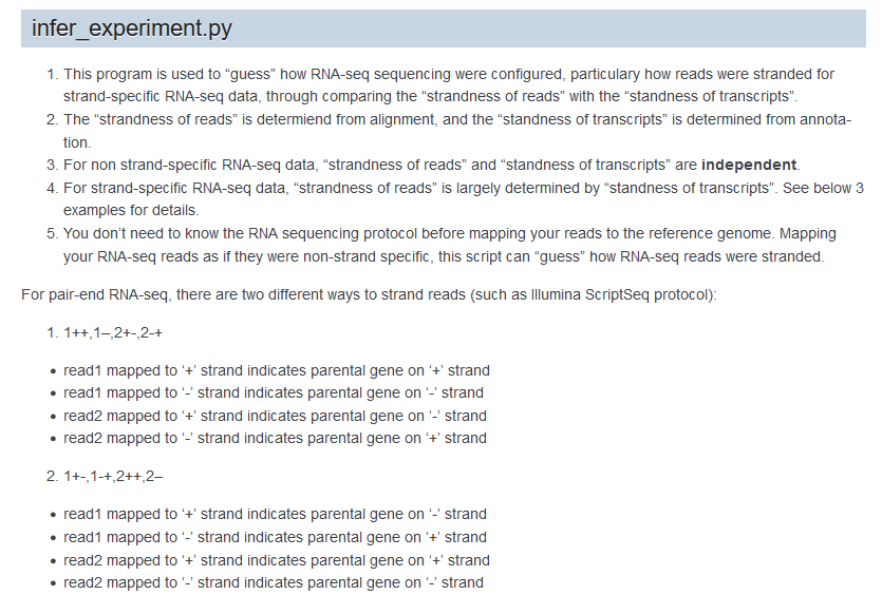
RNAseq: hands-on (5). Comprobar "strandness"

Script: RSeQC infer_experiment.py

https://rseqc.sourceforge.net/

```
gff2bed < Danio_rerio.GRCz11.112.gtf > Danio_rerio.GRCz11.112.bed

infer_experiment.py -r Danio_rerio.GRCz11.112.bed -i 55_sorted.bam
```



infer_experiment.py

1. This program is used to "guess" how RNA-seq sequencing were configured, particulary how reads were stranded for strand-specific RNA-seq data, through comparing the "strandness of reads" with the "standness of transcripts".
2. The "strandness of reads" is determiend from alignment, and the "standness of transcripts" is determined from annotation.
3. For non strand-specific RNA-seq data, "strandness of reads" and "standness of transcripts" are **independent**.
4. For strand-specific RNA-seq data, "strandness of reads" is largely determined by "standness of transcripts". See below 3 examples for details.
5. You don't need to know the RNA sequencing protocol before mapping your reads to the reference genome. Mapping your RNA-seq reads as if they were non-strand specific, this script can "guess" how RNA-seq reads were stranded.

For pair-end RNA-seq, there are two different ways to strand reads (such as Illumina ScriptSeq protocol):

1. 1++,1–,2+-,2-+

- read1 mapped to '+' strand indicates parental gene on '+' strand
- read1 mapped to '-' strand indicates parental gene on '-' strand
- read2 mapped to '+' strand indicates parental gene on '-' strand
- read2 mapped to '-' strand indicates parental gene on '+' strand

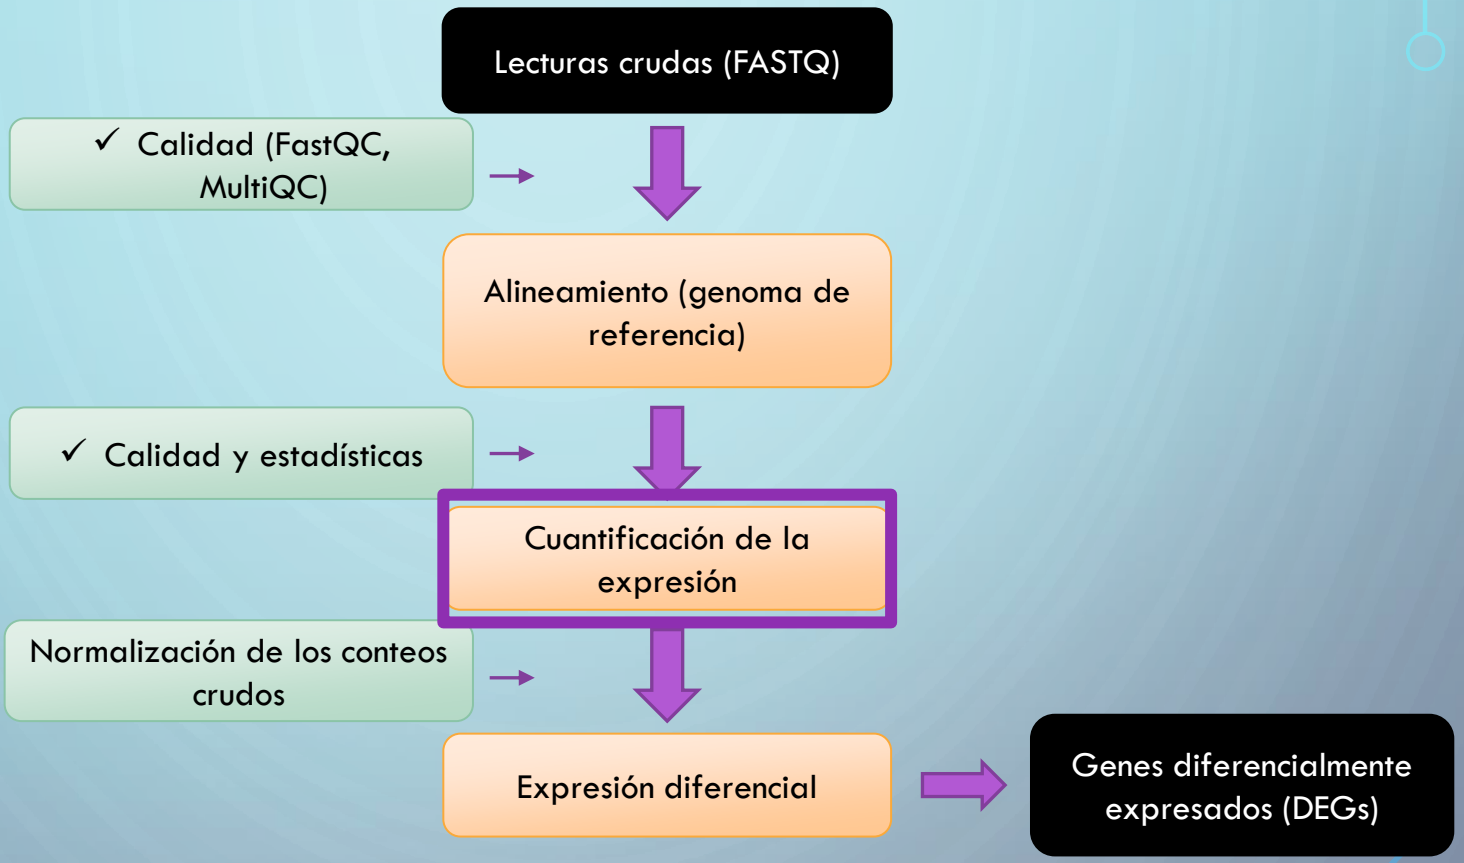
2. 1+-,1-+,2++,2–

- read1 mapped to '+' strand indicates parental gene on '-' strand
- read1 mapped to '-' strand indicates parental gene on '+' strand
- read2 mapped to '+' strand indicates parental gene on '+' strand
- read2 mapped to '-' strand indicates parental gene on '-' strand

Tipo de resultado	Qué significa	Tipo de librería
"1++,1--,2+-,2-+" ~1.0	Las lecturas están en la misma dirección que el gen anotado	fr-secondstrand reverse-stranded
"1+-,1-+,2++,2--" ~1.0	Las lecturas están en la dirección opuesta al gen anotado	fr-firststrand forward-stranded
Ambos ~0.5	Las lecturas no tienen orientación preferente	unstranded

This is SingleEnd Data
Fraction of reads failed to determine: 0.1738
Fraction of reads explained by "++,--": 0.4217
Fraction of reads explained by "+-,-+": 0.4045

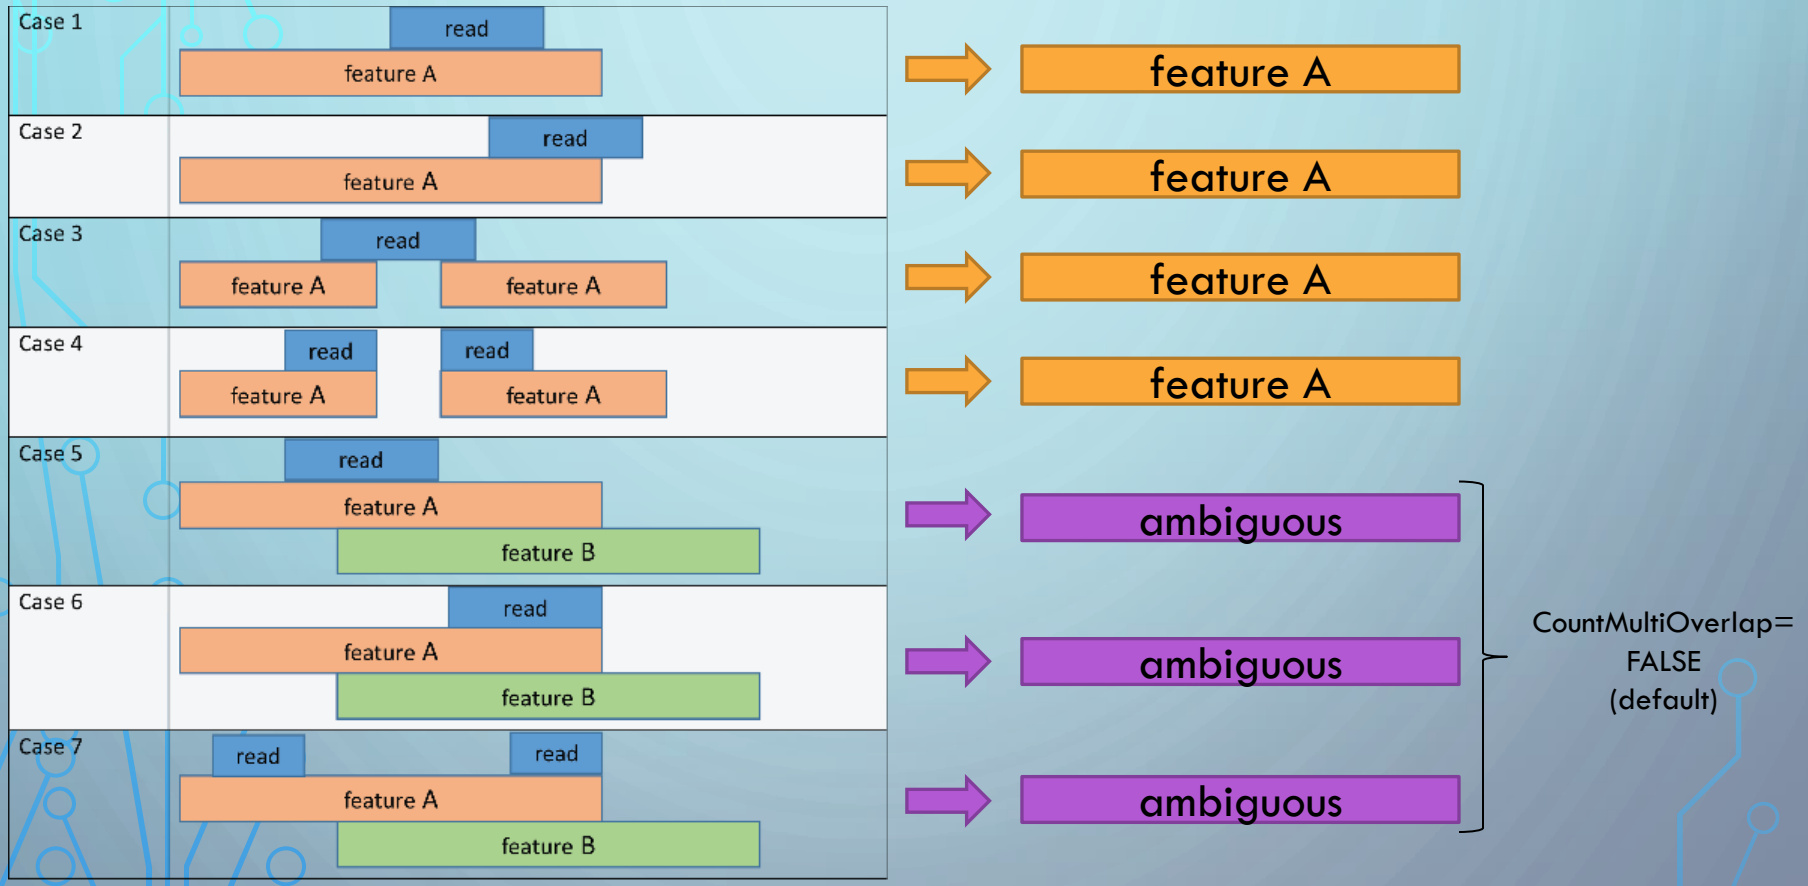
RNAseq: análisis bioinformático básico



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Cuantificación

- Vamos a contar las lecturas crudas que "caen" en cada uno de los genes anotados para nuestra referencia
- El método "por defecto" y que vamos a aplicar se denomina "parcial"



Bioinformatics. 2014 Apr 1;30(7):923-30.doi: 10.1093/bioinformatics/btt656.
https://www.mathworks.com/help/bioinfo/ref/featurecount.html

RNAseq: hands-on (6). Cuantificación

Programa : FeatureCounts

Tenemos que contar todas las lecturas que caen en cada gen en cada alineamiento con htseq-count. Creamos un directorio, nos situamos en el, y hacemos los enlaces simbólicos a lo que necesitamos (GFF y BAM ordenados) y contamos… **todo a la vez**

```
for sample in `cat samples.txt`
do
    featureCounts -T 8 -t exon -g gene_id \
        -a Danio_rerio.GRCz11.112.gtf \
        -o ${sample}_ftC.tsv ${sample}_sorted.bam
done
```

Utilizaremos los siguiente parámetros:

- `-t exon` → contará el número de lecturas en cada exón (feature = exon) contenido en el archivo de anotación
- `-g gene_id` → sumará el número lecturas en todos los exones de cada gene_id para estimar el número de cuentas crudas para ese gen.

RNAseq: hands-on (6). Cuantificación

Programa : FeatureCounts

El output incluye:

- Un archivo *.summary con las estadísticas del recuento
- un archivo .tsv que contiene información genómica y las CUENTAS CRUDAS (raw counts) para cada identificador contenido en el archivo de anotación para el tipo/atributo especificado (en este caso, exon/gene_id)

Status	55_sorted.bam
Assigned	3046149
Unassigned_Unmapped	447422
Unassigned_Read_Type	0
Unassigned_Singleton	0
Unassigned_MappingQuality	0
Unassigned_Chimera	0
Unassigned_FragmentLength	0
Unassigned_Duplicate	0
Unassigned_MultiMapping	0
Unassigned_Secondary	0
Unassigned_NonSplit	0
Unassigned_NoFeatures	286563
Unassigned_Overlapping_Length	0
Unassigned_Ambiguity	219866

Program:featureCounts v2.0.1; Command:"featureCounts" "-T" "5" "-t" "exon" "-g" "gene_id" "-a" "Danio_rerio.GRCz11.112.gtf" "-o" "55.tsv" "55_sorted.bam"

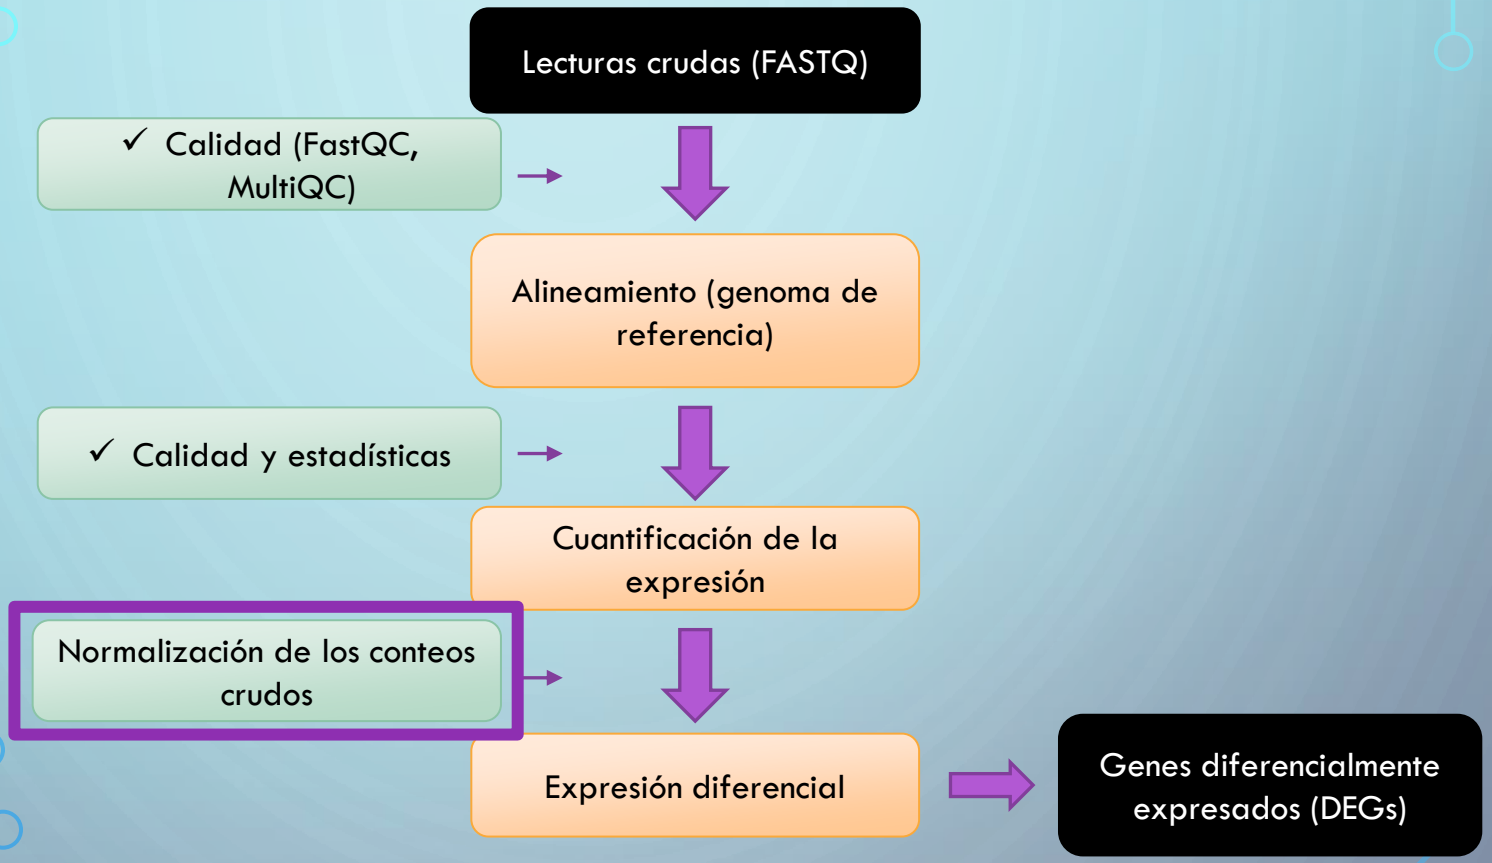
Geneid	Chr	Start	End	Strand	Length	55_sorted.bam
ENSDARG00000103202	4;4;4	30402837;30403203;30403546	30402893;30403350;30403763	+;+;+	423	0
ENSDARG00000009657	4;4;4;4;4;4;4	1722899;1722903;1725130;1725130;1726488;	1722927;1722927;1725266;1725794;1726605;	+;+;+;+;+;+;+	2014	156
ENSDARG00000096472	4;4	40758511;40758989	40758849;40759309	+;+	660	0
ENSDARG00000096156	4;4;4;4;4;4;4;4;4;4;4;4;4;4;4;4;4	11099041;11099358;11099580;11099761;1109	11099241;11099420;11099642;11099823;1110	-;-;-;-;-;-;-;-;-	3091	0
ENSDARG00000076160	4;4;4;4;4;4;4;4;4;4;4;4;4;4;4;4	40835393;40836022;40836371;40836639;4083	40835453;40836246;40836519;40836781;4083	+;+;+;+;+;+;+;+	2179	0
ENSDARG00000117163	4;4;4	30409750;30421584;30422235	30410604;30421733;30422325	-;-;-	1096	3
ENSDARG00000096187	4;4;4;4;4;4;4;4;4;4;4;4;4;4	11112580;11113374;11113556;11113850;1111	11112626;11113457;11113774;11114164;1111	-;-;-;-;-;-;-;-;-	3646	0
ENSDARG00000076014	4;4;4;4;4;4;4;4;4;4;4;4;4;4;4;4;4	8213063;8213156;8233142;8233142;8259644;	8213357;8213357;8233997;8233997;8260060;	+;+;+;+;+;+;+;+	4126	1
ENSDARG00000098876	4;4	30428468;30439967	30430293;30440116	-;-	1976	1
ENSDARG00000031930	4;4;4;4;4;4;4;4	8376362;8376362;8448404;8448404;8475206;	8376526;8376526;8448551;8448551;8475304;	+;+;+;+;+;+;+;+	763	0
ENSDARG00000096435	4;4	40839314;40839633	40839531;40839875	+;+	461	0
ENSDARG00000103471	4;4;4	30454496;30454875;30459185	30454538;30455024;30460765	+;+;+	1774	11
ENSDARG00000093665	4;4;4	40846483;40853631;40854506	40847768;40853781;40854534	-;-;-	1466	0
ENSDARG00000098144	4;4	40858450;40861793	40858599;40861846	+;+	204	1
ENSDARG00000093658	4;4;4;4;4;4;4;4;4;4;4;4	1732825;1736217;1736496;1736938;1738913;	1735043;1736379;1736593;1737090;1738993;	-;-;-;-;-;-;-;-;-	3807	80
ENSDARG00000095324	4;4;4;4;4;4;4;4;4;4;4;4;4;4;4;4;4	5215950;5218178;5218454;5218694;5218695;	5216294;5218382;5218620;5218878;5218878;	+;+;+;+;+;+;+;+	1973	0
ENSDARG00000098510	4;4;4;4;4;4	40880433;40880737;40880769;40882546;4088	40881466;40880763;40881466;40882630;4088	-;-;-;-;-;-	1237	0

Para hacer el análisis de expresión diferencial, necesitamos únicamente el identificador y el valor de cuentas crudas. Lo vamos a extraer de estos archivos:

```
for sample in `cat samples.txt`
do
        awk -F'\t' '{print $1 "\t" $7}' ${sample}_ftC.tsv | tail -n+3
> ../deseq2/${sample}.tsv
done
```

```
ENSDARG00000103202      0
ENSDARG00000009657      156
ENSDARG00000096472      0
ENSDARG00000096156      0
```

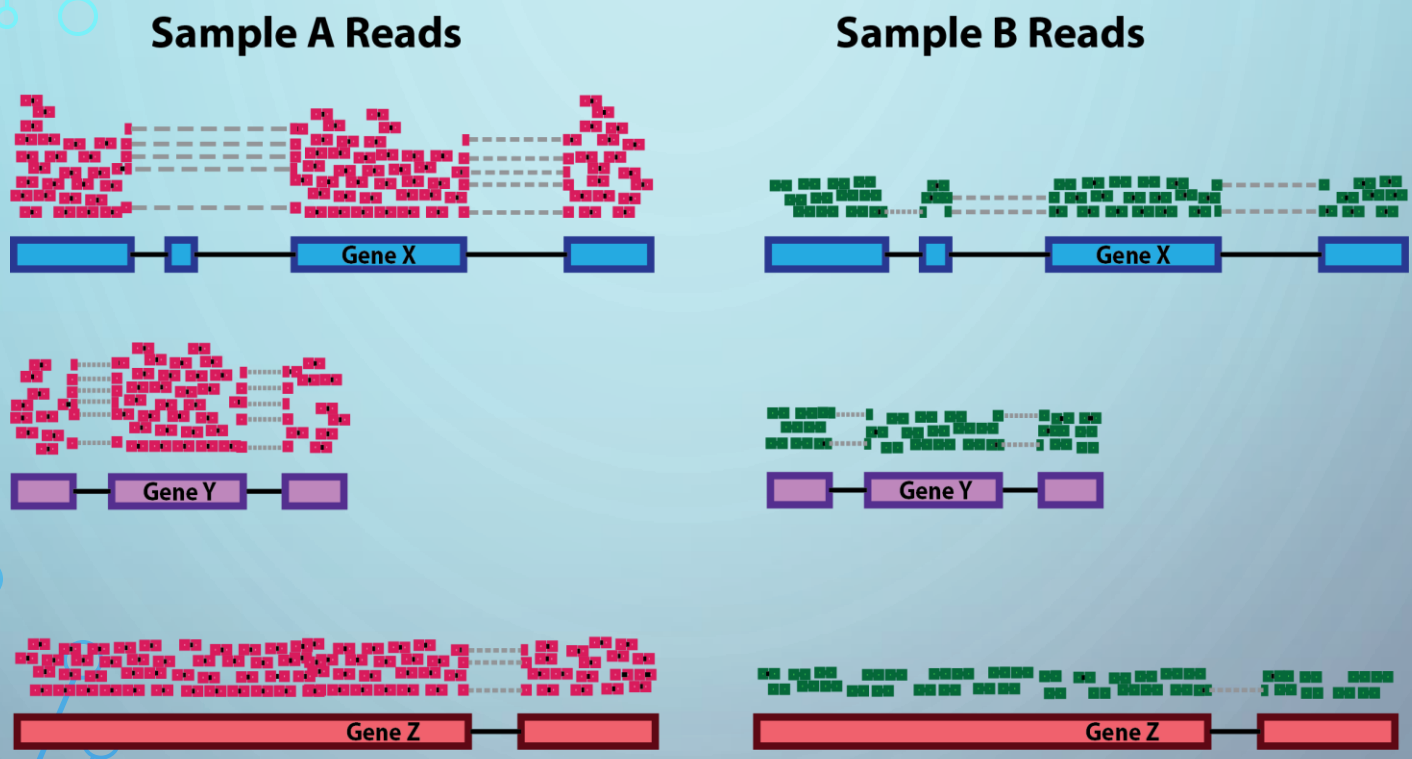
RNAseq: análisis bioinformático básico



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Normalización

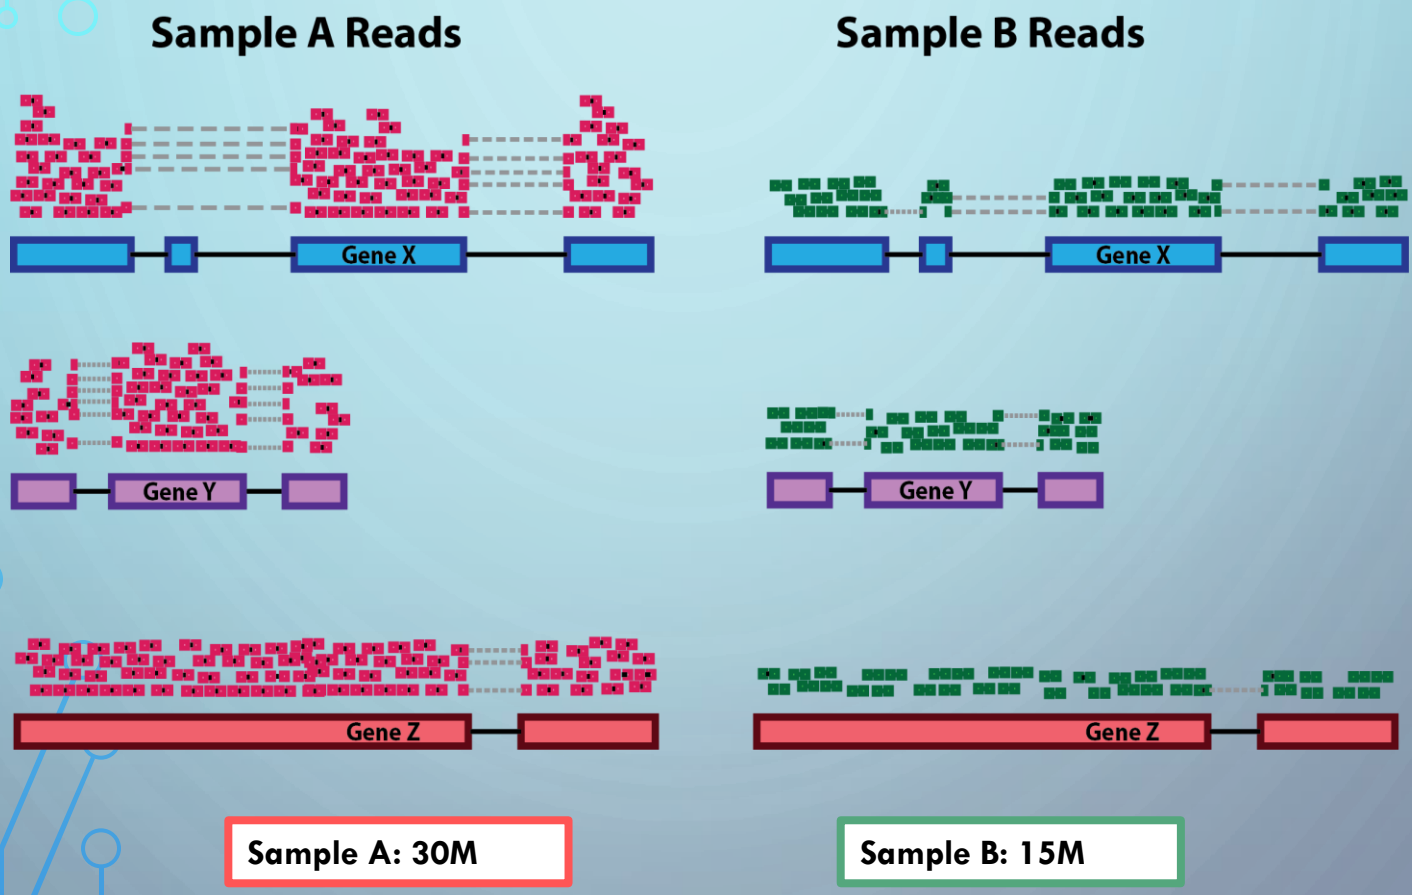
1. PROFUNDIDAD DE SECUENCIACIÓN (Nº LECTURAS TOTALES)



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Normalización

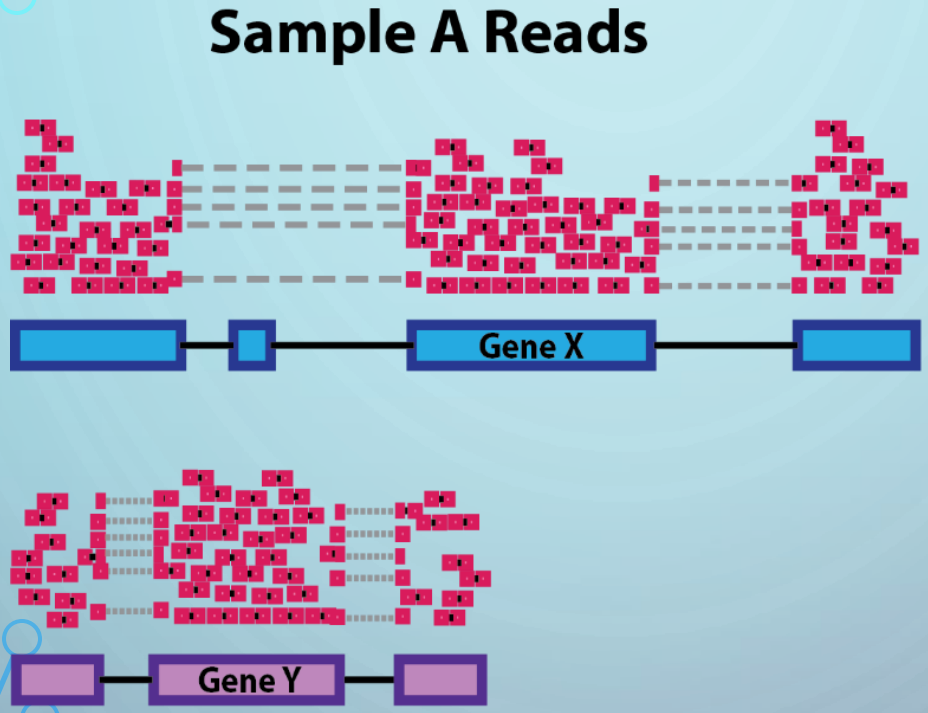
1. PROFUNDIDAD DE SECUENCIACIÓN (Nº LECTURAS TOTALES)



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Normalización

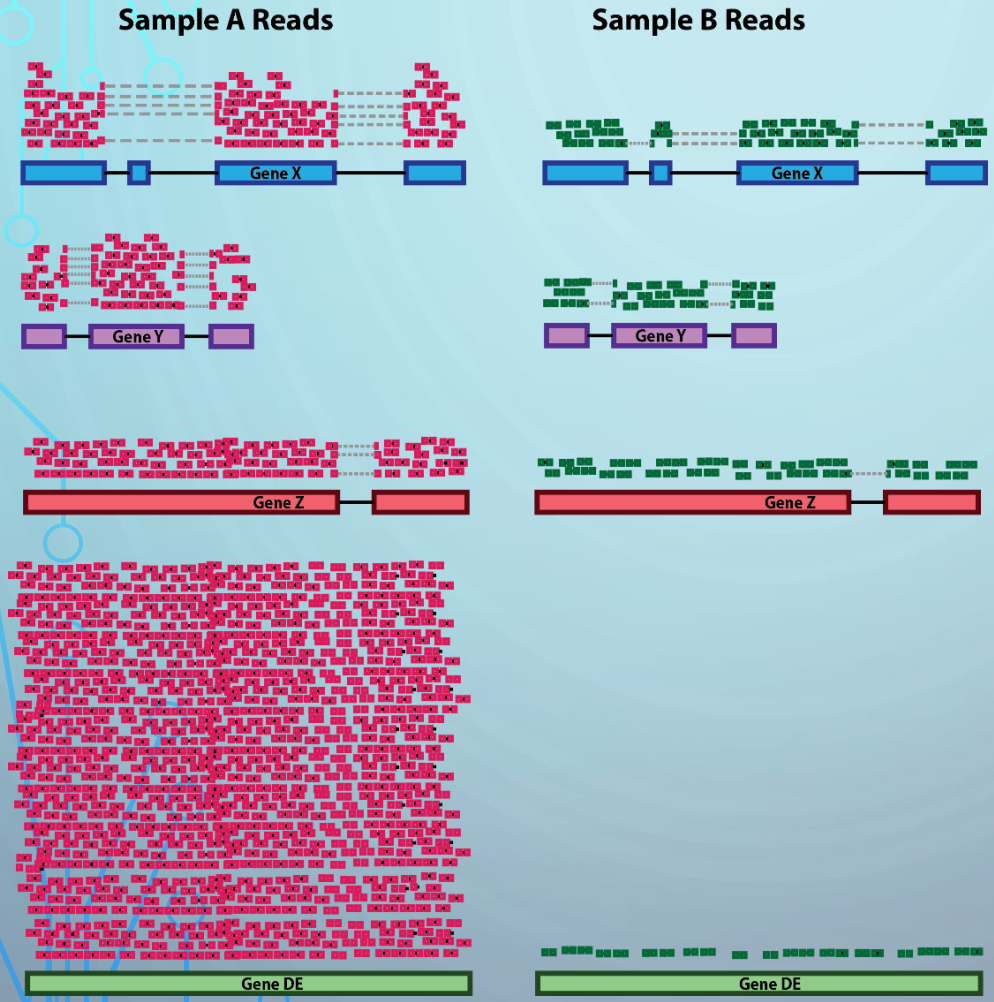
2. LONGITUD DEL GEN



¡Importante si se quiere comparar entre genes!

RNAseq: Normalización

3. RNA COMPOSITION



- Genes muy diferencialmente expresados
- Contaminaciones
- Outliers

pueden sesgar los métodos de normalización.

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Normalización

Unidades de cuentas normalizadas: RPKM

- ✓Profundidad de secuenciación
- ✓Longitud del gen

RPKM: **R**eads **P**er **K**ilobase of transcript per **M**illion reads

$$\mathrm{RPKM}_g = \frac{\frac{r_g 10^3}{\mathrm{fl}_g}}{\frac{R}{10^6}} = \frac{r_g \times 10^9}{\mathrm{fl}_g \times R}$$

- rg → número de lecturas mapeables que caen en los exones del gen
- R → número total de lecturas mapeables en el experimento
- flg → suma de la longitud de los exones en pares de bases

RNAseq: Normalización

Unidades de cuentas normalizadas: CPM

✓Profundidad de secuenciación

Válido si solo comparas los mismos tránscritos entre condiciones.

CPM: **C**ounts **P**er **M**illion reads

$$\mathrm{CPM}_i = \frac{X_i}{\frac{N}{10^6}} = \frac{X_i}{N} \cdot 10^6$$

- Xi → "counts" o número de lecturas que alinean con un gen
- N → número total de lecturas mapeables en el experimento

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Normalización

Unidades de cuentas normalizadas:
Median of Ratios (Deseq2 method)

- ✓Profundidad de secuenciación
- ✓RNA Composition







- Se basa en asumir que NO TODOS los genes van a estar diferencialmente expresados.
- Método muy robusto para casos con muchos DEGs y evitar sesgos por outliers.

RNAseq: Median of Ratios

1. Pseudoreferencia

Gene	SampleA	SampleB	Pseudo-reference sample
EF2A	1489	906	sqrt(1489 * 906) = **1161.5**
ABCD1	22	13	sqrt(22 * 13) = **16.9**

2. Ratio para cada muestra

Gene	SampleA	SampleB	ratio of sampleA/ref	ratio of sampleB/ref
EF2A	1489	906	1489/1161.5 = **1.28**	906/1161.5 = **0.78**
ABCD1	22	13	22/16.9 = **1.30**	13/16.9 = **0.77**

3. Factor de normalización para cada muestra

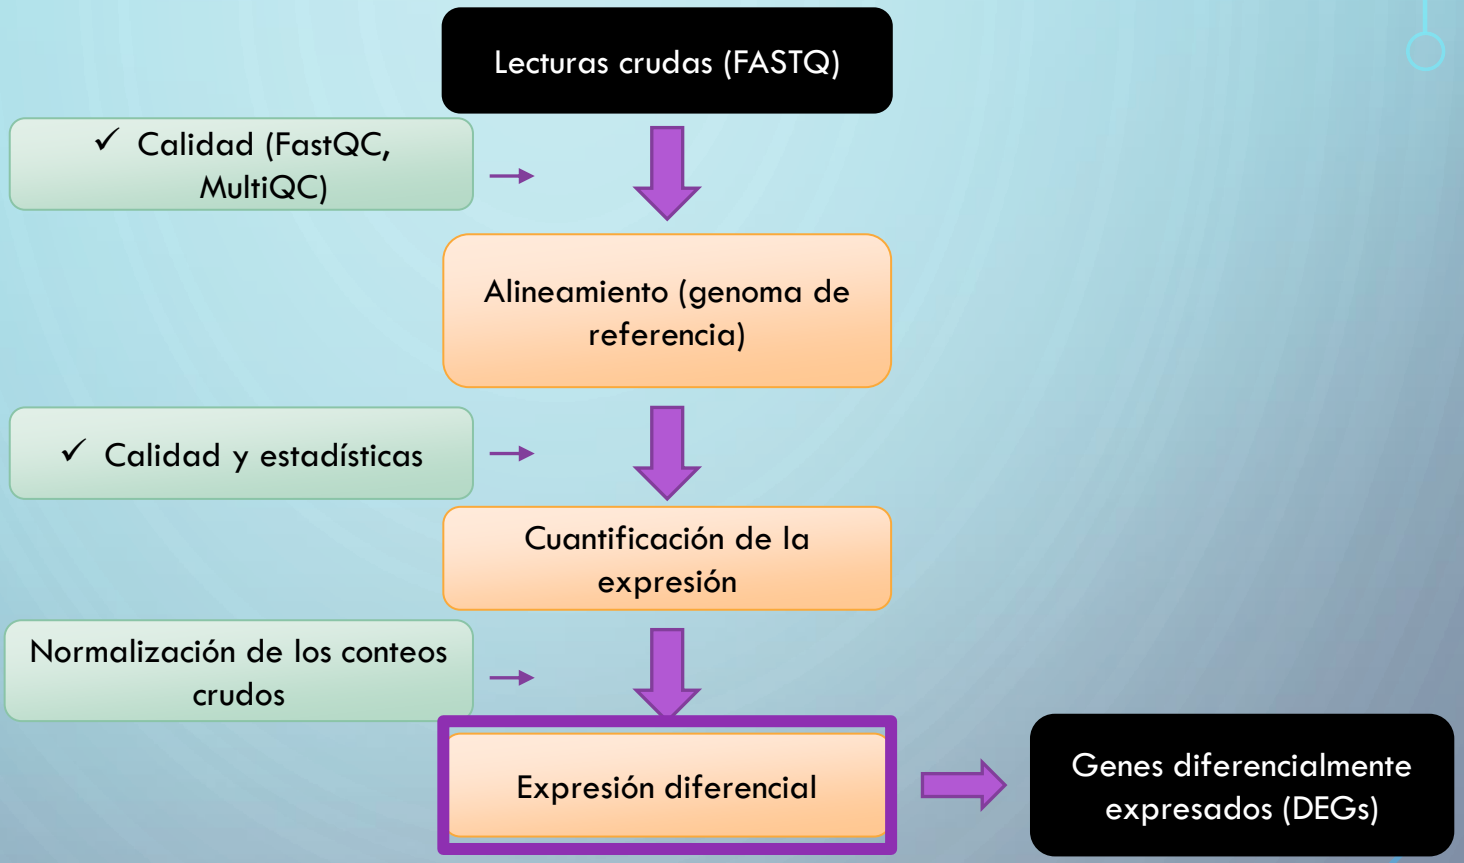
Size factor Sample A = mediana(1.28, 1.30,…,all genes) = **1.3**
Size factor Sample B = mediana(0.78, 0.77,…,all genes) = **0.77**

4. Conteos normalizados

Gene	SampleA	SampleB	Norm. counts sampleA	Norm. counts sampleB
EF2A	1489	906	1489 / 1.3 = **1145.39**	906 / 0.77 = **1176.62**
ABCD1	22	13	22 / 1.3 = **16.92**	13 / 0.77 = **16.88**

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: análisis bioinformático básico



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (7). Expresión diferencial

Programa : DESeq2 (R package)

Creamos un archivo de configuración que necesitaremos para ejecutar deseq2.
Contiene la información necesaria para cada muestra:

- su identificador (sample)
- el archivo de cuentas crudas (file)
- el grupo experimental (condition)

```
$ vim config.txt

sample  file    condition
55  55.tsv  WT
67  67.tsv  WT
61  61.tsv  Mutant
75  75.tsv  Mutant
```

Una vez creado el archivo de configuración, ejecutamos deseq2 desde el script:

```
$ Rscript --vanilla deseq2.R -c config.txt -d org.Dr.eg.db
```

RNAseq: Expresión diferencial.

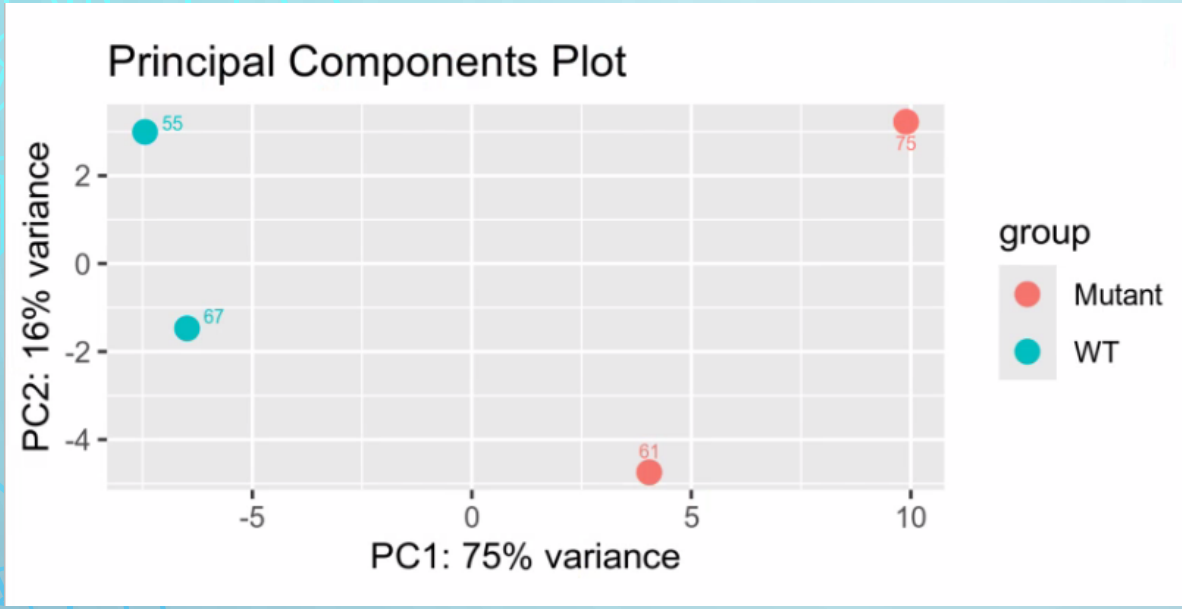
Output (tabla)

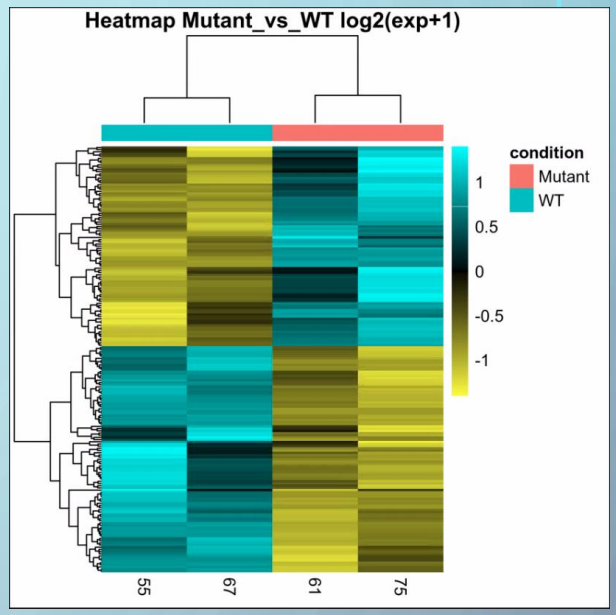
(archivo deseq2_all_Mutant_vs_WT.tsv)

	symbol	baseMean	FoldChange	log2FoldChange	lfcSE	stat	pvalue	padj	description
ENSDARG00000103202		NA	0.238880776235013	0.332954966361453		-1.58660103531015	4.98993133225123	-0.317960494777859	0.750514903580337	NA
ENSDARG00000009657	fgfr1op2	161.955280477536	0.745875993423701	-0.422992301596891		0.281559361856739	-1.50232014594533	0.133014448219319		
ENSDARG00000096472		NA	0	NA	NA	NA	NA	NA	NA	
ENSDARG00000096156		NA	0.238880776235013	0.332954966361453		-1.58660103531015	4.98993133225123	-0.317960494777859	0.750514903580337	NA
ENSDARG00000076160		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000117163		NA	3.73045188245414	0.789609538270102		-0.340788677621089	1.4471870766365	-0.235483499765032	0.813833484100275	NA	NA
ENSDARG00000096187		NA	0.464807998896991	0.895956160790642		-0.158499952065692	4.17730862752239	-0.0379430791925232	0.969733065533366	NA
ENSDARG00000076014	erc1b	0.746137540962228	1.62278255272608	0.698469696669107		3.44229800466733	0.202907968956223	0.839206965521819	NA	
ENSDARG00000098876		NA	1.01231350191636	0.304005359415483		-1.71783133722513	2.88319636250606	-0.595807957988682	0.551303526815543	NA
ENSDARG00000031930		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000096435		NA	0.225927222661978	2.36735293805678		1.24327480705543	4.99523429474786	0.248892190775245	0.803444176117031	NA
ENSDARG00000103471	zgc:173716	5.54958857050595	0.411248824186525		-1.28191654088494	1.32156074743497	-0.970001979381593	0.332045505494751		
ENSDARG00000093665		NA	1.168496774029	0.62258128674671		-0.683665881272458	2.80253980010578	-0.243945110519627	0.807273331181485	NA	NA
ENSDARG00000098144		NA	0.294283095638271	0.299626587542327		-1.73876244701337	4.98004224345251	-0.349146124071418	0.726979610735991	NA
ENSDARG00000093658	tm7sf3	100.445062655058	0.967148557691426		-0.0481905847266984	0.322840089904443	-0.149270757361523	0.881339988973166	0.99924	
ENSDARG00000095324	galnt8b.2	0	NA	NA	NA	NA	NA	polypeptide N-acetylgalactosaminyltransferase 8b, tandem duplicate 2		
ENSDARG00000098510	zgc:174650	0.718030406278087	0.485492556673244		-1.0424789177453	3.49817950959548	-0.298006124295733	0.765698489369724		
ENSDARG00000021336	pax4	0	NA	NA	NA	NA	paired box 4			
ENSDARG00000094646	dyrk2	168.317952293114	0.789354731894293		-0.341254309307511	0.269012641237045	-1.26854376708197	0.204603831274186	0.96401	
ENSDARG00000021595	lhfpl3	0	NA	NA	NA	NA	NA	LHFPL tetraspan subfamily member 3		
ENSDARG00000096039		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000096153	si:dkey-21h14.9	0.238880776235013	0.332954966361453		-1.58660103531015	4.98993133225123	-0.317960494777859	0.750514903580337		
ENSDARG00000095200	si:ch211-197e7.1	0.746137540962228	1.62278255272608	0.698469696669107		3.44229800466733	0.202907968956223	0.8392069655218		
ENSDARG00000096463		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000102062		NA	1.6661522679373	5.47367935154571		2.45251092401889	2.45797000846626	0.997779027234439	0.318386522214211	NA	NA
ENSDARG00000090116	znf1136	4.01039334694633	0.689812730540968		-0.535723340807578	1.38001432305866	-0.388201290273714	0.697867078400898	NA	
ENSDARG00000102464	wnt5b	0	NA	NA	NA	NA	NA	wingless-type MMTV integration site family, member 5b		
ENSDARG00000095149		NA	0.718030406278087	0.485492556673244		-1.0424789177453	3.49817950959548	-0.298006124295733	0.765698489369724	NA
ENSDARG00000092714	si:ch211-266a5.12	0.294283095638271	0.299626587542327		-1.73876244701337	4.98004224345251	-0.349146124071418	0.7269796107359		
ENSDARG00000112103	zgc:173721	0.240268853808061	2.4420331303934	1.28808277310584		4.99209786112503	0.258024343460197	0.796388119818716	NA	
ENSDARG00000096462		NA	0.225927222661978	2.36735293805678		1.24327480705543	4.99523429474786	0.248892190775245	0.803444176117031	NA
ENSDARG00000045801	fbxl14b	41.9562358664844	0.888783046986092		-0.170096796457335	0.474021649222538	-0.35883761160765	0.719716573963422	0.99924	
ENSDARG00000096855		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000104074		NA	0.986406394770289	2.50469848413308		1.32463694209222	2.8948326754515	0.457586703827577	0.647249397786301	NA	NA
ENSDARG00000097754		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000095103		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000015623	ada2b	34.4193833959994	1.96362374150619		0.973518515056655	0.507822150950977	1.91704618089933	0.0552320649851872	0.57245	
ENSDARG00000101202		NA	0.773432725681345	0.444362480351787		-1.1701910866562	3.19361798501866	-0.366415486180749	0.714055065762344	NA
ENSDARG00000102559		NA	1.25119427815137	0.231113189452695		-2.11332849923146	2.68463345946311	-0.787194427523112	0.431168058810882	NA
ENSDARG00000030694	atp6v1e1b	376.031805891275	1.2777509222342	0.353606632623366		0.215428222716502	1.6414127553227	0.100711763891075	0.7600927455482	
ENSDARG00000093168		NA	0	NA	NA	NA	NA	NA		
ENSDARG00000093983		NA	0.720806561424183	7.36480273604564		2.88064688363994	3.70604571540095	0.777283148901549	0.436991734716776	NA
ENSDARG00000030598	nampt1	57.8281026570237	1.70584832549874		0.770489375977049	0.426380096250158	1.80704817779534	0.070754767673279	0.65000	

RNAseq: Expresión diferencial.

Output (gráficos)





PCA plot

Resume las diferencias globales de expresión génica entre tus muestras, reduciendo miles de genes a 2 o 3 dimensiones principales (direcciones de mayor variación en los datos)

Heatmap

Visualiza los niveles de expresión de genes seleccionados (normalmente los DEGs) en todas las muestras.

Fila = un gen

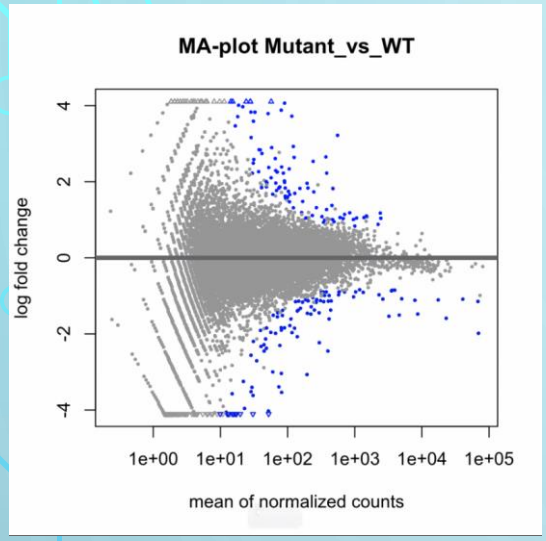
Columna = una muestra

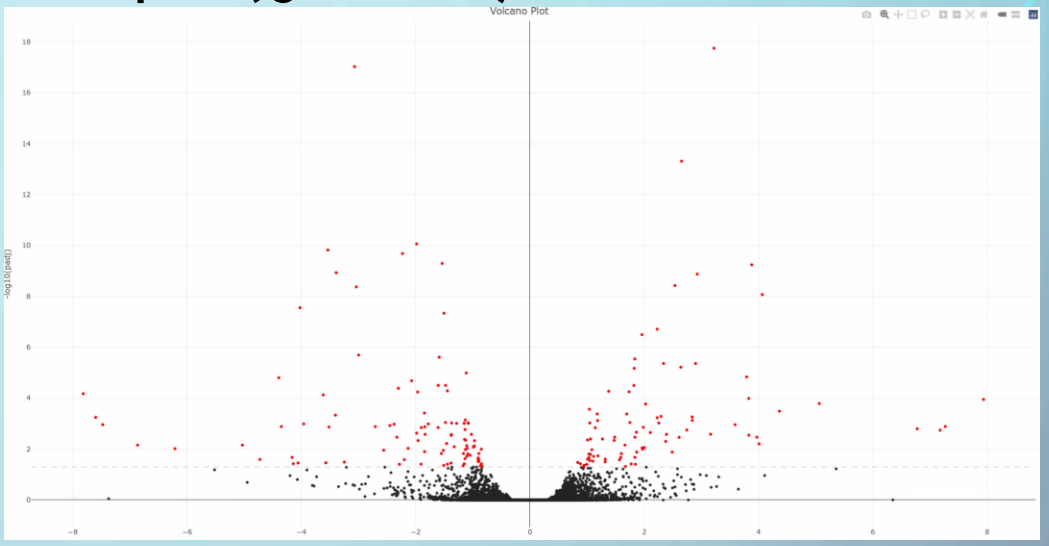
Color = nivel de expresión

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biologia Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Expresión diferencial.

Output (gráficos)





MA-plot

Eje X (A) → nivel medio de expresión: genes poco expresados a la izquierda, muy expresados a la derecha.

Eje Y (M) → $\log_2$(fold change):

Valores positivos → más expresado en condición 1

Valores negativos → más expresado en condición 2

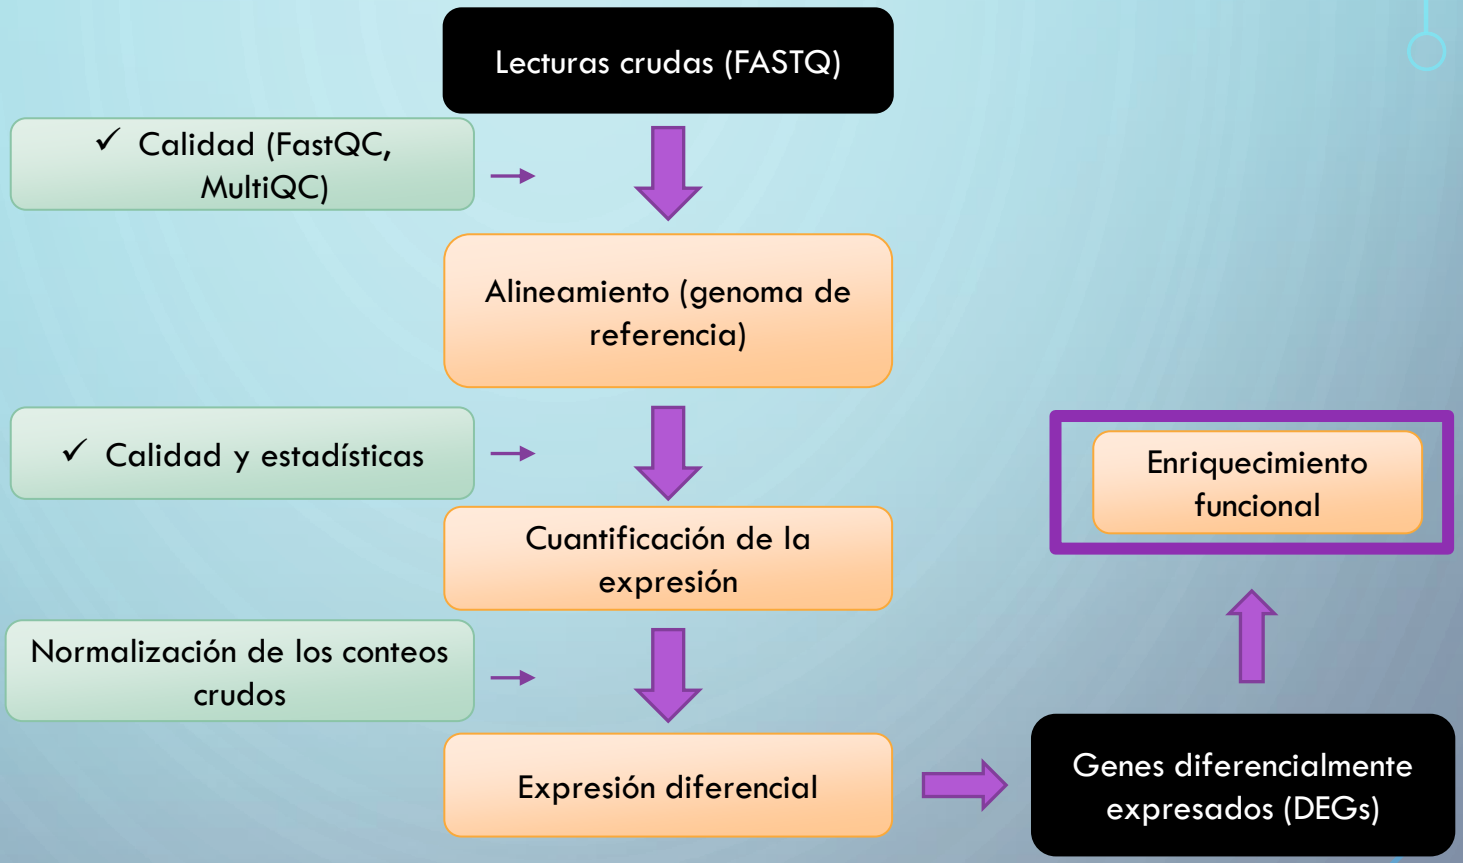
Volcano plot

Eje X → $\log_2$ Fold Change

Eje Y → $-\log_{10}$(p-value) → qué tan significativa es la diferencia (más alto = más significativo).

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biologia Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: post-análisis



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Enriquecimiento funcional

Rutas / GO

- **O**ver – **R**epresentation **A**nalysis (**ORA**)
- Lista de DEGs (acepta pocos genes)
- Análisis de ontologías/rutas afectadas

- **G**ene **S**et **E**nrichment **A**nalysis (**GSEA**)
- Todos los genes + información cuantitativa (Log2FoldChange - stat)
- Análisis de enriquecimiento up o down de las ontologías/rutas.



http://geneontology.org/



https://www.genome.jp/kegg/



https://reactome.org/

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: hands-on (8). Rutas

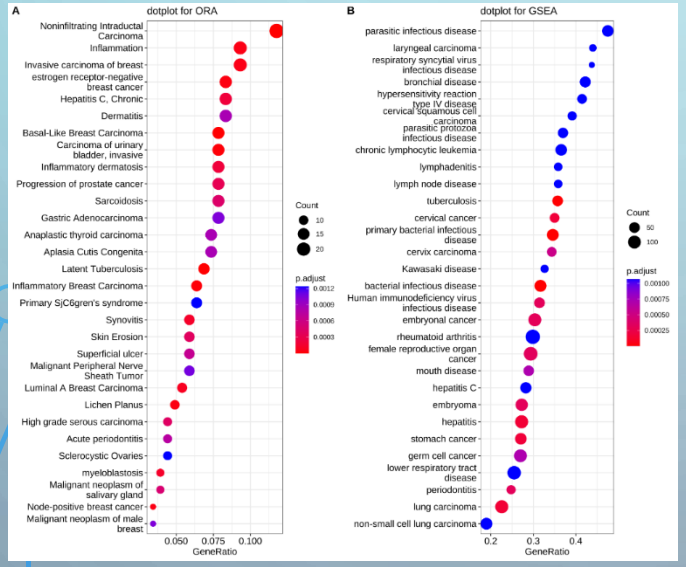
Programa: clusterProfiler (R package)

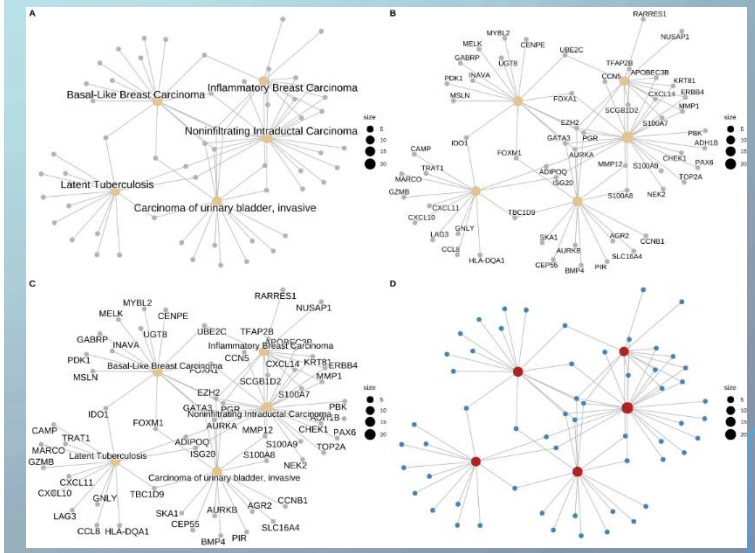
En primer lugar, generamos el archivo con cada identificador y el parámetro por el que vamos a ordenar nuestros genes ("stat")

```
cut -f1,7 deseq2_all_Mutant_vs_WT.tsv > Mutant_WT_all.txt
```

A continuación, corremos GSEA para términos GO:

```
Rscript --vanilla gse_go.R \
-i Mutant_WT_all.txt -p Mutant_vs_WT -o org.Dr.eg.db
```





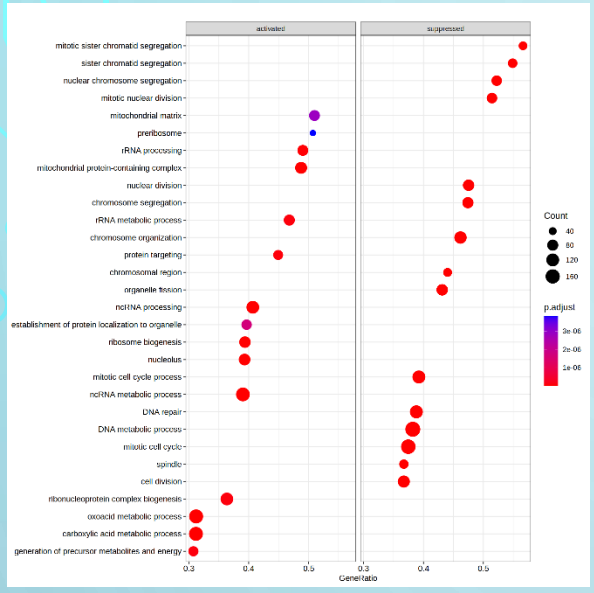
Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

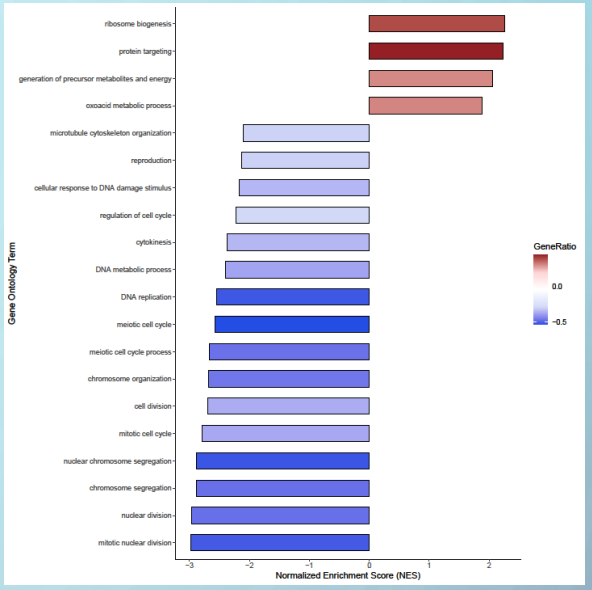
RNAseq: Enriquecimiento funcional. Output

	ONTOLOGY	ID	Description	setSize	enrichmentScore	NES	pvalue	p.adjust	qvalue	rank	leading_edge	core_enrichment
GO:0000278	BP	GO:0000278	mitotic cell cycle	432	-0.613308385313769	-2.83650866355564	1.19700571665321e-40	5.42243589643905e-37	4.4465612358623e-37	3124	tags=43%, list=15%, signal=38%	chaf1b/nsl1/ccne1/e2f4/rock2b/rtknb/mcm3l/
GO:1903047	BP	GO:1903047	mitotic cell cycle process	316	-0.620531310566651	-2.78499682554966	6.45705050755106e-32	1.46252193996032e-28	1.19931217058672e-28	2390	tags=39%, list=11%, signal=35%	mre11a/mad2l1bp/lats1/cdc27/zwilch/chek1/
GO:0000280	BP	GO:0000280	nuclear division	184	-0.700574584231351	-2.94566810385554	3.05791380733204e-29	4.61744984907137e-26	3.78644836002623e-26	2244	tags=46%, list=10%, signal=41%	cdc27/zwilch/bag6l/mnd1/fancd2/e2f5/map9/

Columna	Qué significa
ONTOLOGY	Categoría de la base de datos usada: por ejemplo, BP (Biological Process), MF (Molecular Function), CC (Cellular Component) si es GO, o el nombre de la colección si usas MSigDB (HALLMARK, KEGG).
ID	Identificador único del conjunto de genes (gene set), por ejemplo GO:0006915 para apoptosis.
Description	Nombre descriptivo del gene set, p. ej., “apoptotic process”.
setSize	Número total de genes que componen el conjunto (gene set).
enrichmentScore (ES)	Score de enriquecimiento: indica cuánto están los genes del conjunto concentrados al principio o al final de tu lista ordenada. Valores positivos → enriquecido en el extremo superior; negativos → enriquecido en el extremo inferior.
NES (Normalized Enrichment Score)	ES normalizado para el tamaño del gene set y la variabilidad de la permutación. Permite comparar gene sets de distinto tamaño. Es el valor principal que se usa para jerarquizar resultados.
Pvalue /p.adjust/qvalue	Valor p nominal/ajustado/FDR de significancia para ese gene set.
rank	Posición en la lista ordenada donde ocurre el máximo desplazamiento del running sum (pico del ES). Indica dónde se concentra la señal del gene set.
leading_edge	Subconjunto de genes dentro del gene set que contribuyen más al ES. Es decir, los genes “clave” que impulsan el enriquecimiento.
core_enrichment	Lista de genes reales (símbolos) del gene set que forman el leading edge. Son los genes que efectivamente están enriquecidos en tu dataset.

RNAseq: Enriquecimiento funcional. Output





DOTPLOT

Cada punto = un gene set

Eje Y: nombre del gene set

Eje X: geneRatio

(número de genes de tu lista que pertenecen a una categoría)

÷

(número total de genes en tu lista usada para el análisis)

Tamaño del punto: setSize

(número de genes de la categoría)

Color: nivel de significancia (p o qvalue)

BARPLOT

Cada barra = un gene set

Eje Y: nombre del gene set

Eje X: NES

(Normalized Enrichment Score)

Color: geneRatio

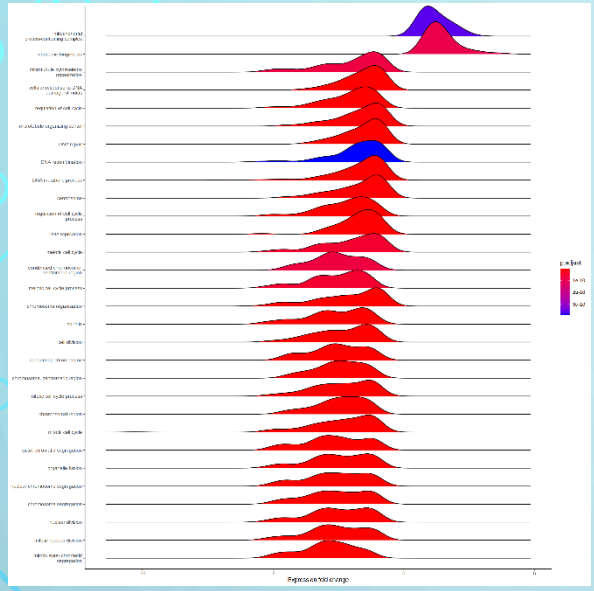
(número de genes de tu lista que pertenecen a una categoría)

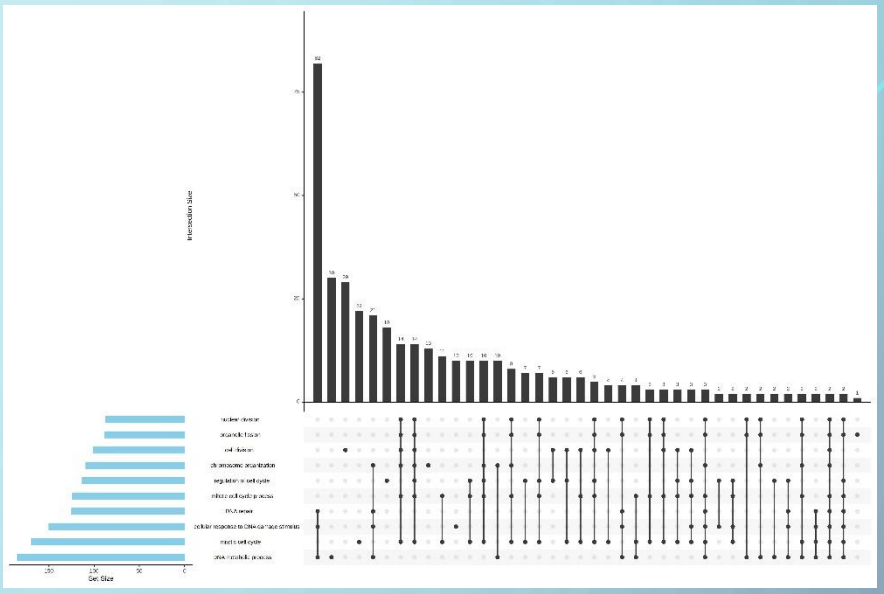
÷

(número total de genes en tu lista usada para el análisis)

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Enriquecimiento funcional. Output





RIDGEPLOT

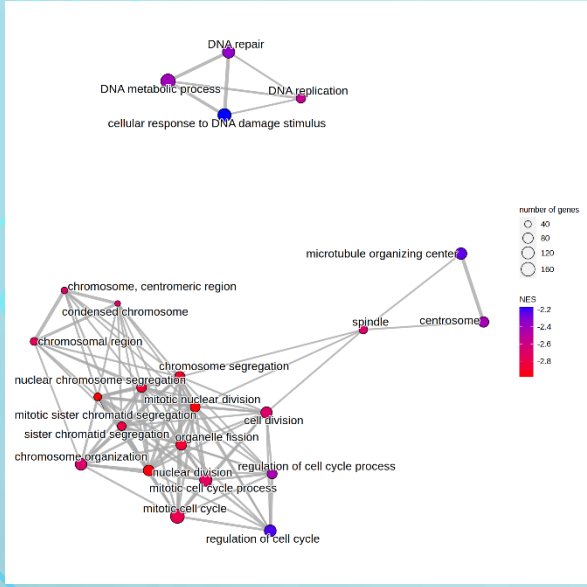
Cada curva (ridge) = un gene set
Eje Y: nombre del gene set
Eje X: posición (ranking) de los genes
Altura de la curva: densidad de genes
Color: nivel de significancia (p o qvalue)

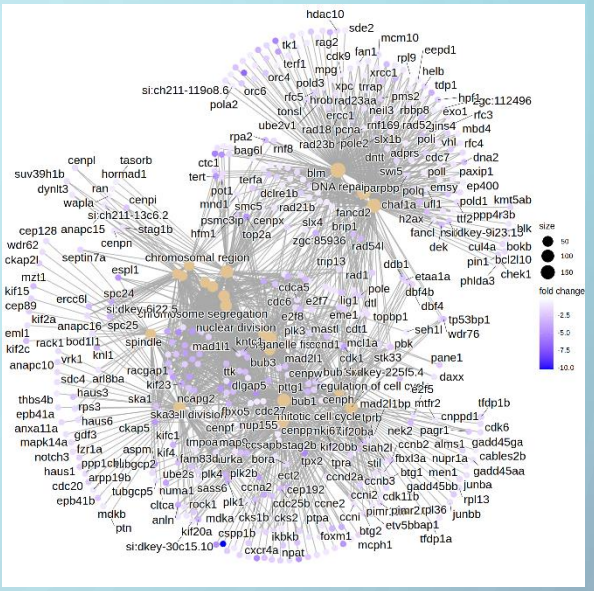
UPSETPLOT

Cada fila = un gene set
Barras: cuántos genes comparten esos sets
Conexiones: combinaciones de sets que comparten genes

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Enriquecimiento funcional. Output





ENRICHMAP

Nodo = un gene set

Tamaño: tamaño del set

Color: NES

(Normalized Enrichment Score)

CNETPLOT (Category Network Plot)

Nodos grandes = gene sets

Tamaño: tamaño del set

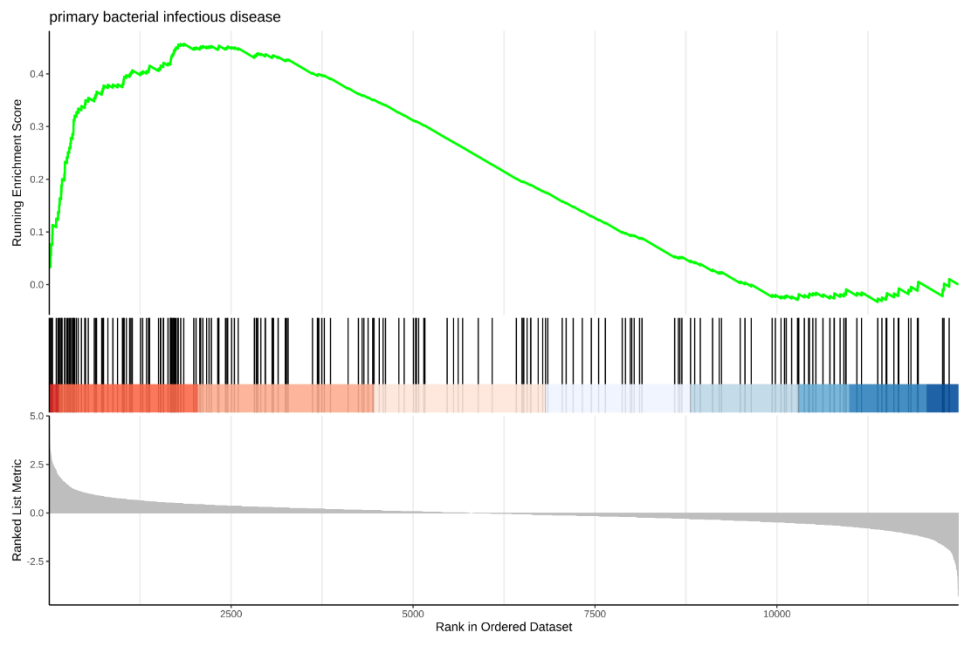
Nodos pequeños = genes individuales

Color: nivel de significancia (p o qvalue)

Líneas: genes que pertenecen a cada set

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Enriquecimiento funcional. Output



GSEA plot

Running enrichment score (RES): valor acumulado que se calcula mientras se recorre toda la lista de genes ordenada (de más upregulated hasta los más downregulated).

Eje X: todos los genes ordenados por su estadístico (ranking), repartidos para cada gene set
Eje Y: métrica de ordenamiento de cada gen (ranking).

El pico de la curva indica dónde se concentran los genes del set (arriba o abajo de la lista).

- Si la curva sube al principio → enriquecido en la condición "arriba" del ranking.
- Si sube al final → enriquecido en la condición "abajo".

RNAseq: Enriquecimiento funcional

Rutas / GO

- **O**ver – **R**epresentation **A**nalysis (**ORA**)
  - Lista de DEGs (acepta pocos genes)
  - Análisis de ontologías/rutas afectadas

- **G**ene **S**et **E**nrichment **A**nalysis (**GSEA**)
  - DEGs + información cuantitativa (Log2FoldChange - stat)
  - Análisis de enriquecimiento up o down de las ontologías/rutas.



http://geneontology.org/



https://www.genome.jp/kegg/

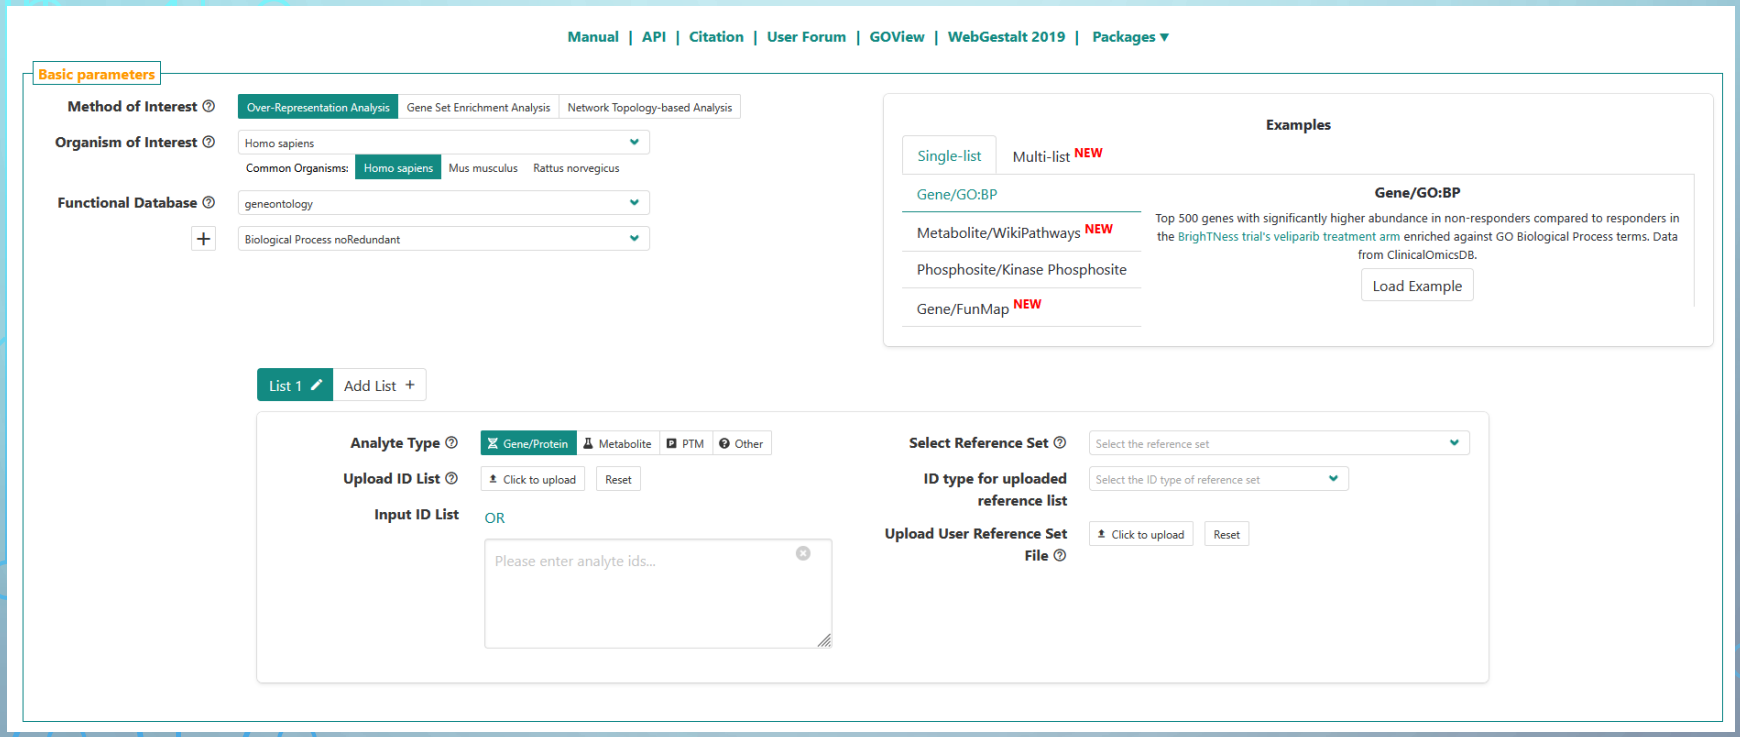


https://reactome.org/

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Enriquecimiento funcional sin R

https://www.webgestalt.org/



Over – Representation Analysis (ORA)

- Lista de DEGs

Gene Set Enrichment Analysis (GSEA)

Todos los genes

+

información cuantitativa (LFC – stat)

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

GEO2R: análisis de expresión diferencial online

Ejemplo con datos de Danio rerio (Microarray):

Publicación: https://pubmed.ncbi.nlm.nih.gov/31535658/

Materials and Methods

Identification of differentially expressed genes (DEGs)

The original GSE56842 datasets were downloaded from NCBI GEO (available online: http://www.ncbi.nlm.nih.gov/geo/). These datasets were submitted by Vajn et al. (2013) and are based on the GPL1319 Platform (Affymetrix Zebrafish Genome Array, Affymetrix Technologies, Santa Clara, CA, USA). The data were derived from a complete spinal cord transection with fluoro-ruby retrograde tracing performed at the 8th vertebral level in adult zebrafish. The fluoro-ruby dye labeled all the neurons in the brain that projected their axons to the 8th vertebra. Three weeks later, fluoro-emerald was injected 4 mm distal to the spinal cord transection site, thereby labeling all neurons that regenerated their axons to this level. The zebrafish were sacrificed 1 week after fluoro-emerald tracing and the brains were enzymatically dissociated. Cells were sorted using fluorescence-activated cell sorting. The GSE56842 dataset contains nine samples, including three non-regenerated neuron samples, three regenerated neuron samples, and three non-lesion samples. In the present study, the regenerated neuron samples and non-regenerated neuron samples were selected for analysis.

The original gene expression profile data were analyzed on the Morpheus website (available online: https://software.broadinstitute.org/morpheus/) to obtain a heat map of the most significant DEGs. GEO2R was used to obtain the DEGs (available online: https://www.ncbi.nlm.nih.gov/geo/geo2r/). We considered $P < 0.05$ to show statistical significance and [logFC] > 1 as the cut-off value.

https://www.ncbi.nlm.nih.gov/geo/geo2r/?acc=GSE56842

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

GEO2R: análisis de expresión diferencial online

Ejemplo con datos de Danio rerio (Microarray):



HOME | SEARCH | SITE MAP | GEO Publications | FAQ | MIAME | Email GEO

NCBI > GEO > **Accession Display** | Not logged in | Login

Scope: Self | Format: HTML | Amount: Quick | GEO accession: GSE56842 | GO

Series GSE56842 — Query DataSets for GSE56842

Status	Public on Apr 17, 2015
Title	Identification of axonal regeneration-associated genes after spinal cord injury in adult zebrafish
Organism	Danio rerio
Experiment type	Expression profiling by array
Summary	Adult zebrafish regenerate about half of cerebrospinal axons by six weeks after a complete spinal cord transection. We isolated the two populations of neurons that successfully regenerated their axons versus those that did not and isolated the total RNA. Cerebrospinal neurons from unlesioned animals were also collected to serve as controls. Whole transcriptome microarray was performed to determine axonal regeneration-associated genes. For each condition (regenerated, non-regenerated and control neurons) we had 3 biological replicates that consisted of neurons pooled from 3 to 9 zebrafish.
Overall design	A complete spinal cord transection with Fluororuby retrograde tracing was performed at the 8th vertebra level in adult zebrafish. Fluororuby labeled all the neurons in the brain that project their axons to the 8th vertebra. Three weeks later Fluoroemerald was injected 4mm distally from the spinal cord transection site, thereby labeling all neurons that regenerated their axons to this level. The zebrafish were sacrificed 1 week after Fluoroemerald tracing, brain enzymatically dissociated and cells sorted using fluorescence-activated cell sorter. After sorting the total RNA was extracted, amplified and labeled with biotin and then hybridized to Affymetrix 3' IVT gene expression microarray. Unlesioned fish were traced with Fluororuby at the 8th vertebra level and labeled neurons isolated 1 week after to serve as control for gene expression microarray.
Contributor(s)	Vajn K, Milosevic J, Tapanes-Castillo A, Plunkett JA, Oudega M
Citation missing	*Has this study been published? Please login to update or notify GEO.*

Analyze with GEO2R

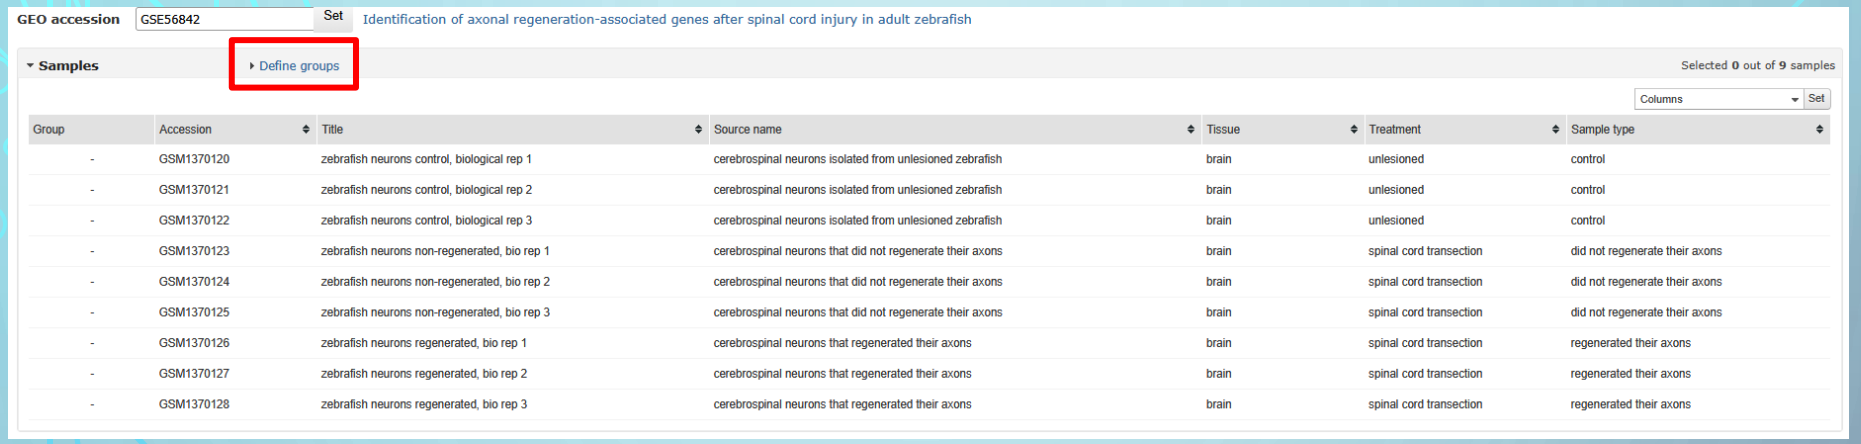
https://www.ncbi.nlm.nih.gov/geo/geo2r/?acc=GSE56842

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

GEO2R: análisis de expresión diferencial online

Ejemplo con datos de Danio rerio (Microarray):

https://www.ncbi.nlm.nih.gov/geo/geo2r/?acc=GSE56842

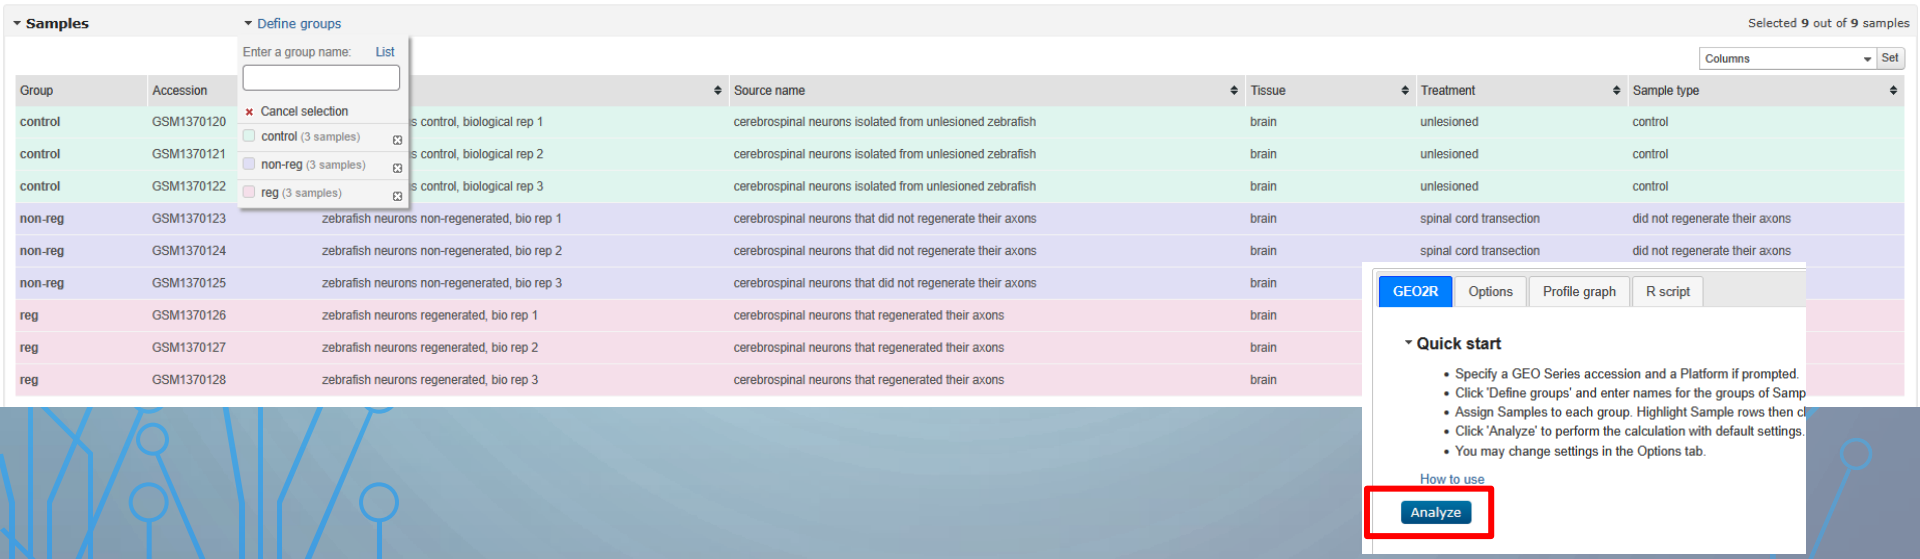


GEO accession: GSE56842 Set — Identification of axonal regeneration-associated genes after spinal cord injury in adult zebrafish

Samples — Define groups — Selected 0 out of 9 samples

Columns Set

Group	Accession	Title	Source name	Tissue	Treatment	Sample type
-	GSM1370120	zebrafish neurons control, biological rep 1	cerebrospinal neurons isolated from unlesioned zebrafish	brain	unlesioned	control
-	GSM1370121	zebrafish neurons control, biological rep 2	cerebrospinal neurons isolated from unlesioned zebrafish	brain	unlesioned	control
-	GSM1370122	zebrafish neurons control, biological rep 3	cerebrospinal neurons isolated from unlesioned zebrafish	brain	unlesioned	control
-	GSM1370123	zebrafish neurons non-regenerated, bio rep 1	cerebrospinal neurons that did not regenerate their axons	brain	spinal cord transection	did not regenerate their axons
-	GSM1370124	zebrafish neurons non-regenerated, bio rep 2	cerebrospinal neurons that did not regenerate their axons	brain	spinal cord transection	did not regenerate their axons
-	GSM1370125	zebrafish neurons non-regenerated, bio rep 3	cerebrospinal neurons that did not regenerate their axons	brain	spinal cord transection	did not regenerate their axons
-	GSM1370126	zebrafish neurons regenerated, bio rep 1	cerebrospinal neurons that regenerated their axons	brain	spinal cord transection	regenerated their axons
-	GSM1370127	zebrafish neurons regenerated, bio rep 2	cerebrospinal neurons that regenerated their axons	brain	spinal cord transection	regenerated their axons
-	GSM1370128	zebrafish neurons regenerated, bio rep 3	cerebrospinal neurons that regenerated their axons	brain	spinal cord transection	regenerated their axons



Samples — Define groups — Selected 9 out of 9 samples

Enter a group name: List

Cancel selection

control (3 samples)

non-reg (3 samples)

reg (3 samples)

Columns Set

Group	Accession	Title	Source name	Tissue	Treatment	Sample type
control	GSM1370120	s control, biological rep 1	cerebrospinal neurons isolated from unlesioned zebrafish	brain	unlesioned	control
control	GSM1370121	s control, biological rep 2	cerebrospinal neurons isolated from unlesioned zebrafish	brain	unlesioned	control
control	GSM1370122	s control, biological rep 3	cerebrospinal neurons isolated from unlesioned zebrafish	brain	unlesioned	control
non-reg	GSM1370123	zebrafish neurons non-regenerated, bio rep 1	cerebrospinal neurons that did not regenerate their axons	brain	spinal cord transection	did not regenerate their axons
non-reg	GSM1370124	zebrafish neurons non-regenerated, bio rep 2	cerebrospinal neurons that did not regenerate their axons	brain	spinal cord transection	did not regenerate their axons
non-reg	GSM1370125	zebrafish neurons non-regenerated, bio rep 3	cerebrospinal neurons that did not regenerate their axons	brain		
reg	GSM1370126	zebrafish neurons regenerated, bio rep 1	cerebrospinal neurons that regenerated their axons	brain		
reg	GSM1370127	zebrafish neurons regenerated, bio rep 2	cerebrospinal neurons that regenerated their axons	brain		
reg	GSM1370128	zebrafish neurons regenerated, bio rep 3	cerebrospinal neurons that regenerated their axons	brain		

GEO2R | Options | Profile graph | R script

Quick start

- Specify a GEO Series accession and a Platform if prompted.
- Click 'Define groups' and enter names for the groups of Samp
- Assign Samples to each group. Highlight Sample rows then cl
- Click 'Analyze' to perform the calculation with default settings.
- You may change settings in the Options tab.

How to use

Analyze

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

GEO2R: análisis de expresión diferencial online

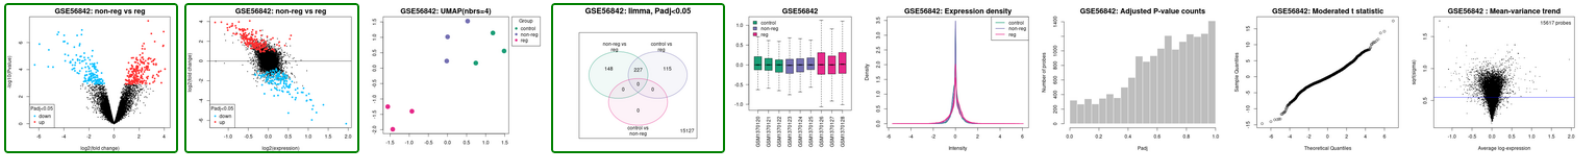
Ejemplo con datos de Danio rerio (Microarray):

https://www.ncbi.nlm.nih.gov/geo/geo2r/?acc=GSE56842

GEO2R | Options | Profile graph | R script

Reanalyze if you changed any options.

Visualization



Top differentially expressed genes

Download full table | Select columns

ID	adj.P.Val	P.Value	F	Gene.symbol	Gene.title
Dr.12739.1.A1_at	0.000742	4.75e-08	178.9		
Dr.8786.1.A1_at	0.001346	2.13e-07	127.5		
Dr.14079.1.S1_at	0.001346	3.17e-07	116.5	ywhaz	tyrosine 3-monooxygenase/tryptophan 5-monooxygen...
Dr.20800.1.A1_at	0.001346	3.55e-07	113.5	aplnra	apelin receptor a
Dr.11340.1.A1_at	0.001346	5.32e-07	103.5	dgkzb	diacylglycerol kinase, zeta b
Dr.3933.1.A1_at	0.001346	5.82e-07	101.4	wu:fc46b01	wu:fc46b01
Dr.5461.1.A1_at	0.001346	6.03e-07	100.6	cox4i1l	cytochrome c oxidase subunit IV isoform 1, like
Dr.13633.1.A1_at	0.001409	7.22e-07	96.5	zgc:92287	zgc:92287
Dr.22721.1.A1_at	0.001517	8.74e-07	92.4	wu:fi45a02	wu:fi45a02

GEO2R | Options | Profile graph | R script

```
# Version info: R 4.2.2, Biobase 2.58.0, GEOquery 2.66.0, limma 3.54.0
################################################################
#   Differential expression analysis with limma
library(GEOquery)
library(limma)
library(umap)

# load series and platform data from GEO

gset <- getGEO("GSE56842", GSEMatrix =TRUE, AnnotGPL=TRUE)
if (length(gset) > 1) idx <- grep("GPL1319", attr(gset, "names")) else idx <- 1
gset <- gset[[idx]]

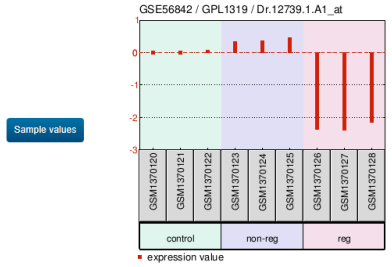
# make proper column names to match toptable
fvarLabels(gset) <- make.names(fvarLabels(gset))

# group membership for all samples
gsms <- "000111222"
sml <- strsplit(gsms, split="")[[1]]

# log2 transformation
ex <- exprs(gset)
qx <- as.numeric(quantile(ex, c(0., 0.25, 0.5, 0.75, 0.99, 1.0), na.rm=T))
LogC <- (qx[5] > 100) ||
```

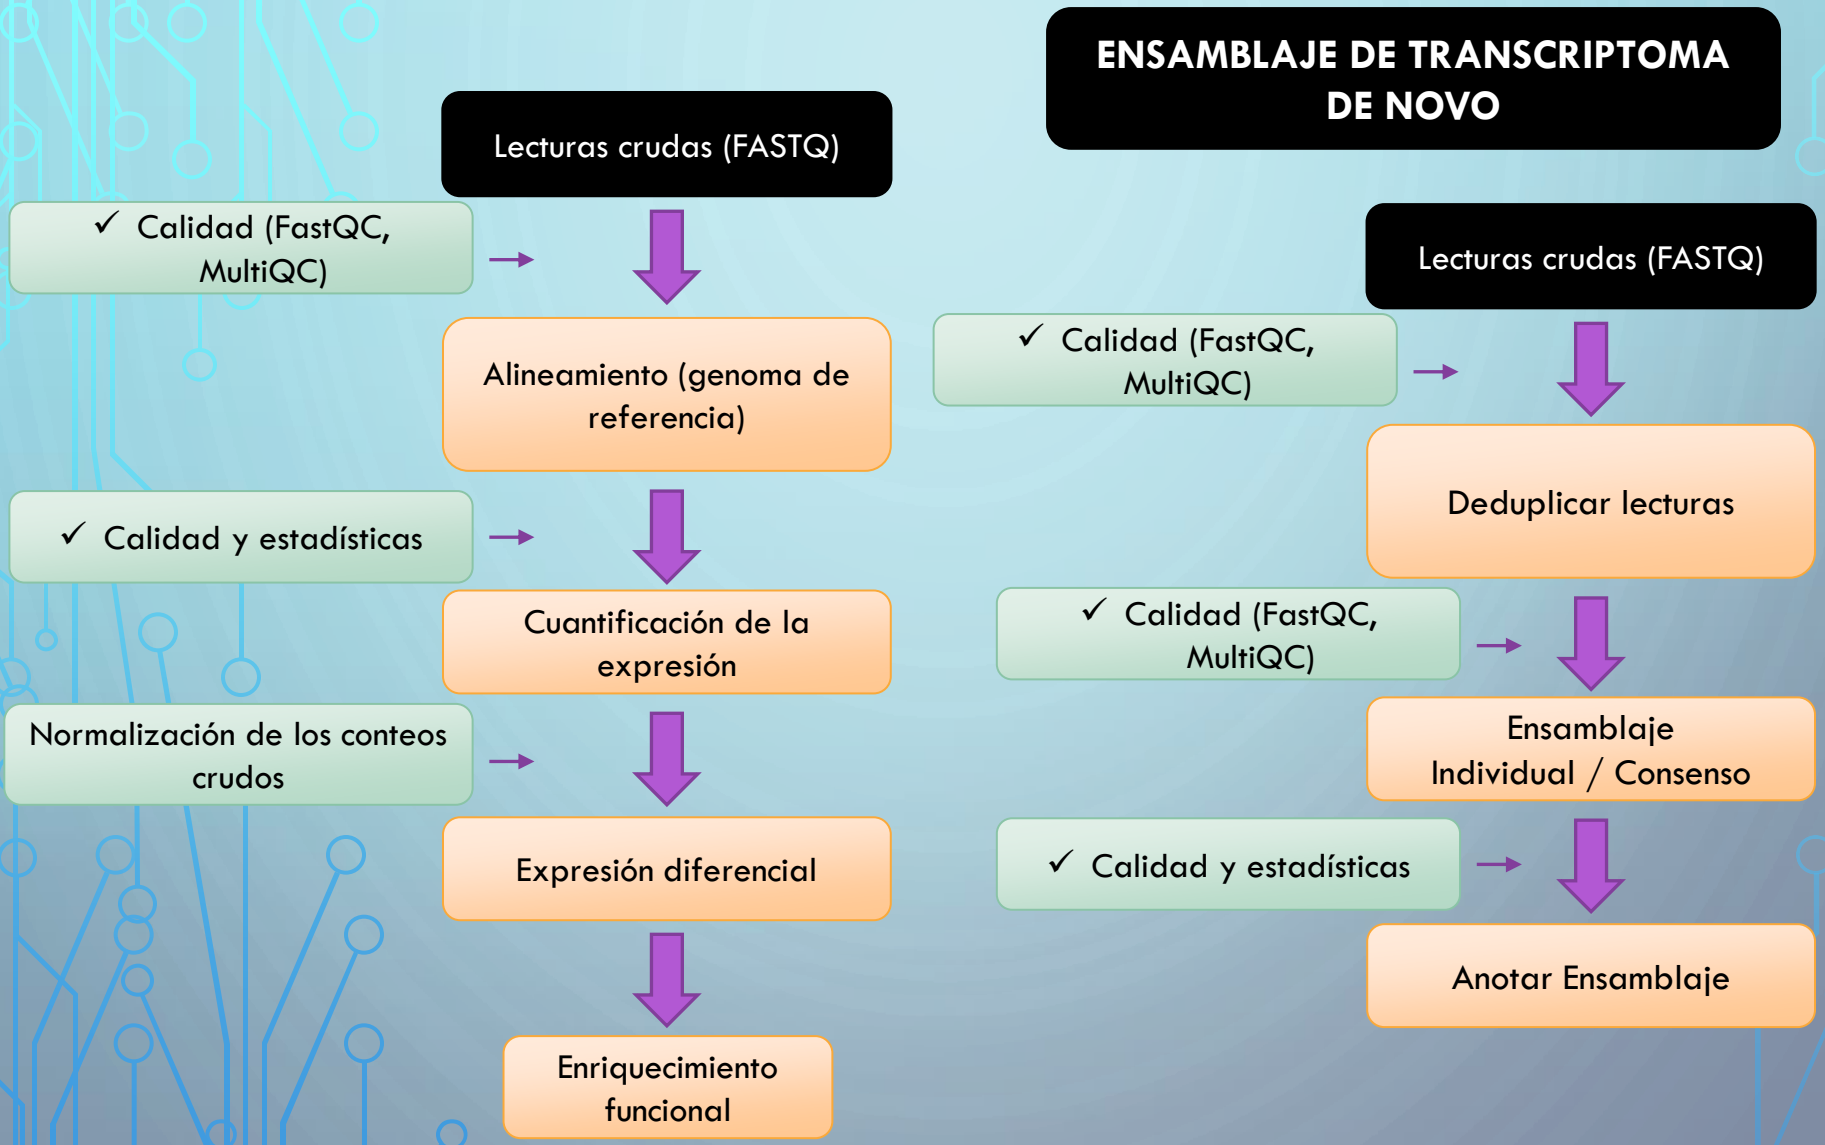
GEO2R | Options | Profile graph | R script

Enter ID: Dr.12739.1.A1_at Set View data for GPL1319



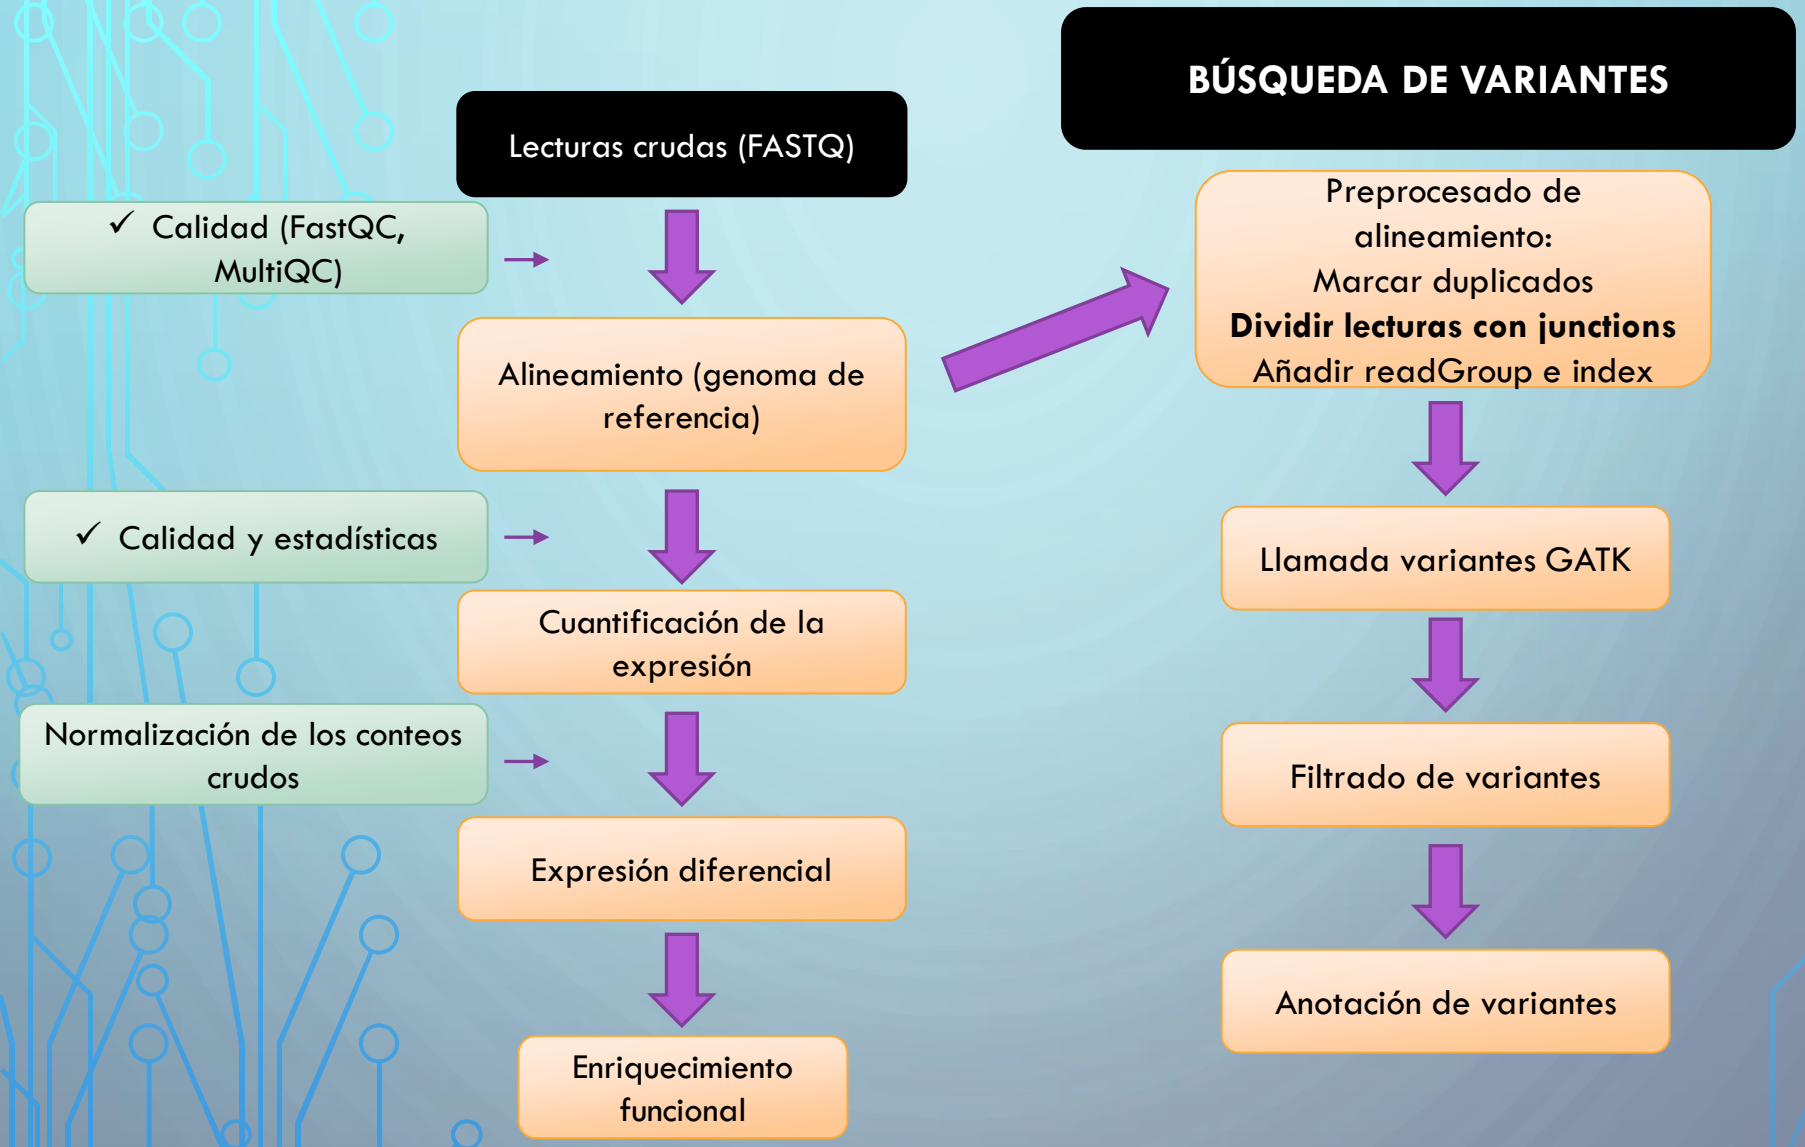
Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Otros análisis



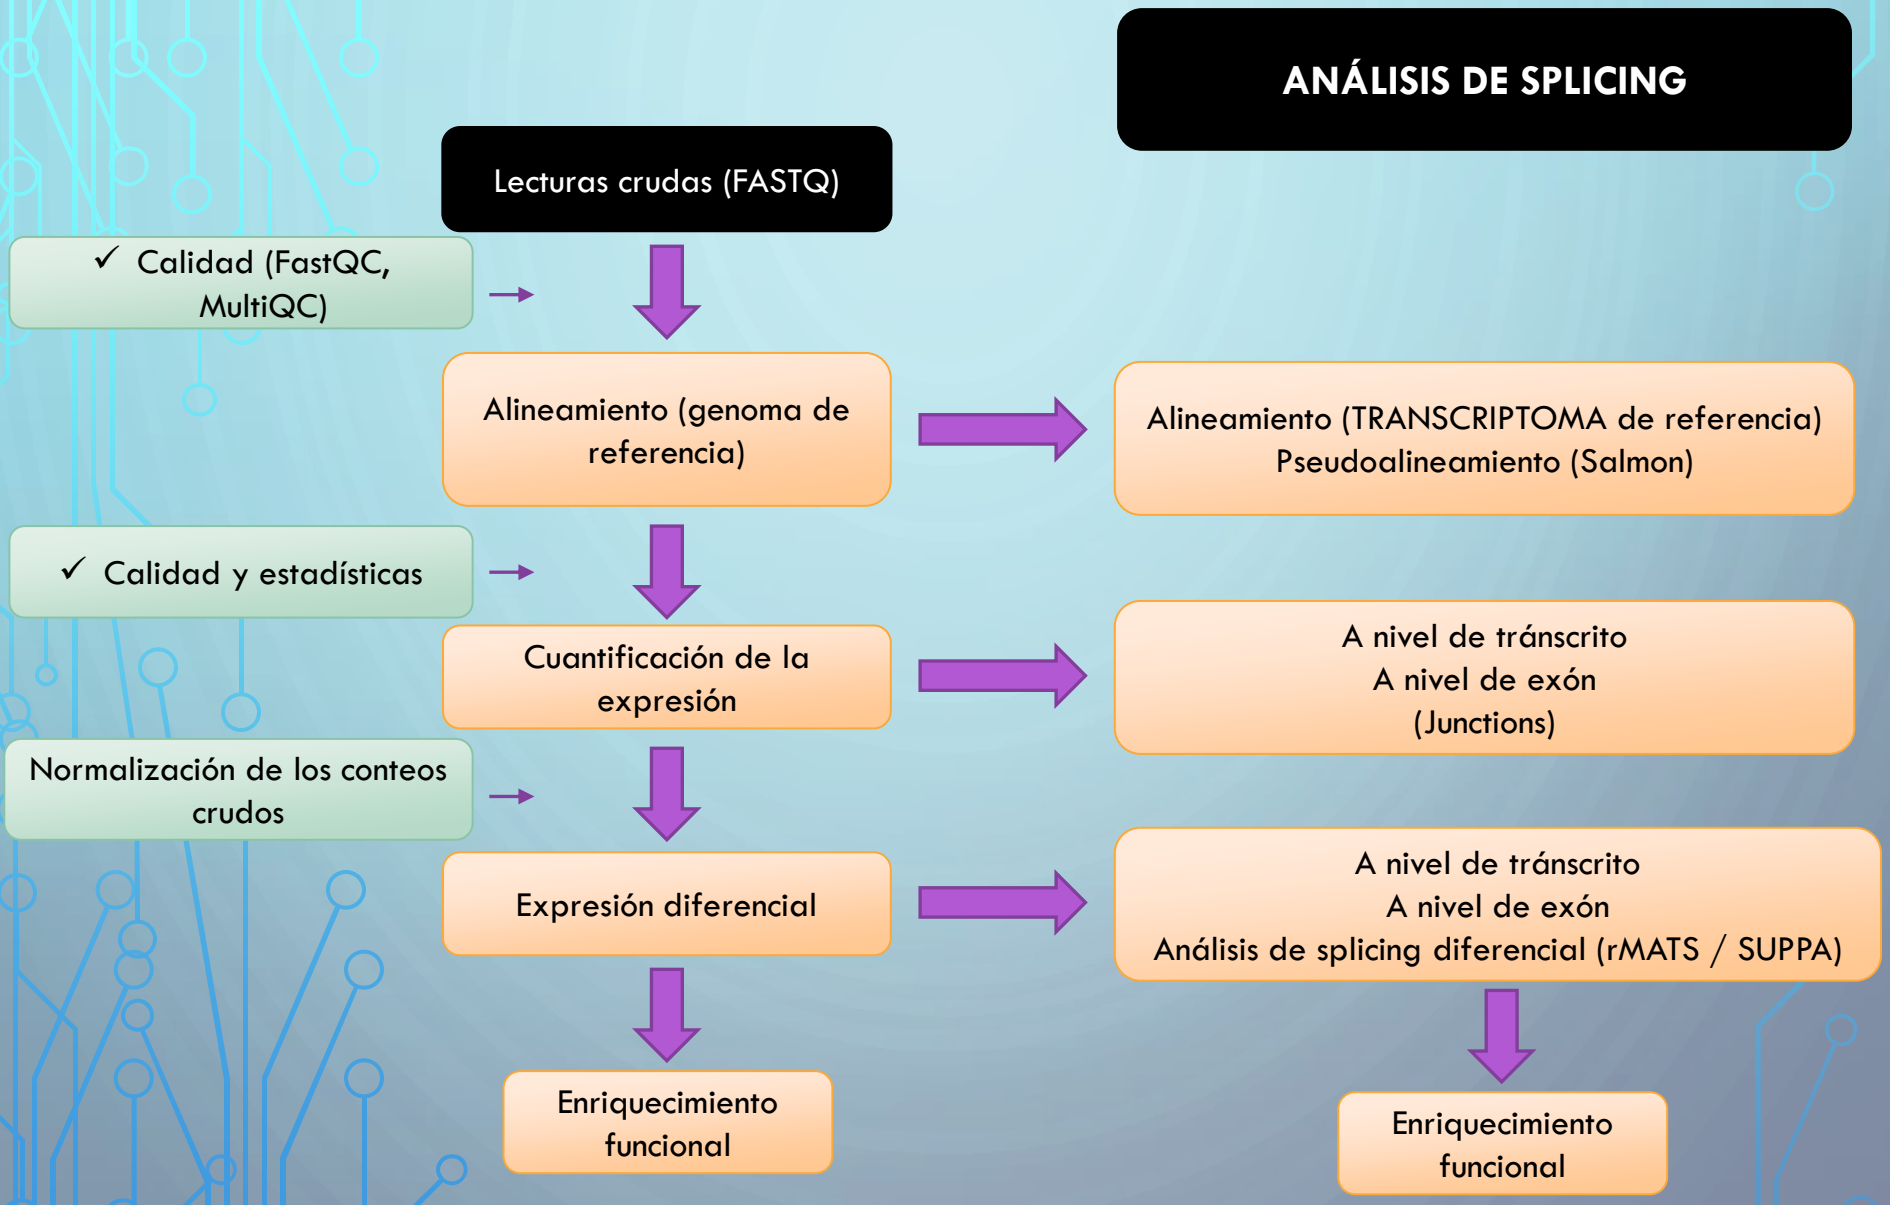
Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Otros análisis

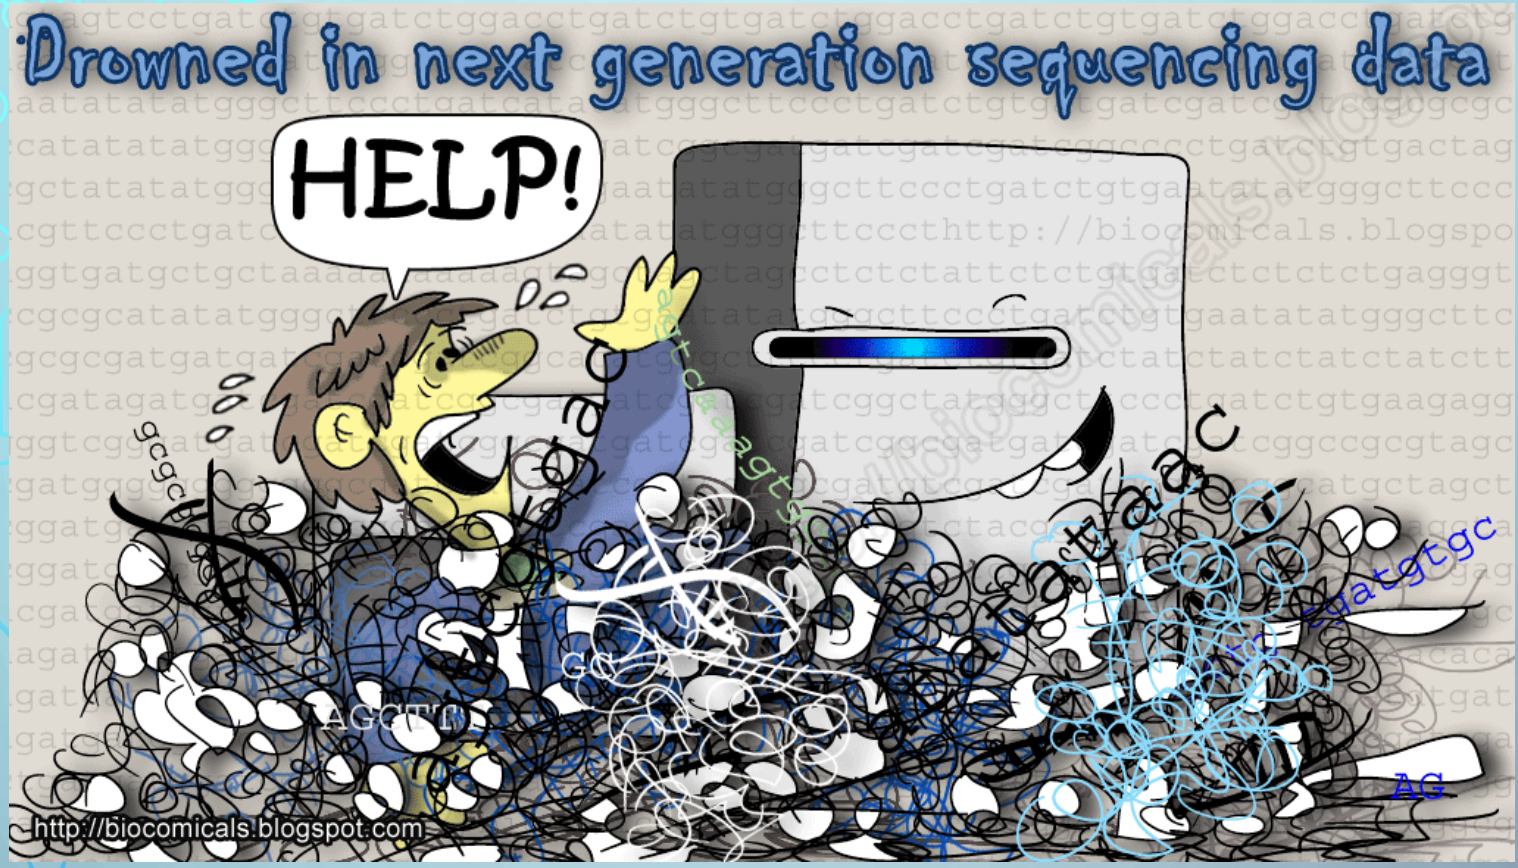


Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

RNAseq: Otros análisis



Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es



Gracias por su atención

¿Preguntas?

Servicio de Análisis BIOcomputacional (SABio)- Centro de Biología Molecular Severo Ochoa
sabio@cbm.csic.es

Servicio de Análisis Biocomputacional CBM



Dónde encontrarnos:

sabio@cbm.csic.es
CBM – Lab 313.2

-> Feedback
-> Docs
-> Encuesta