

ANÁLISIS DE DATOS SINGLE CELL RNA-SEQ

25 al 29 de mayo de 2026

1ª convocatoria 2026 del Gabinete de Formación (CSIC)

Servicio de Análisis Biocomputacional (CBM-CSIC)

Centro de Computación Científica (CCC-UAM)

PRESENTACIÓN

Servicio de **Análisis Biocomputacional (SABio)**



Begoña Aguado
(Scientific Lead)



Sandra González
(Facility Head)



María Santos Galindo



Paula Martínez



Eva Sacristán



María Santos Romero

OBJETIVOS DEL CURSO

Conocer los **fundamentos del scRNA-seq** y algunas de las principales tecnologías.

Entender la **estructura de los datos** de scRNA-seq.

Aplicar un **flujo de análisis de datos** de scRNA-seq, desde el procesamiento inicial de lecturas hasta la obtención de resultados biológicos interpretables.

- Procesar lecturas de secuenciación para generar matrices de conteos.
- Aplicar control de calidad y filtrados para eliminar ruido técnico y células de baja calidad.
- Implementar métodos de normalización y reducción de la dimensionalidad.
- Identificar grupos/clusters de células con perfiles de expresión similares.
- Anotación de tipos celulares.

Familiarizarse con algunos **análisis complementarios y aplicaciones avanzadas** de datos de scRNA-seq

CONTENIDO DEL CURSO

25

Lunes

L1: Introducción a scRNAseq

28

Jueves

L4: Clusterización y anotación

26

Martes

L2: Alineamiento y cuantificación

29

Viernes

L5: Análisis complementarios

27

Miércoles

L3: Control de calidad y normalización

01

Introducción a scRNA-seq


Diseño experimental, protocolo y tecnologías

SINGLE-CELL RNA-seq

RESULTS BY YEAR

53,047 results

Page 1 of 5,305




from pubmed.ncbi.nlm.nih.gov/
Busqueda: "single-cell RNAseq"

El número de publicaciones y proyectos basados en tecnologías de célula única ha experimentado un crecimiento exponencial desde la primera publicación de scRNA-seq en 2009

SINGLE-CELL RNA-seq

scRNA-seq permite estudiar el transcriptoma a nivel de célula única



APLICACIONES DEL SINGLE-CELL RNA-SEQ

- Identificación de tipos celulares (incluso raros o desconocidos).
- Estudiar heterogeneidad de la muestra.
- Identificar genes que se expresan diferencialmente en tipos celulares específicos.
- Investigar cambios en la expresión durante procesos de diferenciación.




Cancer
research



Neuroscience




Inmunology



Development
research

SINGLE-CELL VS. BULK RNA-seq



from <https://lizard.bio/blog/single-cell-vs-bulk/>

SINGLE-CELL VS. BULK RNA-seq

Bulk RNA-seq puede ser suficiente en ciertos escenarios, no hacer scRNA-seq a no ser que sea necesario.

¿Puede la pregunta ser respondida con bulk RNA-seq que es más sencillo y barato? ¿Y con una combinación de FACS y bulk RNA-seq?

DISEÑO EXPERIMENTAL

I. Número de células

Depende del número de poblaciones y la abundancia relativa de estas.

Por ejemplo, si secuenciamos una mezcla de ~10 tipos celulares donde la frecuencia del tipo celular más raro es ~0.03, necesitaríamos secuencias ~2200 células para tener una probabilidad del 90% de capturar al menos 50 de esas células.

<https://satijalab.org/howmanycells/>


II. Profundidad de secuenciación

Requiere conocimiento previo de la cantidad total de mRNA por célula y de la diversidad de mRNAs en esas células.

Difícil de estimar antes de llevar a cabo el experimento.

Teóricamente 250.000 lecturas por células son suficientes para tener precisión, 1M de lecturas por células sería lo ideal (Svensson et al. 2017). **Realidad** ~100.000 lecturas por célula o menos.

TECNOLOGÍAS DE SINGLE-CELL RNA-SEQ




TECNOLOGÍAS DE SINGLE-CELL RNA-SEQ

Cell capture

Plate-based



Microfluidics / Droplets



RNA quantification

Full Length



Medium/Low
throughput

Tag-based



High Throughput

PROTOCOLO EXPERIMENTAL scRNA-SEQ

- I. Preparación de la muestra
- II. Aislamiento de células únicas
- III. Etiquetado de moléculas de mRNA
- IV. Transcripción reversa
- V. Amplificación y preparación de librerías
- VI. Secuenciación

PREPARACIÓN DE
LA MUESTRA



AISLAMIENTO DE
CÉLULAS ÚNICAS



ETIQUETADO



PREPARACIÓN DE
LIBRERÍAS



SECUENCIACIÓN





PROTOCOLO EXPERIMENTAL scRNA-SEQ

II. AISLAMIENTO DE CÉLULAS ÚNICAS

Gotas

Las células son encapsuladas en microgotas

- GEMs (Gel bead-in-emulsion): 10X Genomics
- PIPs (Particle-templated Instant Partitions): Fluent/Illumina




PROTOCOLO EXPERIMENTAL scRNA-SEQ

II. AISLAMIENTO DE CÉLULAS ÚNICAS


Placa

Las células son encapsuladas en pocillos/micropocillos

- Pocillos: Smart-seq2
- Micropocillos: BD Rhapsody



BD Rhapsody




PROTOCOLO EXPERIMENTAL scRNA-SEQ

II. AISLAMIENTO DE CÉLULAS ÚNICAS

Célula


La propia célula permite la compartimentalización de los transcritos durante el etiquetado.

Parse Biosciences



PROTOCOLO EXPERIMENTAL scRNA-SEQ


III. ETIQUETADO DE TRÁNSCRITOS



PROTOCOLO EXPERIMENTAL scRNA-SEQ

III. ETIQUETADO DE TRÁNSCRITOS

Etiquetas/Barcodes: Secuencias de NTs de cierta longitud que se añaden al cDNA




PROTOCOLO EXPERIMENTAL scRNA-SEQ


III. ETIQUETADO DE TRÁNSCRITOS

UMIs (Unique Molecular Identifier): pequeña secuencia random que añade a cada molécula de RNA antes de la amplificación.

PCR duplicate removal **without** UMIs




PCR duplicate removal **with** UMIs




PROTOCOLO EXPERIMENTAL scRNA-SEQ

VI. SECUENCIACIÓN CON ILLUMINA



PROTOCOLO EXPERIMENTAL scRNA-SEQ

VI. SECUENCIACIÓN CON ILLUMINA



PROTOCOLO EXPERIMENTAL scRNA-SEQ

VI. SECUENCIACIÓN CON ILLUMINA

Illumina to sequence molecule



En las **REGIONES SECUENCIADAS** de la molécula tenemos que tener:

Sample barcode	Sample level barcode – same for all cells and RNAs in a library
Cell barcode	Cell level barcode – same for all RNAs in a cell
UMI	UMI – unique for one RNA molecule in one cell
cDNA	RNA fragment sequence

02

Formato de datos de NGS

FORMATO DE ARCHIVOS USADOS EN NGS

FASTA

- ">" identificador de la secuencia o descripción.
- Secuencia en sí misma

Genoma de referencia suele presentarse en este formato.

Extensiones: .fasta, .fa, .fna

```
>Sequence_id  
NUCLEOTIDSEQUENCE  
  
>chr1  
AAATATTCGGGATCGATTACTAAA
```

FORMATO DE ARCHIVOS USADOS EN NGS

FASTQ

(FASTA + calidades)

- Línea 1 empieza '@' identificador secuencia y una descripción opcional.
- Línea 2 secuencia cruda de nucleótidos.
- Línea 3 empieza con '+' y es un campo de texto libre.
- Línea 4 condifica los valores de calidad de la secuencia en la Línea 2.

Calidad (phred score) = probabilidad de que el basecall sea incorrecto.

Las lecturas (reads) suelen presentarse en este formato.

Extensiones: .fq, .fastq

```
@unique_sequence_identifier  
NUCLEOTIDSEQ  
+  
QU@L;TYSCORE
```

FORMATO DE ARCHIVOS USADOS EN NGS

GTF/GFF3

(General Transfer Format/ General Feature Format)

Una línea por cada “atributo” del genoma.

Nueve columnas por cada “atributo”

Opcionalmente puede incluir una columna adicional con información extra.

Más información: <https://www.ensembl.org/info/website/upload/gff.html>

```
##description: evidence-based annotation of the human genome (GRCh38), version 25 (Ensembl 85)
##provider: GENCODE
##contact: gencode-help@sanger.ac.uk
##format: gtf
##date: 2016-07-15
chr1 HAVANA gene 11869 14409 . + . gene_id "ENSG00000223972.5"; gene_type
"transcribed_unprocessed_pseudogene"; gene_status "KNOWN"; gene_name "DDX11L1"; level 2; havana_gene
"OTTHUMG00000000961.2";
chr1 HAVANA transcript 11869 14409 . + . gene_id "ENSG00000223972.5"; transcript_id "ENST00000456328.2"; gene_type
"transcribed_unprocessed_pseudogene"; gene_status "KNOWN"; gene_name "DDX11L1"; transcript_type
"processed_transcript"; transcript_status "KNOWN"; transcript_name "DDX11L1-002"; level 2; transcript_support_level "1"; tag
"basic"; havana_gene "OTTHUMG00000000961.2"; havana_transcript "OTTHUMT00000362751.1";
```

FORMATO DE ARCHIVOS USADOS EN NGS

SAM

(Sequence Alignment Map)

- Almacena información sobre alineamiento de secuencias a una secuencia de referencia.
- Consiste en una cabecera y una sección de alineamiento.
- Formato de texto separado por tabuladores.

```
@HD      VN:1.0  S0:coordinate
@SQ      SN:chr20      LN:64444167
@PG      ID:TopHat      VN:2.0.14      CL:/srv/dna_tools/tophat/tophat -N 3 --read-edit-dist 5 --read-realign-edit-dist 2 -i 50 -I 5000 --max-coverage-intron 5000 -M -o out /data/user446/mapping_tophat/index/chr20 /data/user446/mapping_tophat/L6_18_GTGAAA_L007_R1_001.fastq
HWI-ST1145:74:C101DACXX:7:1102:4284:73714      16      chr20      190930      3      100M      *      0      0
      CCGTGTTTAAAGGTGGATGCGGTCACCTTCCCAGCTAGGCTTAGGGATTCTTAGTTGGCCTAGGAAATCCAGCTAGTCCTGTCTCTCAGTCCCCCTCT
C      BBDCCDDCCDDDDDCDDDDDDCDCCDBC?DDDDDDDDDDDDDDDDCCDDDDDDDDDDCCCCEDDDC?DDDDDDDDDDDDDDDDDDDDDBDHFFFDC@@
      AS:i:-15      XM:i:3      XO:i:0      XG:i:0      MD:Z:55C20C13A9      NM:i:3      NH:i:2      CC:Z:=      CP:i:55352714      HI:i:0
HWI-ST1145:74:C101DACXX:7:1114:2759:41961      16      chr20      193953      50      100M      *      0      0
      TGCTGGATCATCTGTTAGTGGCTTCTGACTCAGAGGACCTTCGTCCTGGGGCAGTGGACCTTCCAGTGATTCCCCTGACATAAGGGGCATGGACGA
G      DCDDDDDDDDDDDDDDDDDDDDCCDDDDDDDEEC>DFFFEJJJJJIGJJJJIHGBHHGJIJJJJJJGJJJIJJJJJIHJJJJJJHHHHHHFFFFFCCC
      AS:i:-16      XM:i:3      XO:i:0      XG:i:0      MD:Z:60G16T18T3      NM:i:3      NH:i:1
HWI-ST1145:74:C101DACXX:7:1204:14760:4030      16      chr20      270877      50      100M      *      0      0
      GGCTTTATTGGTAAAAAAGGAATAGCAGATTTAATCAGAAATTCCCACCTGGCCCAGCAGCACCAACCAGAAAGAAGGGAAGAAGACAGGAAAAAACCA
C      DDDDDDDDDCCDDDDDDDDDEEEEEEEFFFEFFEGHHHFGDJJIHJJIIJJJJIIIGGFJJIIHIIIIJJJJJJIGHHFAHGFHJHFGGHFFDD@BB
      AS:i:-11      XM:i:2      XO:i:0      XG:i:0      MD:Z:0A85G13      NM:i:2      NH:i:1
HWI-ST1145:74:C101DACXX:7:1210:11167:8699      0      chr20      271218      50      50M4700N50M      *      0
      0      GTGGCTCTTCCACAGGAATGTTGAGGATGACATCCATGTCTGGGGTGCACTTGGGTCTCCGAAGCAGAACATCCTCAAATATGACCTCTCG
accepted_hits.sam
```

FORMATO DE ARCHIVOS USADOS EN NGS

BAM

(Binary Alignment Map)

- Representación binaria del archivo SAM.
- Comprimido y no legible directamente.
- Almacena información sobre alineamiento de secuencias a una secuencia de referencia.

FORMATO DE ARCHIVOS USADOS EN NGS

BED

(Browser Extensible Data)

- Usado para almacenar anotaciones de atributos genómicos
- 3 columnas obligatorias (chr, start, end) y 9 columnas opcionales.

```
chr1 213941196 213942363
chr1 213942363 213943530
chr1 213943530 213944697
chr2 158364697 158365864
chr2 158365864 158367031
chr3 127477031 127478198
chr3 127478198 127479365
chr3 127479365 127480532
chr3 127480532 127481699
```

<https://www.ensembl.org/info/website/upload/bed.html>

03

Análisis de datos de scRNAseq

scRNA-seq WORKFLOW

PREPARACIÓN DE
LA MUESTRA



AISLAMIENTO DE
CÉLULAS ÚNICAS



ETIQUETADO

PREPARACIÓN DE
LIBRERIAS




SECUENCIACIÓN



DATA ANALYSIS

ANÁLISIS FUNCIONAL

Anotación del tipo celular,
DEGs, ...



Control de calidad, filtrado,
normalización, reducción de la
dimensionalidad

ANÁLISIS SECUNDARIO
(independiente de plataforma)


CUANTIFICACIÓN POR
CÉLULA Y POR GEN

	Cell 1	Cell 2	...	Cell n
Gene 1	3 UMI	5		0
Gene 2	4	2		2
...				
Gene m	8	9		8


DATOS DE
SECUENCIACIÓN
(archivos FASTQ)

ANÁLISIS PRIMARIO
(dependiente de la
plataforma)

ANÁLISIS DE scRNA-seq




ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS



FORMATO FASTQ

- Formato estándar para almacenar datos de secuenciación y scores de calidad.
- Generado por los instrumentos de secuenciación.
- Punto de entrada para casi todos los análisis de NGS (incluido scRNAseq).




```
@unique_sequence_identifier  
NUCLEOTIDESEQ  
+  
QU@LITYSCORE
```


```
$ head sample1_R1.fq
```

```
@LH00587:250:22WW5WLT4:1:1101:10490:1042 1:N:0:TATTGCGCTC+CCTAACACAG  
CNGTTGTGATGGAAGGGAGTCAGTCTCGAGTGAATAGGGTGACGTTTTTTTTTTTTTTTTTTTTTTTGGAAAGCACGTCCAGGGGAGGAACC  
+  
I#|||||99999|99***g*G***g*****g****g99*99*99***g**g*9999*9g*****g**99**99***g***g  
@LH00587:250:22WW5WLT4:1:1101:10926:1042 1:N:0:TATTGCGCTC+CCTAACACAA  
TNAAAGAGTATGTACAGAGAGTCTACCTCGAGGGAGGTTTGCTACGTTTTTTTTTTTTTTTTTTTTTTTCCACTTTCTCTTCTCCCCCTCTCC  
+  
I#|||||99999|99***g*G***g*****g****g99*99*99***g**g*9999*9g*****g**99**99***g***g
```

ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS




CONTENIDO DEL FASTQ EN DIFERENTES TECNOLOGÍAS

10X



Sample1_R1.fastq
Sample1_R2.fastq
Sample1_I1.fastq




Sample, cell, UMI BC: R1/I1/I2
RNA (3'): R2

Parse Biosciences



Sublibrary_R1.fastq
Sublibrary_R2.fastq



Sample, cell, UMI BC: R2
RNA: R1


BD Rhapsody



Sublibrary_R1.fastq
Sublibrary_R2.fastq



SampleTag_R1.fastq
SampleTag_R2.fastq




Sample, cell, UMI BC: R1/ST1/2
RNA (3'): R2

Illumina/Fluent



Sample1_R1.fastq
Sample1_R2.fastq




Sample, cell, UMI BC: R1
RNA (3'): R2



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS

Illumina to sequence molecule



En las **REGIONES SECUENCIADAS** de la molécula tenemos que tener:

Sample barcode	Sample level barcode – same for all cells and RNAs in a library
Cell barcode	Cell level barcode – same for all RNAs in a cell
UMI	UMI – unique for one RNA molecule in one cell
cDNA	RNA fragment sequence



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS

MOLECULAR BARCODING ACROSS PLATFORMS

Illumina to sequence molecule



10X



Parse Bioscience



BD Rhapsody




Fluent/Illumina



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS

MOLECULAR BARCODING ACROSS PLATFORMS



Illumina to sequence molecule



La extracción de barcodes es específica de la tecnología



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS



Splice-aware aligners: STAR, Salmon, Kallisto, ...




ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS



ELIMINACIÓN DE DUPLICADOS DE PCR

Duplicados de PCR: secuencias con el mismo UMI y mismas coordenadas genómicas.


PCR duplicate removal **without** UMIs



PCR duplicate removal **with** UMIs



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS

ESTRUCTURA DE LA MATRIZ DE CONTEOS

MEX

- Stores only non-zero values

Sample_X folder

```
├── barcodes.tsv.gz
├── features.tsv.gz
└── matrix.mtx.gz
0 directories, 3 files
```

Sample X

	Cell 1	Cell 2	...	Cell n
Gene 1	3 UMI	5		0
Gene 2	4	2		5
...				
Gene m	8	6		8

← **barcodes**

features →

```
$ zcat barcodes.tsv.gz
```

```
AAAAAAAAAAAAATTCA #row 1 barcode (=cell)
AAAAAAAAAAAAACAAA
AAAAAAAAAAAAAGCAGTT
AAAAAAAAAAAAAGTAGTC
AAAAAAAAAAAAAGTCACG
```

```
$ zcat features.tsv.gz
```

```
ENSG00000197530    MIB2    Gene Expression #row 1 feature
ENSG00000189409    MMP23B   Gene Expression
ENSG00000248333    CDK11B   Gene Expression
ENSG00000189339    SLC35E2B Gene Expression
ENSG00000157933    SKI      Gene Expression
```

UMI counts

```
$ zcat matrix.mtx.gz
```


```
1 1 3 #feature in row 1 for cell in row 1 has 3 UMI count
3 2 1
7 2 6
1746 2 2
```

HDF5

- Single binary file, hierarchical internal structure and can store multiple datasets and metadata together
- More compact, scalable and faster to read/write
- May store dimensional reductions, layers (raw counts, normalized counts...)

ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS

PIPELINES/HERRAMIENTAS PARA EL ANÁLISIS PRIMARIO



10XGenomics/
cellranger



**Single Cell Data
Analysis with
Trailmaker**

STARsolo



BD

Advancing the
world of health



ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS

PIPELINES/HERRAMIENTAS PARA DATOS DE 10X GENOMICS

	Cell Ranger	STARsolo	Alevin	Kallisto		Cell Ranger	STARsolo	Alevin	Alevin-fry	Kallisto
Mapping scheme	Exact alignment	Exact alignment	Pseudo mapping	Pseudo mapping	Mapping performance	Longest runtime	- Short runtime - Comparable results with Cell Ranger	- Whitelisting causes loss or gain of barcodes	- Faster mapping in comparison with Alevin. - Pseudoalignment (sketch mode) further decreases runtime	- Shortest runtime - highest mapping rate
Internal Mapper	Star	Star	Salmon	Kallisto						
Reference	Genome	Genome	Transcriptome + Genome	Transcriptome	Barcode correction and filtering			- Detected barcodes that are not in the whitelist	- More barcodes are retained than in Alevin	- Reports more cells
Supported sequence technology	10X Chromium v1 – v3	10X Chromium v2:v3, Smart-seq, Drop-seq, inDrop	10x Chromium v2:v3, Drop-seq, Cel-seq, Cel-seq2, Quartz-seq2	10x Chromium v1 – v3, Cel-seq, Cel-seq2, Drop-seq, inDrops v1-v3, SCRB-Seq, SureCell						
Barcode correction	1-Hamming distance based	1-Hamming distance based	Edit distance calculation	1-Hamming distance based	Gene discovery				- Lower detection of Vmn and Olf gene family than in Alevin	- Highest detection rate of genes - Highest UMI count for genes not expressed in studied tissue
Whitelisting	Whitelist based	Whitelist based	Frequency based, no whitelist needed	Whitelist based						
Alternative Splicing detection	no	yes	no	no	Differences between filtered and unfiltered annotation	- Multi-mapped reads are discarded	- Multi-mapped reads are discarded - EM-algorithm can be used (optional)	- Counts of multi-mapped reads split with EM-algorithm	- Multi-mapped reads are discarded - EM-algorithm can be used (optional)	- Multi-mapped reads are discarded - EM-algorithm can be used (optional)
UMI correction	Two round correction by barcode, read count and annotation Suffix array	Two round correction by barcode, read count and annotation Suffix array	graph based correction	NA						
Index			Colored De-Brujin Graph	Colored De-Brujin Graph	Clustering	- Highest Overlap with SCINA classification	- Very similar to Cell Ranger with minor differences	- Cell types contain lower amount of cells with SCINA classification		- High amount of barcodes not detected
Handling of multimapped reads	discarded	discarded	Distributing read count between genes by EM-algorithm	discarded		- No difference detected	- No difference detected	- Lower detection rate than STARsolo and Alevin-fry	- Improved concordance (than Alevin) with Cell Ranger	- Lowest concordance with Cell Ranger
Output	Matrix + Bam-File and summary file as html-file with primary results as well as clustering and DEG analysis	Gene count matrix and primary results summary	Gene count matrix ready for analysis	External software required to create gene count matrix	Practical Recommendation	- Replacement with STARsolo is recommended	- Recommended as a general purpose mapper		- Pseudoalignment is especially suitable for huge datasets	- Fast mapper - qualitative issues with gene detection

Ralf Schulze Brüning, Lukas Tombor, Marcel H Schulz, Stefanie Dimmeler, David John, Comparative analysis of common alignment tools for single-cell RNA sequencing, *GigaScience*, Volume 11, 2022, giac001, <https://doi.org/10.1093/gigascience/giac001>

ANÁLISIS PRIMARIO: DEL FASTQ A LA MATRIZ DE CONTEOS

PIPELINES/HERRAMIENTAS PARA DATOS DE 10X GENOMICS

STAR solo da resultados casi idénticos más rápido, pero no permite la integración con Loupe.

Cell Ranger está desarrollado (preconfigurado) para la estructura de FASTQ de 10X.

Pseudo-alineadores son más rápidos, pero generan artefactos y no incluyen datos intrónicos.

scRNA-seq WORKFLOW

PREPARACIÓN DE
LA MUESTRA



AISLAMIENTO DE
CÉLULAS ÚNICAS



ETIQUETADO

PREPARACIÓN DE
LIBRERIAS




SECUENCIACIÓN



DATA ANALYSIS

ANÁLISIS FUNCIONAL

Anotación del tipo celular,
DEGs, ...



Control de calidad, filtrado,
normalización, reducción de la
dimensionalidad

ANÁLISIS SECUNDARIO
(independiente de plataforma)

CUANTIFICACIÓN POR
CÉLULA Y POR GEN





	Cell 1	Cell 2	...	Cell n
Gene 1	3 UMI	5		0
Gene 2	4	2		2
...				
Gene m	8	9		8

DATOS DE
SECUENCIACIÓN
(archivos FASTQ)


ANÁLISIS PRIMARIO
(dependiente de la
plataforma)

WORKFLOW DE ANÁLISIS SECUNDARIO

	Cell 1	Cell 2	...	Cell n
				
Gene 1	3 UMI	5		0
Gene 2	4	2		2
...				
Gene m	8	9		8




WORKFLOW DE ANÁLISIS SECUNDARIO




CALIDAD DE LOS DATOS

- Número de genes por célula
- Número de UMIs por célula
- Contenido mitocondrial





WORKFLOW DE ANÁLISIS SECUNDARIO




FILTRADO DE CÉLULAS CON BAJA CALIDAD

- NÚMERO TOTAL DE UMIs POR CÉLULA

Barcodes with low UMI counts may be empty droplets/ambient RNA and no real cells.




WORKFLOW DE ANÁLISIS SECUNDARIO



FILTRADO DE CÉLULAS CON BAJA CALIDAD


- NÚMERO TOTAL DE UMIs POR CÉLULA
- LECTURAS MITOCONDRIALES

High mitochondrial content is associated with unhealthy or broken cells.




$$\text{Proportion of mitochondrial content} = \frac{\# \text{ Mito UMIs}}{\text{Total \# UMIs}}$$

WORKFLOW DE ANÁLISIS SECUNDARIO



FILTRADO DE CÉLULAS CON BAJA CALIDAD

- NÚMERO TOTAL DE UMIs POR CÉLULA
- LECTURAS MITOCONDRIALES
- FILTRADO DE DOBLETES




Multiple cells present in a single droplet/well (doublet) > labelled with the same barcode.



scDblFinder

- Simulates doublets based on expression data.
- Train a classifier with real and simulated data.
- Once trained, associate a doublet score/probability to each cell.
- Cells with high probability of being a doublet should be filtered out.

WORKFLOW DE ANÁLISIS SECUNDARIO



NORMALIZACIÓN

El conteo de UMIs se ve influenciado por factores técnicos que pueden enmascarar señales biológicas:


- Profundidad de secuenciación
- Eficiencia en la captura de RNA
- Amplificación en la PCR
- Contenido total de RNA por célula

La normalización reduce los bias técnicos y las variaciones no biológicas

Métodos populares de normalización son:

- Log normalization
- SCTransform

WORKFLOW DE ANÁLISIS SECUNDARIO




ENCONTRAR GENES VARIABLES

De los ~30.000 genes cuantificados, la mayoría de ellos no son informativos (0 conteos o no variables)

Ranqueo de genes en base a su variabilidad entre células

Seleccionar los N genes más variables (HVGs; Highly Variable Genes)


from Seurat
`FindVariableFeatures()`



FindVariableFeatures
(Seurat)



WORKFLOW DE ANÁLISIS SECUNDARIO



REDUCCIÓN DE LA DIMENSIONALIDAD


Interpretación del espacio multi-dimensional (miles de genes en miles de células) directamente, es difícil.

- Paso estándar en el análisis de datos de single-cell
- Reduce el ruido, facilita la visualización (2D) y reduce el tiempo de computación.

PCA

- Método de reducción lineal de la dimensionalidad.
- Encuentra un set de variables – componentes principales (PCs) – que capturan el máximo de la varianza de los datos.
- Extensamente usado como un paso inicial de reducción de ruido y compression de los datos.
- Usado para genera el input para otros métodos no lineares (e.g., t-SNE or UMAP).

WORKFLOW DE ANÁLISIS SECUNDARIO



REDUCCIÓN DE LA DIMENSIONALIDAD


Nonlinear method optimized for visualizing high-dimensional data in two or three dimensions.

t-SNE


- Preserves local relationships between cells.
- It may distort global relationships, making distances between clusters difficult to interpret.

UMAP:

- UMAP is generally faster than t-SNE and can scale better with larger datasets.
- It often produces embeddings that appear to better represent the global arrangement of clusters.




WORKFLOW DE ANÁLISIS SECUNDARIO




CLUSTERING

Agrupar las células con perfiles de expresión similares, a menudo estas agrupaciones se corresponden con tipos celulares específicos, subtipos o estados.




WORKFLOW DE ANÁLISIS SECUNDARIO



IDENTIFICAR MARCADORES DE CLUSTER

Encontrar genes diferencialmente expresados para cada cluster.



from Seurat

WORKFLOW DE ANÁLISIS SECUNDARIO


ANOTACIÓN DEL TIPO CELULAR

Manual:


- Identificador de un set de genes marcadores por cluster y asignar el cluster a un tipo celular

Automática:

- **Métodos basados en genes marcadores:** basados en la expresión de genes marcadores de tipo celular en el cluster (ej. scType)
- **Métodos basados en correlación:** comparar los perfiles de expresión de una referencia con el dataset de interés (ej. SingleR, Seurat Anchor based method).
- **Métodos de clasificación supervisada:** técnicas de machine learning que entrenan a un clasificador en datasets de referencia anotados. Una vez entrenado, el modelo puede predecir el tipo celular de datos nuevos no anotados (ej. CellTypist).






from Seurat



OTROS ANÁLISIS POSTERIORES

- Análisis de expresión diferencial y rutas
- Análisis de composición de células
- Análisis de comunicación entre células
- Análisis de trayectoria celular



04

Introducción a Linux

SINTAXIS EN BASH

Muchas **instrucciones en Bash** se componen de:

- **Comando:** instrucción que quieres ejecutar.
- **Opciones:** modifican el comportamiento del comando.
- **Argumento:** objetos sobre los que el comando actúa.

Comentarios que no se ejecutan

comando --**opciones** (-o) **argumentos**

Ejemplo:

Muestra las 10 primeras líneas de un fichero

head **mi_texto.txt**

Muestra las 100 primeras líneas de un fichero

head --**lines** 100 **mi_texto.txt**

Muestra las 100 primeras líneas de un fichero


head -n 100 **mi_texto.txt**

SISTEMA DE ARCHIVOS EN LINUX

Set jerárquico de directorios.

Cada directorio puede contener archivos.

No se requieren extensiones de fichero (.tsv, .png, ...), aunque se pueden añadir.



SISTEMA DE ARCHIVOS EN LINUX

Especificación de rutas

Si estoy en /home/user

- Ruta absoluta:

`/home/user/Data/big_data.fq.gz`

- Ruta relativa:

`Data/big_data.fq.gz`



Shortcuts

~ (tilde) – el directorio home del usuario actual

. (un solo punto) – el directorio actual

.. (dos puntos) – el directorio inmediatamente por encima del directorio actual

SISTEMA DE ARCHIVOS EN LINUX

`pwd` – imprime el directorio de trabajo

`cd` – cambiar de directorio, sirve para navegar entre carpetas

`mkdir` – crear un directorio

```
[user@server ~]$ pwd  
/home/user
```

```
[user@server ~]$ mkdir dia1
```

```
[user@server ~]$ cd dia1  
[user@server dia1]$ pwd  
/home/user/dia1
```

```
[user@server dia1]$ cd ..  
[user@server ~]$ pwd  
/home/user/dia1
```

SISTEMA DE ARCHIVOS EN LINUX

Command line completion

- Command line completion is achieved by typing a partial path and then pressing the TAB key (to the left of Q).
- You should use TAB completion to fill in paths for locations which exist so you can't make typing mistakes.

INTRODUCCIÓN A LINUX

WILDCARDS

Una forma rápida de especificar múltiples rutas relacionadas.

Hay dos wildcards principales:

- ***** = Cualquier número de cualquier carácter
- **?** = Uno de cualquier carácter

Se pueden incluir en cualquier punto de la ruta a un archivo y la shell lo expande antes de pasárselo a un programa.

La “command line completion” no funciona después del primer wildcard.

INTRODUCCIÓN A LINUX

`ls` – lista los archivos en un directorio

EJEMPLOS DE WILDCARDS

```
$ ls Monday/*txt
```

```
Monday/mon_1.txt  Monday/mon_2.txt  Monday/mon_3.txt  
Monday/mon_500.txt
```

```
$ ls Monday/mon_?.txt
```

```
Monday/mon_1.txt  Monday/mon_2.txt  Monday/mon_3.txt
```

```
$ ls */*txt
```

```
Friday/fri_1.txt  Monday/mon_1.txt  Monday/mon_3.txt  
Tuesday/tue_1.txt  
Friday/fri_2.txt  Monday/mon_2.txt  Monday/mon_500.txt  
Tuesday/tue_2.txt
```

```
$ ls */*1.txt
```

```
Friday/fri_1.txt  Monday/mon_1.txt  Tuesday/tue_1.txt
```

MANIPULACIÓN DE ARCHIVOS

VISUALIZACIÓN DE ARCHIVOS

`cat [archivo]` Envía el contenido entero de un archivo (o múltiples archivos) a pantalla.

`head` o `tail` para mirar el principio/final de un archivo en pantalla.

- `head -10 [archivo]`
- `tail -20 [archivo]`

`less` ‘paginador’ interactivo que permite visualizar archivos de texto grandes directamente en la terminal

EDICIÓN DE ARCHIVOS

`nano` editor de línea de comando. Si el archivo existe, lo abre, si no, lo crea.

MANIPULACIÓN DE ARCHIVOS

MOVER Y RENOMBRAR

`mv` - se usar para mover y renombrar (mover de un nombre a otro)

`mv [archivo o directorio] [nuevo nombre/ubicación]`

Mover un directorio mueve también todo su contenido

Ejemplos

```
mv old.txt new.txt
```

```
mv old.txt ../Saved/
```

```
mv old.txt ../Saved/new.txt
```

```
mv ../Saved/old.txt .
```

MANIPULACIÓN DE ARCHIVOS

COPIAR

```
cp - copiar  
cp [archivo] [nuevo archivo]
```

Actúa sobre un único archivo

Puede usarse para copiar directorios aplicado de forma recursive (`cp -r`)

Ejemplos

```
cp old.txt new.txt  
cp old.txt ../Saved/  
cp old.txt ../Saved/new.txt  
cp ../Saved/old.txt .  
cp -r ../Saved ./NewDir  
cp -r ../Saved ./ExistingDir/
```

MANIPULACIÓN DE ARCHIVOS

LINK SIMBÓLICOS

`ln` – crear un link simbólico

`ln -s [from] [to]`

Copiar implica duplicar los datos en un archivo, lo que puede suponer un problema cuando se trabaja con archivos pesados.

Los link son una manera de hacer una copia “virtual”.

Haciendo un `ls` se puede ver a dónde apunta el link simbólico.

```
$ cat test.txt  
This is a test file
```

```
$ ln -s test.txt test2.txt  
$ ls -l test2.txt  
lrwxrwxrwx 1 babraham babraham 8 Sep 11 16:27 test2.txt -> test.txt
```

```
$ cat test2.txt  
This is a test file
```

MANIPULACIÓN DE ARCHIVOS

BORRADO

`rm` – eliminar un archivo

```
rm test.txt
```

Para eliminar directorios se usa `rm -r`

Ejemplos

```
rm test_file.txt test_file2.txt
```

```
rm *.txt # hay que tener mucho cuidado usando wildcards con rm
```

```
rm -r Old_directory/
```

ITERACIÓN SOBRE ARCHIVOS

LOOP CON `for` EN BASH

Cuando se procesan datos es común necesitar correr el mismo comando multiples veces para diferentes archivos de input/output.

Crea una variable temporal en el ambiente que puede ser usada dentro de los comandos.

Ejemplo:

```
for file in *.txt
do
    echo ${file}
done
```

CONCATENAR COMANDOS (PIPELINES)

En UNIX programas/comandos sencillos se pueden concatenar para hacer tareas más complejas.

Los ‘pipes’ o tuberías (|) se puede usar para conectar la salida estándar (STDOUT) de un programa con la entrada (STDIN) del siguiente.

Algunos programas útiles para concatenar:

wc	- para contar palabras y líneas
grep	- para buscar un patrón
sort	- para ordenar
uniq	- para deduplicar cosas ordenadas
Zcat	- para descomprimir e imprimir texto

CONCATENAR COMANDOS (PIPELINES)

Ejemplos de pipelines:

```
$ zcat file.fq.gz | wc -l  
179536960
```

```
$ zcat file.fq.gz | grep TTAGGGTTAGGG | wc -l  
3925
```

05


Descarga de lecturas y
análisis de calidad

DESCARGA DE DATOS 10X GENOMICS


[Products](#)[Resources](#)[Support Hub](#)[Company](#)[Order status](#)[Store](#)

Datasets

Explore and download datasets created by 10x Genomics.



Chromium Single Cell - Featured Dataset
320k Cells from 8 Human Tissues, 16-Plex
(scFFPE)



Atera In Situ - Featured Dataset
Preview Data: Atera In Situ Gene
Expression, Human Cervical Cancer
(FFPE)

Visium Spatial - Featured Dataset

Visium HD Gene Expression, 11 mm Capture Area,
Human Colon Cancer (Fresh Frozen)

Xenium In Situ - Featured Dataset

Xenium In Situ Gene and Protein Expression data for
Human Renal Cell Carcinoma (FFPE)

Search datasets

Top searches

[Atera](#)[PBMC](#)[Xenium](#)[HD](#)[GEM-X](#)[Flex](#)[Cell Segmentation](#)[Breast Cancer](#)[Mouse Brain](#)[Brain](#)[Lung](#)[FFPE](#)

Filter datasets



10x Genomics product

Platform



Product



Chemistry version



Additional application



Software



Pipeline version



Datasets (Showing 774 datasets)

Product

Species

Sample type

Cells or nuclei

Preservation

Visium HD Spatial Gene Expression Library, Human Lung
Cancer, Breast Cancer and Colon Cancer Tissue Array (FFPE),
11 mm Capture Area

HD Spatial Gene Expression v1 -
Protocol 2.0



Human

Lung, Breast, Colon

N/A

FFPE

Visium HD Spatial Gene Expression Library, Human Breast
Cancer Tissue Microarray (FFPE), 11 mm Capture Area

HD Spatial Gene Expression v1 -
Protocol 2.0



Human

Breast

N/A

FFPE

Visium HD Spatial Gene Expression Library, Human Colon
Cancer (FF), 11 mm Capture Area

HD Spatial Gene Expression v1 -
Protocol 2.0



Human

Colon

N/A

Fresh Frozen

<https://www.10xgenomics.com/datasets>

DESCARGA DE DATOS 10X GENOMICS

[Products](#)[Resources](#)[Support Hub](#)[Company](#)[Order status](#)[Store](#)[< All datasets](#)

1k PBMCs from a Healthy Donor (v3 chemistry)

Universal 3' dataset analyzed using Cell Ranger 3.0.0

Dataset overview **Output and supplemental files** **Input files**


Peripheral blood mononuclear cells (PBMCs) from a healthy donor (the same cells were used to generate pbmc_1k_v2, pbmc_10k_v3). PBMCs are primary cells with relatively small amounts of RNA (~1pg RNA/cell).

- 1,222 cells detected
- Sequenced on Illumina NovaSeq with approximately 54,000 reads per cell
- 28bp read1 (16bp Chromium barcode and 12bp UMI), 91bp read2 (transcript), and 8bp I7 sample barcode
- run with `--expect-cells=1000`

This dataset is licensed under the Creative Commons Attribution 4.0 International ([CC BY 4.0](#)) license. 10x citation guidelines available [here](#).

<https://www.10xgenomics.com/datasets/1-k-pbm-cs-from-a-healthy-donor-v-3-chemistry-3-standard-3-0-0>

ESTRUCTURA DE LECTURAS DE 10X GENOMICS



ESTRUCTURA DE LECTURAS DE 10X GENOMICS

NOMBRES DE ARCHIVO

I1 - Sample level index read

R1 - Barcode read

- 16bp cell level barcode
- 10bp UMI

R2 - 3' RNA-seq read

L = Lane
↙

sample1_S1_L001_I1_001.fastq.gz
sample1_S1_L001_R1_001.fastq.gz
sample1_S1_L001_R2_001.fastq.gz

↑
S = Sample

ANÁLISIS DE CALIDAD DE LAS LECTURAS


Identificar problemas relacionados con la preparación de librerías o la secuenciación

```
# Crea un directorio en el que almacenar los resultados  
mkdir /home/curso/dia1/fastqc
```

```
# Genera informes de calidad de las secuencias  
fastqc *.fastq.gz -t 6 --outdir /home/curso/dia1/fastqc
```

```
# Agrega los informes generados en un único informe  
multiqc /home/curso/dia1/fastqc
```

FASTQC - Adapter content



FASTQC REPORTS


BASIC STATISTICS

Measure	Value
Filename	pbmc_1k_v3_S1_L001_R1_001.fastq.gz
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	33436697
Total Bases	936.2 Mbp
Sequences flagged as poor quality	0
Sequence length	28
%GC	47

Measure	Value
Filename	pbmc_1k_v3_S1_L001_R2_001.fastq.gz
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	33436697
Total Bases	3 Gbp
Sequences flagged as poor quality	0
Sequence length	91
%GC	45

FASTQC REPORTS

PER BASE SEQUENCE QUALITY




pbmc_1k_v3_S1_L001_R2_001.fastq.gz


FASTQC REPORTS

PER BASE SEQUENCE CONTENT

⚠ Per base sequence content




⚠ Per base sequence content



FASTQC REPORTS

PER BASE SEQUENCE CONTENT




pbmc_1k_v3_S1_L001_R2_001.fastq.gz

ANÁLISIS DE CALIDAD DE LAS LECTURAS

SEQUENCE DUPLICATION LEVELS

❌ Sequence Duplication Levels




pbmc_1k_v3_S1_L001_R2_001.fastq.gz

ANÁLISIS DE CALIDAD DE LAS LECTURAS

SEQUENCE DUPLICATION LEVELS

✔ Adapter Content



pbmc_1k_v3_S1_L001_R2_001.fastq.gz

