




ANÁLISIS DE DATOS SINGLE CELL RNA-SEQ

Del preprocesamiento a la exploración con Seurat

Sesión 1: CellRanger y CellBender

Sesión 2: RStudio y Seurat

1ª convocatoria 2026 del Gabinete de Formación (CSIC)

Servicio de Análisis Biocomputacional (CBM-CSIC)

Centro de Computación Científica (CCC-UAM)

25 al 29 de mayo de 2026

FLUJO DE DATOS

01 / Entrada y Filtro

Lecturas RAW en FASTQ.
Identificación de códigos de barras celulares (barcodes) y conteo de UMIs

02 / Alineamiento


Mapeo de lecturas frente a genoma de referencia indexado.

03 / Cuantificación

Generación de la matriz dispersa final (Genes x Células) lista para cargar en Seurat o Scanpy.

FLUJO DE DATOS: DEL FASTQ A LA MATRIZ DE CONTEOS

- Este preprocesado implica: transformar los **archivos FASTQ** en **matrices de conteo** a través del alineamiento, corrección de barcodes y conteo de UMIs.
- Esta **matriz** representa el número estimado de moléculas distintas derivadas de cada gen por célula cuantificada



https://www.sc-best-practices.org/introduction/raw_data_processing.html#introduction-raw-data-processing-key-takeaway-1

**Después de obtener los archivos FASTQ crudos, es importante evaluar la calidad de las lecturas de secuenciación. Una forma rápida y eficaz de hacerlo es utilizando herramientas de control de calidad (QC) como FastQC.

HERRAMIENTAS

- **Cell Ranger** (Estándar Comercial Oficial 10x Genomics)
- **Mecanismo:** Automático mediante comando 'cellranger count'.

☐ **Alineamiento:** Usa alineador STAR

☐ **Conteo de UMIs:** Usa únicamente las lecturas alineadas con alta confianza que poseen barcodes y UMIs válidos:

1. **Corregir los UMIs:** Los UMIs se corrigen reemplazándolos por aquellos más abundantes que presenten un solo error de emparejamiento en su secuencia (**distancia de Hamming = 1**). Analiza también la calidad de cada base **Q-score** para decidir si la sustitución fue un error real de la máquina o un UMI biológico distinto.
2. **Registrar duplicados de PCR:** Se identifica y registra qué lecturas son duplicados exactos de la misma molécula de ARN.
3. **Contar moléculas únicas:** Se contabilizan únicamente los UMIs únicos como moléculas de ARN originales

- **STARsolo** (Módulo de STAR avanzado para single-cell)
- **Ventajas:** Velocidad hasta 10 veces mayor, imitando con exactitud los criterios de Cell Ranger.
- **Compatibilidad:** Admite 10x, Drop-seq, SPLiT-seq y personalización absoluta de whitelists (con tu propia lista de códigos de barras)

OPCIONES DE: STARsolo

--soloType

Define la configuración de las lecturas. Habitualmente se usa 'CB_UMI_Simple' si el código de barras y UMI se sitúan consecutivos en RI.

--soloCBwhitelist

Enlace directo al archivo plano proporcionado por el desarrollador del kit que contiene el diccionario válido de códigos de barras.

--soloFeatures Gene

Conteo molecular clásico. Procesa y cuantifica estrictamente las lecturas mapeadas sobre exones correspondientes a ARN maduro.

--soloFeatures GeneFull

Conteo inclusivo de exones e intrones. Es una opción fundamental e indispensable si estás analizando núcleos aislados (snRNA-seq).

EJECUCIÓN DE STARsolo

```
# Paso 1: Generación única del índice genómico de referencia
STAR --runMode genomeGenerate --genomeDir /ruta/indice_star \
    --genomeFastaFiles hg38.fa --sjdbGTFfile genes.gtf --runThreadN 12

# Paso 2: Ejecución del mapeo rápido y cuantificación celular
STAR --genomeDir /ruta/indice_star --readFilesCommand zcat \
    --readFilesIn R2_reads.fastq.gz R1_barcodes.fastq.gz \
    --soloType CB_UMI_Simple --soloCBwhitelist /ruta/10x_v3_whitelist.txt \
    --soloCBlen 16 --soloUMIlen 12 --soloFeatures Gene GeneFull --runThreadN 12

# El resultado final se almacena en directorios locales listos: 'Solo.out/'
```

Salidas generadas en formato unificado: matrix.mtx, barcodes.tsv y features.tsv.

Fluent BioScience

Fluent BioScience (PIPSeeker)

- **Concepto:** Emulsión inducida por microesferas pre-diseñadas dentro de un solo tubo de ensayo
- **Pipeline:** 'PIPseq-tools'. Utiliza comando: 'pipseeker'.
- **Alineamiento:** Se proporciona **índice de STAR** para alinear.
- **Conteo: Algoritmo Propietario de Deduplicación por Coordenadas (IMI):** Algoritmo nativo de Fluent BioSciences que calcula el conteo molecular basándose en la coincidencia exacta de la **posición genómica de inicio y fin del fragmento mapeado** (en lugar de usar secuencias UMI sintéticas convencionales) para colapsar los duplicados de PCR

Instrucciones para crear referencia personalizada para PIPseeker de FluentBio: <https://www.fluentbio.com/wp-content/uploads/2022/06/Instructions-for-Creating-Custom-PIPseeker-References-1.pdf>

```
${WORKING_DIR}/scripts/pipseeker-v3.3.0-linux/pipseeker full \  
  --chemistry V \  
  --fastq "${FASTQ_DIR}/${sample}" \  
  --star-index-path "${WORKING_DIR}/data/01_reference/custom_hg38_reference/STAR_index" \  
  --output-path "${OUT_DIR}/${sample}_custom" \  
  --verbosity 1 \  
  --threads $(nproc) \  
  --save-svg
```

Output: CSV o H5 que se pueden cargar en Seurat (R) o Scanpy (python). También HTML...

BD Rhapsody

Documentación:

<https://www.bdbiosciences.com/content/dam/bdb/marketing-documents/products-pdf-folder/software-informatics/rhapsody-sequence-analysis-pipeline/Rhapsody-Sequence-Analysis-Pipeline-UG.pdf>

```
# Create a conda environment. Alternatively, use the bd_rhapsody.yml file in this repository.
conda create --name bd_rhapsody python=3.11
```

```
pip install cwlref-runner
```

```
# Download repository with CWL and YML files
wget https://bitbucket.org/CRSDev/cwl/get/f7a9e6ee973c.zip
unzip f7a9e6ee973c.zip
```

```
# Pull docker image using singularity
module load singularity
singularity pull docker://bdgenomics/rhapsody
```

```
# Activate conda environment
conda activate bd_rhapsody
```

```
# Load singularity module
module load singularity
```

```
# Run the pipeline allowing for singularity
cwl-runner \
```

```
--singularity \
```

```
CRSDev-cwl-f7a9e6ee973c/v3.0/rhapsody_pipeline_3.0.cwl \
```

```
../data/pipeline_test_3.0.yml
```

Archivo de workflow

Archivo de especificaciones (files, reference index...)

BD Rhapsody

- **Concepto:** Captura física celular basada en pocillos magnéticos (microwells).
- **Pipeline:** Utiliza 'BD Rhapsody Analysis Pipeline' estructurado bajo contenedores cerrados **Docker/singularity**. También tiene plataforma online
- **Alineamiento:** Se proporciona **índice de STAR** para alinear.
- **Cómo calcula el conteo:** Filtrado por **Distancia de Hamming = 1 + (método RSEC)**: algoritmo **recursivo** basado en la profundidad de lectura para eliminar de forma jerárquica los UMIs erróneos dentro de los correctos.

Output: CSV o H5 que se pueden cargar en Seurat (R) o Scanpy (python). También HTML...

Parse (Pipestance y Plataforma nube)

Parse Evercode (Pipestance)

- **Concepto:** Las células o núcleos actúan como sus propios compartimentos a través de varias rondas sucesivas de división y pegado de códigos de barras (split-and-pool barcoding) en placas de pocillos.
- **Pipeline:** Utiliza módulos llamados pipestance (por ejemplo, **split-pipe**). Su concepto es un pipeline todo en uno.
- Usa **algoritmo de alineamiento STAR**.
- **Cómo calcula el conteo:** Filtrado por **Distancia de Hamming = 1 y abundancia relativa**. Si dos UMIs en el mismo gen y célula varían por una sola letra debido a un error de la máquina o de la PCR, los fusiona en uno solo.

Trailmaker (Nube Visual)

- **Concepto:** Plataforma analítica “no-code” basada al 100% en infraestructura de servidores Web.
- **Cómo calcula el conteo:** El investigador simplemente arrastra los archivos FASTQ a la interfaz del navegador. La plataforma ejecuta el mapeo, alineamiento y limpieza en segundo plano entregando matrices interactivas de forma visual.

Ventaja: Puede usarse para visualización y análisis de datos procedentes de otras tecnologías.

Archivos output

matrix.mtx

Estructura numérica pura dispersa. Contiene las coordenadas de los índices de expresión válidos, omitiendo los millones de valores con cero para ahorrar espacio en disco.

barcodes.tsv

Secuencias de oligonucleótidos celulares limpios que han superado los umbrales bioinformáticos mínimos y representan células o núcleos individuales reales.

features.tsv

Diccionario con los identificadores de los genes (Ensembl ID / Gene Symbol) detectados en el experimento, mapeados directamente con las bases del genoma de referencia.

EJECUCIÓN DE CELLRANGER

CellRanger es un conjunto de flujos de análisis (pipelines) que realizan el demultiplexado de muestras, el procesamiento de barcodes, el conteo de genes de células individuales (single cell) 3' y 5', el ensamblaje y anotación de secuencias de transcritos V(D)J, y el análisis de Feature Barcodes para análisis de proteínas de superficie a partir de datos de Single Cell de la plataforma 10x Genomics Chromium

10x GENOMICS

ProductsResourcesSupport HubCompany

Order StatusStoreSearch

Support home

Cell Ranger

Tutorials

Cell Ranger

Overview

Getting Started

Supported Libraries

Download Center

Cloud Analysis

Cell Ranger Commands

Analysis

Inputs

Running Pipelines

Outputs

Tutorials

Version v10.0 (Latest)

View source code

Get Started with Cell Ranger

Cell Ranger installation

Cell Ranger reanalyze

Rerun secondary analysis for a completed cellranger count or aggr run with different parameters

Cell Ranger multi for Immune Profiling

Analyze V(D)J and 5' GEX with Cell Ranger multi

Cell Ranger vdj

Analyze V(D)J libraries with Cell Ranger vdj

Tumor Microenvironment Data Analysis and Visualization

Analysis and visualization of data in the tumor microenvironment application note using the Loupe and Loupe V(D)J Browsers

Cell Ranger count

Analyze Gene Expression and Feature Barcode data with Cell Ranger count

Cell Ranger mkref

Build a custom reference using Cell Ranger mkref

Cell Ranger multi for BEAM-Ab

Analyze your GEX + VDJ + B cell Antigen Capture libraries with Cell Ranger multi

Capturing Neutrophils

Capturing Neutrophils in 10x Single Cell Gene Expression Data

Cell Ranger Pipeline Telemetry

Understand pipeline telemetry data collection and learn how to disable it if needed

Cell Ranger aggr

Aggregating data with Cell Ranger aggr

Cell Ranger multi for 3' Cell Multiplexing

Analyze cell multiplexing data with Cell Ranger multi

Cell Ranger multi for BEAM-T

Analyze your GEX + VDJ + T cell Antigen Capture libraries with Cell Ranger multi

Example Data Analysis

Analyze scRNA-Seq Data From a Publication Using 10x Software

EJECUCIÓN DE CELLRANGER

CellRanger es un conjunto de flujos de análisis (pipelines) que realizan el demultiplexado de muestras, el procesamiento de barcodes, el conteo de genes de células individuales (single cell) 3' y 5', el ensamblaje y anotación de secuencias de transcritos V(D)J, y el análisis de Feature Barcodes para análisis de proteínas de superficie a partir de datos de Single Cell de la plataforma 10x Genomics Chromium

10X GENOMICS

ProductsResourcesSupport HubCompany

Order StatusStoreSearch

Support home > Cell Ranger > Tutorials

Cell Ranger

Overview

Getting Started

Supported Libraries

Download Center

Cloud Analysis

Cell Ranger Commands

Analysis

Inputs

Running Pipelines

Outputs

Tutorials

Version v10.0 (Latest)

View source code

Get Started with Cell Ranger

Cell Ranger installation

Cell Ranger reanalyze

Rerun secondary analysis for a completed cellranger count or aggr run with different parameters

Cell Ranger multi for Immune Profiling

Analyze V(D)J and 5' GEX with Cell Ranger multi

Cell Ranger vdj

Analyze V(D)J libraries with Cell Ranger vdj

Tumor Microenvironment Data Analysis and Visualization

Analysis and visualization of data in the tumor microenvironment application note using the Loupe and Loupe V(D)J Browsers

Cell Ranger count

Analyze Gene Expression and Feature Barcode data with Cell Ranger count

Cell Ranger mkref

Build a custom reference using Cell Ranger mkref

Cell Ranger multi for BEAM-Ab

Analyze your GEX + VDJ + B cell Antigen Capture libraries with Cell Ranger multi

Capturing Neutrophils

Capturing Neutrophils in 10x Single Cell Gene Expression Data

Cell Ranger Pipeline Telemetry

Understand pipeline telemetry data collection and learn how to disable it if needed

Cell Ranger aggr

Aggregating data with Cell Ranger aggr

Cell Ranger multi for 3' Cell Multiplexing

Analyze cell multiplexing data with Cell Ranger multi

Cell Ranger multi for BEAM-T

Analyze your GEX + VDJ + T cell Antigen Capture libraries with Cell Ranger multi

Example Data Analysis

Analyze scRNA-Seq Data From a Publication Using 10x Software

PREPROCESAMIENTO Y CONTROL DE CALIDAD 10X (CELLRANGER)

Ventajas

- Es el **pipeline oficial** de 10x Genomics → permite estandarizar.
- **Automático** (cellranger count):
 - Alineamiento de lecturas.
 - Asignación de Barcodes (células) y UMIs (moléculas).
 - Conteo de genes y filtrado inicial de células.
- Genera un archivo **HTML visual** muy intuitivo e informativo.
- **Versatilidad de datos** (Multi-ómica): ARN, CITE-seq, V(D)J (Receptores de células T y B)
- **Integración con Loupe Browser** (produce archivos .cloupe).
- **Actualización** constante y mantenido por 10x Genomics.

PREPROCESAMIENTO Y CONTROL DE CALIDAD 10X (CELLRANGER)


DESVENTAJAS

- **Consumo de RAM:** Los pasos de alineamiento (STAR) y el conteo requieren gran cantidad de memoria. Se recomienda un mínimo de **64 GB** para muestras estándar, y más para muestras con gran número de células.
- **Caja Negra:** Es difícil personalizar el alineamiento. Por ejemplo, si trabajas con genomas no estándar o quieres modificar parámetros de STAR (el alineador que usa internamente), Cell Ranger no te da mucha flexibilidad.
- **Sensibilidad al ARN Ambiental:** Aunque filtra células, no es el mejor eliminando el ruido de fondo (ARN ambiental).
- **Rendimiento en muestras complejas:** En muestras con núcleos muy pequeños o con mucha "basura" (debris), el algoritmo de Cell Ranger puede descartar células reales o incluir gotas vacías por error.

EJECUCIÓN DE CELLRANGER MKREF

¿Por qué crear referencias personalizadas en CellRanger (mkref)?

- Especies no modelo: Cuando 10x Genomics no ofrece la referencia pre-construida (humano/ratón).
- Genes transgénicos: Para rastrear la expresión de reporteros como GFP o secuencias virales...
- Personalización: Añadir o filtrar genes específicos según el diseño experimental.



```
cellranger mkref --genome=chrY --fasta=chrY.fa --genes=chrY.gtf
```



DESCARGAR REFERENCIA OFICIAL (RECOMENDADA)

- Descarga pre-construida de 10x Genomics
- Humano, ratón y organismos modelo


- **Comando:**

wget <https://cf.10xgenomics.com/supp/cell-exp/refdata-gex-GRCh38-2024-A.tar.gz>

tar -xzf refdata-gex-GRCh38-2024-A.tar.gz

- ✓ Lista para usar directamente


EJECUCIÓN DE CELLRANGER COUNT



```
cellranger count --help
```

```
cellranger count --id=PBMC --transcriptome=../data/reference/refdata-gex-GRCh38-2024-A/ --  
fastqs=./ --sample=pbmc_lk_v3 --create-bam=true --localcores=8 --localmem=64
```

EJECUCIÓN DE CELLRANGER COUNT



```
cellranger count --help
```

```
— analysis
— cloupe.cloupe
— filtered_feature_bc_matrix
— filtered_feature_bc_matrix.h5
— metrics_summary.csv
— molecule_info.h5
— possorted_genome_bam.bam
— possorted_genome_bam.bam.bai
— raw_feature_bc_matrix
— raw_feature_bc_matrix.h5
— web_summary.html
```

WEB_SUMMARY (HTML)

Echamos un vistazo al directorio de salida:

```
/home/curso/Software/curso_scRNAseq/dia2/cellranger/PBMC/outs
```

El informe de análisis (`web_summary.html`) suele ser un buen lugar para empezar.

WEB_SUMMARY (HTML)



Cell Ranger • count

PBMC

Summary

Gene Expression

1,221

Estimated Number of Cells

54,547

Mean Reads per Cell

3,290

Median Genes per Cell

Run Summary

Sample ID	PBMC
Sample Description	
Chemistry	Single Cell 3' v3 (polyA)
Include introns	True
Transcriptome	GRCh38-2024-A
Pipeline Version	cellranger-9.0.1


Sequencing ?

Number of Reads	66,601,887
Number of Short Reads Skipped	0
Valid Barcodes	97.4%
Valid UMIs	99.9%
Sequencing Saturation	70.8%
Q30 Bases in Barcode	94.1%
Q30 Bases in RNA Read	90.2%
Q30 Bases in UMI	92.7%

Mapping ?

Reads Mapped to Genome	96.1%
Reads Mapped Confidently to Genome	93.7%
Reads Mapped Confidently to Intergenic Regions	3.7%
Reads Mapped Confidently to Intronic Regions	31.1%
Reads Mapped Confidently to Exonic Regions	58.9%
Reads Mapped Confidently to Transcriptome	81.4%
Reads Mapped Antisense to Gene	7.9%

Cells ?



Estimated Number of Cells	1,221
Fraction Reads in Cells	95.6%
Mean Reads per Cell	54,547
Median UMI Counts per Cell	10,029
Median Genes per Cell	3,290
Total Genes Detected	25,863


OTROS EJEMPLOS

Alert	Value	Detail
 Fraction of RNA read bases with Q-score $\geq$ 30 is low	62.0%	Fraction of RNA read bases with Q-score $\geq$ 30 should be above 65%. A lower fraction might indicate poor sequencing quality. This is Read 1 for the Single Cell 3' v1 chemistry and Single Cell 5' paired end, Read 2 for the Single Cell 3' v2/v3 chemistry and Single Cell 5' R2-only)


Summary	Gene Expression
2,822 Estimated Number of Cells	
354 Mean Reads per Cell	68 Median Genes per Cell

Run Summary	
Sample ID	ETV6-RUNX1_1
Sample Description	
Chemistry	Single Cell 3' v2
Include introns	True
Transcriptome	cellranger_index-
Pipeline Version	cellranger-9.0.1

Sequencing 	
Number of Reads	1,000,000
Number of Short Reads Skipped	0
Valid Barcodes	98.4%
Valid UMIs	100.0%
Sequencing Saturation	7.0%
Q30 Bases in Barcode	96.6%
Q30 Bases in RNA Read	62.0%
Q30 Bases in UMI	96.7%



OTROS EJEMPLOS



Aunque la **baja calidad de las bases** (Q-score) genera preocupación, el principal problema es el **escaso número de lecturas por célula (~350)** y la **baja saturación (7%)**, lejos del objetivo recomendado de 30.000 a 50.000.

Saturación: Fracción de la complejidad de la librería capturada.


- ¿Cuántas lecturas necesito para hallar un nuevo transcrito (UMI)?
 - *Cálculo:* $1 / (1 - \text{saturación})$

Estrategia según el objetivo

- **Identificar poblaciones (Clustering):** Saturación **baja/media** es suficiente. No hace falta detectar cada UMI.
- **Genes de baja expresión:** Requiere saturación **alta** para capturar transcritos raros.
- **Células primarias (PBMCs):** Suelen saturar rápido (>90%) por su bajo contenido de ARN.

OTROS EJEMPLOS

Gráfico típico



Muestra: 1,839 células

Poblaciones heterogéneas

En muestras con distintos tipos celulares puede aparecer:

- un patrón bimodal


Por ejemplo:

- PBMCs → alta expresión génica
- neutrófilos → baja expresión génica

Esto genera dos distribuciones diferentes.

OTROS EJEMPLOS

Parámetro: `--force-cells=8000`



Interpretación del Barcode Rank Plot


La muestra parece heterogénea:

- PBMCs
- neutrófilos

Pero la transición azul-gris es más baja de lo esperado.

¿Qué significa?

Que probablemente algunas gotas vacías fueron clasificadas como células por el uso de: `--force-cells`. → Pero luego se puede filtrar.



RESUMEN CONCEPTUAL FINAL

✓ Buenas señales

- alto mapping
- alta saturación de secuenciación
- clusters claros en t-SNE
- cliff/knee definido
- buena separación células/background

⚠ Señales de alerta

- pocos genes por célula
- muchos reads intergénicos
- bajo número de lecturas en células
- muchos genes mitocondriales
- ausencia de clusters

PREPROCESAMIENTO Y CONTROL DE CALIDAD (CELLBENDER)



CellBender

- **CellBender:** Herramienta basada en *deep learning* (modelo generativo profundo) que elimina automáticamente el ruido y la contaminación de ARN ambiental en experimentos de secuenciación por gotas (doplet-based) de secuenciación de ARN de célula única (scRNA-seq).

Pasos

- Carga de datos crudos: Archivos .h5 de plataformas como 10x Genomics.
- Eliminación de ruido: Separa ARN real del ARN ambiental.
- Modelo de inferencia variacional: Usa **autoencoders variacionales (VAE)** y modelos probabilísticos.
- Salida limpia: Genera matrices listas para análisis biológico.

asume que cada gota observada es la suma de:

[ARN de una célula real] + [Contaminación ambiental].

```
cellbender remove-background --input raw_feature_bc_matrix.h5 --output raw_feature_bc_matrix_cellbender.h5
```

PARÁMETROS CLAVE EN CELLBENDER (REMOVE-BACKGROUND)

•--expected-cells (**Células Objetivo**)

- Definición:** Cantidad de células reales que se planificó recuperar en el experimento.
- Estimación:** Se obtiene directamente del dato "*Estimated Number of Cells*" en el archivo web_summary.html de Cell Ranger.
- Riesgo:** Si se coloca un valor muy bajo, el algoritmo eliminará por error tipos celulares escasos.

•--total-droplets-included (**Gotas Totales**).

- Definición:** Número de barcodes (ordenados por UMI/lecturas de mayor a menor) que el programa incluirá en su análisis.
- Estrategia:** Debe incluir todas las células reales más unas 10k–15k gotitas vacías de la "meseta" de la curva UMI.
- Compromiso:** Un número mayor permite al algoritmo aprender mejor el perfil de fondo, pero incrementa drásticamente el tiempo de cómputo.

•--fpr (**Tasa de Falsos Positivos**)

- Definición:** Proporción de señal biológica real que se tolera perder a cambio de una limpieza más estricta.
- Configuración:**
 - 0.01 (Por defecto): Para muestras limpias y de alta calidad.
 - 0.1 a 0.3: Para muestras comprometidas o con alto ARN ambiental (ej. núcleos aislados).

•--learning-rate (**Tasa de Aprendizaje**)

- Definición:** Tasa en la que la red neuronal de CellBender ajusta sus cálculos matemáticos para aprender a distinguir el perfil del ARN ambiental (ruido) de las células reales.
- Configuración:** 1e-4 / 0.0001 (Por defecto).

•--epochs (**Épocas de Entrenamiento**)

- Definición:** Número de pasadas completas que realiza el modelo de aprendizaje automático sobre los datos para aprender a diferenciar el ruido.
- Estándar:** Se recomienda fijar en **150** como punto de inicio óptimo para datos de expresión génica de célula única

EJECUCIÓN DE CELLBENDER


Ventajas

- Elimina automáticamente el ARN ambiental y el ruido
- Mejora la precisión de los resultados biológicos
- Usa inteligencia artificial (*deep learning*)
- Compatible con datasets grandes y complejos
- Reduce errores en clustering e identificación celular

Desventajas

- Alto consumo de RAM
- El procesamiento puede tardar en datasets grandes

CELLBENDER OUTPUT



Empty droplets (azul)


- pico fuerte en valores bajos (10–100 UMIs)
 - luego cae rápidamente
- ☞ Esto es lo esperado:
- fondo ambiental
 - gotas vacías o casi vacías

Non-empty droplets (naranja)

- distribución desplazada a la derecha
 - pico alrededor de miles—decenas de miles de UMIs
- ☞ Esto representa: células reales

Examine how many counts were removed in total

removed 155269 counts from non-empty droplets
removed 1.10% of the counts in non-empty droplets




CELLBENDER OUTPUT

Curva de aprendizaje

El ELBO (*Evidence Lower Bound*) mide la calidad del ajuste del modelo: valores más altos (menos negativos porque es logarítmico) indican mejor aprendizaje.

- El ELBO aumenta rápidamente al inicio → el modelo aprende la estructura de los datos.
- La curva de entrenamiento converge hacia una meseta estable (~época 30–40).
- Se observan pequeñas oscilaciones normales en optimización estocástica.



Inestabilidad del Test ELBO

- **Comportamiento:** Sigue la tendencia inicial de entrenamiento, pero sufre grandes fluctuaciones y una **caída drástica al final**.
- **Causas posibles:**
 - Sobreajuste (*Overfitting*).
 - Inestabilidad del modelo matemático.
 - Exceso de épocas de entrenamiento (--epochs).

⚠ **Diagnóstico:** El descenso final del Test ELBO indica un entrenamiento inestable o subóptimo.

• **Solución: Reducir Tasa de Aprendizaje:** Aplicar un --learning-rate menor (ej. reducir a la mitad).


En general:

- Si vemos caídas bruscas hacia abajo → proceso es inestable → **reducir la tasa de aprendizaje (learning rate) a la mitad**.
- Si la curva sigue subiendo y no se aplana, hay que **correrlo con más épocas (epochs)**, sin pasar de 300 como regla general

AJUSTE DE CELLBENDER

CellBender eliminó un total de **152.399 lecturas (counts)**
Esto representa exactamente el **1,08%** del total


Esto pasa mucho en datos que son muy muy grandes (y muy heterogéneos) y en datos que son muy pequeños, porque con pocos UMIs a cellbender le cuesta más hacer un buen modelo




```
cellbender remove-background --input raw_feature_bc_matrix.h5 --expected-cells 1221 y --learning-rate 0.000005  
--output raw_feature_bc_matrix_cellbender.h5
```

CELLBENDER OUTPUT

Probabilidad de Célula (Cell Probabilities) by default






Probabilidad de Célula (Cell Probabilities) with params



CELLBENDER OUTPUT


CellBender: Concordancia entre input y output

- Cada punto representa:
 - una célula/barcode (izquierda)
 - un gen (derecha)
- La mayoría de puntos se mantienen cerca de la diagonal: alta concordancia entre datos originales y corregidos
- CellBender elimina principalmente:
 - RNA ambiental
 - contaminación técnica
 - counts de droplets vacíos
- La corrección afecta sobre todo a células con pocos UMIs: donde el ruido relativo es mayor
- No se observa sobrecorrección:
 - no hay pérdida masiva de counts
 - no se altera el transcriptoma global




CELLBENDER OUTPUT

Proyección PCA by defect




Proyección PCA with params



RSTUDIO

File > New File > R script



<https://www.uv.es/vcoll/primeros-pasos.html>

PRIMEROS PASOS CON R

OBJETO SEURAT

`seu@meta.data`

`seu$nCount_RNA`

`seu@assays`

`GetAssayData(seu, layer = "counts") == seu@assays$RNA@layers$counts`

`Layers(seu)`


`Features(seu) == rownames(seu) #genes`

`Cells(seu) == colnames(seu)`

```
> library(Seurat)
> data <- Read10X(data.dir = "filtered_feature_bc_matrix")
> seu <- CreateSeuratObject(data)
> head(seu)
      orig.ident nCount_RNA nFeature_RNA
AAACCCAAGGAGAGTA-1 SeuratProject      12958      3918
AAACGCTTCAGCCCAG-1 SeuratProject       9527      3293
AAAGAACAGACGACTG-1 SeuratProject       6601      2667
AAAGAACCAATGGCAG-1 SeuratProject       4419      2155
AAAGAACGTCTGCAAT-1 SeuratProject      10004      3203
AAAGGATAGTAGACAT-1 SeuratProject      12245      3357
AAAGGATCACCGGCTA-1 SeuratProject       8269      2940
AAAGGATTCAGCTTGA-1 SeuratProject      18876      4942
AAAGGATTCCGTTTCG-1 SeuratProject     24530      5275
AAAGGGCTCATGCCCT-1 SeuratProject     10478      3216
> class(seu)
[1] "Seurat"
attr(,"package")
[1] "SeuratObject"
> class(data)
[1] "dgCMatrix"
attr(,"package")
[1] "Matrix"
>
```

`SeuratObject::Seurat`

 sparse matrix
 list of objects



-  Resultados de normalización (`@assays$RNA@data`)
-  Análisis de componentes principales (PCA) y UMAP (`@reductions`)
-  Estructura de clustering (`@graphs`)

HISTOGRAMA DE SEU

`hist(seu$nCount_RNA)`

`hist(seu@meta.data$nCount_RNA)`

