




ANÁLISIS DE DATOS SINGLE CELL RNA-SEQ

Control de calidad y normalización

Sesión 1: Criterios de calidad a nivel célula y métodos de normalización

Sesión 2: Reducción de la dimensionalidad (PCA, UMAP, t-SNE)

1ª convocatoria 2026 del Gabinete de Formación (CSIC)

Servicio de Análisis Biocomputacional (CBM-CSIC)

Centro de Computación Científica (CCC-UAM)

25 al 29 de mayo de 2026

Datos generados con CellRanger

```
$ ll cellranger/PBMC/outs/  
./  
../  
analysis/  
cloupe.cloupe  
filtered_feature_bc_matrix/  
filtered_feature_bc_matrix.h5  
metrics_summary.csv  
molecule_info.h5  
possorted_genome_bam.bam  
possorted_genome_bam.bam.bai  
raw_feature_bc_matrix/  
raw_feature_bc_matrix.h5  
web_summary.html
```

```
$ ll cellranger/PBMC/outs/filtered_feature_bc_matrix  
./  
../  
barcodes.tsv.gz  
features.tsv.gz  
matrix.mtx.gz
```

1. matrix.mtx

- Number of UMIs for a given gene in a given cell
- Sparse matrix (only non-zero entries are stored), in MEX format
 - Header: third line tells how many genes and cells you have
 - Each row: gene index, cell index, **number of UMIs**
- Make sure that you use the filtered feature barcode matrix (contains only those cell barcodes which are present in your data)

2. barcodes.tsv

- Cell barcodes present in your data

3. features.tsv (genes.tsv)

- Identifier, name and type (gene expression)

%%MatrixMarket matrix coordinate real			
#			
32738	2700	2286884	
32709	1	4	
32707	1	1	
32706	1	10	
32704	1	1	
32703	1	5	
32702	1	6	
32700	1	10	
32699	1	25	
...			
32709	ENSG00000243485	MIR1302-10	AAACATACAACCAC-1
32710	ENSG00000237613	FAM138A	AAACATTGAGCTAC-1
32711	ENSG00000186092	OR4F5	AAACATTGATCAGC-1
...	ENSG00000238009	RP11-34P13.7	AAACCGTGCTTCCG-1
	ENSG00000239945	RP11-34P13.8	AAACCGTGATGCG-1
	ENSG00000237683	AL627309.1	AAACGCACTGGTAC-1
	ENSG00000239906	RP11-34P13.14	AAACGCTGACCACT-1
			AAACGCTGGTTCCT-1
			AAACGCTGTAGCCA-1

Importar los datos a R con Seurat

```
$ ll cellranger/PBMC/outs/  
./  
../  
analysis/  
cloupe_cloupe  
filtered_feature_bc_matrix/  
filtered_feature_bc_matrix.h5  
metrics_summary.csv  
molecule_info.h5  
possorted_genome_bam.bam  
possorted_genome_bam.bam.bai  
raw_feature_bc_matrix/  
raw_feature_bc_matrix.h5  
web_summary.html
```

```
$ ll cellranger/PBMC/outs/filtered_feature_bc_matrix  
./  
../  
barcodes.tsv.gz  
features.tsv.gz  
matrix.mtx.gz
```

```
> library(Seurat)  
> data <- Read10X(data.dir = "cellranger/PBMC/outs/filtered_feature_bc_matrix")  
> seu <- CreateSeuratObject(data)
```




Seurat v5

We are excited to release Seurat v5! To install, please follow the instructions in our [install page](#). This update brings the following new features and functionality:

- **Integrative multimodal analysis:** The cellular transcriptome is just one aspect of cellular identity, and recent technologies enable routine profiling of chromatin accessibility, histone modifications, and protein levels from single cells. In Seurat v5, we introduce 'bridge integration', a statistical method to integrate experiments measuring different modalities (i.e. separate scRNA-seq and scATAC-seq datasets), using a separate multiomic dataset as a molecular 'bridge'. For example, we demonstrate how to map scATAC-seq datasets onto scRNA-seq datasets, to assist users in interpreting and annotating data from new modalities.

<https://satijalab.org/seurat/>



- Vector: colección unidimensional de elementos del mismo tipo
 - Base de todas las estructuras de R
- Matriz: estructura bidimensional (filas × columnas) con elementos del mismo tipo
- Array: extensión de la matriz a múltiples dimensiones
- Lista: colección de elementos que pueden ser de distinto tipo
- Data frame: tabla bidimensional donde cada columna es un vector
- Objeto S4: objeto formal con estructura estricta y *slots*

```


> str(seu)
Formal class 'Seurat' [package "SeuratObject"] with 13 slots
 ..@ assays      :List of 1
 .. ..$ RNA:Formal class 'Assay5' [package "SeuratObject"] with 8 slots
 .. .. ..@ layers :List of 1
 .. .. .. ..$ counts:Formal class 'dgMatrix' [package "Matrix"] with 6 slots
 .. .. .. .. ..@ 1 : int [1:4099222] 16 22 55 58 64 66 67 69 79 81 ...
 .. .. .. .. ..@ p : int [1:1222] 0 3918 7211 9878 12033 15236 18593 21533 26475 317
 .. .. .. .. ..@ Dim : int [1:2] 38606 1221
 .. .. .. .. ..@ Dimnames:List of 2
 .. .. .. .. .. ..$ : NULL
 .. .. .. .. .. ..$ : NULL
 .. .. .. .. ..@ x : num [1:4099222] 1 1 3 1 1 1 1 2 1 1 ...
 .. .. .. .. ..@ factors : list()
 .. .. .. ..@ cells :Formal class 'LogMap' [package "SeuratObject"] with 1 slot
 .. .. .. .. ..@ .Data: logi [1:1221, 1] TRUE TRUE TRUE TRUE TRUE TRUE ...
 .. .. .. .. ..- attr(*, "dimnames")=List of 2
 .. .. .. .. .. ..$ : chr [1:1221] "AAACCCAAGGAGAGTA-1" "AAACGCTTCAGCCCAG-1" "AAAGAACAGACG
 .. .. .. .. .. ..$ : chr "counts"
 .. .. .. .. ..$ dim : int [1:2] 1221 1
 .. .. .. .. ..$ dimnames:List of 2
 .. .. .. .. .. ..$ : chr [1:1221] "AAACCCAAGGAGAGTA-1" "AAACGCTTCAGCCCAG-1" "AAAGAACAGACGACT
 .. .. .. .. .. ..$ : chr "counts"
 .. .. .. ..@ features :Formal class 'LogMap' [package "SeuratObject"] with 1 slot
 .. .. .. .. ..@ .Data: logi [1:38606, 1] TRUE TRUE TRUE TRUE TRUE TRUE ...
 .. .. .. .. ..- attr(*, "dimnames")=List of 2
 .. .. .. .. .. ..$ : chr [1:38606] "DDX11L2" "MIR1302-2HG" "FAM138A" "ENSG00000290826" ..
 .. .. .. .. .. ..$ : chr "counts"
 .. .. .. .. ..$ dim : int [1:2] 38606 1
 .. .. .. .. ..$ dimnames:List of 2
 .. .. .. .. .. ..$ : chr [1:38606] "DDX11L2" "MIR1302-2HG" "FAM138A" "ENSG00000290826" ...
 .. .. .. .. .. ..$ : chr "counts"
 .. .. .. ..@ default : int 1
 .. .. .. ..@ assay.orig: chr(0)
 .. .. .. ..@ meta.data : 'data.frame': 38606 obs. of 0 variables
 .. .. .. ..@ misc :List of 1
 .. .. .. .. ..$ calcN: logi TRUE
 .. .. .. ..@ key : chr "rna"
 .. ..@ meta.data : 'data.frame': 1221 obs. of 3 variables:
 .. .. ..$ orig.ident : Factor w/ 1 level "SeuratProject": 1 1 1 1 1 1 1 1 1 1 ...
 .. .. ..$ nCount_RNA : num [1:1221] 12958 9527 6601 4419 10004 ...
 .. .. ..$ nFeature_RNA: int [1:1221] 3918 3293 2667 2155 3203 3357 2940 4942 5275 3216 ...
 ..@ active.assay: chr "RNA"
 ..@ active.ident: Factor w/ 1 level "SeuratProject": 1 1 1 1 1 1 1 1 1 1 ...
 .. ..- attr(*, "names")= chr [1:1221] "AAACCCAAGGAGAGTA-1" "AAACGCTTCAGCCCAG-1" "AAAGAACAGACGAC
 ..@ graphs : list()
 ..@ neighbors : list()
 ..@ reductions : list()
 ..@ images : list()
 ..@ project.name: chr "SeuratProject"
 ..@ misc : list()
 ..@ version :Classes 'package_version', 'numeric_version' hidden list of 1
 .. ..$ : int [1:3] 5 0 2
 ..@ commands : list()
 ..@ tools : list()

```

matrix.mtx.gz

barcodes.tsv.g

features.tsv



Resultados de normalización

Estructura de clustering

Resultados de las reducciones de dimensionalidad (PCA y UMAP)

> seu@meta.data

> seu\$nCount_RNA

> seu@assays


> GetAssayData(seu, layer = "counts") // seu@assays\$RNA@layers\$counts

> Layers(seu)



> Features(seu) // rownames(seu) #genes

> Cells(seu) // colnames(seu) #cells


scRNAseq Biocomputational Workflow




QUALITY CONTROL




QC metrics &
isOutlier



CellBender



CellRanger




scDbIFinder

Quality Control




- ✓ Limpiar mRNA ambiental
- ✓ Eliminar gotas vacías o con mRNA ambiental
- ✗ Eliminar dobletes
- ✗ Eliminar células muertas o con daño celular

OBJETIVO:
quedarnos con células reales y
de buena calidad



QUALITY CONTROL: ELIMINAR DOUBLETS




Un *doublet* ocurre cuando:

- una gota contiene más de una célula (o núcleo)
- pero recibe un único *barcode*

Consecuencia: las lecturas de más de una célula se combinan y se interpretan como una sola.

En plataformas como 10x, la tasa de *doublets* aumenta con el número de células cargadas.

Incluso en condiciones estándar: >5% de las “células” pueden ser doublets




⚠ Impacto en el análisis -> Distorsionan el *clustering*

- Generan perfiles de expresión mezclados
- Pueden parecer nuevos tipos celulares o estados intermedios falsos

↓
Especialmente problemáticos en análisis de trayectorias / desarrollo celular

```
> sce <- as.SingleCellExperiment(seu)
> sce <- scDblFinder(sce)
```

```
%h%-$ ls SRR9264343/outs/raw_feature_bc_matrix
barcodes.tsv.gz
features.tsv.gz
matrix.mtx.gz
```



<https://bioconductor.org/packages/release/bioc/html/SingleCellExperiment.html>

SingleCellExperiment

S4 Classes for Single Cell Data

Defines a S4 class for storing data from single-cell experiments. This includes specialized methods to store and retrieve spike-in information, dimensionality reduction coordinates and size factors for each cell, along with the usual metadata for genes and libraries.

+ información

<https://bioconductor.org/packages/devel/bioc/vignettes/SingleCellExperiment/inst/doc/intro.html>

Un objeto S4 es un **contenedor de datos muy organizado**, con **reglas estrictas sobre qué puede contener y cómo se usa**

```
> sce <- as.SingleCellExperiment(seu)
> sce <- scDblFinder(sce)
```



<https://bioconductor.org/packages/release/bioc/html/scDblFinder.html>

scDblFinder

The scDblFinder package gathers various methods for the detection and handling of doublets/multiplets in single-cell sequencing data (i.e. multiple cells captured within the same droplet or reaction volume). It includes methods formerly found in the scan package, the new fast and comprehensive scDblFinder method, and a reimplementaion of the Amulet detection method for single-cell ATAC-seq.



The input of scDblFinder is an object sce of class SingleCellExperiment (empty drops having already been removed).

<https://pmc.ncbi.nlm.nih.gov/articles/PMC7897250/>
<https://f1000research.com/articles/10-979#sec20>

1) Creación de Doublets Artificiales

clusters = FALSE

clusters = TRUE




-> Combinación de células:


doublet = counts_A + counts_B

Hace modificaciones para simular variabilidad experimental real:

- 25% halfSize (escalado)
- 25% adjustSize (ajustado por tamaño de librería)
- 25% (introduce ruido estadístico)




2) Combinación de los datos (reales + artificiales) y (PCA)




3) Construcción kNN y extracción de parámetros

4) Entrenamiento del modelo y thresholding








Train doublet classifier

Exclude doublets





5) Identificación de doublets







QUALITY CONTROL




QC metrics &
isOutlier



CellBender



CellRanger




scDbtFinder

Quality Control




- ✓ Limpiar mRNA ambiental
- ✓ Eliminar gotas vacías o con mRNA ambiental
- ✓ Eliminar dobletes
- ✗ Eliminar células muertas o con daño celular

OBJETIVO:
quedarnos con células reales y
de buena calidad



QUALITY CONTROL: Filtrar células de mala calidad



3 métricas esenciales en Seurat:

- **percent.mt:** porcentaje de expresión de genes mitocondriales respecto al total de expresión
- **nFeature_RNA:** número de genes (features) por célula
- **nCount_RNA:** número de moléculas (UMIs) por célula

QUALITY CONTROL: Filtrar células de mala calidad



Low # genes /
total molecules

Dying/ low quality cells



Very high # genes
/ total molecules

Doublets/ multiplets



High %
mitochondrial genes

Dying/ low quality cells

3 métricas esenciales en Seurat:

- **percent.mt:** porcentaje de expresión de genes mitocondriales respecto al total de expresión
- **nFeature_RNA:** número de genes (features) por célula
- **nCount_RNA:** número de moléculas (UMIs) por célula

QUALITY CONTROL: Filtrar células de mala calidad



Low # genes /
total molecules

Dying/ low quality cells



Very high # genes
/ total molecules

Doublets/ multiplets



High %
mitochondrial genes

Dying/ low quality cells

3 métricas esenciales en Seurat:

- **percent.mt**: porcentaje de expresión de genes mitocondriales respecto al total de expresión
- **nFeature_RNA**: número de genes (features) por célula
- **nCount_RNA**: número de moléculas (UMIs) por célula

> head(seu)

	orig.ident	nCount_RNA	nFeature_RNA	doublet	doublet_score
AAACCCAAGGAGAGTA-1	SeuratProject	12958	3918	singlet	0.043012988
AAACGCTTCAGCCCAG-1	SeuratProject	9527	3293	singlet	0.108826026
AAAGAACAGACGACTG-1	SeuratProject	6601	2667	singlet	0.004649329
AAAGAACCAATGGCAG-1	SeuratProject	4419	2155	singlet	0.004024064
AAAGAACGTCTGCAAT-1	SeuratProject	10004	3203	singlet	0.087817192
AAAGGATAGTAGACAT-1	SeuratProject	12245	3357	singlet	0.002539045
AAAGGATCACCGGCTA-1	SeuratProject	8269	2940	singlet	0.003615922
AAAGGATTGAGCTTGA-1	SeuratProject	18876	4942	singlet	0.036192518
AAAGGATTCCGTTTCG-1	SeuratProject	24530	5275	singlet	0.076159649
AAAGGGCTCATGCCCT-1	SeuratProject	10478	3216	singlet	0.008529043

QUALITY CONTROL: Filtrar células de mala calidad



Low # genes /
total molecules

Dying/ low quality cells



Very high # genes
/ total molecules

Doublets/ multiplets



High %
mitochondrial genes

Dying/ low quality cells



En humanos, los genes mitocondriales empiezan por “MT”, pero esto puede variar de una especie a otra. Por ejemplo, en ratón (*Mus musculus*) los genes mitocondriales empiezan con “mt”.

¡DEBEMOS COMPROBARLO ANTES!

```
> sum(grepl("^MT-", rownames(seu)))
```

- ✓ ~10–50 genes → correcto
- ✗ 0
- ✗ cientos

3 métricas esenciales en Seurat:

- **percent.mt**: porcentaje de expresión de genes mitocondriales respecto al total de expresión
- **nFeature_RNA**: número de genes (features) por célula
- **nCount_RNA**: número de moléculas (UMIs) por célula

```
> seu$percent.mt <- PercentageFeatureSet(seu,  
pattern = "^MT-")
```

```
> head(seu)
```

	orig.ident	nCount_RNA	nFeature_RNA	doublet	doublet_score	percent.mt
AAACCCAAGGAGAGTA-1	SeuratProject	12958	3918	singlet	0.043012988	7.099861
AAACGCTTCAGCCCAG-1	SeuratProject	9527	3293	singlet	0.108826026	4.649942
AAAGAACAGACGACTG-1	SeuratProject	6601	2667	singlet	0.004649329	4.044842
AAAGAACCAATGGCAG-1	SeuratProject	4419	2155	singlet	0.004024064	3.779136
AAAGAACGTCTGCAAT-1	SeuratProject	10004	3203	singlet	0.087817192	4.408237
AAAGGATAGTAGACAT-1	SeuratProject	12245	3357	singlet	0.002539045	5.765619
AAAGGATCACC GGCTA-1	SeuratProject	8269	2940	singlet	0.003615922	6.445761
AAAGGATT CAGCTTGA-1	SeuratProject	18876	4942	singlet	0.036192518	4.471286
AAAGGATTCCGTTTCG-1	SeuratProject	24530	5275	singlet	0.076159649	6.689768
AAAGGGCTCATGCCCT-1	SeuratProject	10478	3216	singlet	0.008529043	7.243749

QUALITY CONTROL: Filtrar células de mala calidad



Low # genes /
total molecules

Dying/ low quality cells



Very high # genes
/ total molecules

Doublets/ multiplets




High %
mitochondrial genes

Dying/ low quality cells

3 métricas esenciales en Seurat:

- **percent.mt**: porcentaje de expresión de genes mitocondriales respecto al total de expresión
- **nFeature_RNA**: número de genes (features) por célula
- **nCount_RNA**: número de moléculas (UMIs) por célula

```
> VlnPlot(seu, features=  
c("nCount_RNA", "nFeature_RNA", "percent.mt"))
```



QUALITY CONTROL: Filtrar células de mala calidad

```
> seu$nCount_outliers <- isOutlier(seu$nCount_RNA, nmads = 5)
> seu$nFeature_outliers <- isOutlier(seu$nFeature_RNA, nmads = 5)
> seu$mt_outliers <- isOutlier(seu$percent.mt, nmads = 5, type = "higher")
```



<https://bioconductor.org/packages/release/bioc/html/scuttle.html>

scuttle

Legacy Utilities for Single-Cell RNA-Seq Analysis

QUALITY CONTROL: Filtrar células de mala calidad

```
> seu$nCount_outliers <- isOutlier(seu$nCount_RNA, nmads = 5)
> seu$nFeature_outliers <- isOutlier(seu$nFeature_RNA, nmads = 5)
> seu$mt_outliers <- isOutlier(seu$percent.mt, nmads = 5, type = "higher")
```

isOutlier() calcula cuál es el comportamiento típico de nuestras células (mediana), cuánto varían normalmente (MAD), y marca como problemáticas las que están demasiado lejos.

$$MAD = \frac{\sum |x_i - \bar{x}|}{n}$$

nCount_RNA → x = c(1000, 1100, 1200, 1300, 1400, 1500, 8000)

x_i	$ x_i - \bar{x} $
1000	$ 1000 - 1300 = 300$
1100	$ 1100 - 1300 = 200$
1200	$ 1200 - 1300 = 100$
1300	$ 1300 - 1300 = 0$
1400	$ 1400 - 1300 = 100$
1500	$ 1500 - 1300 = 200$
8000	$ 8000 - 1300 = 6700$

$\bar{x}$

MAD

$|x_i - \bar{x}| = c(0, 100, 100, 200, 200, 300, 6700)$


Limits → $\bar{x} \pm nmads * MAD$

- lower = $1300 - 3 \times 200 = 700$
- upper = $1300 + 3 \times 200 = 1900$

x_i	$\hat{z}$ Is outlier?
1000	✓ NO
1100	✓ NO
1200	✓ NO
1300	✓ NO
1400	✓ NO
1500	✓ NO
8000	✗ YES -> $8000 > 1900$

QUALITY CONTROL: Filtrar células de mala calidad

```
> seu$nCount_outliers <- isOutlier(seu$nCount_RNA, nmads = 5)
> seu$nFeature_outliers <- isOutlier(seu$nFeature_RNA, nmads = 5)
> seu$mt_outliers <- isOutlier(seu$percent.mt, nmads = 5, type = "higher")
```



Consideramos outliers:

- células con poco/mucho RNA/genes ✗
- células con alto % de genes mitocondriales ✗

Marcamos como sospechosos los valores que están a más de 5 desviaciones de la mediana

```
> seu$outliers <- "KEEP"
> seu$outliers[seu$nCount_outliers == "TRUE" | seu$nFeature_outliers == "TRUE" |
seu$mt_outliers == "TRUE"] <- "FILTER"
```


Creamos una etiqueta para célula:


- *KEEP*: esa célula se mantiene, no es un *outlier*
- *FILTER*: esa célula la eliminamos, es un *outlier* porque ha fallado uno o más criterios de calidad

QUALITY CONTROL: Filtrar células de mala calidad



```
> p1 <- FeatureScatter(seu, group.by= "outliers", feature1 = "nCount_RNA", feature2 = "percent.mt",  
  cols = c("darkred", "darkblue"))  
> p2 <- FeatureScatter(seu, group.by= "outliers", feature1 = "nFeature_RNA", feature2 = "percent.mt",  
  cols = c("darkred", "darkblue"))  
> p3 <- FeatureScatter(seu, group.by= "outliers", feature1 = "nCount_RNA", feature2 = "nFeature_RNA",  
  cols = c("darkred", "darkblue"))
```

p1 + p2 + p3







QUALITY CONTROL




QC metrics &
isOutlier



CellBender



CellRanger




scDbtFinder

Quality Control




- ✓ Limpiar mRNA ambiental
- ✓ Eliminar gotas vacías o con mRNA ambiental
- ✓ Eliminar dobletes
- ✓ Eliminar células muertas o con daño celular

OBJETIVO:
quedarnos con células reales y
de buena calidad



scRNAseq Biocomputational Workflow



NORMALIZACIÓN, ESCALA E IDENTIFICACIÓN DE LOS GENES MÁS VARIABLES

PROBLEMAS:

- Las células tienen distinto número total de *counts* (profundidad de secuenciación)
 - > No son comparables directamente
- Los genes tienen escalas muy diferentes
 - > Algunos dominan el análisis
- Hay miles de genes, pero la mayoría no cambia entre células
 - > Mucho ruido, dificulta detectar diferencias biológicas

SOLUCIÓN:

```
> seu <- NormalizeData(seu)
```

```
> seu <- ScaleData(seu)
```

```
> seu <- FindVariableFeatures(seu)
```

RESULTADOS:

En cada paso estamos resolviendo un problema diferente:

- 1) Hacemos comparables las células
- 2) Equilibramos los datos para analizarlos correctamente
- 3) Nos quedamos con los genes informativos.

La normalización corrige las diferencias entre células ajustando la profundidad de secuenciación u otras variaciones técnicas, lo que garantiza que los valores de expresión génica sean comparables entre células.

El escalado corrige las diferencias entre genes ajustando los rangos variables de niveles de expresión entre genes, asegurando que ningún gen con una expresión muy alta domine el análisis.

NORMALIZACIÓN, ESCALA E IDENTIFICACIÓN DE LOS GENES MÁS VARIABLES

```
> seu <- NormalizeData(seu)
```

Por defecto (method = "LogNormalize"), hace esto en 3 pasos:

1) Normalización por biblioteca (library size normalization)

Divide cada gen por el total de counts de la célula → valor *normalizado* =
$$\frac{\text{counts del gen}}{\text{total counts de la célula}}$$

Convierte *counts* absolutos en proporciones relativas.

2) Escalado (multiplicación por factor)

Multiplica por un factor (por defecto 10,000) → valor $\times 10,000$

Para tener números más manejables.

3) Log-transformación

$\log(1 + x)$

Reduce efecto de valores extremos.



	Cell 1	Cell 2	Cell 3
Total reads	3	300	100
RAW			
Gene A	1	100	50
Gene B	2	200	50
NORMALISED			
Gene A	8.1	8.1	8.5
Gene B	8.8	8.8	8.5

LOG1P NORMALISATION

NORMALIZACIÓN, ESCALA E IDENTIFICACIÓN DE LOS GENES MÁS VARIABLES

```
> seu <- ScaleData(seu)
```

Por defecto hace estos 2 pasos:

1) Centrado (media = 0) $\rightarrow x - \text{media}$

2) Escalado (varianza = 1) $\rightarrow \frac{x}{\text{desviación estándar}}$

Todos los genes tienen la misma media (0) y la misma varianza (1).

```
> seu <- FindVariableFeatures(seu)
```

Buscar genes (por defecto ~2000 genes más variables) que tengan una alta variabilidad entre células (una vez corregida la media).

La variabilidad depende de la media:

- Genes muy expresados $\rightarrow$ más ruido esperado
- Genes poco expresados $\rightarrow$ más dispersión aparente

RAW

Gene A	1	100	50
Gene B	2	200	50

NORMALISED


Gene A	8.1	8.1	8.5
Gene B	8.8	8.8	8.5

SCALED

Gene A	-0.57	-0.57	+1.19
Gene B	+0.58	+0.58	-1.16

LOG2 NORMALISATION

Z-SCORE



Seurat corrige esto usando un modelo (relación media-varianza)

NORMALIZACIÓN, ESCALA E IDENTIFICACIÓN DE LOS GENES MÁS VARIABLES

En datos de scRNA-seq existe **fuerte relación entre la expresión promedio de un gen y su varianza**

↑ expresión -> ↑ variabilidad

```
> seu <- NormalizeData(seu)
> seu <- ScaleData(seu)
> seu <- FindVariableFeatures(seu)
```

No tiene en cuenta la naturaleza basada en recuentos de los datos de secuenciación .

- ✗ Trata cada paso de forma independiente
 - ✗ No modela bien el ruido técnico (muy importante en single-cell)
 - ✗ Puede introducir artefactos si los pasos no están bien coordinados
- 

NORMALIZACIÓN, ESCALA E IDENTIFICACIÓN DE LOS GENES MÁS VARIABLES

En datos de scRNA-seq existe **fuerte relación entre la expresión promedio de un gen y su varianza**

↑ expresión -> ↑ variabilidad

No tiene en cuenta la naturaleza basada en recuentos de los datos de secuenciación .

```
> seu <- NormalizeData(seu)
> seu <- ScaleData(seu)
> seu <- FindVariableFeatures(seu)
```

- ✗ Trata cada paso de forma independiente
- ✗ No modela bien el ruido técnico (muy importante en single-cell)
- ✗ Puede introducir artefactos si los pasos no están bien coordinados

```
> seu <- SCTransform(seu)
```

En lugar de corregir los datos paso a paso, construye un **modelo que separa señal biológica de ruido técnico de una sola vez**.


Para cada gen, se ajusta un modelo:

$\log(\text{recuento esperado}) = \log(\text{profundidad de secuenciación}) \times \beta + \text{otros factores}$

- Estima parámetros como el parámetro de dispersión (θ), que controla cuánta varianza hay más allá de lo esperado de la media.
- Utiliza un enfoque de regularización donde los genes con niveles de expresión similares comparten información para mejorar la estimación.

- ✓ Más robusto al ruido técnico
- ✓ Menos decisiones manuales
- ✓ Mejores resultados en clustering
- ✓ Pipeline más sencillo

scRNAseq Biocomputational Workflow



REDUCCIÓN DE LA DIMENSIONALIDAD

En scRNA-seq, cada gen es una dimensión:

- 1 célula = 1 lista de ~20.000 genes
- Cada célula es un punto en un espacio de 20.000 dimensiones

PROBLEMA:

Los datos contienen muchísima información, pero no podemos acceder a ella

SOLUCIÓN:


Reducir dimensionalidad -> transformar los datos de muchas variables (genes) a pocas variables, manteniendo la información más relevante.

Célula 1 = (G1, G2, G3, ..., G20000)



Célula 1 = (Dim1, Dim2)

- Combinaciones de genes
- No representan genes individuales
- Representan patrones de expresión



REDUCCIÓN DE LA DIMENSIONALIDAD: PCA


PCA: busca nuevas “direcciones” en los datos donde ocurra la mayor variabilidad. → **Encuentra combinaciones de genes que explican las diferencias más grandes entre células.**

<https://stats.stackexchange.com/questions/2691/making-sense-of-principal-component-analysis-eigenvectors-eigenvalues>

Suponemos un conjunto de observaciones para las que se dispone de dos variables (X_1 , X_2).


El vector que define la primera componente principal (Z_1) sigue la dirección en la que las observaciones varían más (línea roja).

La segunda componente (Z_2) sigue la segunda dirección en la que los datos muestran mayor varianza y que no está correlacionada con la primera componente. La condición de no correlación entre componentes principales equivale a decir que sus direcciones son perpendiculares/ortogonales.



- 1) Nube de puntos (células)
- 2) ¿En qué dirección varían más los datos? → PC1
- 3) ¿Cuál es la siguiente dirección de mayor variación, independiente de la anterior? → PC2


PCA rota el sistema de referencia para mirar los datos desde el mejor ángulo posible.



⚠ PCA solo ve relaciones lineales:
No puede detectar estructuras curvas o complejas

REDUCCIÓN DE LA DIMENSIONALIDAD: PCA, t-SNE, UMAP

⚠ PCA solo ve relaciones lineales:
No puede detectar estructuras curvas o complejas



- Relaciones lineales: relaciones simples y rectilíneas donde las cosas cambian a un ritmo constante
- No lineal significa relaciones más complejas, curvilíneas o flexibles donde las cosas cambian de manera variable.

↓
t-SNE, UMAP

	PCA	t-SNE	UMAP
Type of Method	Linear method (uses linear transformations)	Non-linear method (focuses on local structure)	Non-linear method (focuses on both local and global structure)
Focus	Maximizing variance (global structure)	Preserving local structure (neighborhoods)	Preserving both local and global structure
Preserves	Variance (overall spread of the data)	Local relationships (similarity between neighbors)	Local and global relationships (overall shape and clusters)
Output	Linear transformation of the data into principal components	2D or 3D representation that reflects local similarities	2D or 3D representation with more global structure
Scalability	Highly scalable (works well with large datasets)	Computationally expensive on large datasets	Scalable, faster than t-SNE, works well with large datasets
Speed	Fast	Slow, especially for large datasets	Faster than t-SNE, more scalable
Reproducibility	Very stable and deterministic	Results can vary with different runs	More stable than t-SNE, but less deterministic than PCA
Interpretability	Results are easy to interpret (principal components)	Results are harder to interpret (abstract relationships)	Results are more interpretable than t-SNE, but not as clear as PCA
Best for	When you want to preserve overall variance and reduce dimensionality linearly (e.g., for feature extraction, noise reduction)	When you want to explore local structure and identify clusters in the data	When you want to preserve both local and global structure, especially in complex, large datasets

10.000 genes

Gene ID	Cell_1	Cell_2	Cell_3	Cell_4	Cell_5	Cell_6	...	Cell_50000
TP53	80	50	63	36	60	0		99
EGFR	90	160	100	32	18	0		95
VEGFA	109	29	95	29	36	1		92
APOE	95	123	84	28	48	5		89
IL6	67	95	76	23	67	10		100
TGFB1	82	92	78	25	36	10		112
AKT1	71	124	81	26	37	0		113
MTHFR	70	97	90	24	91	0		100
...								
BRCA1	75	90	78	21	142	0		82

UMAP



2 "UMAP coordinates" or embeddings

UMAP	Cell_1	Cell_2	Cell_3	Cell_4	...	Cell_50000
UMAP_1	3	-8	9	-2		3
UMAP_2	4	-1	3	-1		4

t-SNE



2 "t-SNE coordinates" or embeddings

tSNE	Cell_1	Cell_2	Cell_3	Cell_4	...	Cell_50000
t-SNE_1	3	-8	9	-2		3
t-SNE_2	4	-1	3	-1		4



PCA

50 principal components


PC	Cell_1	Cell_2	Cell_3	Cell_4	Cell_5	Cell_6	...	Cell_50000
PC_1	3	-8	9	-2	5	2		3
PC_2	4	-1	3	-1	5	-4		4
PC_3	3	2	4	2	5	2		2
PC_4	-4	3	2	4	4	-1		4
PC_5	3	4	-4	5	3	2		5
PC_6	3	5	5	2	-4	3		2
PC_7	-6	2	5	-4	3	4		-4
PC_8	3	-4	-6	5	4	5		-6
...								
PC_50	5	2	-4	2	-4	3		2

PCA es **determinista y altamente reproducible**, lo que significa que siempre obtendrá los mismos resultados.

t-SNE y UMAP son **algoritmos no deterministas** (estocásticos): al ejecutarlos repetidamente con el mismo conjunto de datos y los mismos parámetros, es posible obtener resultados **ligeramente diferentes** cada vez. Esto se debe a que ambos algoritmos incorporan elementos aleatorios en su proceso de optimización.

⚠ Usar una semilla al ejecutarlos

PCA is deterministic, t-SNE and UMAP are stochastic




Same input

Gene ID	cell_1	Cell_2	Cell_3	Cell_4	Cell_5	Cell_6	...	Cell_50000
TP53	80	50	63	36	60	0		99
EGFR	90	160	100	32	18	0		95
VEGFA	109	29	95	29	36	1		92
APOE	95	123	84	28	48	5		89
IL6	67	95	76	23	67	10		100
TGFBI	82	92	78	25	36	10		112
AKT1	71	124	81	26	37	0		113
MTHFR	70	97	90	24	91	0		100
...								
BRCA1	75	90	78	21	142	0		82

UMAP


min.dist = 5,
n_neighbours = 10

Slightly different outputs



PCA vs UMAP vs t-SNE: ¿cuándo usar cada método?

- **PCA** : conjuntos de datos donde las relaciones son principalmente lineales y se desea conservar las características más importantes.
 - Se usa comúnmente para el **preprocesamiento de datos** (reducción de ruido, selección de características)
- **t-SNE**: visualizar **conjuntos de datos pequeños y medianos**, y para explorar **relaciones locales** o agrupaciones. Para descubrir estructuras detalladas, como identificar relaciones estrechas entre células.
- **UMAP**: funciona bien tanto con conjuntos de datos grandes como pequeños, especialmente cuando se busca un **buen equilibrio entre la preservación de la estructura local y global**.



1) PCA para reducir los miles de genes a unas pocas componentes principales -> reducción de ruido y selección de características más informativas

scRNAseq dataset, 10000 genes

Gene ID	Cell_1	Cell_2	Cell_3	Cell_4	Cell_5	Cell_6	...	Cell_50000
TP53	88	50	63	36	60	0	...	99
EGFR	90	160	100	32	18	0	...	95
VEGFA	109	29	95	29	36	1	...	92
APOL1	95	123	84	18	48	5	...	89
IL6	67	95	76	23	67	10	...	100
TP53P1	82	92	78	25	36	10	...	112
ANKK1	71	124	81	26	37	0	...	113
MTORF1	70	97	90	24	91	0	...	100
...	...	...	...	...	...	...	...	...
BRCA1	75	90	70	21	142	0	...	82

PCA


50 principal components

PC	Cell_1	Cell_2	Cell_3	Cell_4	Cell_5	Cell_6	...	Cell_50000
PC_1	3	-8	9	-2	5	2	...	3
PC_2	4	-1	3	-1	5	-4	...	4
PC_3	3	2	4	2	5	2	...	2
PC_4	-4	3	2	4	4	-1	...	4
PC_5	3	4	-4	5	3	2	...	5
PC_6	3	5	5	2	-4	3	...	2
PC_7	-6	2	5	-4	3	4	...	-4
PC_8	3	-4	-6	5	4	5	...	-6
...	...	...	...	...	...	...	...	...
PC_50	5	2	-4	2	-4	3	...	2

UMAP

t-SNE y UMAP son muy similares, pero como UMAP es más rápido y menos exigente computacionalmente que t-SNE, suele ser el algoritmo preferido.

2) UMAP: obtención de una proyección 2D de nuestras células -> visualización de los principales grupos de células en función de sus perfiles de expresión génica





2 "UMAP coordinates" or embeddings

UMAP	Cell_1	Cell_2	Cell_3	Cell_4	...	Cell_50000
UMAP_1	3	-8	9	-2	...	3
UMAP_2	4	-1	3	-1	...	4


plot

REDUCCIÓN DE LA DIMENSIONALIDAD: t-SNE







REDUCCIÓN DE LA DIMENSIONALIDAD: t-SNE

Low perplexity



High perplexity



Hiperparámetro

Perplejidad -> cantidad de vecinos que cada punto considera al construir su mapa de similitud.

- **↓ perplejidad:** considera pocos vecinos -> se centra en **relaciones locales**


Sensible a pequeñas diferencias entre células e intentará preservar grupos compactos de células que tengan perfiles de expresión genética muy similares

- **↑ perplejidad:** considera muchos vecinos -> se centra en **relaciones globales**

La disposición general de los tipos de células probablemente sea más clara


En nuestros datos de scRNAseq, establecer una perplejidad baja nos ayudaría a visualizar pequeñas diferencias entre subtipos de células inmunitarias (por ejemplo, células T CD4+ y células T CD8+). Sin embargo, podría no preservar la organización a gran escala entre tipos celulares como células inmunitarias y no inmunitarias, y estas podrían aparecer más mezcladas.

REDUCCIÓN DE LA DIMENSIONALIDAD: UMAP





REDUCCIÓN DE LA DIMENSIONALIDAD: UMAP

n_neighbours = 2




Low n_neighbours
Low min_dist

Focus on local relationships





n_neighbours = 4



High n_neighbours
High min_dist

Focus on global relationships



Myeloid cells T-cells Cancer cells B-cells Epithelial cells

Hiperparámetros

n_neighbours -> tamaño del radio que usa para determinar qué células están conectadas y cuáles no.

min_dist -> distancia mínima entre puntos en el espacio de baja dimensión

- $\downarrow$ **n_neighbours** / $\downarrow$ **min_dist**: conservan las relaciones locales

Las células que son muy similares entre sí se agruparán

- $\uparrow$ **n_neighbours** / $\uparrow$ **min_dist**: conservan las relaciones globales

La disposición general de los tipos de células probablemente sea más clara

scRNAseq Biocomputational Workflow

