




ANÁLISIS DE DATOS SINGLE CELL RNA-SEQ

23 al 27 de mayo de 2026

1ª convocatoria 2026 del Gabinete de Formación (CSIC)

Servicio de Análisis Biocomputacional (CBM-CSIC)

Centro de Computación Científica (CCC-UAM)



scRNAseq

CLUSTERING

María Santos Galindo

Servicio de Análisis Biocomputacional (CBM-CSIC)

Clustering: ¿qué es?

Agrupación de células según su expresión génica



Identificar tipos celulares

Detectar heterogeneidad

Descubrir nuevas poblaciones



Clustering: ¿qué es?

UMAP plot
Previo a clustering




Clustering: ¿qué es?

UMAP plot
Previo a clustering





UMAP plot
Posterior a clustering




Clustering: ¿qué es?

UMAP plot
Previo a clustering



UMAP plot
Posterior a clustering



Clustering: ¿cómo se hace?

QC lecturas

Clustering: ¿cómo se hace?

QC lecturas



Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger

Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado

Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización

Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización



Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización



Reducción de la dimensionalidad

Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización



Reducción de la dimensionalidad



Clustering: ¿cómo se hace?

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización



Reducción de la dimensionalidad





Clustering




Clustering: ¿qué es?

UMAP plot
Previo a clustering



UMAP plot
Posterior a clustering



Clustering: ¿cómo se hace?

Metodologías de clustering

Hay diversas metodologías de agrupamiento:

- Jerárquica:

✓ Pros:

No requiere número de clusters inicial
Genera dendrogramas

✗ Contrás:

Escala mal con grandes datasets
Sensible al ruido

Clustering: ¿cómo se hace?

Metodologías de clustering

Hay diversas metodologías de agrupamiento:

- **Jerárquica**
- **K-means:** Divide datos en k grupos minimizando la varianza interna


✓ Pros:
Simple
Rápido

✗ Contras:
Necesita definir k
No captura bien estructuras complejas

Clustering: K-means

K-Means is an unsupervised learning algorithm designed for clustering tasks.

- Identifies k number of centroids
- Allocates every data point to the nearest cluster, while keeping the centroids as small as possible.



<https://www.linkedin.com/pulse/understanding-k-means-k-nearest-neighbours-key-confusing-maryam-7aktc>

Clustering: ¿cómo se hace?

Metodologías de clustering


Hay diversas metodologías de agrupamiento:

- Jerárquica
- K-means
- Basada en grafos → KNN – “K-nearest neighbour”

Clustering: KNN (*K-nearest neighbour*)

KNN is a supervised learning algorithm used for classification and regression tasks.

- It finds the most similar data points (nearest neighbors)
- Predicts the output based on a majority vote (for classification) or average (for regression).



<https://www.linkedin.com/pulse/understanding-k-means-k-nearest-neighbours-key-confusing-maryam-7aktc>

Clustering: KNN (*K-nearest neighbour*)

Nodes (nodos)

Edges (aristas)


Clusters (grupos)

→ células


→ distancias → semejanza

→ células muy conectadas entre sí

→ células poco conectadas con otros grupos




Clustering: KNN (*K-nearest neighbour*)



La célula 1 se conectará con la célula 2 si la distancia entre 1 y 2 se encuentra entre las “k” distancias más pequeñas de 1 con el resto de células




Clustering: KNN (*K-nearest neighbour*)




La célula 1 se conectará con la célula 2 si la distancia entre 1 y 2 se encuentra entre las “k” distancias más pequeñas de 1 con el resto de células. Entonces serán “vecinos cercanos”

Clustering: SNN (*Shared nearest neighbour*)

Para cada pareja de células, se cuenta el número de vecinos comunes según KNN. Se creará una arista si comparten un número “suficiente” (según el umbral que se establezca) de vecinos cercanos.



Clustering: Detección de comunidades






Las células se agruparán en función de la densidad de conexiones que presentan, es decir, cada comunidad tendrá más aristas uniéndolo a sus componentes entre sí que uniéndolo a sus componentes con otros elementos del grafo

Clustering: FindNeighbors()




Primero, vamos a utilizar la función `FindNeighbors()` de Seurat para hacer el grafo SNN. Esta función:

1. Determina los KNN para cada célula
2. Hace un ranking de vecinos basado en la distancia y genera un grafo
3. Utiliza el grafo KNN para construir el grafo SNN, calculando la superposición de vecinos (índice de Jaccard)



Clustering: FindClusters()

A continuación, vamos a utilizar la función `FindClusters()` de Seurat para hacer el agrupamiento en función del grafo SNN. Va a “cortar” el grafo en clusters, por defecto en Seurat 5.3 utiliza el ALGORITMO DE LOUVAIN, que optimiza la modularidad



Clustering: FindClusters()

Valor	Algoritmo	Descripción	Características / Cuándo usar
0	Original Louvain (igraph)	Louvain clásico usando <code>igraph::cluster_louvain</code> .	Clusters menos estables, rápido, no garantiza que los clusters sean conexos internamente. Útil para exploración rápida.
1	Louvain modularity optimization (default)	Optimización modularidad con enfoque multilevel.	Versión optimizada del Louvain clásico. Buen equilibrio entre velocidad y precisión. Este es el default en Seurat 5.3 .
2	SNN-Smart Local Moving (SLM)	Variante de Louvain que usa refinamiento de modularidad local.	Más rápido que Louvain para grandes datasets, puede generar clusters más consistentes.
3	Leiden (via igraph)	Leiden clásico usando <code>igraph</code> backend.	Garantiza clusters conectados, más estable y reproducible. Muy recomendado para datasets grandes o ruidosos.
4	Leiden (via leidenbase)	Leiden usando el paquete <code>leidenbase</code> en R.	Similar al anterior, pero más eficiente en algunos datasets grandes y con soporte para distintas métricas de distancia. Recomendado si quieres máxima robustez.



Clustering: FindClusters()

Valor	Algoritmo	Descripción	Características / Cuándo usar
5	Multilevel	Algoritmo multilevel de optimización de modularidad (similar a Louvain).	Rápido, menos sensible al orden de nodos, útil en datasets medianos a grandes.
6	FastGreedy	Método de greedy aglomerativo para modularidad (igraph).	Bueno para datasets pequeños, no tan eficiente en datasets grandes.
7	Walktrap	Basado en caminatas aleatorias sobre el grafo.	Útil para clusters que tienen forma compleja en el grafo, lento en datasets grandes.
8	Infomap	Basado en teoría de la información; optimiza la compresión de flujos en el grafo.	Detecta comunidades jerárquicas, más sensible a la estructura global, pero puede ser más complejo de interpretar.
9	Label Propagation	Cada nodo “propaga” su etiqueta a vecinos hasta converger.	Muy rápido, pero menos robusto; puede generar clusters grandes y heterogéneos.

Clustering: FindClusters()

Además, vamos a aportar el parámetro de resolución, que va a controlar la “granularidad” del agrupamiento:

- Valores altos (e.g., 0.8–1.2) -> muchos clusters pequeños
- Valores bajos (e.g., 0.4–0.6) -> pocos clusters, más grandes
- Valor por defecto: 0.8





PASAMOS AL LADO OSCURO...

1. Abrimos Rstudio
 2. Abrimos el script Paso1_clustering.R
 3. Cargamos librerías
 4. Ejecutamos FindNeighbors()
 5. Ejecutamos FindClusters()
 6. Visualizamos clusters en UMAP
- 


¿Qué tal ha ido? ¿Tienen sentido los clusters?
¿Qué ocurriría si subimos o bajamos la
resolución?

Clustering: resultado

UMAP plot
Previo a clustering




UMAP plot
Posterior a clustering




Clustering: resultado

#resolución → #clusters


1.0 → más clusters, más pequeños



0.4





0.1 → menos clusters, más grandes




Clustering: resultado

UMAP plot
Previo a clustering



UMAP plot
Posterior a clustering



OBJETO SEURAT

`seu@meta.data`

`seu$nCount_RNA`

`seu@assays`

`GetAssayData(seu, layer = "counts") == seu@assays$RNA@layers$counts`

`Layers(seu)`


`Features(seu) == rownames(seu) #genes`

`Cells(seu) == colnames(seu)`

```
> library(Seurat)
> data <- Read10X(data.dir = "filtered_feature_bc_matrix")
> seu <- CreateSeuratObject(data)
> head(seu)
      orig.ident nCount_RNA nFeature_RNA
AAACCCAAGGAGAGTA-1 SeuratProject      12958      3918
AAACGCTTCAGCCCAG-1 SeuratProject       9527      3293
AAAGAACAGACGACTG-1 SeuratProject       6601      2667
AAAGAACCAATGGCAG-1 SeuratProject       4419      2155
AAAGAACGTCTGCAAT-1 SeuratProject      10004      3203
AAAGGATAGTAGACAT-1 SeuratProject      12245      3357
AAAGGATCACCGGCTA-1 SeuratProject       8269      2940
AAAGGATTCAGCTTGA-1 SeuratProject      18876      4942
AAAGGATTCGGTTTCG-1 SeuratProject     24530      5275
AAAGGGCTCATGCCCT-1 SeuratProject     10478      3216
> class(seu)
[1] "Seurat"
attr(,"package")
[1] "SeuratObject"
> class(data)
[1] "dgCMatrix"
attr(,"package")
[1] "Matrix"
>
```

`SeuratObject::Seurat`

 sparse matrix
 list of objects



-  Resultados de normalización (`@assays$RNA@data`)
-  Análisis de componentes principales (PCA) y UMAP (`@reductions`)
-  Estructura de clustering (`@graphs`)

Clustering

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización



Reducción de la dimensionalidad



Clustering





scRNAseq

ANOTACIÓN

María Santos Galindo

Servicio de Análisis Biocomputacional (CBM-CSIC)

Anotación

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización



Reducción de la dimensionalidad



Clustering



Anotación



¿Qué define a mis clusters?

Agrupación de células según su expresión génica

Seurat tiene dos funciones para identificar qué genes son los que más han contribuido a nuestra segregación:

FindAllMarkers() → Genes específicos de cada cluster. Compara un grupo contra el resto de células del dataset

FindMarkers() → Encuentra DEGs entre 2 grupos específicamente. Tendremos que darle estos grupos como parámetros **ident.1** e **ident.2**

¿Qué define a mis clusters?

Agrupación de células según su expresión génica

Seurat tiene dos funciones para identificar qué genes son los que más han contribuido a nuestra segregación:

FindAllMarkers() → Genes específicos de cada cluster. Compara un grupo contra el resto de células del dataset

FindMarkers() → Encuentra DEGs entre 2 grupos específicamente. Tendremos que darle estos grupos como parámetros **ident.1** e **ident.2**

¿Qué define a mis clusters?

Agrupación de células según su expresión génica

Seurat tiene dos funciones para identificar qué genes son los que más han contribuido a nuestra segregación:

FindAllMarkers() → Genes específicos de cada cluster. Compara un grupo contra el resto de células del dataset

FindMarkers() → Encuentra DEGs entre 2 grupos específicamente. Tendremos que darle estos grupos como parámetros **ident.1** e **ident.2**

Hoy no... mañana



PASAMOS AL LADO OSCURO...

1. Abrimos Rstudio
2. Abrimos el script Paso2_anot_bymarkers.R
3. Cargamos librerías
4. Ejecutamos FindAllMarkers()




¿Qué define a mis clusters?

FindAllMarkers()

Compara un grupo contra el resto de células del dataset

CLUSTER 0



p_val	avg_log2FC	pct.1	pct.2	p_val_adj	gene
3,2291E-194	6,272864689	0,985	0,082	6,0481E-190	S100A12
1,3884E-184	5,348600514	1	0,127	2,6005E-180	VCAN
4,9845E-182	4,983483892	0,956	0,075	9,336E-178	CD14
2,6224E-181	4,480334611	0,993	0,102	4,9117E-177	CSF3R
1,7112E-175	4,26709188	0,938	0,061	3,2051E-171	ENSG00000257764
1,4682E-174	4,367752774	0,996	0,139	2,7499E-170	MNDA
6,0036E-169	6,186721512	0,996	0,21	1,1245E-164	S100A8
2,0294E-167	4,25828014	0,982	0,119	3,801E-163	CD36
9,6453E-166	3,736804253	0,971	0,094	1,8066E-161	MS4A6A
1,215E-165	3,987431155	0,953	0,095	2,2757E-161	CSTA
1,124E-164	3,857620324	1	0,141	2,1053E-160	FCN1

Casi todas las células
del cluster 0 lo expresan

Un bajo % del resto de
células lo expresan

Consideraremos marcadores de cluster solamente aquellos genes que se expresan de forma selectiva en el cluster, no aquéllos que están reprimidos selectivamente → **only.pos=TRUE**

PASAMOS AL LADO OSCURO...




1. Abrimos Rstudio
2. Abrimos el script Paso2_anot_bymarkers.R
3. Cargamos librerías
4. Ejecutamos FindAllMarkers()
5. Visualizamos como Heatmap



¿Qué define a mis clusters?


FindAllMarkers() -> visualización general

Podemos visualizar los genes más representativos (por ejemplo, el top10) de cada cluster en forma de heatmap



¿Qué tipo celular predomina en cada cluster?

FindAllMarkers()



Los genes marcadores de cada cluster nos pueden permitir hacer una


ANOTACIÓN MANUAL A NIVEL DE CLUSTER

Para ello debemos tener un conocimiento previo de:

- Tipos celulares presentes en la muestra
- Qué genes son los que se expresan en cada uno de esos tipos celulares diferencialmente

¿Qué tipo celular predomina en cada cluster?


Tipos celulares presentes en la muestra



¿Qué tipo celular predomina en cada cluster?

Tipos celulares presentes en la muestra


¿Qué genes son los que se expresan en cada uno de esos tipos celulares diferencialmente?



¿Qué tipo celular predomina en cada cluster?

Tipos celulares presentes en la muestra

¿Qué genes son los que se expresan en cada uno de esos tipos celulares diferencialmente?



¿Qué tipo celular predomina en cada cluster?

Vamos a mirar cómo se distribuye la expresión de los genes marcadores de tipo celular previamente conocidos en nuestro dataset

→ Feature plot



Colorea a modo de gradiente los “Features” que le indiquemos, pudiendo estimar de visu si un cluster expresa más o menos cada uno de los genes marcadores

PASAMOS AL LADO OSCURO...

1. Abrimos Rstudio
 2. Abrimos el script Paso2_anot_bymarkers.R
 3. Cargamos librerías
 4. Ejecutamos FindAllMarkers()
 5. Visualizamos como Heatmap
 6. Visualizamos Marker Genes → FeaturePlot()
- 


¿Qué tipo celular predomina en cada cluster?

Vamos a mirar cómo se distribuye la expresión de los genes marcadores de tipo celular previamente conocidos en nuestro dataset



¿Qué tipo celular predomina en cada cluster?

Vamos a mirar cómo se distribuye la expresión de los genes marcadores de tipo celular previamente conocidos en nuestro dataset



¿Qué tipo celular predomina en cada cluster?

Vamos a mirar cómo se distribuye la expresión de los genes marcadores de tipo celular previamente conocidos en nuestro dataset

→ Feature plot

Colorea a modo de gradiente los “Features” que le indiquemos, pudiendo estimar de visu si un cluster expresa más o menos cada uno de los genes marcadores


→ Dotplot

Veremos en cuántos clusters se expresa cada uno de los genes marcadores y los niveles de expresión. De nuevo, nos ayuda a estimar de visu si hay una relación directa entre la expresión de un gen marcador y un cluster en particular.

PASAMOS AL LADO OSCURO...

1. Abrimos Rstudio
 2. Abrimos el script Paso2_anot_bymarkers.R
 3. Cargamos librerías
 4. Ejecutamos FindAllMarkers()
 5. Visualizamos como Heatmap
 6. Visualizamos Marker Genes → FeaturePlot()
 7. Visualizamos Marker Genes → DotPlot()
- 

¿Qué tipo celular predomina en cada cluster?



¿Qué tipo celular predomina en cada cluster?

Interpretación biológica:


#Clusters 1-2-5-6 -> alta expresion de CD3D -> celulas T

#Clusters 3-7 -> alta expresion de MS4A1 -> celulas B

#Clusters 0-4 (9?) -> alta expresion de LYZ -> monocitos

#Cluster 5-6-8 -> alta expresion de NKG7 -> NK

#Cluster 9 -> alta expresion de PPBP -> plaquetas



¿Qué tipo celular predomina en cada cluster?

Interpretación biológica:



#Clusters 1-2-5-6 -> alta expresion de CD3D -> celulas T

#Clusters 3-7 -> alta expresion de MS4A1 -> celulas B

#Clusters 0-4 (9?) -> alta expresion de LYZ -> monocitos

#Cluster 5-6-8 -> alta expresion de NKG7 -> NK

#Cluster 9 -> alta expresion de PPBP -> plaquetas



¿Qué tipo celular predomina en cada cluster?

Interpretación biológica:



#Clusters 1-2-5-6 -> alta expresion de CD3D -> celulas T

#Clusters 3-7 -> alta expresion de MS4A1 -> celulas B

#Clusters 0-4 (9?) -> alta expresion de LYZ -> monocitos

#Cluster 5-6-8 -> alta expresion de NKG7 -> NK


#Cluster 9 -> alta expresion de PPBP -> plaquetas



¿Qué tipo celular predomina en cada cluster?

Tipos celulares presentes en la muestra


¿Qué genes son los que se expresan en cada uno de esos tipos celulares diferencialmente?



¿Qué tipo celular predomina en cada cluster?

Tipos celulares presentes en la muestra

¿Qué genes son los que se expresan en cada uno de esos tipos celulares diferencialmente?



NKG7 también lo
expresan las
células T
citotóxicas

De clusters a poblaciones celulares


El clustering organiza las células; la anotación les da significado biológico

De clusters a poblaciones celulares

El clustering organiza las células; la anotación les da significado biológico

Anotación a nivel de cluster

Un label por cluster




T cells

- ✓ Simple
- ✓ Robusto
- X Ignora heterogeneidad

Anotación a nivel de célula

Un label por célula



T / B / NK / Mono

- ✓ Más resolución
- ✓ Detecta subtipos
- X Más ruido / labels ambiguos


Anotación manual a nivel de cluster

El clustering organiza las células; la anotación les da significado biológico

NO ANOTAR POR UN GEN; ANOTAR POR FIRMAS

Anotación a nivel de cluster

Un label por cluster



T cells

✓ Simple ✓ Robusto
X Ignora heterogeneidad

¿Por qué un solo gen no basta?

1. Genes compartidos

Ejemplo: NKG7 aparece en NK pero también en T citotóxicas.

2. Dropouts

Un marcador puede no detectarse aunque la célula lo exprese.

3. Estados celulares

Activación ≠ identidad.


4. Genes inducibles

Anotación manual a nivel de cluster

El clustering organiza las células; la anotación les da significado biológico

Anotación a nivel de cluster

Un label por cluster



T cells

✓ Simple ✓ Robusto
X Ignora heterogeneidad



Pros

- Muy interpretable
- Enseña biología real
- Detecta artefactos
- Flexible
- Permite descubrir poblaciones nuevas




Contras

- Subjetiva
- Depende de experiencia
- Poco reproducible
- Difícil en datasets grandes
- Subtipos complejos pueden confundirse

Anotación manual a nivel de cluster

Interpretación biológica:

- #Clusters 1-2-5-6 -> alta expresion de CD3D -> celulas T
- #Clusters 3-7 -> alta expresion de MS4A1 -> celulas B
- #Clusters 0-4 (9?) -> alta expresion de LYZ -> monocitos
- #Cluster 5-6-8 -> alta expresion de NKG7 -> NK
- #Cluster 9 -> alta expresion de PPBP -> plaquetas





CLUSTER	Marker	ANOTACIÓN MANUAL
0	LYZ	Monocytes
1	CD3D	T cells
2	CD3D	T cells
3	MS4A1	B cells
4	LYZ	Monocytes
5	CD3D + NKG7	cyt T cells
6	CD3D + NKG7	cyt T cells
7	MS4A1	B cells
8	NKG7	NK
9	PPBP	Platelets

PASAMOS AL LADO OSCURO...

1. Abrimos Rstudio
 2. Abrimos el script Paso2_anot_bymarkers.R
 3. Cargamos librerías
 4. Ejecutamos FindAllMarkers()
 5. Visualizamos como Heatmap
 6. Visualizamos Marker Genes → FeaturePlot()
 7. Anotamos y visualizamos → DimPlot()
- 

Anotación manual a nivel de cluster

El clustering organiza las células; la anotación les da significado biológico



OBJETO SEURAT

`seu@meta.data`
`seu$nCount_RNA`

`seu@assays`

`GetAssayData(seu, layer = "counts") == seu@assays$RNA@layers$counts`

`Layers(seu)`


`Features(seu) == rownames(seu) #genes`

`Cells(seu) == colnames(seu)`

```
> library(Seurat)
> data <- Read10X(data.dir = "filtered_feature_bc_matrix")
> seu <- CreateSeuratObject(data)
> head(seu)
      orig.ident nCount_RNA nFeature_RNA
AAACCCAAGGAGAGTA-1 SeuratProject      12958      3918
AAACGCTTCAGCCCAG-1 SeuratProject       9527      3293
AAAGAACAGACGACTG-1 SeuratProject       6601      2667
AAAGAACCAATGGCAG-1 SeuratProject       4419      2155
AAAGAACGTCTGCAAT-1 SeuratProject      10004      3203
AAAGGATAGTAGACAT-1 SeuratProject      12245      3357
AAAGGATCACCGGCTA-1 SeuratProject       8269      2940
AAAGGATTCAGCTTGA-1 SeuratProject      18876      4942
AAAGGATTCGTTTCG-1 SeuratProject      24530      5275
AAAGGGCTCATGCCCT-1 SeuratProject      10478      3216
> class(seu)
[1] "Seurat"
attr(,"package")
[1] "SeuratObject"
> class(data)
[1] "dgCMatrix"
attr(,"package")
[1] "Matrix"
>
```

SeuratObject::Seurat

 sparse matrix
 list of objects




-  Resultados de normalización (@assays\$RNA@data)
-  Análisis de componentes principales (PCA) y UMAP (@reductions)
-  Estructura de clustering (@graphs)

De clusters a poblaciones celulares

El clustering organiza las células; la anotación les da significado biológico

Anotación a nivel de cluster

Un label por cluster




T cells

- ✓ Simple
- ✓ Robusto
- X Ignora heterogeneidad

Anotación a nivel de célula

Un label por célula



T / B / NK / Mono


- ✓ Más resolución
- ✓ Detecta subtipos
- X Más ruido / labels ambiguos

Anotación automática a nivel de célula

El clustering organiza las células; la anotación les da significado biológico

Anotación a nivel de célula

Un label por célula



T / B / NK / Mono

- ✓ Más **resolución**
- ✓ Detecta subtipos
- X Más ruido / labels ambiguos



Pros

- Rápida
- Reproducible
- Escalable
- Muy útil para datasets grandes



Contras

- Hereda errores de la referencia
- Puede “forzar” identidades
- Mala extrapolación a tejidos nuevos
- Detecta mal estados raros
- Puede ocultar poblaciones nuevas

Anotación automática a nivel de célula

1

REFERENCIA

Atlas celular
ya anotado

2

QUERY

Células
desconocidas

3

COMPARACIÓN

Similitud
transcriptómica

4

LABEL TRANSFER

Asignación
automática

5

SCORE

Confianza de
predicción

¿A qué célula conocida se parece más?

- 🧬 La referencia contiene miles de células ya anotadas.
- 🔍 La query se compara contra perfiles transcriptómicos completos.
- 👉 El algoritmo busca vecinos similares (“anchors”).






Anotación automática a nivel de célula

1

REFERENCIA

Atlas celular
ya anotado



Azimuth

App for reference-based single-cell analysis



Garnett

Automated cell type classification

Get started»

MapMyCells

GUIDES
METHODS
& TUTORIALS



Anotación automática a nivel de célula

2

QUERY

Células desconocidas

3

COMPARACIÓN

Similitud transcriptómica

Paso 1 – Espacio común (PCA):

Las células se proyectan en un espacio reducido
Miles de genes → Punto en espacio N-dimensional

Paso 2 – Buscar vecinos similares

La célula nueva busca “vecinos más parecidos”
K-nearest neighbors

Seurat intenta encontrar pares de células equivalentes entre referencia y consulta

ANCHORS – ANCLAS

Cada ancla se asocia con unas métricas que permitirán la transferencia de identidad

Anotación automática a nivel de célula

4

LABEL TRANSFER

Asignación
automática

5

SCORE

Confianza de
predicción

Paso 1 – Propagación de etiquetas

Las anclas se utilizan para propagar las etiquetas de la referencia al query

Paso 2 – Cálculo del “prediction score”

Cada asignación de identidad celular tendrá asociado un score de calidad de dicha asignación

Query cell

?



NK

0.91

CytT

0.07

Mono

0.02

PREDICTION SCORE

- 1.- Cada célula del query se conecta a varios anchors
- 2.- Cada anchor “arrastra” información de la referencia (labels)
- 3.- Esa información se combina (tipo voto ponderado) Se genera: `predicted.id` y `prediction.score`

NO ES probabilidad “clásica” donde $0.92 = 92\%$ de probabilidad *real*. Es una medida de consistencia basada en anchors y vecinos en el espacio de referencia.

Anotación automática a nivel de célula

4

LABEL TRANSFER

Asignación automática

5

SCORE

Confianza de predicción

Paso 1 – Propagación de etiquetas

Las anclas se utilizan para propagar las etiquetas de la referencia al query

Paso 2 – Cálculo del “prediction score”

Cada asignación de identidad celular tendrá asociado un score de calidad de dicha asignación

Query cell

?



NK

0.91

CytT

0.07

Mono

0.02

PREDICTION SCORE

- 1.- Cada célula del query se conecta a varios anchors
- 2.- Cada anchor “arrastra” información de la referencia (labels)
- 3.- Esa información se combina (tipo voto ponderado) Se genera: `predicted.id` y `prediction.score`


NO ES probabilidad “clásica” donde $0.92 = 92\%$ de probabilidad *real*. Es una medida de consistencia basada en anchors y vecinos en el espacio de referencia.

1. Espacio reducido (PCA)

Cada punto = célula

Referencia (anotada)

Query (sin anotar)




Tipos celulares (en referencia)

● T cells ● B cells ● Monocytes

2. Vecinos más cercanos (kNN)

Para cada célula query → vecinos en referencia (líneas naranjas)

Para cada célula referencia → vecinos en query (líneas azules)




k = número de vecinos (ej. k = 20)

3. Anchors = Mutual Nearest Neighbors (MNN)

Se queda solo con las relaciones recíprocas.

Cada línea = un anchor (par MNN)



Una célula query puede tener **varios anchors** (con varias células de referencia).


Una célula referencia también puede tener **varios anchors**.

4. Grafo de anchors (many-to-many)

Vista como grafo bipartito

Referencia (anotada)

Query (sin anotar)



Q2 está conectado con varios T cells de la referencia → **varios anchors**

Q5 está conectado con B cells y también con Monocytes → **identidad ambigua**

5. Uso en TransferData

Cada query recibe votos de sus anchors (ponderados por la calidad/distancia).

Query	Votos (ejemplo)	Predicción	Prediction score
Q2	● ● ● ● ● ● ●	T cell	0.92
Q3	● ● ● ●	T cell	0.76
Q5	● ● ● ● ● ● ●	B cell	0.48
Q7	● ● ● ● ● ● ●	Monocyte	0.35

Votos de anchors

● T cell ● B cell ● Monocyte

Prediction score =
consenso / consistencia
de los votos

En resumen: FindTransferAnchors construye múltiples anchors (relaciones MNN) entre referencia y query. Cada célula query se conecta con varios anchors (many-to-many). TransferData usa esos anchors para transferir etiquetas por consenso y calcular un score de confianza.

Anotación automática a nivel de célula

1

REFERENCIA

Atlas celular
ya anotado

2

QUERY

Células
desconocidas

3

COMPARACIÓN

Similitud
transcriptómica

4

LABEL TRANSFER

Asignación
automática

5

SCORE

Confianza de
predicción



satijalab/**seurat-**
data



Dataset distribution for Seurat

9 Contributors 38 Issues 154 Stars 45 Forks

SEU

ANCHORS

PREDICTIONS

PASAMOS AL LADO OSCURO...

1. Abrimos Rstudio
2. Abrimos el script Paso3_anot_Seurat.R
3. Cargamos librerías
4. Buscamos, instalamos y cargamos referencia





AvailableData()

Dataset	Version	Summary	species	system	ncells	tech
adiposeref	1.0.0	Azimuth Reference: adipose	human	adipose	160075	scRNA-seq and sNuc-seq
bmcite	0.3.0	30k Bone Marrow Cells	human	bone marrow	30672	NA
bonemarrowref	1.0.0	Azimuth Reference: bonemarrow	human	bonemarrow	297627	10x v2
cbmc	3.1.4	scRNAseq and 13-antibody sequencing of CBMCs	human	CBMC (cord blood)	8617	CITE-seq
celegans.embryo	0.1.0	6k C. elegans embryos from Packer and Zhu et al (2019)	C. elegans	embryo	6188	NA
fetusref	1.0.0	Azimuth Reference: fetus	human	fetus	377456	NA
hcabm40k	3.0.0	40,000 Cells From the Human Cell Atlas ICA Bone Marrow Dataset	human	bone marrow	40000	10x v2
heartref	1.0.0	Azimuth Reference: heart	human	heart	656509	scRNA-seq and sNuc-seq
humancortexref	1.0.0	Azimuth Reference: humancortex	human	motor cortex	76533	NA
ifnb	3.1.0	IFNB-Stimulated and Control PBMCs	human	PBMC	13999	10x v1
kidneyref	1.0.2	Azimuth Reference: kidney	human	kidney	64693	snRNA-seq
lungref	2.0.0	Azimuth Reference: lung	human	lung	584884	NA
mousecortexref	1.0.0	Azimuth Reference: mousecortex	mouse	motor cortex	159738	10x v3
panc8	3.0.2	Eight Pancreas Datasets Across Five Technologies	human	Pancreatic Islets	14892	SMARTSeq2, Fluidigm C1, CelSeq, CelSeq2, inDrops
pancreasref	1.0.0	Azimuth Reference: pancreas	human	pancreas	35289	NA
pbmc3k	3.1.4	3k PBMCs from 10X Genomics	human	PBMC	2700	10x v1
pbmcMultiome	0.1.4	10X Genomics PBMC Multiome Dataset	human	pbmc	11909	NA
pbmceref	1.0.0	Azimuth Reference: pbmc	human	PBMC	2700	10x v1
pbmcscsca	3.0.0	Broad Institute PBMC Systematic Comparative Analysis	human	PBMC	31021	10x v2, 10x v3, SMARTSeq2, Seq-Well, inDrops, Drop-seq, CelSeq2
ssHippo	3.1.4	Slide-seq v2 dataset of mouse hippocampus	mouse	hippocampus	NA	slideseq v2
stxBrain	0.1.2	10X Genomics Visium Mouse Brain Dataset	mouse	brain	12167	visium
stxKidney	0.1.0	10X Genomics Visium Mouse Kidney Dataset	mouse	kidney	1438	visium
thp1.eccite	3.1.5	ECCITE-seq THP-1	human	NA	NA	NA
tonsilref	2.0.0	Azimuth Reference: tonsil	human	tonsil	377963	scRNA-seq



PASAMOS AL LADO OSCURO...

1. Abrimos Rstudio
2. Abrimos el script Paso3_anot_Seurat.R
3. Cargamos librerías
4. Buscamos, instalamos y cargamos referencia
5. Normalizamos referencia → `SCTransform()`
6. Buscamos anchors → `FindTransferAnchors()`
7. Transferimos identidades → `TransferData()`
8. Añadimos a seu → `AddMetaData()`
9. Visualizamos → `DimPlot()` / `FeaturePlot()`

Anotación automática a nivel de célula



Anotación automática a nivel de célula



Anotación

QC lecturas



Alineamiento - Cell Ranger



QC - Detección de outliers - Filtrado



Normalización



Reducción de la dimensionalidad





Clustering



Anotación



RESUMEN: CLUSTERING Y ANOTACIÓN



CADA PUNTO DEJA DE SER UNA CÉLULA “ANÓNIMA” Y SE CONVIERTE EN UN TIPO CELULAR CON SIGNIFICADO BIOLÓGICO

OBJETO SEURAT

`seu@meta.data`

`seu$nCount_RNA`

`seu@assays`

`GetAssayData(seu, layer = "counts") == seu@assays$RNA@layers$counts`

`Layers(seu)`


`Features(seu) == rownames(seu) #genes`

`Cells(seu) == colnames(seu)`

```
> library(Seurat)
> data <- Read10X(data.dir = "filtered_feature_bc_matrix")
> seu <- CreateSeuratObject(data)
> head(seu)
      orig.ident nCount_RNA nFeature_RNA
AAACCCAAGGAGAGTA-1 SeuratProject      12958      3918
AAACGCTTCAGCCCAG-1 SeuratProject       9527      3293
AAAGAACAGACGACTG-1 SeuratProject       6601      2667
AAAGAACCAATGGCAG-1 SeuratProject       4419      2155
AAAGAACGTCTGCAAT-1 SeuratProject      10004      3203
AAAGGATAGTAGACAT-1 SeuratProject      12245      3357
AAAGGATCACCGGCTA-1 SeuratProject       8269      2940
AAAGGATTCAGCTTGA-1 SeuratProject      18876      4942
AAAGGATTCGGTTTCG-1 SeuratProject     24530      5275
AAAGGGCTCATGCCCT-1 SeuratProject     10478      3216
> class(seu)
[1] "Seurat"
attr(,"package")
[1] "SeuratObject"
> class(data)
[1] "dgCMatrix"
attr(,"package")
[1] "Matrix"
>
```

`SeuratObject::Seurat`

 sparse matrix
 list of objects



-  Resultados de normalización (`@assays$RNA@data`)
-  Análisis de componentes principales (PCA) y UMAP (`@reductions`)
-  Estructura de clustering (`@graphs`)

