




ANÁLISIS DE DATOS SINGLE CELL RNA-SEQ

Análisis downstream

Sesión 1: Expresión diferencial y Análisis de proporciones celulares

Sesión 2: Análisis de trayectoria y Análisis de Comunicación celular


25 al 29 de mayo de 2026

1ª convocatoria 2026 del Gabinete de Formación (CSIC)

Servicio de Análisis Biocomputacional (CBM-CSIC)


Centro de Computación Científica (CCC-UAM)

Análisis estándar. ¿Qué hemos hecho hasta ahora?




Análisis downstream

Cell-Cell Interaction




Integration




Spatial Transcriptomics



Differential Expression




Differential Proportion





Gene matrix

RNA Velocity



Trajectory Inference






Análisis de Expresión Diferencial

¿Qué es el análisis de expresión diferencial?

Objetivo: Identificar genes (DEGs) que cambian significativamente entre grupos/muestras/clusters. Permite identificar mecanismos biológicos activos



Particularidades del single cell RNaseq

El análisis DE presenta desafíos específicos en scRNAseq:

- **Dropouts**

Muchos genes no se detectan en todas las células

- **Sparsity (Zero inflation)**


La mayoría de los conteos son 0

- **Batch effects**


Variabilidad técnica entre lotes

- **Variabilidad celular**


Heterogeneidad biológica entre células



Distribución de counts por gen



Ejemplo: expresión de un gen en diferentes células (violin plot)



Métodos estadísticos más comunes



No todos los métodos modelan correctamente la estructura del scRNAseq

Métodos comunes



Wilcoxon rank-sum

No paramétrico.
Compara medianas entre grupos.



MAST

Modelo lineal generalizado.
Considera dropouts.



DESeq2

Modelo binomial negativo.
Diseñado para datos bulk.



edgeR

Modelo binomial negativo.
Robusto para sobre-dispersión.




limma-voom

Transformación voom +
modelos lineales.


- Muchos asumen independencia entre observaciones.
- No son adecuados para matrices con inflación de 0s.
- La elección del método debe alinearse con el objetivo y el diseño experimental

El problema de la pseudorreplicación

- Las células NO son muestras independientes



Esquema del problema




Unidad experimental:
PACIENTE

Múltiples células:
Observaciones
técnicas

- Las células del mismo paciente, comparten el mismo contexto biológico.
- Tratarlas como eventos independientes, infla el tamaño muestral y puede generar falsos positivos

Estrategia del pseudobulk


- Se agregan los conteos de todas las células de un mismo paciente y tipo celular
- Se obtiene una matriz “bulk-like”: Paciente x Gen
- Ventajas: Menos falsos positivos, más robustez



Estrategia del pseudobulk


A partir de un objeto Seurat

```
# 1. Agrupar cuentas sumando los UMIs por tipo celular y muestra biológica
pseudobulk_counts <- AggregateExpression(seurat_obj,
  assays = "RNA",
  slot = "counts",
  group.by = c("celltype", "sample_id"),
  return.seurat = FALSE)
```



¿Qué comparaciones podemos hacer?

Análisis de expresión diferencial entre muestras o entre tipos celulares.



1 MUESTRA

- Expresión diferencial entre todos los tipos celulares/clusters.
- Expresión diferencial entre dos tipos específicos / clusters (CD4 vs CD8)

2 MUESTRAS o +

- Expresión diferencial entre muestras dentro del mismo tipo celular

Análisis con Seurat



<https://satijalab.org/seurat/>

1. Abrimos Rstudio
2. Abrimos el script Diffexpr.R
3. Calculamos 3 comparaciones:


- Un tipo (Naive CD4 T) vs el resto de células
- Entre dos tipos específicos (Naive CD4 T vs CD8 T)
- Genes marcadores de todos los tipos celulares

Análisis con Seurat

FindMarkers -> Genes diferenciales entre dos sets

FindAllMarkers -> Genes diferenciales entre un set y el resto de células

Naive CD4 T vs el resto




Análisis con Seurat

FindMarkers -> Genes diferenciales entre dos sets

FindAllMarkers -> Genes diferenciales entre un set y el resto de células

Naive CD4 T vs CD8 T



Análisis con Seurat

FindMarkers -> Genes diferenciales entre dos sets

FindAllMarkers -> Genes diferenciales entre un set y el resto de células

Genes marcadores de
todos los tipos celulares





Análisis de Composición celular (Proporción de tipos celulares)

Análisis de Composición celular

- ¿Qué tipos celulares aumentan o disminuyen entre condiciones?

Tipo celular	Control	Caso
T cells	20%	40%
Monocytes	35%	10%

- Se analizan frecuencias, no la expresión génica


$$\text{Frecuencia relativa} = \frac{\text{Número de células Tipo } X}{\text{Número total de células}}$$

ALTERNATIVAS

- Proporción por linaje
- Abundancia absoluta
- Abundancia normalizada

Problema

- Datos relativos (siempre respecto al total)



Importante

Las proporciones no son independientes
Un cambio en una categoría afecta a las demás

Tienen suma constante (100%)
Las proporciones siempre suman el total, lo que puede inducir correlaciones falsas.

Métodos

- Existen diferentes estrategias para el análisis de composición celular
- La elección depende del diseño del experimento y la pregunta biológica



1. Test simples

Adecuados para comparaciones básicas entre dos condiciones.



Chi cuadrado

Prueba no paramétrica que evalúa si existe asociación entre condición y tipo celular.



2. Modelos más robustos

Consideran la naturaleza composicional y la variabilidad entre muestras.



Dirichlet models

Modelan datos composicionales usando la distribución Dirichlet.



Beta-binomial

Extensión binomial que captura sobre-dispersión en conteos.



Mixed models

Incluyen efectos aleatorios para considerar la variabilidad entre muestras/pacientes.

Nuevo dataset

- Necesitamos 2 muestras para poder comparar.
- Nuevo dataset : [5k Human PBMCs \(Donor 2\)](#)

Objeto Seurat (*combined_donors.rds*)

Combinación de nuestros datos (Donor1) y datos de otra muestra (Donor2).

1. Abrimos Rstudio
2. Cargamos el script DiffProp.R
3. Calculamos diferencias de proporciones de tipos celulares mediante el test estadístico X cuadrado

Test estadístico global

Obtenemos la tabla de frecuencias

Donante	B	CD14+Mono	CD8 T	DC
Donor1	184	302	121	18
Donor2	637	1590	498	118

¡Necesitamos trabajar con proporciones!

χ^2

H0 (hipótesis nula)

La proporción de tipos celulares es igual entre donantes.

H1 (hipótesis alternativa)

La composición celular difiere entre donantes.

Test estadístico global

Obtenemos la tabla de frecuencias

Donante	B	CD14+Mono	CD8 T	DC
Donor1	184	302	121	18
Donor2	637	1590	498	118

¡Necesitamos trabajar con proporciones!

Pearson's Chi-squared test with simulated p-value (based on 2000 replicates)

data: freqs

X-squared = 138.88, df = NA, p-value = **0.0004998**

P-value < 0.05 indica diferencias significativas entre donantes.
¿Pero qué tipos celulares son diferentes?

Test estadístico individual

```
source("ctprop_test.R")
```


Script específico para este análisis estadístico entre donantes:

- 1. Cálculo del FoldChange:**
FC > 0 Más abundante en Donante 1
FC < 0 Más abundante en Donor 1
- 2. Test estadístico (Two proportion Z test)**
H0 (hipótesis nula)
Proporción es igual entre donantes
H1 (hipótesis alternativa)
Proporción no es igual entre donantes
- 3. Corrección del p-value por FDR**
Reduce falsos positivos



Visualización


Existen múltiples gráficos para visualizar este tipo de resultados, pero los más comunes son el piechart y el barplot.

Composición celular por muestra
Donor1



Donor2






Análisis de Trayectoria


Análisis de Trayectoria

- **Objetivo:** Ordenar células individuales a lo largo de un proceso biológico continuo, basándose en la similitud de sus perfiles de expresión génica.



Análisis de Trayectoria

- **Objetivo:** Ordenar células individuales a lo largo de un proceso biológico continuo, basándose en la similitud de sus perfiles de expresión génica.




IMPORTANTE


SIEMPRE se trata de una **inferencia** de estados y trayectorias

El problema de la imagen fija

scRNAseq captura células en un único momento temporal



Lo que queremos inferir: el proceso biológico



¿Qué queremos reconstruir?

- Progresión celular
- Estados transitorios
- Diferenciación y lineajes
- Decisiones de destino (cell fate)
- Activación, respuesta, plasticidad, etc.

A partir de miles de células observadas en un único momento

Ordenando correctamente las células podemos inferir la dinámica real


Métodos de análisis de trayectoria

Los algoritmos de trayectoria asumen que las células se distribuyen en un espacio de alta dimensión, que podemos aproximar mediante un grafo

Idea general


1. Datos de alta dimensión

Cada célula se representa por miles de genes.



2. Reducción de dimensionalidad

Proyectamos las células en un espacio 2D/3D (UMAP, PCA, etc.).




3. Vecinos más cercanos

Conectamos cada célula con sus vecinas más similares.




4. Abstracción del grafo

Simplificamos el grafo para capturar la estructura global.



5. Inferencia de trayectorias


El grafo permite inferir caminos, ramas y ordenamiento (pseudotime).



Una nube de puntos estática se convierte en una estructura ordenada

Qué es el pseudotime?

Distancia abstracta ordena las células a lo largo de un linaje basándose en cambios graduales en su perfil de expresión. Mide el **progreso de diferenciación**.



Importante



NO es tiempo real

El pseudotime no corresponde a minutos, horas o días.



NO implica velocidad constante

La distancia entre células en pseudotime no refleja cuánto tiempo toma el proceso.



Representa progresión relativa

Ordena las células de forma relativa a lo largo de un proceso biológico, sin asumir escalas temporales específicas.

Herramientas



Basado en graph learning
Robusto
Muy usado



Simple
Basado en clusters





Module: PAGA
Basado en conectividad entre
clusters
Ideal para datasets grandes

**scVelo - RNA velocity generalized through
dynamical modeling**

Estudio de RNA velocity
Análisis de dirección dinámica
No tan usado solo para trayectoria

Monocle3 workflow




Estudio de procesos

- Es importante tener datos adecuados para el análisis de trayectoria.


Células PBMC de nuestro caso práctico:

No forman parte de ningún proceso dinámico que podamos estudiar




Estudio de procesos

- **Nuevo Dataset:** [Packer & Zhu et al.](#)
- Estudio de desarrollo de embriones (pequeño subset de neuronas)
 1. Abrimos Rstudio
 2. Abrimos el script trajectory.R
 3. Usamos el paquete Monocle3 para:
 - Calcular grafo de trayectoria
 - Calcular pseudotiempo
 - Calcular y visualizar genes diferenciales




Análisis con Monocle3

- Visualización del estado embrionario




Análisis con Monocle3

- Visualización del pseudotiempo




Análisis con Monocle3

- Genes dinámicos que cambian con la trayectoria.
- DEGs que cambian con el pseudotiempo



Análisis con Monocle3

- Visualizar cambios dinámicos en genes






Análisis de comunicación celular (Cell to cell)


Análisis de comunicación celular

- **Objetivo:** Entender cómo las poblaciones celulares coordinan sus funciones mediante señales moleculares.
- **Fundamento:** Co-expresión de **ligandos** (célula emisora) y sus **receptores** (célula receptora).





Herramientas y bases de datos

- Múltiples herramientas, cada una con su base de datos




Herramientas y bases de datos

- Multiples herramientas, cada una con su base de datos



Análisis con CellChat







Análisis con CellChat

- Usamos el nuestro dataset original anotado (“seurat_annotated_auto.rds”)
 - CellChat usa bases de datos de ligando-receptor conocidas.
Para humano → CellChatDB.human
Para ratón → CellChatDB.mouse
1. Abrimos Rstudio
 2. Abrimos el script trajectory.R
 3. Usamos el paquete CellChat para:
 - Detectar genes e interacciones sobre-representados
 - Calcular probabilidad de interacciones
 - Inferir comunicación a nivel de vías

Análisis con CellChat





- Visualización de los resultados




Análisis con CellChat



- Visualizamos Complejo Mayor de Histocompatibilidad clase II






Análisis adicionales

RNA Velocity

- Técnica que predice el **estado futuro** de una célula individual.
- Se basa en el modelado de la abundancia de ARNm a través de las tasas de **transcripción, procesamiento (splicing) y degradación**
- Desequilibrio entre el pre-ARNm (unspliced, intrones presentes) y el ARNm maduro (spliced, exones únicamente)
 - Poco pre-ARNm = Represión
 - Mucho pre-ARNm = Inducción.
- **Software estándar: scVelo / velocity.**





Integración

- **Objetivo:** Superponer diferentes datasets en un espacio común donde células del mismo tipo se agrupen, independientemente de su origen.

PROBLEMA

Efecto de Lote (Batch Effect):
Variaciones técnicas derivadas de diferentes días de captura, reactivos, laboratorios o tecnologías.


RETO

Preservación Biológica: El reto crítico es no "sobre-correr" (over-correction), lo cual borraría diferencias biológicas reales entre condiciones.

Herramientas y métodos


1 Identificación de Anclajes (MNN)

Buscar “Vecinos Más Cercanos Mutuos” (Mutual Nearest Neighbors).
Si la célula A del lote 1 es vecina de la célula B del lote 2, y viceversa,
se consideran biológicamente idénticas.



2 Corrección No Lineal

Se usan algoritmos que respetan la estructura no lineal de los datos
(ej. Harmony, RPCA o scVI basado en Deep Learning).



Integración con Seurat

